Лабораторная работа 6

Deep Energy-Based Models и Normalizing Flows

Density estimation, sampling, invertibility и ограничения представления распределений

Курс «Нейронные сети»

Редакция 4 от 8 октября 2026 г.

1 Введение

Лабораторная работа 6 открывает генеративный блок курса и посвящена двум принципиально различным подходам к моделированию распределения данных:

1. Energy-Based Models (EBM), задающим ненормированную плотность через функцию энергии;
2. Normalizing Flows (NF), задающим точную нормированную плотность через последовательность обратимых преобразований.

Основная задача — **сравнить две различные философии density modeling на одних и тех же распределениях и под единым experimental protocol**.

Все запуски идут в проекте из ЛР0. У запуска есть `EXP_ID`, `RUN_ID`, паспорт и итоговая конфигурация. Каждое число отчёта сопровождается ссылкой на `RUN_ID`.

2 Мотивация

Пусть имеется неизвестное распределение данных $x \sim p_{\text{data}}(x)$, $x \in \mathbb{R}^d$. Генеративная модель строит распределение $p_\theta(x)$ или эквивалентный механизм, позволяющий оценивать совместимость точки с данными, генерировать новые объекты, по возможности вычислять likelihood и переносить вероятностную массу в сложные области пространства. Разные классы моделей делают разные компромиссы: EBM допускает гибкую энергию, но нормировочная константа недоступна; Flow даёт точный likelihood, но архитектура обязана быть обратимой с вычислимым якобианом.

3 Цель работы

Необходимо построить сравнительное исследование EBM и Normalizing Flow на общей системе целевых распределений и исследовать влияние пяти факторов: класса модели, метода sampling, ёмкости модели, топологии целевого распределения и оптимизации.

Как требования к правдоподобию, порождению примеров и обратимости ограничивают устройство порождающей модели?

4 Что нужно знать заранее

Если какой-то пункт незнаком, восполните пробел по указанному источнику.

- Нормальное распределение, смесь, математическое ожидание — [2, разд. 3.8, 3.9].
- Ненормированная модель и статистическая сумма — [2, разд. 16.2, 18.1], [1, разд. 8.2].
- Contrastive divergence — [2, разд. 18.2].
- Цепи Монте-Карло и перемешивание далёких мод — [2, разд. 17.3, 17.5].
- Ориентированная порождающая модель: сначала шум, затем преобразование — [2, разд. 20.10].
- Распределения и градиент по входу в PyTorch — `torch.distributions` [3], `torch.autograd.grad` [4].
- Проект из ЛР0 и парные разности из ЛР1.

5 Результаты обучения

После выполнения работы вы сможете:

1. объяснять, зачем плотности нужна нормирующая константа и при каком виде энергии она конечна;
2. делать шаг Ланжевена при согласованном шуме и проверять его дисперсию на квадратичной энергии;
3. обучать энергетическую модель, отсоединяя вход отрицательных примеров, и хранить эти примеры в буфере;
4. собирать поток из аффинных слоёв связи и отдельно проверять логарифм определителя якобиана;
5. сравнивать обе модели на одной цели, держа точное правдоподобие и оценку на сетке разными величинами;
6. формулировать вывод по трём общим `seeds` через парные разности.

6 Модели и обозначения

6.1 Плотность через энергию

Модель на основе энергии (energy-based model) задаёт плотность так [5, 2]:

$$p_\theta(x) = \frac{\exp(-E_\theta(x))}{Z_\theta}, \qquad Z_\theta = \int_{\mathbb{R}^d} \exp(-E_\theta(x))\, dx. \tag{6.1}$$

Здесь x — точка, E_θ — энергия с параметрами θ, Z_θ — нормирующая константа. Вес $\exp(-E_\theta)$ становится вероятностью после деления на Z_θ. Для произвольной сети интеграл не берётся в замкнутом виде. На плоскости его заменяют суммой по сетке. Для картинки 28×28 два узла на ось дают 2^{784} клеток, и ту же сумму не считают. Две сети с одной энергией на данных могут иметь разные Z_θ. Их энергии — не вероятности.

Постоянная энергия на всей плоскости интеграла не имеет: Z_θ бесконечна, и формулы (6.1) нет. В работе энергия удерживает точки квадратичным членом:

$$E_\theta(x) = \frac{\|x\|_2^2}{2s^2} + r_\theta(x), \qquad r_\theta(x) \geq r_{\min} > -\infty. \tag{6.2}$$

Здесь $s > 0$ — масштаб удержания, r_θ — выход сети, ограниченный снизу. Тогда $Z_\theta \le e^{-r_{\min}}(2\pi s^2)^{d/2} < \infty$.

В этой работе $s = 3$, а r_θ — сеть с выходом tanh. Значит, $|r_\theta| < 1$ и можно взять $r_{\min} = -1$. Хвост вне шара радиуса R в размерности $d = 2$ оценивается так:

$$\int_{\|x\|>R} e^{-E_\theta(x)}\,dx \;\le\; e^{-r_{\min}}\,2\pi s^2\,e^{-R^2/(2s^2)}. \tag{6.3}$$

Правая часть при $s = 3$, $r_{\min} = -1$ и $R = 14$ равна 0,0029. Квадрат со стороной 30, в котором лежит этот шар, годится как область численного интеграла: масса вне квадрата ещё меньше.

Правдоподобие одной точки содержит $\log Z_\theta$. Градиент по параметрам поэтому состоит из двух фаз [6]:

$$\nabla_\theta \mathcal{L} = \mathbb{E}_{x^+}\big[\nabla_\theta E_\theta(x^+)\big] - \mathbb{E}_{x^-}\big[\nabla_\theta E_\theta(x^-)\big]. \tag{6.4}$$

Здесь x^+ — данные, x^- — точки модели, $\mathcal{L}$ — среднее $-\log p_\theta$ по данным. Первая фаза понижает энергию на данных. Вторая поднимает её там, где модель сейчас ставит точки. Иначе энергия падает всюду, а доля данных не растёт. При конечном числе шагов x^- берутся из цепи. Это сопоставительное расхождение, а не точное правдоподобие [6].

Вход x^- в (6.4) — константа. Отсоединяют вход, не число $E_\theta(x^-)$: градиент по θ на этих точках нужен. Градиент сквозь траекторию цепи — другая величина [9].

Подробнее: [2, разд. 16.2, 18.1, 18.2]; [5, 6, 9].

6.2 Шаг Ланжевена

Градиент энергии по точке совпадает с полем score, взятым со знаком минус: $\nabla_x \log p_\theta(x) = -\nabla_x E_\theta(x)$. Слагаемое $\log Z_\theta$ от x не зависит [12]. Шаг ниже идёт вниз по энергии и тем самым вверх по плотности.

Непрерывная динамика Ланжевена (Langevin dynamics) при температуре T

$$dx_t = -\nabla_x E_\theta(x_t)\,dt + \sqrt{2T}\,dW_t \tag{6.5}$$

имеет стационарную плотность, пропорциональную $\exp(-E_\theta/T)$. Здесь W_t — стандартный винеровский процесс. При $T = 1$ стационарная плотность — это p_θ.

За малое время η шум винеровского процесса имеет дисперсию $2T\eta$. Дискретный шаг поэтому такой:

$$x_{k+1} = x_k - \eta\,\nabla_x E_\theta(x_k) + \sigma\,\epsilon_k, \qquad \sigma^2 = 2\eta T, \qquad \epsilon_k \sim \mathcal{N}(0, I). \tag{6.6}$$

Здесь $\eta > 0$ — шаг, σ — масштаб шума, ϵ_k — стандартный нормальный вектор. Сдвиг ведёт к меньшей энергии. Шум не даёт точке застыть в ближайшем минимуме. В коде σ вычисляют из η и T. Свободная пара (η, σ) задаёт температуру $T = \sigma^2/(2\eta)$.

В части статей сдвиг равен $(\eta'/2)\nabla E_\theta$, а шум имеет масштаб $\sqrt{\eta'}$ [11]. Это формула (6.6) при $T = 1$ и $\eta = \eta'/2$. Статья с $\eta' = 0{,}1$ означает здесь $\eta = 0{,}05$ и $\sigma = \sqrt{0{,}1} \approx 0{,}316$. Шаг $\eta = 0{,}1$ вместе с шумом $\sqrt{0{,}1}$ даёт температуру $1/2$.

Даже при верной связи конечный шаг смещён. Для энергии $E(x) = x^2/2$ градиент равен x, и шаг линеен: новое значение есть $(1-\eta)x + \sigma\epsilon$. Стационарная дисперсия v этой рекурсии удовлетворяет $v = (1-\eta)^2 v + \sigma^2$. Отсюда при $0 < \eta < 2$

$$v = \frac{\sigma^2}{2\eta - \eta^2}, \qquad \text{при } \sigma^2 = 2\eta: \quad v = \frac{1}{1 - \eta/2}. \tag{6.7}$$

При $\eta = 0{,}05$ и верной связи получается 1,026, а не единица. Единицу даёт непрерывная динамика или поправка Метрополиса [10]. В основных запусках поправки нет. При том же шаге и $\sigma = 0{,}1$ получается 0,103. Формула (6.7) верна без границы. Проверку дисперсии делают без отражения.

Малое число шагов даёт короткий генератор (short-run), а не выборку из p_θ [8]. Основной режим — формула (6.6) при $T = 1$ и отражении от границы Ω. Обрезка к границе без отражения в этом режиме не используется.

Чтобы цепь быстрее доходила до мод, начало шага берут из буфера прошлых отрицательных примеров [7]:

$$x_0 = \begin{cases} x_{\text{replay}} \sim \text{Uniform}(\mathcal{B}), & \text{с вероятностью } 1 - p_{\text{restart}}, \\ x_{\text{random}} \sim \mathcal{N}(0, I), & \text{с вероятностью } p_{\text{restart}}. \end{cases} \tag{6.8}$$

Здесь $\mathcal{B}$ — буфер, $p_{\text{restart}} = 0{,}05$. Буфер и состояние его генератора случайных чисел хранят в контрольной точке. Буфер из одной моды удерживает новые цепи в этой моде.

Подробнее: [2, разд. 17.3, 17.5, 18.4]; [10, 11, 12, 7, 8].

6.3 Плотность через обратимое преобразование

Поток задаёт отображение f_θ из точки данных x в базовый шум $z = f_\theta(x)$. Базовый шум имеет стандартное нормальное распределение. Порождение идёт в обратную сторону: рисуют z и применяют f_θ^{-1}. Это ориентированная порождающая модель [2, разд. 20.10].

Одномерный пример. Пусть $z = 2x$ и z стандартно нормален. Плотность x в нуле равна $2/\sqrt{2\pi} \approx 0{,}798$, а плотность z в нуле — $1/\sqrt{2\pi} \approx 0{,}399$. Множитель 2 — это $|dz/dx|$. В логарифме плотности он даёт $\ln 2 \approx 0{,}693$.

Общая формула замены переменных [13]:

$$\begin{aligned} \log p_X(x) &= \log p_Z\big(f_\theta(x)\big) + \log\big|\det J_f(x)\big|, \\ \log p_X(x) &= \log p_Z(z_{K_f}) + \sum_{k=1}^{K_f} \log\big|\det J_{f_k}(z_{k-1})\big|. \end{aligned} \tag{6.9}$$

Здесь $J_f = \partial f_\theta / \partial x$ — якобиан, $z_0 = x$, $z_k = f_k(z_{k-1})$, K_f — число блоков. Отображение f_θ ведёт из данных в шум. Обратный порядок блоков меняет знак логарифма определителя.

Полный определитель произвольной сети дорог. Аффинный слой связи (affine coupling) делает якобиан треугольным [15]. Координаты делят на две части $x = (x_a, x_b)$:

$$\begin{aligned} y_a &= x_a, & y_b &= x_b \odot \exp\big(s_\theta(x_a)\big) + t_\theta(x_a), \\ x_a &= y_a, & x_b &= \big(y_b - t_\theta(y_a)\big) \odot \exp\big(-s_\theta(y_a)\big). \end{aligned} \tag{6.10}$$

Символ $\odot$ — покомпонентное произведение. Сети s_θ и t_θ сами могут быть необратимыми: обратный шаг подставляет те же s_θ и t_θ в явную формулу. В размерности 2 каждая часть — одно число, и $\odot$ — обычное умножение.

Определитель треугольный, поэтому

$$\log\big|\det J\big| = \sum_j s_\theta(x_a)_j. \tag{6.11}$$

В сумму входит значение s_θ, а не производная сети s_θ. Знак сохраняют: при $s_\theta = -1$ логарифм определителя равен -1, а не 1.

Нулевой масштаб $s_\theta = 0$ и нулевой сдвиг дают тождественное отображение. Большие s_θ раздувают обратный шаг [17]. Масштаб ограничивают: $s_\theta = c\,\tanh(\tilde{s}_\theta/c)$, где $c > 0$ берётся из профиля. Тогда $|s_\theta| \le c$.

Если все блоки делят координаты одинаково, часть x_a только копируется. Её распределение остаётся стандартным нормальным. Поэтому между блоками половины меняют местами. Перестановка обратима, её логарифм определителя равен нулю.

Стандартный нормальный шум связен. Гладкое обратимое отображение не рвёт связность. Носитель из нескольких отдельных кусков оно не воспроизводит точно и на практике оставляет между модами мост положительной плотности [16]. Высота моста зависит от глубины, базового распределения и размерности. Энергия такого запрета не имеет: между модами её можно поднять.

Точное правдоподобие и качество примеров — разные свойства [18]. Малое правдоподобие на далёких точках тоже не обязано получаться само собой [19].

Подробнее: [13, 14, 15, 16, 17].

6.4 Метрики

Отрицательное логарифмическое правдоподобие (negative log-likelihood) считают только у потока, по точной формуле (6.9). Для энергии на ограниченной области Ω считают сеточную оценку:

$$\begin{aligned} \mathrm{NLL} &= -\frac{1}{N}\sum_{i=1}^{N} \log p_\theta(x_i), \qquad \hat{Z}_\Omega = \sum_{j=1}^{M} e^{-E_\theta(x_j)}\,\Delta, \\ \hat{p}_\theta(x) &= e^{-E_\theta(x)}/\hat{Z}_\Omega, \qquad D_{\mathrm{grid}} = \frac{1}{M}\sum_{j=1}^{M} \bigl|\hat{p}_\theta(x_j) - p(x_j)\bigr|. \end{aligned} \tag{6.12}$$

Здесь $\{x_j\}$ — центры ячеек, Δ — площадь ячейки, p — истинная плотность цели. Величину $\hat{p}_\theta$ помечают как нормированную на Ω. Она близка к p_θ, когда хвост (6.3) мал. В одну колонку с точным NLL её не ставят.

Качество примеров измеряют одинаково у обеих моделей. Берут $N = 5000$ примеров и точки `test`:

$$\begin{aligned} \mathrm{Cov} &= \frac{\#\{m :\ \hat{p}_m \ge p_m/2\}}{M}, \qquad D_{\mathrm{mode}} = \frac{1}{2}\sum_m |p_m - \hat{p}_m|, \\ \mathrm{MMD}^2 &= \mathbb{E}\,k(x,x') + \mathbb{E}\,k(y,y') - 2\,\mathbb{E}\,k(x,y), \qquad k(x,y) = \exp\bigl(-\|x-y\|^2/(2h^2)\bigr). \end{aligned} \tag{6.13}$$

Здесь M — число мод, $\hat{p}_m$ — доля примеров моды m, p_m — её истинная доля. Функция `mode_id` берёт ближайший центр, если до него не больше 3σ, иначе помечает точку как внешнюю. Внешняя метка входит в D_{mode}. Мода покрыта, если $\hat{p}_m \ge p_m/2$. В MMD^2 [20] точки x, x' — из цели, y, y' — из модели. Полоса h — медиана попарных расстояний по 2000 точкам `train`, одна на цель. Семя выбора этих точек записывают.

У двумерного нормального закона доля точек дальше 3σ от центра равна $e^{-9/2} \approx 0{,}011$. Около 1,1% точек цели законно получают внешнюю метку.

Уровень шума метрики — её среднее в пяти сравнениях свежих точек цели с `test`. Различие ниже этого уровня не интерпретируют.

Ошибка обратимости:

$$\varepsilon_{\mathrm{inv}} = \frac{\|x - f^{-1}(f(x))\|_2}{\|x\|_2 + 10^{-8}}. \tag{6.14}$$

Основное сравнение двух конфигураций A и B делают на трёх общих `seeds` $s = 1, 2, 3$, как в ЛР1:

$$\Delta_s = Q(\mathrm{A}, s) - Q(\mathrm{B}, s), \qquad \bar{\Delta} = \frac{1}{3}\sum_{s=1}^{3} \Delta_s, \qquad s_\Delta = \sqrt{\frac{1}{2}\sum_{s=1}^{3}(\Delta_s - \bar{\Delta})^2}. \tag{6.15}$$

Здесь Q — заранее выбранная метрика. Вывод о различии установлен, если все три Δ_s одного знака и $|\bar{\Delta}| \geq 2s_\Delta$. Иначе пишут: различие не установлено. В отчёте приводят все три разности.

Подробнее: [20, 18].

6.5 Сводка обозначений

Обозначение	Смысл
x, d, p_{data}, p_θ, θ	точка, размерность, плотность данных, модель, её параметры
E_θ, Z_θ, s, r_θ, $r_{\min}$	энергия, нормировка, масштаб удержания, остаток сети, его нижняя граница
Ω, R, Δ, $\hat{Z}_\Omega$, $\hat{p}_\theta$	область сетки, радиус хвоста, площадь ячейки, оценка нормировки и плотности
η, σ, T, K, ϵ_k	шаг Ланжевена, масштаб шума, температура, число шагов, шум шага
x^+, x^-, $\mathcal{B}$, p_{restart}	данные, примеры модели, буфер, вероятность случайного старта
f_θ, z, J_f, K_f, c	отображение потока, базовый шум, якобиан, число слоёв связи, предел масштаба
s_θ, t_θ, x_a, x_b	сети масштаба и сдвига, копируемая и преобразуемая части
NLL, D_{grid}, Cov, D_{mode}	правдоподобие потока, ошибка сетки, покрытие мод, расхождение долей
MMD^2, h, ε_{inv}	ядерное расхождение, полоса ядра, относительная ошибка обратного шага
Δ_s, $\bar{\Delta}$, s_Δ	парная разность, её среднее и стандартное отклонение

7 Данные и оборудование

Цели — смеси равных круговых нормальных компонент:

$$p(x) = \sum_{m=1}^{M} \pi_m \mathcal{N}(x; \mu_m, \sigma^2 I), \qquad \pi_m = 1/M. \tag{6.16}$$

Центры и σ заданы таблицей. Координаты не стандартизуют: иначе в правдоподобие вошёл бы якобиан стандартизации.

Имя	Центры μ_m	σ
`two_blobs`	$(-2,\ 0)$, $(2,\ 0)$	0,3
`eight_gaussians`	$3(\cos\frac{2\pi m}{8}, \sin\frac{2\pi m}{8})$, $m = 0, \ldots, 7$	0,2
`four_corners`	все пары $(\pm 2{,}5,\ \pm 2{,}5)$	0,3
`three_blobs`	$(0;\ 2{,}5)$, $(-2{,}2;\ -1{,}3)$, $(2{,}2;\ -1{,}3)$	0,25

Моды этих смесей далеко разведены: соседние центры отстоят больше чем на 10σ. Область всех целей одна, $\Omega = [-15,\ 15]^2$. Она содержит шар радиуса 14.

Генератор создаёт `train` из 20 000 точек, `val` из 5000 и `test` из 5000. Начальные значения генератора — 601, 602 и 603. Их пишут в паспорт: это отпечаток данных. Часть `cal` не создают. Её читает только ЛР8.

В середине между центрами `two_blobs` истинный логарифм плотности равен −21,65. Промежуток цели практически пуст.

Изображения используются только в дополнительном задании.

Оборудование. Видеокарта не нужна. Двумерные модели обучают на процессоре. Видеокарта нужна только для дополнительного задания с изображениями.

8 Индивидуальный профиль

Параметры ЛР6 считает функция `lab_pick` из ЛР1. Добавьте в генератор профиля три поля:

```
profile["lab6_target"] = lab_pick(sid, 6, 0, 2,
    ["eight_gaussians", "four_corners", "three_blobs"])
profile["lab6_eta"] = lab_pick(sid, 6, 2, 4,
    [[0.01, 0.05, 0.1, 0.4], [0.005, 0.02, 0.08, 0.5]])
profile["lab6_scale"] = lab_pick(sid, 6, 4, 6, [1.0, 2.0, 4.0])
```

Здесь `sid` — номер зачётки, `profile` — словарь профиля из ЛР0. Первое поле — трудная цель эксперимента E3. Второе — сетка шагов η при $T = 1$. Третье — предел c масштаба слоя связи. Для номера `20250137` получаются цель `three_blobs`, шаги 0,005, 0,02, 0,08, 0,5 и предел $c = 4$.

9 Задания

9.1 Задание 1. Целевые двумерные распределения и оценка плотности

Что сделать.

1. Реализуйте реестр целей. У каждой цели есть выборка, логарифм плотности, номер моды и область:

   ```
   x = distribution.sample(n)
   log_p = distribution.log_prob(x)
   mode_id = distribution.mode_id(x)
   domain = distribution.domain          # Omega = [-15, 15] ** 2
   ```

2. Внесите четыре смеси раздела 7. Веса равные. `mode_id` возвращает номер ближайшего центра, если расстояние не больше 3σ, иначе -1.

3. Создайте части `train`, `val` и `test` с семенами 601, 602, 603. Часть `cal` не создавайте.

4. Реализуйте оценку плотности. Она строит карту истинной плотности, карту потока, карту энергии, наложение примеров, $\hat{Z}_\Omega$, $\hat{p}_\theta$, D_{grid}, Cov, D_{mode} и MMD^2. Сетка — 120×120 центров ячеек с шагом 0,25, площадь ячейки $\Delta = 0{,}0625$.

5. Пометьте $\hat{p}_\theta$ флагом `normalized_on_omega`. Точный `log_prob` энергетической модели этот модуль не выдаёт.
6. Посчитайте уровень шума MMD^2 и D_{mode} пятью повторами.

Что должно получиться. Любая цель экспериментов создаётся именем из конфигурации. Карты и метрики считаются одним вызовом оценщика.

Как проверить себя. В нуле `log_prob` цели `two_blobs` равен $-21{,}65$ с точностью 0,01. Центр моды получает свой номер. Тест 6 проходит.

9.2 Задание 2. Модель энергии и сэмплер Ланжевена

Что сделать.

1. Реализуйте энергию (6.2) при $s = 3$. Остаток — полносвязная сеть: три скрытых слоя ширины 128 с ReLU и выход tanh. Квадратичный член прибавляют снаружи сети.
2. Энергия возвращает один скаляр на точку. Точный `log_prob` у энергии недоступен: метод сообщает об этом либо возвращает $\log \hat{p}_\theta$ с флагом области. Примеры строит `sample`.
3. Реализуйте шаг (6.6). В основном режиме функция получает η и T, а σ вычисляет сама. Градиент по x считается через `torch.autograd.grad` и не делает шага оптимизатора. Сохраняйте траекторию $x_0, \ldots, x_K$. Граница — отражение внутрь Ω. Для теста дисперсии предусмотрен режим без границы.

```
def langevin_sample(energy_fn, x0, eta, temperature, steps, boundary):
    # sigma**2 = 2 * eta * temperature; sigma is not an argument
    ...
    return x, trajectory
```

4. Реализуйте буфер (6.8) ёмкостью 10 000 с вытеснением случайной ячейки. Контрольная точка хранит точки буфера и состояние его генератора случайных чисел.
5. Шаг обучения — формула (6.4). Вход отрицательных примеров отсоединён:

```
def energy_loss(energy_fn, x_pos, x_neg):
    e_pos = energy_fn(x_pos)
    e_neg = energy_fn(x_neg.detach())
    return e_pos.mean() - e_neg.mean()
```

6. Для диагностики считайте смещение D_K — среднее $\|x_K - x_0\|_2$, энергию вдоль траектории и число смен моды.
7. Начните обучение так: 5000 шагов Adam, скорость 10^{-3}, пакет 256, $K = 50$, $T = 1$. Шаг η — второе значение `lab6_eta`. Штраф на величину энергии допустим только если его коэффициент записан в конфигурации [7].

Что должно получиться. Одна и та же энергия обучается и замораживается. Дальше сетка шагов меняет только сэмплер.

Как проверить себя. Тесты 1–3 проходят. При $\eta = 0{,}05$ и $T = 1$ дисперсия длинной цепи на энергии $x^2/2$ близка к 1,026, а не к 1.

9.3 Задание 3. Нормализующий поток на аффинных слоях связи

Что сделать.

1. У блока есть прямой шаг и обратный. Прямой возвращает образ и логарифм определителя. Обратный возвращает прообраз.
2. Реализуйте слой (6.10)–(6.11). Сети s_θ и t_θ — отдельные полносвязные сети ширины 64 с двумя скрытыми слоями ReLU. Масштаб ограничьте пределом c из профиля. Прямой и обратный шаг вызывают одни и те же сети.
3. Между K_f слоями связи поставьте $K_f - 1$ перестановку координат. В размерности 2 это обмен двух координат. Логарифм определителя перестановки равен нулю.
4. Соберите поток. Прямой проход идёт от первого блока к последнему и суммирует логарифмы определителей, затем прибавляет логарифм базовой плотности. Обратный проход для примеров идёт от последнего блока к первому. Базовое распределение — стандартное нормальное, объект `torch.distributions` [3].
5. Проверьте логарифм определителя отдельно от пары «прямой и обратный». Для $d = 2$ соберите якобиан по столбцам вызовами `torch.autograd.grad` [4] и сравните logdet с суммой значений s_θ.
6. Обучите поток максимизацией среднего $\log p_\theta$ на `train`. Контроль — NLL на `val`. Старт: 5000 шагов Adam, скорость 10^{-3}, пакет 256.

Что должно получиться. Поток выдаёт точный `log_prob` и примеры без цепи. Энергетическая модель тем же интерфейсом примеров пользуется, а точный `log_prob` не имитирует.

Как проверить себя. Тесты 4 и 5 проходят. Слой с $s_\theta = -1$ и $t_\theta = 0$ даёт логарифм определителя -1.

Что добавляется в общий проект. Модули `src/generative/` (`distributions.py`, `density.py`, `ebm.py`, `samplers.py`, `flows.py`), `src/diagnostics/` (`density_metrics.py`, `mcmc.py`, `invertibility.py`) и `src/analysis/` `generative_comparison.py`. Ими пользуются следующие работы, когда сравнивают способы задать $p(x)$.

10 Эксперименты

Перед каждым экспериментом запишите гипотезу: что вы ожидаете увидеть и по какой формуле. Эксперименты E1 и E2 поисковые, для них достаточно одного `seed`, равного 1. Главный вывод проверяется в E3 на трёх `seeds`. Расхождение с гипотезой допустимо, если указано, какое предположение не выполнилось.

10.1 Эксперимент E1. Шаг Ланжевена

Вопрос. Как шаг η меняет цепь одной и той же энергии и где у этой энергии низкие места?

Что сделать. Обучите одну энергетическую модель на `two_blobs` по заданию 2 и заморозьте веса.

1. Постройте карту E_θ и карту $\hat{p}_\theta$ на Ω. Нанесите точки данных. Запишите E_θ в обоих центрах и в нуле, среднее E_θ на `test` и оценку хвоста (6.3) при $R = 14$.
2. Для каждого η из `lab6_eta` при $T = 1$ и $K = 50$ посчитайте MMD^2, Cov, D_K и долю точек вне Ω. Постройте эти величины от η. Сохраните траектории.
3. На энергии $E(x) = x^2/2$, без границы, для каждого η оцените стационарную дисперсию: 8 цепей, $2 \cdot 10^5$ шагов после отбрасывания 10^4. Сравните с (6.7).
4. Контроль связи. Возьмите σ, согласованное со вторым η сетки, и подставьте его в наибольший η, не пересчитывая. Запишите $T = \sigma^2/(2\eta)$ и измеренную дисперсию.
5. Рабочий шаг — наименьший η с тремя свойствами: нет NaN, доля точек вне Ω не больше 5%, хотя бы 20% цепей из одного центра заканчиваются в другом. Если такого η нет, возьмите устойчивый шаг с наименьшим MMD^2. Напишите, что за $K = 50$ моды не смешались.

Порог приёмки.

- Относительная ошибка дисперсии против (6.7) не больше 5% на каждом η сетки и на контроле с чужим σ.
- Оценка хвоста при $R = 14$ не больше 0,01. Подстановка в (6.3) даёт 0,0029.
- После обучения энергия обоих центров ниже энергии в нуле.
- Для каждого η записаны D_K, Cov, MMD^2 и флаг устойчивости. Названы слишком малый шаг, рабочий и слишком большой. У наибольшего η предсказанная v не меньше 1,2.

Граница применимости. Формула (6.7) проверена на квадратичной энергии без границы. У выученной энергии градиент другой, а отражение от Ω включено. Шаг подобран на двух облаках. На цели с большим числом мод тот же K может не перемешивать цепи.

10.2 Эксперимент E2. Глубина потока

Вопрос. Когда лишний слой связи перестаёт улучшать правдоподобие и растёт ли ошибка обратимости?

Что сделать. Обучите поток на `two_blobs` при $K_f \in \{2,\ 4,\ 8,\ 16\}$. Предел c — из профиля. Число шагов оптимизатора, пакет, скорость и `seed` одинаковы.

1. Для каждой глубины запишите NLL на `val` со стандартной ошибкой среднего, MMD^2, Cov, число параметров, время порождения 5000 точек и $\varepsilon_{\mathrm{inv}}$ на `test`.
2. Постройте NLL, MMD^2 и $\varepsilon_{\mathrm{inv}}$ от K_f.
3. Повторите $\varepsilon_{\mathrm{inv}}$ на 100 точках с нормой 20.

Улучшение заметно, если NLL упал больше чем на две стандартные ошибки. Глубину для E3 возьмите наименьшей, после которой следующий шаг уже не заметен. Если заметны все шаги, возьмите $K_f = 8$.

Порог приёмки.

- На точках `test` медиана ε_{inv} не больше 10^{-5}, расхождение аналитического логарифма определителя с автоградом не больше 10^{-5}.
- В таблице есть все четыре глубины. Указана глубина, после которой выигрыш теряется на фоне двух стандартных ошибок, либо явно сказано, что такого насыщения нет.

Граница применимости. Порог 10^{-5} относится к точкам данных в `float64`. На норме 20 ошибка может вырасти: обратный масштаб $\exp(-s_\theta)$ усиливает погрешность [17]. Если она не выросла, так и запишите. Предел c из профиля сужает слой: малый c стабильнее и слабее по преобразованию.

10.3 Эксперимент E3. Энергетическая модель и поток на трудной цели

Вопрос. На цели профиля с несколькими далёкими модами чем различаются энергетическая модель и поток, если число параметров близко?

Что сделать. Цель — `lab6_target`. До запусков запишите гипотезу в `hypothesis.md` и зафиксируйте файл в Git.

1. Метрика Q — это MMD^2 или D_{mode}. Укажите, какая модель стоит первой в разности (6.15).
2. Меняется только класс модели.
3. Зафиксированы цель, Ω, шаг и K из E1, глубина и c из E2, число шагов оптимизатора и три `seeds`.
4. Записаны ожидаемый знак $\bar{\Delta}$ и результат, который опровергнет гипотезу.

Подгоните ширину одной из сетей так, чтобы числа параметров различались не больше чем на 20%. Глубину и K_f не меняйте. Обучите обе модели на `seeds` $1, 2, 3$.

1. Для каждого запуска запишите число параметров, время обучения, время порождения 5000 точек, Cov, D_{mode}, MMD^2. Для потока — NLL на `test`. Для энергии — D_{grid} и хвост (6.3), с пометкой нормировки на Ω.
2. Возьмите два ближайших центра. В их середине запишите истинный логарифм плотности, логарифм плотности потока и $\log \hat{p}_\theta$. Нарисуйте примеры и плотности. Отрезок между центрами выделите.
3. Постройте три точки Δ_s и среднее.

Порог приёмки. Числа параметров различаются не больше чем на 20%. Приведены все три Δ_s. Вывод о различии установлен только если знаки совпали, $|\bar{\Delta}| \geq 2s_\Delta$ и модуль средней разности не ниже уровня шума метрики. Иначе вывод: различие не установлено. Расхождение с `hypothesis.md` оценку не снижает, если оно объяснено.

Граница применимости. Середина между модами — место запрета на разрыв связности [16]. У цели там почти пусто. У потока плотность на отрезке может остаться заметно выше истинной. У энергии барьер в энергии допустим. Если мост потока не

виден, запишите это как наблюдение: высота моста зависит от глубины и от c. Три `seeds` описывают разброс на этой цели. На другие цели вывод сам не переносится.

11 Контрфактические вопросы

Ответ опирается на ваши числа и на `RUN_ID`. Если числа в сделанных запусках нет, выполните дополнительную оценку.

1. Возьмите два наименьших η из E1 и их D_K. Что делает цепь при фиксированном K, когда шаг стремится к нулю?
2. На наибольшем η сравните измеренную дисперсию квадратичной энергии с (6.7). В какой величине выученная энергия первой уходит от этой картины: в устойчивости, в Cov или в MMD^2?
3. По контролю E1 запишите эффективную температуру и измеренную дисперсию. К какому стационарному закону идёт эта цепь?
4. Возьмите две глубины E2. Приведите NLL и MMD^2. Совпадает ли лучшее правдоподобие с лучшими примерами?
5. В середине моста E3 приведите три логарифма: истинный, поток и $\log \hat{p}_\theta$. Низкая энергия на точках данных сама по себе показывает ли, что промежуток пуст?

12 Обязательные тесты

1. Энергия возвращает один скаляр на точку и не меньше $\|x\|^2/(2s^2) - 1$ с допуском 10^{-5}. Квадратичный член лежит вне сети.
2. В основном режиме $\sigma^2 = 2\eta T$, свободного аргумента σ нет. На энергии $x^2/2$ без границы, при $\eta = 0{,}05$, относительная ошибка дисперсии против 1,026 не больше 5%. Протокол цепей — как в E1.
3. Сэмплер не меняет θ. Градиент шага обучения совпадает с разностью средних $\nabla_\theta E_\theta$ на данных и на отсоединённом x^- с точностью 10^{-5}. Отсоединение числа $E_\theta(x^-)$ этот тест не проходит.
4. На $\|x\| \le 5$ в `float64` медиана ε_{inv} не больше 10^{-5}. У слоя с $s_\theta = -1$ и $t_\theta = 0$ логарифм определителя равен -1 и совпадает с автоградом с точностью 10^{-5}. То же расхождение для случайно инициализированного слоя с ненулевым s_θ.
5. Слой с $s_\theta = 0$ и $t_\theta = 0$ — тождество с точностью 10^{-6}. Перестановка совпадает со своим обратным шагом. Поток из одного слоя с $s_\theta = -1$ удовлетворяет $\log p_\theta(x) = \log p_Z(f(x)) - 1$. Логарифм плотности одной точки не зависит от соседей по пакету.
6. Оценщик ставит флаг `normalized_on_omega` и не выдаёт $\hat{p}_\theta$ как точный `log_prob`. Буфер после записи и чтения контрольной точки совпадает побитово.

13 Что сдать

Сдаются модули заданий 1–3, конфигурации E1–E3, файл `hypothesis.md`, тесты и отчёт. Отчёт состоит из пяти частей:

1. **Профиль и протокол:** цель, сетка η, предел c, область Ω, шаг обучения, глубина потока для E3.
2. **E1:** карты энергии и $\hat{p}_\theta$, таблица дисперсии против (6.7), три режима шага, выбранный η.
3. **E2:** таблица по глубинам, графики, выбранная глубина, ошибка обратимости на норме 20.
4. **E3:** гипотеза, числа параметров, метрики обеих моделей, логарифмы на мосту, все Δ_s, вывод.
5. **Ответы на контрфактические вопросы.**

Каждое число сопровождается ссылкой на `RUN_ID`. Графики строятся из сохранённых результатов.

14 Критерии завершения и оценивания

Работа завершена при всех условиях списка.

- эксперименты E1–E3 выполнены, у каждого результата есть `RUN_ID`;
- тесты проходят;
- файл `hypothesis.md` зафиксирован в Git до запусков E3;
- у энергии указаны область нормировки и хвост, у потока — точное правдоподобие;
- на все контрфактические вопросы даны ответы с собственными числами.

Веса частей оценки те же, что в ЛР0: реализация 0,15, экспериментальный протокол 0,30, диагностика 0,30, перенос 0,25.

15 Дополнительные задания

1. **Число шагов цепи.** У замороженной энергии E1, на рабочем η, постройте MMD^2, Cov и время порождения для $K \in \{1,\ 5,\ 10,\ 25,\ 50,\ 100\}$. Укажите наименьшее K, после которого дальнейший выигрыш в MMD^2 не выше уровня шума метрики.
2. **Правдоподобие вне данных.** Возьмите поток, обученный на `two_blobs`. Посчитайте средний $\log p_\theta$ на `test`, на тех же точках после сдвига на $(4,\ 4)$ и на цели профиля. Разложите среднее на $\log p_Z(z)$ и $\log|\det J|$. Меньшее правдоподобие на далёких точках не обязано получиться [19]. Напишите, какой член разложения отвечает за ваше наблюдение.
3. **Изображения.** Выберите MNIST [21] или FashionMNIST [22]. Из официального обучения отделите `val` из 5000 примеров стратифицированно. Часть `cal` пуста, `test` — официальный. Достаточно одной ветви. Энергия: свёрточный остаток того же класса (6.2), шаг (6.6), без сеточной нормировки. Поток: равномерная деквантизация [18]

$$y = \frac{x+u}{256}, \quad u \sim \mathrm{Uniform}\big([0,1)^D\big), \quad \frac{-\mathbb{E}_u[\ln p_Y(y)] + D\ln 256}{D\ln 2}. \tag{6.17}$$

Здесь x — целые пиксели от 0 до 255, D — число пикселей, логарифм натуральный. Вторая дробь — оценка в битах на пиксель, верхняя граница дискретного

правдоподобия. Модель задают на $y \in [0,1)^D$, без предварительного логита. Для плотности $p_Y = 1$ оценка равна 8. Сообщайте её отдельно от непрерывного NLL на y.

16 Контрольные вопросы

1. Когда энергия задаёт плотность, а когда интеграл Z_θ бесконечен?
2. Почему понижения энергии только на данных недостаточно?
3. Что делают две фазы градиента (6.4) и почему отсоединяют вход x^-, а не значение энергии?
4. Откуда в шаге берётся связь $\sigma^2 = 2\eta T$? Какая температура получится при другой паре?
5. Куда направлено отображение в формуле (6.9) и что даёт логарифм определителя?
6. Почему якобиан слоя связи треугольный и почему согласия прямого и обратного логарифмов мало для проверки?
7. Почему поток со стандартным нормальным шумом оставляет мост между далёкими модами, а энергия может поставить там барьер?
8. Почему NLL потока и энергию модели не вычитают как одну и ту же величину?

17 Итог

Плотность можно задать энергией или обратимым преобразованием. В первом случае нормирующая константа неизвестна, а примеры даёт шаг Ланжевена при согласованном шуме. Во втором правдоподобие точно, пока считается логарифм определителя, но гладкое обратимое отображение не вырезает пустые промежутки между модами. Способ представления выбирает и обучение, и порождение, и то, какие утверждения о плотности вообще допустимы.

Литература

[1] Николенко С., Кадурин А., Архангельская Е. Глубокое обучение. Погружение в мир нейронных сетей. — СПб.: Питер, 2018. — 480 с.

[2] Гудфеллоу Я., Бенджио И., Курвилль А. Глубокое обучение / пер. с англ. А. А. Слинкина. — 2-е изд., испр. — М.: ДМК Пресс, 2018. — 652 с.

[3] PyTorch Documentation: torch.distributions. https://docs.pytorch.org/docs/stable/distributions.html

[4] PyTorch Documentation: torch.autograd.grad. https://docs.pytorch.org/docs/stable/generated/torch.autograd.grad.html

[5] Y. LeCun, S. Chopra, R. Hadsell, M. Ranzato, F. J. Huang. A Tutorial on Energy-Based Learning. In *Predicting Structured Data*, MIT Press, 2006.

[6] G. E. Hinton. Training Products of Experts by Minimizing Contrastive Divergence. *Neural Computation*, 14(8):1771–1800, 2002.

[7] Y. Du, I. Mordatch. Implicit Generation and Generalization in Energy-Based Models. *NeurIPS*, 2019.

[8] E. Nijkamp, M. Hill, S.-C. Zhu, Y. N. Wu. Learning Non-Convergent Non-Persistent Short-Run MCMC Toward Energy-Based Model. *NeurIPS*, 2019.

[9] Y. Song, D. P. Kingma. How to Train Your Energy-Based Models. arXiv:2101.03288, 2021.

[10] G. O. Roberts, R. L. Tweedie. Exponential Convergence of Langevin Distributions and Their Discrete Approximations. *Bernoulli*, 2(4):341–363, 1996.

[11] M. Welling, Y. W. Teh. Bayesian Learning via Stochastic Gradient Langevin Dynamics. *ICML*, 2011.

[12] Y. Song, S. Ermon. Generative Modeling by Estimating Gradients of the Data Distribution. *NeurIPS*, 2019.

[13] D. J. Rezende, S. Mohamed. Variational Inference with Normalizing Flows. *ICML*, 2015.

[14] G. Papamakarios, E. Nalisnick, D. J. Rezende, S. Mohamed, B. Lakshminarayanan. Normalizing Flows for Probabilistic Modeling and Inference. *JMLR*, 22(57):1–64, 2021.

[15] L. Dinh, J. Sohl-Dickstein, S. Bengio. Density Estimation using Real NVP. *ICLR*, 2017.

[16] R. Cornish, A. Caterini, G. Deligiannidis, A. Doucet. Relaxing Bijectivity Constraints with Continuously Indexed Normalising Flows. *ICML*, 2020.

[17] J. Behrmann, P. Vicol, K.-C. Wang, R. Grosse, J.-H. Jacobsen. Understanding and Mitigating Exploding Inverses in Invertible Neural Networks. *AISTATS*, 2021.

[18] L. Theis, A. van den Oord, M. Bethge. A Note on the Evaluation of Generative Models. *ICLR*, 2016.

[19] E. Nalisnick, A. Matsukawa, Y. W. Teh, D. Gorur, B. Lakshminarayanan. Do Deep Generative Models Know What They Don't Know? *ICLR*, 2019.

[20] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf, A. Smola. A Kernel Two-Sample Test. *JMLR*, 13:723–773, 2012.

[21] Y. LeCun, L. Bottou, Y. Bengio, P. Haffner. Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.

[22] H. Xiao, K. Rasul, R. Vollgraf. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv:1708.07747, 2017.