Лабораторная работа 8

Когда предсказанию сети можно доверять

Надёжность, калибровка и неопределённость

Курс «Нейронные сети»

Редакция 4 от 8 октября 2026 г.

1 Введение

Точность на тестовых данных показывает, как часто модель права в среднем. На практике важнее другое: можно ли доверять конкретному ответу. Классификатор сообщает не только класс, но и уверенность (confidence) — вероятность, которую он приписывает этому классу. Если уверенности можно верить, сомнительные ответы можно передать на проверку человеку.

Уверенность заслуживает доверия, если совпадает с долей верных ответов. Модель называют *откалиброванной* (calibrated), если это верно при любом уровне уверенности. Среди предсказаний с уверенностью 0,8 верны около 80%. Если из 1000 таких ответов верны только 600, модель переоценивает себя на 0,2. Глубокие сети часто излишне уверены [6].

Калибровка — одно из свойств надёжности. Модель может ошибаться на шуме, поддаваться незаметному возмущению и уверенно назвать знакомым классом изображение, которого не было в обучении. Эти свойства измеряются отдельно.

Новые модели не обучаются. Берутся контрольные точки ЛР2 и проект из ЛР0. У запуска есть `EXP_ID` и `RUN_ID`. Числа в отчёте ссылаются на `RUN_ID`.

2 Цель работы

Цель работы — построить инструменты оценки надёжности и составить **профиль надёжности** моделей ЛР2. Профиль заменяет одно число — точность — несколькими измерениями: калибровкой, поведением при искажениях, устойчивостью к атакам и качеством мер неопределённости. Для каждого измерения указывается, при каких условиях оно определено.

Когда предсказанию сети можно доверять, и какие свойства надёжности не следуют из точности на чистых данных?

3 Что нужно знать заранее

Если какой-то пункт незнаком, восполните пробел по указанному источнику.

- Функция softmax, перекрёстная энтропия (cross-entropy) и метод максимального правдоподобия — [1, разд. 2.3], [2, разд. 5.5, 6.2].

- Условная вероятность и энтропия — [2, разд. 3.5, 3.13].
- Назначение проверочной и тестовой частей данных — [2, разд. 5.3].
- Свёрточные сети и модели с вниманием — [1, разд. 5.4, 8.1]; модели ЛР2.
- Состязательные примеры и градиент по входу сети — [2, разд. 7.13]; руководство PyTorch по FGSM [3]; функция `torch.autograd.grad` [4].
- Показатели качества и доля объектов, на которые система отвечает — [2, разд. 11.1].
- Проект для экспериментов из ЛР0 и контрольные точки моделей ЛР2.

4 Результаты обучения

После выполнения работы вы сможете:

1. отличать точность от калибровки и строить диаграмму надёжности;
2. вычислять ECE, NLL и оценку Брайера и объяснять, что измеряет каждая из них;
3. применять температурное масштабирование и объяснять, почему оно не меняет предсказанный класс;
4. отличать искажение входа от данных незнакомых классов и знать, какие метрики определены в каждом случае;
5. реализовывать атаки FGSM и PGD с правильной проекцией;
6. оценивать меры неопределённости по тому, как они отделяют ошибки и незнакомые данные.

5 Модели и обозначения

5.1 Уверенность и калибровка

Классификатор f_θ получает изображение $x \in [0,1]^d$, где d — число значений пикселей. Он выдаёт вектор логитов (logits) $z(x) \in \mathbb{R}^C$, где C — число классов. Нормализация входа считается частью f_θ. Вероятности классов, предсказанный класс и уверенность:

$$p_c(x) = \frac{e^{z_c(x)}}{\sum_{j=1}^{C} e^{z_j(x)}}, \qquad \hat{y}(x) = \arg\max_c p_c(x), \qquad \operatorname{conf}(x) = \max_c p_c(x), \tag{8.1}$$

где $p_c(x)$ — вероятность класса c. Модель *откалибрована*, если уверенность совпадает с долей верных ответов [6]:

$$\Pr\big(\hat{Y} = Y \mid \operatorname{conf}(X) = p\big) = p \quad \text{для всех} \quad p \in [0,1], \tag{8.2}$$

где X — случайный объект, Y — его верный класс, $\hat{Y} = \hat{y}(X)$. Простыми словами: среди предсказаний с уверенностью 0,8 верны 80%. Калибровка и точность — разные свойства. Модель, которая для десяти равновероятных классов всегда выдаёт вероятность 0,1, откалибрована и при этом бесполезна.

5.2 Как измерить калибровку

Условие (8.2) проверяют по M интервалам уверенности $B_1, \dots, B_M$ равной ширины или с равным числом объектов. В каждом интервале сравнивают долю верных ответов и среднюю уверенность:

$$\mathrm{acc}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} \mathbf{1}(\hat{y}_i = y_i), \qquad \mathrm{conf}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} \mathrm{conf}(x_i), \tag{8.3}$$

где $|B_m|$ — число объектов в B_m, $\mathbf{1}(\cdot)$ равно 1 при выполнении условия и 0 иначе. Диаграмма надёжности (reliability diagram) показывает зависимость $\mathrm{acc}(B_m)$ от $\mathrm{conf}(B_m)$ [6]. Точки ниже диагонали означают излишнюю уверенность. Ожидаемая ошибка калибровки (expected calibration error, ECE) [7] — взвешенное отклонение от диагонали:

$$\mathrm{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{N} \bigl|\mathrm{acc}(B_m) - \mathrm{conf}(B_m)\bigr|, \tag{8.4}$$

где N — число объектов. Пустые интервалы в сумму не входят: для них доля верных ответов не определена. При малом M отклонения разных знаков внутри интервала гасят друг друга, и ECE занижается. При большом M шум в малочисленных интервалах её завышает [8]. Вместе с ECE указывают M, тип интервалов и число пустых интервалов. Сравнивать ECE можно только при одной схеме.

5.3 NLL и оценка Брайера

Весь вектор вероятностей учитывают отрицательное логарифмическое правдоподобие (negative log-likelihood, NLL) и оценка Брайера (Brier score) [9]:

$$\mathrm{NLL} = -\frac{1}{N} \sum_{i=1}^{N} \ln p_{y_i}(x_i), \qquad \mathrm{BS} = \frac{1}{N} \sum_{i=1}^{N} \sum_{c=1}^{C} \bigl(p_c(x_i) - \mathbf{1}(y_i = c)\bigr)^2. \tag{8.5}$$

NLL сильно штрафует уверенные ошибки: при $p_{y_i}(x_i) = 0{,}01$ слагаемое равно $\ln 100 \approx 4{,}6$. Обе метрики — строго правильные правила оценки (strictly proper scoring rules): их ожидаемое значение минимально только при истинных вероятностях [10]. Поэтому они зависят и от калибровки, и от умения отличать лёгкие объекты от трудных. Они могут ухудшиться, когда ECE улучшается.

Подробнее: [2, разд. 3.13, 5.5]; [1, разд. 2.3]; [6].

5.4 Температурное масштабирование

Температурное масштабирование (temperature scaling) делит все логиты на одно число $T > 0$ [6]:

$$p_c^{(T)}(x) = \mathrm{softmax}\bigl(z(x)/T\bigr)_c, \qquad T^\star = \arg\min_{T>0} \ \mathrm{NLL}^{(T)}\bigl(\mathcal{D}_{\mathrm{val}}\bigr), \tag{8.6}$$

где $\mathrm{NLL}^{(T)}(\mathcal{D}_{\mathrm{val}})$ — NLL вероятностей $p^{(T)}$ на части `val`. При $T > 1$ уверенность падает, при $T < 1$ растёт. Деление на положительное число не меняет порядок логитов, поэтому предсказанный класс и точность сохраняются. $T^\star$ подбирается только на `val`: подбор на `test` сделал бы итоговые числа оптимистичными. Температура, подобранная на одних данных, не обязана подходить для других [11].

5.5 Меры неопределённости

Мера неопределённости $U(x)$ тем больше, чем меньше уверенность. Сравниваются три меры:

$$U_{\mathrm{MSP}}(x) = 1 - \max_c p_c(x), \quad H(x) = -\sum_{c=1}^{C} p_c(x) \ln p_c(x), \quad U_{\mathrm{margin}}(x) = 1 - p_{(1)}(x) + p_{(2)}(x), \tag{8.7}$$

где $p_{(1)} \geq p_{(2)}$ — две наибольшие вероятности, слагаемые с $p_c = 0$ в H равны нулю. Мера U_{MSP} основана на наибольшей вероятности (maximum softmax probability, MSP) и служит базовой [12]. Энтропия H принимает значения от 0 до $\ln C$; при $C = 10$ это примерно 2,3. Мера U_{margin} использует отступ (margin) между двумя наибольшими вероятностями. Все три меры вычисляются из одного вектора вероятностей. Поэтому они не различают неоднозначность объекта и незнание модели.

5.6 Сдвиг распределения

Модель обучена на $P_{\mathrm{train}}(X, Y)$, а применяется к $P_{\mathrm{test}}(X, Y)$. При *сдвиге входного распределения* (covariate shift) меняется $P(X)$, а $P(Y \mid X)$ и набор классов сохраняются. Размытый автомобиль остаётся автомобилем [13], поэтому точность, ECE, NLL и оценка Брайера определены.

При *семантическом сдвиге* (semantic shift) появляются классы, которых нет у модели. Это *данные вне распределения* (out-of-distribution, OOD): например, цифры SVHN для модели CIFAR-10. Верного ответа нет, поэтому точность, ECE, NLL и оценка Брайера **не вычисляются**. Остаются метрики обнаружения (раздел 5.9). Температуру применить можно: смысл теряют метрики, а не преобразование.

5.7 Состязательные возмущения

Состязательный пример (adversarial example) — изображение с малым возмущением, подобранным так, чтобы модель ошиблась [14, 15]. От случайного шума той же величины такое возмущение отличается направлением: оно согласовано с градиентом функции потерь. Атака ищет наихудшее возмущение δ с допустимой величиной возмущения ε:

$$\max_{\delta} \ \mathcal{L}\big(f_\theta(x+\delta), y\big) \quad \text{при} \quad \|\delta\|_\infty = \max_j |\delta_j| \leq \varepsilon, \quad x + \delta \in [0,1]^d, \tag{8.8}$$

где $\mathcal{L}$ — перекрёстная энтропия, y — верный класс. Атака меняет изображение до нормализации, поэтому ε задаётся в единицах исходных пикселей: $\varepsilon = 8/255 \approx 0{,}031$ — не более 8 уровней яркости из 255.

FGSM (fast gradient sign method) [15] берёт максимум линейного приближения $\mathcal{L}(x) + \delta^\top \nabla_x \mathcal{L}$ на шаре $\|\delta\|_\infty \leq \varepsilon$. Он равен $\delta = \varepsilon \operatorname{sign}(\nabla_x \mathcal{L})$. Проекция $\Pi_{[0,1]^d}$ обрезает значения до $[0, 1]$:

$$x_{\mathrm{adv}} = \Pi_{[0,1]^d}\Big[x + \varepsilon \operatorname{sign}\big(\nabla_x \mathcal{L}(f_\theta(x), y)\big)\Big]. \tag{8.9}$$

PGD (projected gradient descent) [16] делает K шагов величины α из случайной точки шара. После каждого шага точка проецируется на допустимое множество:

$$\begin{gathered} x^{(0)} = \Pi\big[x + u\big], \qquad u \sim \mathcal{U}\big([-\varepsilon, \varepsilon]^d\big); \\ x^{(t+1)} = \Pi\Big[x^{(t)} + \alpha \operatorname{sign}\big(\nabla_x \mathcal{L}(f_\theta(x^{(t)}), y)\big)\Big], \qquad t = 0, \ldots, K-1; \\ \Pi[v] = \min\big(\max(v,\ x - \varepsilon,\ 0),\ x + \varepsilon,\ 1\big) \text{ покомпонентно,} \end{gathered} \tag{8.10}$$

где u — равномерный случайный сдвиг, $x_{\text{adv}} = x^{(K)}$. Шар $\|v - x\|_\infty \le \varepsilon$ и куб $[0,1]^d$ — ограничения по координатам, поэтому покомпонентное обрезание точно проецирует на их пересечение. По умолчанию $\alpha = 2{,}5\,\varepsilon/K$: суммарный путь $2{,}5\,\varepsilon$ длиннее диаметра шара 2ε вдоль координаты. Из R стартов берётся худший для модели.

Атака идёт в режиме оценки и не меняет параметры. Если PGD снижает точность меньше, чем FGSM при той же ε, сначала ищите ошибку реализации. Точность при атаке — лишь верхняя оценка устойчивости: более сильная атака может снизить её ещё [17].

5.8 Отказ от предсказания

При хорошей мере неопределённости неуверенные ответы можно передать человеку. Это *отказ от предсказания* (selective prediction) [18]: модель отвечает, только если $U(x) \le \tau$, где τ — порог:

$$a_\tau(x) = \mathbf{1}\big(U(x) \le \tau\big), \quad \text{Cov}(\tau) = \frac{1}{N}\sum_{i=1}^{N} a_\tau(x_i), \quad \text{Risk}(\tau) = \frac{\sum_i a_\tau(x_i)\,\mathbf{1}(\hat{y}_i \ne y_i)}{\sum_i a_\tau(x_i)}, \tag{8.11}$$

где Cov — покрытие, то есть доля объектов с ответом; Risk — доля ошибок среди них. При нулевом покрытии риск не определён и записывается как отсутствующее значение, а не как ноль. Кривая «риск — покрытие» (risk–coverage curve) строится по всем порогам, площадь под ней [19]

$$\text{AURC} = \frac{1}{N}\sum_{k=1}^{N} \widehat{\text{Risk}}(k), \qquad \widehat{\text{Risk}}(k) = \frac{1}{k}\sum_{j=1}^{k} \mathbf{1}\big(\hat{y}_{(j)} \ne y_{(j)}\big), \tag{8.12}$$

где объекты упорядочены по возрастанию U, а $\widehat{\text{Risk}}(k)$ — доля ошибок среди k самых уверенных. Чем меньше AURC, тем лучше мера отделяет ошибки. При случайном порядке AURC в среднем равна доле ошибок. Наименьшее значение даёт порядок, в котором ошибки стоят в конце. AURC зависит от точности, поэтому для разных моделей приводят и разность с этим наименьшим значением.

5.9 Обнаружение данных вне распределения

Обнаружение OOD — двоичная задача: по $U(x)$ решить, знаком ли объект модели. Положительный класс — OOD, метки классов OOD-объектов не используются:

$$\begin{gathered}\text{AUROC} = \Pr\big(U(X_{\text{OOD}}) > U(X_{\text{ID}})\big) + \tfrac{1}{2}\Pr\big(U(X_{\text{OOD}}) = U(X_{\text{ID}})\big), \\ \text{FPR@95} = \Pr\big(U(X_{\text{ID}}) > \tau_{95}\big),\end{gathered} \tag{8.13}$$

где X_{ID} — объект знакомого распределения, X_{OOD} — объект OOD-набора, τ_{95} — порог, при котором распознаются 95% OOD-объектов. Значение AUROC $= 0{,}5$ — угадывание, 1 — полное разделение. FPR@95 — доля знакомых объектов, отмеченных как OOD. Строго возрастающее преобразование U не меняет AUROC. Площадь под кривой precision–recall (AUPR) зависит ещё и от доли OOD-объектов.

5.10 Сводка обозначений

Обозначение	Смысл
x, d, y, C, ℓ	вход, число его значений, верный класс, число классов, сила искажения
$z(x)$, $p_c(x)$, $\hat{y}$, $\mathrm{conf}(x)$	логиты, вероятность класса, предсказанный класс, уверенность
B_m, M, N, ECE, NLL, BS	интервал уверенности, число интервалов, число объектов, метрики калибровки и качества вероятностей
T, $T^\star$, U, H, τ	температура, её значение по `val`, мера неопределённости, энтропия, порог
δ, ε, α, K, R, Π	возмущение, его допустимая величина, шаг и число шагов PGD, число стартов, проекция
Cov, Risk, AURC, AUROC, FPR@95, AUPR	покрытие, риск, метрики отказа от предсказания и обнаружения OOD

6 Данные и оборудование

Модели. Контрольные точки ЛР2: CNN семейства ResNet и ViT на CIFAR-10 [21] или на кадрах лиц. Допускается модель ЛР4: замороженный кодировщик и линейный классификатор. Сохраняйте логиты.

Роли данных. Разбиение берётся из ЛР0 по «Протоколу данных курса». На `val` подбирается $T^\star$, на `test` считаются только итоговые числа. Часть `cal` впервые читается здесь и только для конформного предсказания. Если роли `cal` нет, выделите её из `test` и укажите уменьшенный объём `test`. Кадры лиц разбиты по актёрам, кадры одного клипа не расходятся по ролям. Единица анализа — клип.

Искажения. Шум, размытие, яркость, контраст и закрытие части изображения. Сила $\ell \in \{0, \ldots, 5\}$ согласована с CIFAR-10-C [13]. При $\ell = 0$ данные чистые.

OOD-данные. Для CIFAR-10 далёкий OOD — test SVHN [22], близкий — test CIFAR-100 без 11 классов из протокола данных. Для лиц далёкий OOD — изображения без лиц, близкий — кадры второго корпуса. Это сдвиг домена при тех же классах, а не семантический OOD. Метки OOD-данных не используются.

Оборудование. Достаточно процессора: метрики считаются по логитам. Видеокарта ускоряет атаки. Без неё атакуйте одну и ту же подвыборку `test` из 1000 изображений.

7 Индивидуальный профиль

Профиль ЛР8 вычисляется функцией `lab_pick` из ЛР1 по номеру зачётки и номеру работы. Добавьте в генератор профиля три поля:

```
def lab_pick(student_id: str, lab: int, a: int, b: int, options: list):
    hk = hashlib.sha256(f"{student_id}:lab{lab}".encode("utf-8")).hexdigest()
    return options[int(hk[a:b], 16) % len(options)]

profile["lab8_arch"] = lab_pick(sid, 8, 0, 2, ["cnn", "vit"])
profile["lab8_corruption"] = lab_pick(sid, 8, 2, 4,
    ["gaussian_noise", "gaussian_blur", "contrast", "occlusion"])
profile["lab8_pgd_eps_255"] = lab_pick(sid, 8, 4, 6, [2, 4, 8])
```

Здесь `sid` — номер зачётки, `profile` — словарь профиля из ЛР0. Профиль задаёт архитектуру и тип искажения для основного сравнения E2 и величину ε для PGD в E3 в единицах $1/255$. Например, для номера `20250137` получаются CNN, закрытие части изображения и $\varepsilon = 8/255$. Остальные настройки общие: для ECE — $M = 15$ интервалов равной ширины, для PGD — $K = 10$ шагов и $R = 1$ старт.

8 Задания

8.1 Задание 1. Калибровка и температурное масштабирование

Что сделать.

1. Прогоните модели ЛР2 по `val` и `test` и сохраните логиты, метки и идентификаторы объектов из файла разбиения. Дальше метрики пересчитываются по сохранённым логитам, без нового прогона.
2. Реализуйте ECE (8.4) с параметрами M и тип интервалов; функция возвращает и число пустых интервалов. Реализуйте NLL, оценку Брайера (8.5), диаграмму надёжности и гистограмму уверенности.
3. Реализуйте калибратор температуры (8.6). Методы — `fit` по логитам и меткам `val` и `transform`. Ищите $\ln T$: так условие $T > 0$ выполняется само. Подходит одномерная минимизация или сетка. Запишите $T^\star$ в паспорт запуска.
4. Калибратор принимает только объекты `val` и проверяет это по идентификаторам из файла разбиения. Оценщик отказывается считать точность, ECE, NLL и оценку Брайера на выборке с флагом OOD.

Что должно получиться. Таблица «модель → точность, ECE, NLL, оценка Брайера до и после масштабирования».

Как проверить себя. После масштабирования предсказанные классы не меняются, а NLL на `val` не растёт (тесты 1–3).

8.2 Задание 2. Искажения и оценка неопределённости

Что сделать.

1. Реализуйте не менее четырёх искажений из раздела 6 с силой $\ell \in \{0, \dots, 5\}$. Параметры каждой силы задайте в конфигурации. Размытие, яркость и контраст можно взять из `torchvision` [5].
2. При $\ell = 0$ искажение возвращает исходное изображение. Искажения сохраняют размер, диапазон $[0, 1]$ и метку, а при фиксированном seed дают одинаковый результат.
3. Реализуйте три меры (8.7) в одном модуле с единым знаком: больше — значит менее уверенно.
4. Для каждого объекта сохраняйте запись: логиты, предсказанный класс, уверенность, H, U_{margin}, корректность ответа, флаг ID или OOD, тип и силу искажения, идентификатор объекта, для кадров лиц — идентификатор клипа. У OOD-объектов поле корректности пустое: верного класса у них нет.

Что должно получиться. Таблица записей по всем моделям, типам и силам искажений, из которой метрики E2 считаются без нового прогона.

Как проверить себя. Искажение силы 0 совпадает с исходным изображением, а повтор с тем же seed даёт те же изображения (тест 4).

8.3 Задание 3. Атаки FGSM и PGD

Что сделать.

1. Реализуйте FGSM (8.9) и PGD (8.10) сами, без библиотек атак. В PGD нужны случайный старт и R стартов с выбором худшего результата для каждого объекта.
2. Оформите нормализацию первым слоем модели. Тогда атака работает с изображением в шкале $[0, 1]$, а ε и α задаются в единицах $1/255$.
3. Градиент по входу вычисляйте функцией `torch.autograd.grad` [4]: она не накапливает градиенты в параметрах модели.
4. Атакуйте модель в режиме оценки (`model.eval()`), её параметры не должны измениться. Записывайте в паспорт запуска ε, α, K, R, наличие случайного старта и способ нормализации.

Что должно получиться. Функция `attack(model, x, y, cfg)` возвращает состязательные примеры и нормы их возмущений.

Как проверить себя. Для всех примеров $\|\delta\|_\infty \le \varepsilon$ и $x_{\text{adv}} \in [0, 1]^d$, а при $\varepsilon = 0$ атака возвращает исходное изображение (тест 5).

8.4 Задание 4. Отказ от предсказания и обнаружение данных вне распределения

Что сделать.

1. Реализуйте обёртку `prediction, accepted = predictor(x, threshold)` с порогом по любой мере (8.7). Реализуйте функции `risk_coverage(U, correct)` и `aurc(U, correct)` по формулам (8.11) и (8.12). При нулевом покрытии риск возвращается как `None`.
2. Реализуйте оценщик обнаружения OOD: AUROC, AUPR, FPR@95 (8.13) и гистограммы меры для ID и OOD. Он принимает только значения меры и двоичный флаг OOD, без меток классов.
3. Для каждой модели постройте кривые «риск — покрытие» трёх мер на чистом `test`. Вычислите AUROC трёх мер на далёком OOD-наборе.
4. Соберите для каждой контрольной точки профиль надёжности `reliability.json` с разделами `clean`, `corruption`, `adversarial`, `selective`, `ood` и `undefined`. Последний перечисляет невычисленные комбинации «метрика, данные» и причину, например `"ece on svhn: no true class"`.

Что должно получиться. Профиль надёжности каждой модели, в котором рядом с числами перечислено, что не определено.

Что добавляется в общий проект. Модули `src/reliability/` (`calibration.py`, `uncertainty.py`, `selective.py`, `ood.py`, `metrics.py`), `src/corruptions/image.py`, `src/attacks/` (`fgsm.py`, `pgd.py`) и `src/analysis/reliability_profile.py`; для дополнительного задания 1 — `src/reliability/conformal.py`. Этими модулями пользуются в ЛР9.

Как проверить себя. При покрытии 100% риск равен доле ошибок, а AURC оракульного порядка не больше AURC любой меры (тест 6).

9 Эксперименты

Перед экспериментом запишите гипотезу со ссылкой на формулу раздела 5. E1 и E3 — поисковые: хватает одного seed. Главный вывод проверяется в E2 на трёх seeds. Если результат разошёлся с предсказанием, укажите, какое предположение не выполнилось.

9.1 Эксперимент E1. Калибровка и температура

Вопрос. Совпадает ли порядок моделей по точности и по калибровке? Что меняет температурное масштабирование?

Что сделать. Возьмите обе модели ЛР2. На чистом `test` вычислите точность, ECE, NLL и оценку Брайера, постройте диаграммы надёжности и гистограммы уверенности. Подберите $T^\star$ на `val` по формуле (8.6) и повторите измерения. Сведите значения до и после масштабирования в одну таблицу. Сравните предсказанные классы до и после для каждого объекта.

Порог приёмки.

- Предсказанные классы до и после масштабирования совпадают у 100% объектов, разность точностей равна нулю. Это следует из (8.6).
- NLL на `val` при $T^\star$ не больше, чем при $T = 1$: значение $T = 1$ входит в область поиска.
- Для каждого значения ECE указаны M, тип интервалов и число пустых интервалов. Если ECE на `test` выросла, причина объяснена.

Граница применимости. Пересчитайте ECE до и после масштабирования при $M = 5$, $M = 50$ и для интервалов с равным числом объектов. Сохраняется ли вывод E1? Если изменение от смены схемы сравнимо с эффектом температуры, вывод зависит от способа измерения.

9.2 Эксперимент E2. Калибровка при сдвиге распределения

Вопрос. Переносится ли температура, подобранная на чистых данных, на искажённые изображения?

Что сделать. Возьмите архитектуру из профиля. Для каждого типа искажения и каждой силы $\ell = 0, \dots, 5$ вычислите на `test` точность, среднюю уверенность, ECE и NLL. Сделайте это дважды: при $T = 1$ и при $T^\star$ с чистой `val`. Постройте графики

от силы искажения. Отметьте режимы, где точность падает, а уверенность почти не меняется или растёт [11].

Основное сравнение. Выигрыш температуры $g = \mathrm{ECE}_{T=1} - \mathrm{ECE}_{T^\star}$ показывает, насколько она уменьшает ECE. Условие A — чистый `test`. Условие B — искажение из профиля силы $\ell = 5$. $T^\star$ подобрана только на чистой `val` и одна и та же в обоих условиях. До запусков запишите в `hypothesis.md`, что меняется, что зафиксировано и какой результат опровергнет гипотезу. Зафиксируйте файл в Git. Ожидание: на чистых данных g больше [11].

Возьмите три контрольные точки архитектуры из профиля, seeds $s = 1, 2, 3$. Для каждой подберите свою $T^\star$ на чистой `val`. Если точка одна, разделите `test` на три части по единице анализа и укажите замену. Парные разности:

$$\Delta_s = g_{\mathrm{A}}(s) - g_{\mathrm{B}}(s), \qquad \bar{\Delta} = \frac{1}{3}\sum_{s=1}^{3} \Delta_s, \qquad s_\Delta = \sqrt{\frac{1}{2}\sum_{s=1}^{3}(\Delta_s - \bar{\Delta})^2}, \tag{8.14}$$

где $g_{\mathrm{A}}(s)$ и $g_{\mathrm{B}}(s)$ — выигрыш g в условиях A и B для seed s. $\bar{\Delta}$ — средняя разность, s_Δ — её стандартное отклонение.

Порог приёмки.

- Вывод «на чистых данных температура помогает сильнее» установлен, если все три Δ_s положительны и $\bar{\Delta} \geq 2s_\Delta$. Если все три отрицательны и $|\bar{\Delta}| \geq 2s_\Delta$, установлен обратный вывод. Иначе напишите «различие переноса не установлено». Приведите все три Δ_s, а также g_{A} и g_{B}.
- При $\ell = 0$ метрики совпадают с E1 с точностью 10^{-6}.
- Для каждого типа и силы приведены ECE и NLL при $T = 1$ и при $T^\star$, в одной схеме ECE.

Граница применимости. Найдите наименьшую силу, при которой $g \leq 0$, или укажите, что такой силы нет. Подберите T_5 на `val` с тем же искажением силы 5 и сравните её с $T^\star$. Для заранее неизвестного сдвига T_5 подобрать нельзя: части `val` с будущим искажением ещё нет.

9.3 Эксперимент E3. Атаки FGSM и PGD

Вопрос. Насколько одношаговая атака недооценивает уязвимость модели по сравнению с многошаговой?

Что сделать. Возьмите обе модели и одну подвыборку `test` для всех атак. Для FGSM постройте график точности и средней уверенности от $\varepsilon \in \{0, 1, 2, 4, 8\}/255$. При ε из профиля выполните PGD: $K = 10$ шагов, $\alpha = 2{,}5\,\varepsilon/K$, случайный старт. Нанесите точность при PGD на тот же график. Покажите несколько примеров: исходное изображение, состязательный пример и увеличенное возмущение δ с его нормой $\|\delta\|_\infty$.

Порог приёмки.

- Для всех состязательных примеров $\|\delta\|_\infty \leq \varepsilon + 10^{-6}$ и $x_{\mathrm{adv}} \in [0, 1]^d$.
- При $\varepsilon = 0$ точность совпадает с точностью на чистой подвыборке.
- При ε из профиля точность при PGD не выше, чем при FGSM. Если это не так, найдена и описана ошибка реализации.

Граница применимости. FGSM использует линейное приближение и даёт грубую оценку. Повторите PGD с 20 шагами и двумя стартами. Если точность снизилась ещё, 10 шагов было мало [17]. Какой вывод можно сделать по точности при атаке, а какой нельзя?

10 Контрфактические вопросы

Ответ опирается на ваши числа со ссылками на `RUN_ID`. Если для ответа нужен дополнительный запуск, выполните его.

1. Может ли температура уменьшить ECE на `test` и одновременно увеличить NLL или оценку Брайера? Найдите это в E1 или объясните, почему так не вышло. Почему NLL на `val` вырасти не может?
2. Примените температуру T_5 из E2 к искажённому и к чистому `test`. Что выигрывается на искажённых данных и что теряется на чистых?
3. Замените в E3 состязательное возмущение случайным $\delta = \varepsilon \operatorname{sign}(u)$, где u — гауссов шум; норма $\|\delta\|_\infty$ та же. Предскажите изменение точности и проверьте одним запуском. Почему направление возмущения важнее его величины?
4. Исправит ли температура уверенные ошибки на состязательных примерах? Вычислите среднюю уверенность и ECE на примерах FGSM при ε из профиля для $T = 1$ и для $T^\star$.
5. Температура не меняет предсказанный класс. Может ли она изменить AURC и AUROC меры U_{MSP}? Сравните значения для $T = 1$ и $T^\star$ по своим данным и объясните результат.

11 Обязательные тесты

1. Вероятности после softmax в сумме равны 1. При $T = 1$ вероятности не меняются, при любом $T > 0$ предсказанный класс не меняется.
2. Синтетическая выборка из 10^5 объектов: уверенность равномерна на $[0{,}2;\ 1]$, ответ верен с вероятностью, равной уверенности. Для неё ECE $\leq 0{,}01$ при $M = 15$. Если вероятность верного ответа на 0,1 меньше уверенности, ECE отличается от 0,1 не более чем на 0,01.
3. Калибратор отклоняет объекты не из `val`. Оценщик отказывается считать точность, ECE и NLL на выборке с флагом OOD. Оценщик обнаружения OOD не принимает метки классов.
4. Искажение силы 0 возвращает исходное изображение. Искажения сохраняют размер и метку, при одном seed результат одинаков.
5. После FGSM и после каждого шага PGD $\|\delta\|_\infty \leq \varepsilon$ и $x_{\mathrm{adv}} \in [0, 1]^d$. Случайный старт лежит внутри шара. Атака не меняет параметры модели и не переводит её в режим обучения.
6. При покрытии 100% риск равен доле ошибок, при нулевом возвращается отсутствующее значение. AURC оракульного порядка не больше AURC любой меры. AUROC не меняется при строго возрастающем преобразовании меры.

12 Что сдать

Сдаются модули заданий 1–4, конфигурации E1–E3, файл `hypothesis.md`, тесты, профили надёжности `reliability.json` и отчёт. Отчёт состоит из шести частей:

1. **Профиль и протокол:** модели ЛР2 и их `RUN_ID`, роли данных, схема ECE, значения $T^\star$, параметры искажений и атак.
2. **E1:** таблица метрик до и после масштабирования, диаграммы надёжности, выводы.
3. **E2:** графики по силе искажения, гипотеза, все три Δ_s, вывод, граница применимости.
4. **E3:** график точности от ε для FGSM и PGD, примеры возмущений, выводы.
5. **Профиль надёжности:** кривые «риск — покрытие», AUROC, перечень неопределённых комбинаций, ограничения работы.
6. **Ответы на контрфактические вопросы.**

Каждое число сопровождается ссылкой на `RUN_ID`. Графики строятся автоматически из сохранённых результатов. В подписях графиков указываются схема ECE, $T^\star$ и параметры атаки.

13 Критерии завершения и оценивания

Работа завершена, если одновременно:

- эксперименты E1–E3 выполнены, у каждого результата есть `RUN_ID`;
- тесты проходят;
- файл `hypothesis.md` зафиксирован в Git до запусков основного сравнения E2;
- схема ECE, $T^\star$ с частью данных и параметры атак записаны в итоговой конфигурации, профиль надёжности содержит поле `undefined`;
- на все контрфактические вопросы даны ответы с собственными числами.

Веса частей оценки те же, что в ЛР0: реализация 0,15, экспериментальный протокол 0,30, диагностика 0,30, перенос 0,25.

14 Дополнительные задания

1. **Конформное предсказание** (conformal prediction) [20]. Оно выдаёт множество классов $\Gamma(x)$, которое содержит верный класс с вероятностью не меньше $1-\alpha_{\text{ср}}$. На части `cal` из n объектов вычислите меры несоответствия $r_i = 1 - p_{y_i}(x_i)$ и порог с поправкой на конечную выборку:

$$k = \lceil (n+1)(1-\alpha_{\text{ср}}) \rceil, \qquad \hat{q} = r_{(k)}, \qquad \Gamma(x) = \{ c : 1 - p_c(x) \le \hat{q} \}, \tag{8.15}$$

   где $r_{(k)}$ — k-е по возрастанию значение r_i. При $k = n+1$ порог $\hat{q} = +\infty$. Для $n = 2000$ и $\alpha_{\text{ср}} = 0{,}1$ получается $k = \lceil 1800{,}9 \rceil = 1801$. Если `cal` и `test` обменяемы, вероятность попадания лежит между $1-\alpha_{\text{ср}}$ и $1-\alpha_{\text{ср}} + 1/(n+1)$. Верхняя граница требует различных r_i. Без округления вверх может нарушиться нижняя. Гарантия средняя, не для каждого x. Температуру подбирают на `val` до просмотра `cal`. Проверьте, что `cal` не пересекается с `val` и `test`. На чистом и на искажённом `test`

вычислите долю попаданий и средний размер множества. При сдвиге обменяемость нарушается: падает доля попаданий или растёт размер множества?

2. **Близкий и далёкий OOD.** Для трёх мер вычислите AUROC, AUPR и FPR@95 на близком и далёком OOD-наборах. Найдите долю OOD-объектов с уверенностью выше 0,9. Высокий AUROC на далёком OOD не гарантирует обнаружения близкого [23]. Подтверждается ли это на ваших данных? Для кадров лиц учтите, что близкий набор — сдвиг домена, а не новые классы.

3. **Ансамбль.** Усредните вероятности трёх контрольных точек из E2: $\bar{p}(x) = \frac{1}{3}\sum_{s=1}^{3} p^{(s)}(x)$, где $p^{(s)}$ — вероятности модели с seed s [24]. Сравните ансамбль с одиночной моделью по ECE, NLL, AURC и AUROC на чистых и искажённых данных. Расхождение моделей ансамбля отражает незнание модели [2, разд. 7.11]. Почему ансамбль всё же не является точным байесовским выводом [1, разд. 10.5]?

15 Контрольные вопросы

1. Чем калибровка отличается от точности? Может ли откалиброванная модель иметь низкую точность?
2. Почему ECE зависит от числа и типа интервалов?
3. Что измеряют NLL и оценка Брайера и почему они зависят не только от калибровки?
4. Почему температурное масштабирование не меняет предсказанный класс?
5. Чем сдвиг входного распределения отличается от семантического сдвига? Какие метрики определены в каждом случае?
6. Почему FGSM основан на линейном приближении? Зачем PGD проецирует точку на пересечение шара и куба $[0, 1]^d$?
7. Когда риск при отказе от предсказания не определён? Что показывает AUROC?
8. Зачем в конформном предсказании поправка $(n + 1)$ и какие предположения дают гарантию покрытия?

16 Итог

После ЛР8 модель описывают профилем надёжности. В нём калибровка, поведение при искажениях, устойчивость к атакам и качество мер неопределённости. Для каждой величины указано, где она не определена. По профилю видно, когда предсказанию можно доверять. Высокая уверенность — ещё не свидетельство правильного ответа.

Литература

[1] Николенко С., Кадурин А., Архангельская Е. Глубокое обучение. Погружение в мир нейронных сетей. — СПб.: Питер, 2018. — 480 с.

[2] Гудфеллоу Я., Бенджио И., Курвилль А. Глубокое обучение / пер. с англ. А. А. Слинкина. — 2-е изд., испр. — М.: ДМК Пресс, 2018. — 652 с.

[3] PyTorch Tutorials: Adversarial Example Generation. https://docs.pytorch.org/tutorials/beginner/fgsm_tutorial.html

[4] PyTorch Documentation: torch.autograd.grad. https://docs.pytorch.org/docs/stable/generated/torch.autograd.grad.html

[5] PyTorch Documentation: torchvision.transforms. https://docs.pytorch.org/vision/stable/transforms.html

[6] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger. On Calibration of Modern Neural Networks. *ICML*, 2017.

[7] M. P. Naeini, G. F. Cooper, M. Hauskrecht. Obtaining Well Calibrated Probabilities Using Bayesian Binning. *AAAI*, 2015.

[8] J. Nixon, M. Dusenberry, L. Zhang et al. Measuring Calibration in Deep Learning. *CVPR Workshops*, 2019.

[9] G. W. Brier. Verification of Forecasts Expressed in Terms of Probability. *Monthly Weather Review*, 78(1):1–3, 1950.

[10] T. Gneiting, A. E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007.

[11] Y. Ovadia, E. Fertig, J. Ren et al. Can You Trust Your Model's Uncertainty? Evaluating Predictive Uncertainty under Dataset Shift. *NeurIPS*, 2019.

[12] D. Hendrycks, K. Gimpel. A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks. *ICLR*, 2017.

[13] D. Hendrycks, T. Dietterich. Benchmarking Neural Network Robustness to Common Corruptions and Perturbations. *ICLR*, 2019.

[14] C. Szegedy, W. Zaremba, I. Sutskever et al. Intriguing Properties of Neural Networks. *ICLR*, 2014.

[15] I. J. Goodfellow, J. Shlens, C. Szegedy. Explaining and Harnessing Adversarial Examples. *ICLR*, 2015.

[16] A. Madry, A. Makelov, L. Schmidt et al. Towards Deep Learning Models Resistant to Adversarial Attacks. *ICLR*, 2018.

[17] F. Croce, M. Hein. Reliable Evaluation of Adversarial Robustness with an Ensemble of Diverse Parameter-Free Attacks. *ICML*, 2020.

[18] Y. Geifman, R. El-Yaniv. Selective Classification for Deep Neural Networks. *NeurIPS*, 2017.

[19] Y. Geifman, G. Uziel, R. El-Yaniv. Bias-Reduced Uncertainty Estimation for Deep Neural Classifiers. *ICLR*, 2019.

[20] A. N. Angelopoulos, S. Bates. Conformal Prediction: A Gentle Introduction. *Foundations and Trends in Machine Learning*, 16(4):494–591, 2023.

[21] A. Krizhevsky. Learning Multiple Layers of Features from Tiny Images. Technical report, University of Toronto, 2009.

[22] Y. Netzer, T. Wang, A. Coates et al. Reading Digits in Natural Images with Unsupervised Feature Learning. *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.

[23] S. Fort, J. Ren, B. Lakshminarayanan. Exploring the Limits of Out-of-Distribution Detection. *NeurIPS*, 2021.

[24] B. Lakshminarayanan, A. Pritzel, C. Blundell. Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles. *NeurIPS*, 2017.