Лабораторная работа 9

Multimodal Representation Learning

Audio-visual emotion recognition: fusion, missing modalities и modality reliability

Курс «Нейронные сети»

Редакция 4 от 8 октября 2026 г.

1 Введение

Модель с несколькими источниками данных называют *мультимодальной* (multimodal). Каждый источник — *модальность*. Здесь их две: видео лица и аудио речи. Задача — узнать эмоцию короткого клипа.

Соединить признаки нетрудно. Трудно доказать, что модель пользуется обеими модальностями. Пусть по видео macro-F1 равен 0,60, а по видео и аудио — 0,62. Прирост 0,02 может дать новая информация, большее число параметров или разброс между seeds. Модель сравнивают с одномодальными, с контролем того же размера и на трёх seeds. Вклад измеряют вмешательством в ту же модель: аудио убирают или подменяют чужим.

Вторая тема — отказ модальности: микрофон молчит, запись зашумлена или лицо и голос спорят. Для каждого случая определены не все метрики.

Эксперименты идут в проекте из ЛР0: у запуска есть `EXP_ID`, `RUN_ID` и паспорт. Числа отчёта ссылаются на `RUN_ID`. Кодировщики кадров — из ЛР2 или ЛР4, искажения видео — из ЛР8.

2 Цель работы

Цель — построить модель эмоции по лицу и речи и сравнить способы объединения модальностей. Вмешательствами нужно установить, как модель использует каждую модальность: при полных данных, при пропуске и при конфликте. Итог — ответ, откуда берётся выигрыш и где он пропадает.

Когда модель, объединяющая аудио и видео, действительно использует обе модальности? Что происходит с предсказаниями, если одна модальность пропадает или противоречит другой?

3 Что нужно знать заранее

Если пункт незнаком, восполните пробел по указанному источнику.

- Свёрточные сети и признаки слоёв — [1, разд. 5.2, 5.4], модели ЛР2. Перенос обучения — [2, разд. 15.2].
- Звук: частота дискретизации, спектрограмма, мел-спектрограмма — курс Hugging Face по аудио [5], [2, разд. 12.3], `MelSpectrogram` [3].
- Прореживание (dropout) — [2, разд. 7.12]. На этой идее основано обучение с выпадением модальности.
- Для дополнительных заданий: внимание — [1, разд. 8.1], [4], ЛР3. Калибровка и ECE — ЛР8, [17].
- Проект экспериментов из ЛР0.

4 Результаты обучения

После выполнения работы вы сможете:

1. объяснять признаки кадров лица и лог-мел-спектрограмму и сопоставлять кадры аудио и видео по времени;
2. обучать одномодальные модели как обязательную точку отсчёта;
3. реализовать раннее слияние, позднее слияние и слияние со шлюзом через один интерфейс;
4. отделять выигрыш второй модальности от роста числа параметров и от разброса между seeds;
5. измерять вклад модальности вмешательством в ту же модель;
6. описывать пропуск, искажение и конфликт только теми метриками, которые в этих условиях определены.

5 Модели и обозначения

5.1 Задача и метрика

Клип — запись 3–4 с: актёр произносит фразу с заданной эмоцией. Из клипа берут кадры лица x_v и звук x_a. Метка $y \in \{1, \dots, C\}$ — одна из $C = 8$ эмоций. Модель обрабатывает клип так:

$$\begin{gathered} Z_v = \varphi_v(x_v), \qquad Z_a = \varphi_a(x_a), \qquad z_v = \frac{1}{T_v}\sum_{t=0}^{T_v-1} Z_{v,t}, \qquad z_a = \frac{1}{T_a}\sum_{k=0}^{T_a-1} Z_{a,k}, \\ z_f = F(z_v, z_a), \qquad p = \operatorname{softmax}\big(h(z_f)\big), \qquad \hat{y} = \arg\max_c p_c, \qquad \operatorname{conf} = \max_c p_c, \end{gathered} \tag{9.1}$$

Здесь φ_v и φ_a — кодировщики (encoders) видео и аудио. Строки $Z_v \in \mathbb{R}^{T_v \times d_v}$ и $Z_a \in \mathbb{R}^{T_a \times d_a}$ — признаки кадров. z_v и z_a — представления клипа, средние по времени. F — слияние (fusion), z_f — объединённое представление, h — голова (head) с C выходами. p — вероятности, $\hat{y}$ — класс, conf — уверенность. Позиции дополнения (padding) в средние не входят. Кодировщики заморожены, признаки считают один раз. Обучаются слияние и голова.

Классы несбалансированы. В RAVDESS у нейтрального состояния 96 клипов, у остальных классов — по 192 [6]. Поэтому основная метрика — macro-F1, среднее качество по классам:

$$\mathrm{F1}_c = \frac{2\,\mathrm{TP}_c}{2\,\mathrm{TP}_c + \mathrm{FP}_c + \mathrm{FN}_c}, \qquad M = \frac{1}{C}\sum_{c=1}^{C} \mathrm{F1}_c. \tag{9.2}$$

Здесь TP_c, FP_c, FN_c — верные ответы класса c, ложные срабатывания и пропуски. Если класс ни разу не угадан, $\mathrm{F1}_c = 0$. Редкий класс весит столько же, сколько частый.

Пример. В test 300 клипов: 20 нейтральных и по 40 остальных. Модель верна на семи классах и все нейтральные относит к спокойствию. Accuracy равна $280/300 \approx 0{,}93$. F1 нейтрального класса равен нулю, F1 спокойствия — 0,8, поэтому $M = 0{,}85$. Далее M — macro-F1 на test. Accuracy — вспомогательная метрика. Счёт идёт по клипам, а не по кадрам.

5.2 Признаки кадров лица и мел-спектрограмма

Признаки кадров лица. Частоту кадров понижают до η_v в секунду, по умолчанию $\eta_v = 5$. Каждый кадр идёт в замороженный кодировщик из ЛР2 или ЛР4. Выход слоя перед классификатором — вектор из d_v чисел, например $d_v = 512$ у ResNet-18. Это и есть признаки кадра: похожие лица дают близкие векторы. Клип 3,5 с даёт 18 кадров и матрицу Z_v размера 18×512.

Мел-спектрограмма. Звук — отсчёты давления, в пакете $f_s = 16\,000$ в секунду. Сигнал режут на окна по 25 мс с шагом 10 мс. Преобразование Фурье в окне показывает энергию каждой частоты. Картинку по всем окнам называют спектрограммой: время по горизонтали, частота по вертикали, яркость — энергия.

Слух различает низкие частоты тоньше высоких. Шкала мел (mel) это учитывает. Промежуток 100–200 Гц занимает около 133 мел, а 4000–4100 Гц — около 24 мел. Поэтому частоты объединяют в N_{mel} полос: узких внизу и широких вверху. От энергии полосы берут логарифм. Он сжимает разброс громкости, примерно как слух. Получается лог-мел-спектрограмма (log-mel spectrogram):

$$S_{j,k} = \log\Bigl(\sum_{\omega=1}^{N_\omega} B_{j\omega}\,\bigl|\mathrm{STFT}(x_a)_{\omega,k}\bigr|^2 + \varepsilon_0\Bigr), \qquad T_a = \Bigl\lfloor \frac{L}{n_{\mathrm{hop}}} \Bigr\rfloor + 1, \tag{9.3}$$

Здесь j — номер полосы, k — номер окна. $\mathrm{STFT}(x_a)_{\omega,k}$ — коэффициент Фурье частоты ω в окне k, $N_\omega = n_{\mathrm{fft}}/2 + 1$. $B_{j\omega} \geq 0$ — вес частоты в полосе, n_{fft} — длина окна. L — число отсчётов, n_{hop} — шаг окна, $\varepsilon_0 > 0$ — малая константа. Формула для T_a верна, когда края сигнала дополняют на половину окна. Так делает `torchaudio` при `center=True` [3]. Без дополнения кадров было бы $\lfloor (L - n_{\mathrm{fft}})/n_{\mathrm{hop}} \rfloor + 1$. В работе $N_{\mathrm{mel}} = 64$, $n_{\mathrm{fft}} = 400$ (25 мс), $n_{\mathrm{hop}} = 160$ (10 мс). Клип 3,5 с даёт $L = 56\,000$ и матрицу S размера 64×351. Без дополнения краёв было бы 348 окон.

Аудиокодировщик — свёрточная сеть над S, как над кадром в ЛР2. Если она сжимает время в r раз, шаг признаков — $r\,n_{\mathrm{hop}}$ отсчётов.

Подробнее: [5]; [2, разд. 12.3]; [3].

5.3 Синхронизация аудио и видео

У видео 5 кадров в секунду, у спектрограммы — 100. Соответствие задают моменты времени:

$$\tau_t^v = \frac{t}{\eta_v}, \qquad \tau_k^a = \frac{k\, n_{\text{hop}}}{f_s}, \qquad \mathcal{K}(t) = \Big\{ k : -\frac{\tau_w}{2} \le \tau_k^a - \tau_t^v < \frac{\tau_w}{2} \Big\}. \tag{9.4}$$

Здесь $t = 0, \dots, T_v - 1$ — номер видеокадра. τ_t^v и τ_k^a — моменты видеокадра и центра аудиокадра в секундах. $\mathcal{K}(t)$ — аудиокадры, сопоставленные видеокадру t. Ширина окна τ_w по умолчанию равна $1/\eta_v$.

При $\eta_v = 5$ окно длится 200 мс, то есть 20 шагов спектрограммы. Окно полуоткрытое: граничный кадр не попадает в два окна. Сравнивайте моменты в целых отсчётах. Закрытое сравнение $|\tau_k^a - \tau_t^v| \le \tau_w/2$ в секундах даёт сбои: аудиокадр 10 попадает в два окна, а аудиокадр 150 — ни в одно. На уровне клипа признаки усредняют, и выравнивание почти не меняет M. Оно нужно для проверки данных и дополнительных заданий.

5.4 Стратегии слияния

Стратегии различаются этапом объединения модальностей [7].

Раннее слияние (early fusion) соединяет признаки до классификатора:

$$z_f = [z_v; z_a] \in \mathbb{R}^{d_v + d_a}, \qquad p = \operatorname{softmax}\big(h(z_f)\big). \tag{9.5}$$

При линейной голове $h(z_f) = H_v z_v + H_a z_a + b$: H_v и H_a — части матрицы весов, b — смещение. Вклады складываются и не взаимодействуют. Взаимодействие даёт только нелинейная голова [8].

Позднее слияние (late fusion) усредняет вероятности двух одномодальных моделей:

$$p_f = \lambda\, p_{\text{V}} + (1 - \lambda)\, p_{\text{A}}, \qquad \lambda \in [0, 1]. \tag{9.6}$$

p_{V} и p_{A} — вероятности по видео и по аудио, λ — вес видео. Обязателен $\lambda = 1/2$; допускается λ с val. Общих параметров нет: это эталон без взаимодействия. Пусть видео даёт 0,9 классу «гнев», а аудио — 0,9 классу «радость». При $\lambda = 1/2$ каждый класс получит 0,45, и уверенность падает сама.

Слияние со шлюзом (gated fusion) для каждого клипа решает, какой модальности доверять [9]:

$$\begin{gathered} u_v = \tanh(W_v z_v), \quad u_a = \tanh(W_a z_a), \\ g = \sigma\big(W_g [z_v; z_a] + b_g\big), \quad z_f = g \odot u_v + (1 - g) \odot u_a. \end{gathered} \tag{9.7}$$

$W_v \in \mathbb{R}^{d \times d_v}$ и $W_a \in \mathbb{R}^{d \times d_a}$ проецируют признаки в общее пространство размерности d. σ — логистическая функция, $\odot$ — поэлементное умножение. $W_g \in \mathbb{R}^{d \times (d_v + d_a)}$ и b_g задают шлюз (gate) $g \in (0, 1)^d$. Скалярный шлюз — одно число на клип, тогда W_g — строка. Соглашение: $g \to 1$ — видео, $g \to 0$ — аудио. Среднее $\bar{g}$ показывает наклон модели. Обучение на чистых данных не гарантирует реакцию шлюза на испорченную модальность.

Подробнее: [7, 9, 8].

5.5 Выигрыш от слияния и контроль числа параметров

Высокое качество объединённой модели само по себе ничего не доказывает. Его сравнивают с лучшей одномодальной моделью и с двумя контролями:

$$G = M_{\mathrm{AV}} - \max(M_{\mathrm{A}}, M_{\mathrm{V}}), \qquad G_{\mathrm{ctrl}} = M_{\mathrm{AV}} - \max(M_{\mathrm{A}}^{+}, M_{\mathrm{V}}^{+}), \qquad G_{\mathrm{int}} = M_{\mathrm{AV}} - M_{\mathrm{late}}. \tag{9.8}$$

Здесь M_{AV}, M_{A}, M_{V} и M_{late} — macro-F1 объединённой модели, моделей по аудио и по видео и позднего слияния. M_{A}^{+} и M_{V}^{+} — одномодальные модели с увеличенной головой. Обучаемых параметров у них столько же, сколько у слияния и головы объединённой модели. Это контроль с тем же числом параметров (parameter-matched control). Число обучаемых параметров модели m обозначается $|\theta_m|$. Замороженные кодировщики в него не входят.

Если $G > 0$, но $G_{\mathrm{ctrl}} \leq 0$, выигрыш дала ёмкость, а не вторая модальность. Взаимодействие есть, только если $G_{\mathrm{int}} > 0$ при сопоставимом числе параметров [8].

5.6 Вклад модальности: вмешательство в ту же модель

Разность $M_{\mathrm{AV}} - M_{\mathrm{V}}$ двух разных моделей не измеряет вклад аудио. В неё входят различия обучения и числа параметров. Она не равна нулю, даже если объединённая модель аудио игнорирует. Вклад измеряют вмешательством в одну модель:

$$R_a = M_{\mathrm{AV}} - M_{\mathrm{AV}}^{(-a)}, \qquad \tilde{R}_a = \frac{R_a}{M_{\mathrm{AV}} - M_0}, \qquad \delta_a(x) = \left\| p(x) - p^{(-a)}(x) \right\|_1. \tag{9.9}$$

Здесь $M_{\mathrm{AV}}^{(-a)}$ — macro-F1 той же модели без аудио. M_0 — macro-F1 предсказателя, который всегда выдаёт самый частый класс. На test пакета $M_0 \approx 0{,}03$. Вероятности $p(x)$ и $p^{(-a)}(x)$ получены на клипе x без вмешательства и с ним. Норма $\|\cdot\|_1$ — сумма модулей разностей по классам. Так же задают R_v, $\tilde{R}_v$ и $\delta_v(x)$ для видео.

R_a — потеря качества без аудио, $\tilde{R}_a$ — её доля сверх тривиального уровня. Если модель не зависит от аудио, то $\delta_a(x) = 0$ и $R_a = 0$ на любом клипе. Это проверяет тест.

Второе вмешательство — перемешивание (shuffle): аудио клипа i заменяют аудио клипа $\pi(i)$. У перестановки π нет неподвижных точек. Изменение вероятностей считают по (9.9) с $p^{(\pi)}(x)$ вместо $p^{(-a)}(x)$. Близкое к нулю изменение значит, что модель почти не использует аудио. Маскирование подаёт необычный вход, перемешивание — чужое настоящее аудио, поэтому оценки могут различаться. Обе зависят от заменителя и от того, видела ли модель пропуск при обучении.

5.7 Пропуск и искажение модальности

Пропуск задают маской на представлениях клипа:

$$\tilde{z}_a = m_a z_a + (1 - m_a)\, e_a, \qquad \tilde{z}_v = m_v z_v + (1 - m_v)\, e_v, \qquad m_a + m_v \geq 1, \tag{9.10}$$

где $m_a, m_v \in \{0, 1\}$ — маски присутствия, e_a и e_v — векторы-заменители (null token), нулевые или обучаемые. Пропуск обеих модальностей запрещён: поведение без входа не определено.

Нулевой вектор необычен для модели, обученной только на полных парах. Падение M при $m_a = 0$ смешивает потерю информации с реакцией на незнакомый вход. Разделить их помогает выпадение модальности (modality dropout) [10, 11]. Маска клипа случайна:

$$\Pr(m_v = 1, m_a = 1) = 1 - p_{\mathrm{drop}}, \qquad \Pr(m_v = 0, m_a = 1) = \Pr(m_v = 1, m_a = 0) = \frac{p_{\mathrm{drop}}}{2}. \tag{9.11}$$

Здесь p_{drop} — вероятность выпадения. Это прореживание, применённое к модальности целиком. В позднем слиянии пропуск прост: берут вероятности оставшейся модели, то есть $\lambda = 1$ или $\lambda = 0$.

Чаще модальность не пропадает, а портится. Шум к аудио добавляют с заданным отношением сигнал/шум (signal-to-noise ratio) в децибелах:

$$x'_a = x_a + \gamma\,\xi, \qquad \gamma = \sqrt{\frac{\sum_{\ell=1}^{L} x_{a,\ell}^2}{10^{\text{SNR}/10}\,\sum_{\ell=1}^{L} \xi_\ell^2}}, \tag{9.12}$$

где ξ — шум той же длины, белый или записанный фоновый. $x_{a,\ell}$ и ξ_ℓ — отсчёты с номером ℓ. При таком γ отношение мощностей равно заданному SNR. При 20 дБ сигнал в 100 раз мощнее шума, при 0 дБ мощности равны. При -5 дБ шум мощнее примерно в 3,2 раза. Для видео берут искажения ЛР8: размытие и пропуск кадров [12]. Уровень 0 — чистые данные. Метка при искажении не меняется.

Подробнее: [10, 11]; [2, разд. 7.12].

5.8 Конфликтующие пары

Возьмём видео v_i клипа i и аудио a_j клипа j другого актёра. Если эмоции совпадают, правильный ответ известен. Иначе его нет: какая эмоция у пары «гневное лицо, радостный голос»? Поэтому три протокола имеют явно заданную цель:

(а) $y_i = y_j$: цель — метка y_i, macro-F1 и accuracy определены;

(б) $y_i \neq y_j$: правильного ответа нет, поэтому accuracy, macro-F1, ECE и риск выборочного предсказания не считают; измеряют, за какой модальностью следует модель, её уверенность и значение шлюза;

(в) обнаружение рассогласования: бинарная задача «различаются ли метки», качество показателя оценивают по AUROC.

Для пар протокола (б):

$$r_v = \frac{1}{|\Pi|}\sum_{(i,j)\in\Pi} \mathbf{1}\big(\hat{y}_{ij} = y_i\big), \qquad r_a = \frac{1}{|\Pi|}\sum_{(i,j)\in\Pi} \mathbf{1}\big(\hat{y}_{ij} = y_j\big), \qquad r_0 = 1 - r_v - r_a,$$
$$\delta_{ij} = \big\|p(v_i, a_j) - p(v_i, a_i)\big\|_1. \tag{9.13}$$

Здесь Π — пары протокола (б), $\hat{y}_{ij}$ — класс пары (v_i, a_j), $\mathbf{1}(\cdot)$ — индикатор. Доли r_v, r_a и r_0 показывают, как часто модель следует за видео, за аудио или ни за одной модальностью. δ_{ij} показывает, насколько изменились вероятности от замены своего аудио на чужое.

Высокая уверенность на парах (б) не доказывает плохую калибровку: событие «предсказание верно» не определено. В протоколе (в) AUROC — вероятность, что пара с разными метками получит больший показатель, чем пара с одинаковыми. Значение 0,5 — уровень угадывания. Показатели — $1 - \text{conf}$ и δ_a.

5.9 Сводка обозначений

Обозначение	Смысл
x_v, x_a, y, C	кадры, звук, метка, число классов
Z_v, Z_a, z_v, z_a, z_f, p, conf	признаки кадров, представления, вероятности, уверенность
M, M_0, G, G_{ctrl}, G_{int}	macro-F1, тривиальный уровень, выигрыши от слияния
S, N_{mel}, n_{hop}, f_s, η_v	спектрограмма, полосы, шаг окна, частоты кадров
$\mathcal{K}(t)$, τ_w, λ, g, $\bar{g}$	окно выравнивания, вес позднего слияния, шлюз
R_a, $\tilde{R}_a$, δ_a, m_a, p_{drop}	вклад аудио, маска, вероятность выпадения
r_v, r_a, r_0, δ_{ij}, $\lvert\theta_m\rvert$	доли следования, эффект замены аудио, число параметров

6 Данные и оборудование

По умолчанию это речевые клипы RAVDESS [6]: 24 актёра, 8 эмоций, 1440 клипов. В пакете есть кадры лиц 224×224 с частотой 10 кадров в секунду и аудио тех же клипов: 16 кГц, моно. Аудио и кадры одного клипа связаны только через `clip_id`.

Разбиение сделано по актёрам: иначе модель может узнавать манеру актёра, а не эмоцию. По умолчанию train — 14 актёров (840 клипов), val — 3 (180), cal — 2 (120), test — 5 (300). Разбиение наследуется из ЛР2. На val выбирают гиперпараметры, λ и момент остановки. Test служит только для итоговых чисел. Часть cal в этой работе не читают: она нужна конформному предсказанию ЛР8. Статистики нормализации считают только по train.

Оборудование. Модели обучают на заранее извлечённых признаках, и для этого достаточно процессора. Однократное извлечение признаков кадров быстрее на видеокарте. Без неё выполните его на процессоре один раз и сохраните признаки на диск.

7 Индивидуальный профиль

Как в ЛР1, параметры задаёт функция `lab_pick`. Добавьте три поля:

```
profile["lab9_visual_encoder"] = lab_pick(
    sid, 9, 0, 2, ["cnn_lab2", "vit_lab2", "ssl_lab4"])
profile["lab9_encoder"] = lab_pick(sid, 9, 0, 2, ["resnet18", "vit_small"])
profile["lab9_p_drop"] = lab_pick(sid, 9, 2, 4, [0.1, 0.3, 0.5])
profile["lab9_gate"] = lab_pick(sid, 9, 4, 6, ["vector", "scalar"])
```

Здесь `sid` — номер зачётки. Профиль задаёт кодировщик кадров, вероятность p_{drop} для E2 и тип шлюза в (9.7). Кодировщик — свёрточная сеть или ViT из ЛР2 либо кодировщик без разметки из ЛР4. Смена профиля меняет конфигурацию, а не код.

8 Задания

8.1 Задание 1. Единый интерфейс модальностей и синхронизация

Что сделать.

1. Понизьте частоту кадров до $\eta_v = 5$. Пропустите кадры через замороженный кодировщик профиля и сохраните Z_v с ключом `clip_id`. Кадры с `face_found=false` пропускайте.
2. Вычислите лог-мел-спектрограммы (9.3). Обучите над ними свёрточную сеть на train с остановкой по val. Заморозьте её и сохраните Z_a.
3. Сделайте единый вызов: обе модальности и явная маска (9.10).

```
Z_v = visual_cache[clip_id]     # [T_v, d_v]
Z_a = audio_cache[clip_id]      # [T_a, d_a]
p = model(visual=Z_v, audio=Z_a, mask=(m_v, m_a), align=meta)
```

   Пропуск передаётся маской, а не подменой тензора снаружи. Вид вектора-заменителя задаёт конфигурация.
4. Реализуйте синхронизацию (9.4): моменты, окна $\mathcal{K}(t)$, маски дополнения и сдвиг аудио. Сравнивайте моменты в целых отсчётах.
5. В паспорт запуска пишите η_v, f_s, n_{hop}, r, τ_w, смещение `av_offset_ms` и хеши контрольных точек кодировщиков.

Что должно получиться. Для любого клипа одним вызовом получаются признаки обеих модальностей, маски и окна. Все модели вызываются одинаково.

Как проверить себя. Аудио и кадры примера относятся к одному клипу. Окна не пересекаются и не оставляют пропусков. Маска не меняет присутствующую модальность (тесты 1–3).

8.2 Задание 2. Стратегии слияния: раннее, позднее, со шлюзом

Что сделать.

1. Реализуйте реестр: модели по видео и по аудио, раннее (9.5), позднее (9.6) и со шлюзом (9.7). Голова — сеть с одним скрытым слоем. Ширину слоя задаёт конфигурация.
2. Реестр пишет $|\theta_m|$ каждой модели, отдельно для слияния и для головы.
3. Сделайте одномодальный контроль: голову над одной модальностью с шириной под $|\theta_m|$ объединённой модели. Шаг ширины меняет число параметров на $d_v + C + 1$ или на $d_a + C + 1$. Добейтесь совпадения до 1%. Если шаг крупнее, возьмите ближайшую ширину и укажите расхождение.
4. Позднее слияние берёт сохранённые вероятности одномодальных моделей. Вес λ подберите на val по сетке $\{0; 0{,}1; \ldots; 1\}$. Вариант $\lambda = 1/2$ сохраняйте всегда.
5. Для шлюза сохраняйте $g(x)$ каждого клипа: $\bar{g}$, разброс, средние по классам, отдельно для верных и ошибочных ответов.

Что должно получиться. Модель получается сменой строки конфигурации. В `summary.json` есть macro-F1, accuracy, $|\theta_m|$ и сводка шлюза.

Как проверить себя. При $g \equiv 1$ и $g \equiv 0$ шлюз совпадает с видео- и аудиоветвью. При $\lambda = 1$ и $\lambda = 0$ позднее слияние воспроизводит одномодальные модели (тест 4).

8.3 Задание 3. Искажение модальностей и вклад каждой модальности

Что сделать.

1. Реализуйте шум по (9.12) и маскирование участков спектрограммы по времени [13]. Подключите размытие и пропуск кадров из ЛР8. Уровень 0 — чистые данные. При фиксированном seed искажения повторяются.
2. Искажения применяйте к сигналу или кадрам, затем заново считайте признаки теми же кодировщиками. Каждый вид и уровень храните отдельно. Пропуск кадров можно сделать маской по готовым признакам.
3. Оценщик вклада для каждого клипа хранит вероятности одной модели: без вмешательства, без аудио, без видео и при перемешивании. Считайте величины (9.9) для обеих модальностей.
4. Вероятности отдельно обученных одномодальных моделей храните с пометкой источника. Не смешивайте их с вмешательствами в одну модель.
5. Оценщик пар из E3 отказывается считать accuracy, macro-F1, ECE и риск на парах протокола (б).

Что должно получиться. Для любой модели одним вызовом строится сводка `fusion_profile` в `summary.json`. В ней число параметров, macro-F1, выигрыши (9.8), вклады (9.9) и доли следования из E3. Поле `undefined` перечисляет метрики, которые здесь не определены, и причину.

Как проверить себя. На модели без зависимости от аудио $\delta_a \equiv 0$ и $R_a = 0$. Измеренный SNR совпадает с заданным до 0,1 дБ (тесты 5 и 6).

Что добавляется в общий проект. Модули `src/multimodal/` (`alignment.py`, `modality_mask.py`, `corruptions.py`, `fusion.py`, `pairs.py`), `src/models/` (`audio_cnn.py`, `multimodal/`) и `src/diagnostics/` (`contribution.py`, `gate_stats.py`). Ими можно разбирать любую модель с несколькими входами.

9 Эксперименты

Перед запуском запишите гипотезу: что меняется, что зафиксировано, ожидаемый знак эффекта и какой результат её опровергнет. Поисковая часть E1, а также E2 и E3, выполняется с одним seed. Главный вывод проверяется в E1 на трёх seeds. Гиперпараметры и λ выбирают на val. Test — только для итоговых чисел. Расхождение с гипотезой допустимо, если указано, какое предположение не выполнилось.

9.1 Эксперимент E1. Одномодальные модели и слияние

Вопрос. Даёт ли объединение аудио и видео выигрыш по macro-F1, который нельзя объяснить ростом числа параметров?

Что сделать.

1. Обучите одномодальные модели, раннее слияние и слияние со шлюзом. Посчитайте позднее слияние при $\lambda = 1/2$ и при λ с val. Запишите macro-F1, accuracy, $|\theta_m|$ и матрицы ошибок.
2. Вычислите G и G_{int} (9.8). Если $|\theta_m|$ различаются более чем вдвое, обсудите это. Для лучшей по val стратегии обучите контроли и вычислите G_{ctrl}.
3. Основное сравнение: F — лучшая стратегия, U — сильнейший по val контроль. До запусков зафиксируйте в Git `hypothesis.md`: чем различаются F и U, что зафиксировано, ожидаемый знак и что опровергнет гипотезу.
4. Обучите F и U с seeds $s = 1, 2, 3$. Seed задаёт инициализацию головы и порядок batch, но не признаки. По macro-F1 на test:

$$\Delta_s = M_{\text{F}}(s) - M_{\text{U}}(s), \qquad \bar{\Delta} = \frac{1}{3}\sum_{s=1}^{3} \Delta_s, \qquad s_\Delta = \sqrt{\frac{1}{2}\sum_{s=1}^{3}(\Delta_s - \bar{\Delta})^2}. \tag{9.14}$$

   $M_{\text{F}}(s)$ и $M_{\text{U}}(s)$ — macro-F1 при seed s, $\bar{\Delta}$ — среднее, s_Δ — стандартное отклонение. Δ_s — это G_{ctrl} при одном seed.
5. Постройте macro-F1 всех моделей с подписью $|\theta_m|$ и три Δ_s.

Порог приёмки. $|\theta|$ моделей F и U совпадает до 1% либо указаны ближайшая ширина и расхождение. Вывод «F и U различаются» установлен, если все три Δ_s одного знака и $|\bar{\Delta}| \geq 2s_\Delta$. При $\bar{\Delta} > 0$ это выигрыш сверх контроля. Иначе пишите «различие не установлено». В отчёте — все три Δ_s и G, G_{int}, G_{ctrl} поисковой части.

Граница применимости. Если $G > 0$, но $G_{\text{ctrl}} \leq 0$, выигрыш дало число параметров. С другими кодировщиками порядок может измениться. Три seeds — одно разбиение, пять актёров test — малая выборка. Укажите это в ограничениях.

9.2 Эксперимент E2. Пропуск модальности

Вопрос. Насколько падает качество, когда пропадает аудио или видео, и помогает ли обучение с выпадением модальности?

Что сделать.

1. Обучите слияние со шлюзом с выпадением (9.11). Вероятность p_{drop} возьмите из профиля. Остальные модели возьмите из поисковой части E1: они обучены на полных парах.
2. На test для каждой модели слияния вычислите M_{AV}, $M_{\text{AV}}^{(-a)}$, $M_{\text{AV}}^{(-v)}$, R_a, R_v, $\tilde{R}_a$ и $\tilde{R}_v$. Вектор-заменитель для всех — нулевой.
3. Сравните $R_v - R_a$ с $M_{\text{V}} - M_{\text{A}}$ из E1. Объясните, почему эти разности не обязаны совпадать.
4. Для шлюза без выпадения сравните маскирование аудио с перемешиванием: среднее $\delta_a(x)$ и долю клипов со сменой класса.
5. Постройте график macro-F1 каждой модели в трёх режимах: полные данные, без аудио, без видео.

Порог приёмки. Для каждой модели и каждой пропущенной модальности приведены M, R и $\tilde{R}$, при одном и том же векторе-заменителе. Для перемешивания указан seed, неподвижных точек нет. Указан наибольший SNR сетки ниже, при котором зашумлённое аудио хуже пропущенного. Если такого уровня нет, это написано явно.

Граница применимости. Пропуск — крайний случай: чаще аудио зашумлено. Для обеих моделей со шлюзом постройте macro-F1 и $\bar{g}$ при SNR $\in \{30, 20, 10, 0, -5\}$ дБ и отметьте уровень «без аудио». С какого шума аудио лучше не подавать? Смещается ли $\bar{g}$ к видео? Молчание шлюза допустимо: он учился на чистых данных.

9.3 Эксперимент E3. Конфликтующие пары

Вопрос. Что делает модель, когда лицо и голос выражают разные эмоции: снижает уверенность или следует за одной модальностью?

Что сделать.

1. Из клипов test по seed сформируйте не менее 200 пар протокола (а) и не менее 200 пар протокола (б). Видео и аудио пары — от разных актёров. Список пар сохраните.
2. Для раннего слияния, шлюза и позднего слияния с $\lambda = 1/2$ вычислите: в (а) — macro-F1 и accuracy по y_i; в (б) — r_v, r_a, r_0, δ_{ij}, conf и $\bar{g}$; в (в) — AUROC по $1 - \text{conf}$ и по δ_a.
3. Для сравнения вычислите conf и $\bar{g}$ на исходных клипах test.
4. Постройте гистограммы conf на исходных клипах, парах (а) и парах (б). Постройте столбцы r_v, r_a, r_0 для каждой модели.

Порог приёмки. Не менее 200 пар протоколов (а) и (б). На парах (б) не считаются accuracy, macro-F1, ECE и риск: запрос вызывает ошибку. Ответ дан через r_v, r_a, r_0, conf и $\bar{g}$. Для протокола (в) приведены AUROC обоих показателей рядом с уровнем 0,5.

Граница применимости. В синтетической паре лицо и голос принадлежат разным людям. Модель может реагировать на чужой голос, а не на другую эмоцию. Пары (а) — контроль: актёры разные, эмоции совпадают. Если уверенность падает на них так же, эффект вызван сменой актёра. Выводы не переносятся на сдержанную эмоцию или иронию.

10 Контрфактические вопросы

Ответ опирается на ваши числа и ссылки на `RUN_ID`. Если нужен ещё один запуск, выполните его.

1. Пусть M_{A} заметно больше M_{V} или наоборот. Обязана ли объединённая модель использовать слабую модальность? Ответьте по своим $\tilde{R}_a$, $\tilde{R}_v$ и средним δ_a, δ_v из E2.
2. Удвойте ширину скрытого слоя одномодального контроля из E1 и обучите его заново. Как изменился G_{ctrl}? Объясняется ли ваш выигрыш G числом параметров?

3. Пусть перемешивание аудио почти не меняет предсказаний. Какой вывод наиболее вероятен и согласуется ли он с вашим R_a? Если оценки маскирования и перемешивания расходятся, объясните почему.
4. Размойте видео на test одним уровнем искажения из ЛР8. Вычислите M_{AV} и $\bar{g}$. Если M_{AV} почти не изменилась, доказывает ли это устойчивость? Как отличить её от игнорирования видео?
5. Обязан ли шлюз уменьшать вес аудио, когда оно становится шумнее? Покажите свою зависимость $\bar{g}$ от SNR из E2. Почему обучение на чистых данных может не научить такой реакции?

11 Обязательные тесты

1. Аудио и кадры примера имеют один `clip_id`; актёры частей не пересекаются; кадры клипа лежат в одной части.
2. Окна (9.4) не пересекаются и не оставляют пропусков; дополнение не входит в средние по времени.
3. При $m_a = 0$ замена аудио случайными признаками не меняет p; присутствующую модальность маска не меняет.
4. При $g \equiv 1$ и $g \equiv 0$ шлюз совпадает с ветвями видео и аудио; при $\lambda = 1$ и $\lambda = 0$ позднее слияние совпадает с одномодальными моделями и даёт нормированные вероятности.
5. На модели без аудио $\delta_a \equiv 0$ и $R_a = 0$; перемешивание — перестановка без неподвижных точек, метки те же.
6. Измеренный SNR совпадает с заданным до 0,1 дБ; уровень 0 возвращает чистые данные; запрос accuracy, macro-F1, ECE или риска на парах (б) вызывает ошибку.

12 Что сдать

Сдаются модули заданий 1–3, конфигурации E1–E3, файл `hypothesis.md`, тесты и отчёт. Отчёт состоит из шести частей:

1. **Профиль и протокол:** кодировщики, p_{drop}, тип шлюза, ширина голов, параметры выравнивания, выбранное λ.
2. **E1:** таблица моделей с macro-F1, accuracy, $|\theta_m|$, G, G_{int}, G_{ctrl}; гипотеза, все Δ_s, вывод.
3. **E2:** таблица M, R, $\tilde{R}$; сравнение маскирования и перемешивания; кривые macro-F1 и $\bar{g}$ от SNR.
4. **E3:** r_v, r_a, r_0, гистограммы conf, $\bar{g}$, AUROC; какие величины не определены на парах (б) и почему.
5. **Ответы на контрфактические вопросы.**
6. **Ограничения:** что не проверено и почему.

Каждое число ссылается на `RUN_ID`. Графики строятся из сохранённых результатов.

13 Критерии завершения и оценивания

Работа завершена, если одновременно:

- эксперименты E1–E3 выполнены и у каждого результата есть `RUN_ID`;
- тесты проходят;
- файл `hypothesis.md` зафиксирован в Git до запусков основного сравнения E1;
- в отчёте по E3 перечислено, какие метрики на парах (б) не определены и почему;
- на все контрфактические вопросы даны ответы с собственными числами.

Веса частей оценки те же, что в ЛР0: реализация 0,15, экспериментальный протокол 0,30, диагностика 0,30, перенос 0,25.

14 Дополнительные задания

1. **Перекрёстное внимание.** Кадры видео обращаются к аудио: запросы — по Z_v, ключи и значения — по Z_a [14].

$$A = \mathrm{softmax}\Big(\frac{Z_v W_Q (Z_a W_K)^\top}{\sqrt{d_k}} + M_{\mathrm{pad}}\Big), \qquad Z_{v\leftarrow a} = A\, Z_a W_V. \tag{9.15}$$

   W_Q, W_K, W_V — проекции, d_k — размерность ключа, softmax — по строкам, $M_{\mathrm{pad}} = -\infty$ на дополнении. Реализация своя, из ЛР3; сверка — `MultiheadAttention` [4]. Замените веса равномерными (энтропия тогда равна 1), обнулите k наибольших с перенормировкой и отключите блок. Сравните macro-F1 и уверенность: сами веса не объясняют решение [15, 16].

2. **Калибровка при пропуске.** Подберите температуру $T^\star$ на val по чистым данным, как в ЛР8 [17]. Примените её при пропуске аудио и при пропуске видео. Сравните ECE и NLL. Переносится ли калибровка на отказ модальности?

3. **Временной сдвиг.** Сдвиньте аудио на -500, -250, 0, 250 и 500 мс, края дополните. Постройте macro-F1 раннего слияния и перекрёстного внимания. Для эмоции клипа малый сдвиг часто безвреден. Если внимание не сдвигается по времени, использует ли модель синхронизацию [18]?

Регрессия. При валентности и возбуждении, например OMG-Emotion [19], повторите E1: ошибка, CCC [20] и $G^{\mathcal{L}} = \min(\mathcal{L}_{\mathrm{A}}, \mathcal{L}_{\mathrm{V}}) - \mathcal{L}_{\mathrm{AV}}$. Дисперсия — у гетероскедастичной головы [21]. ECE к регрессии не применяют.

15 Контрольные вопросы

1. Чем раннее слияние с линейной головой отличается от позднего и от шлюза?
2. Почему $M_{\mathrm{AV}} - M_{\mathrm{V}}$ не измеряет вклад аудио?
3. Зачем в лог-мел-спектрограмме шкала мел и логарифм энергии?
4. Почему кадры аудио и видео сопоставляют по времени, а не по номерам?
5. Чем нулевой вектор вместо аудио отличается от настоящего пропуска?
6. Зачем выпадение модальности и почему маска $(0, 0)$ запрещена?

7. Почему на парах с разными метками не считают accuracy и ECE?
8. Зачем делить данные по актёрам, а не по клипам?

16 Итог

Выигрыш от слияния сравнивают с лучшей одномодальной моделью и с контролем того же размера. Вклад модальности измеряют вмешательством в ту же модель. Пропуск, шум и конфликт описывают только теми метриками, которые определены.

Литература

[1] Николенко С., Кадурин А., Архангельская Е. Глубокое обучение. Погружение в мир нейронных сетей. — СПб.: Питер, 2018. — 480 с.

[2] Гудфеллоу Я., Бенджио И., Курвилль А. Глубокое обучение / пер. с англ. А. А. Слинкина. — 2-е изд., испр. — М.: ДМК Пресс, 2018. — 652 с.

[3] PyTorch Documentation: torchaudio.transforms.MelSpectrogram. https://docs.pytorch.org/audio/stable/generated/torchaudio.transforms.MelSpectrogram.html

[4] PyTorch Documentation: torch.nn.MultiheadAttention. https://docs.pytorch.org/docs/stable/generated/torch.nn.MultiheadAttention.html

[5] Hugging Face Audio Course: Introduction to audio data. https://huggingface.co/learn/audio-course/chapter1/audio_data

[6] S. R. Livingstone, F. A. Russo. The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS). *PLoS ONE*, 13(5), 2018.

[7] T. Baltrušaitis, C. Ahuja, L.-P. Morency. Multimodal Machine Learning: A Survey and Taxonomy. *IEEE TPAMI*, 41(2), 2019.

[8] J. Hessel, L. Lee. Does my multimodal model learn cross-modal interactions? *EMNLP*, 2020.

[9] J. Arevalo, T. Solorio, M. Montes-y-Gómez, F. A. González. Gated Multimodal Units for Information Fusion. *ICLR Workshop*, 2017.

[10] N. Neverova, C. Wolf, G. Taylor, F. Nebout. ModDrop: Adaptive Multi-Modal Gesture Recognition. *IEEE TPAMI* 38(8), 2016.

[11] M. Ma, J. Ren, L. Zhao, D. Testuggine, X. Peng. Are Multimodal Transformers Robust to Missing Modality? *CVPR*, 2022.

[12] D. Hendrycks, T. Dietterich. Benchmarking Neural Network Robustness to Common Corruptions and Perturbations. *ICLR*, 2019.

[13] D. S. Park et al. SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition. *Interspeech*, 2019.

[14] Y.-H. H. Tsai, S. Bai, P. P. Liang et al. Multimodal Transformer for Unaligned Multimodal Language Sequences. *ACL*, 2019.

[15] S. Jain, B. C. Wallace. Attention is not Explanation. *NAACL*, 2019.

[16] S. Wiegreffe, Y. Pinter. Attention is not not Explanation. *EMNLP*, 2019.

[17] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger. On Calibration of Modern Neural Networks. *ICML*, 2017.

[18] A. Owens, A. A. Efros. Audio-Visual Scene Analysis with Self-Supervised Multisensory Features. *ECCV*, 2018.

[19] P. Barros, N. Churamani, E. Lakomkin et al. The OMG-Emotion Behavior Dataset. *IJCNN*, 2018.

[20] L. I-K. Lin. A Concordance Correlation Coefficient to Evaluate Reproducibility. *Biometrics* 45(1), 1989.

[21] A. Kendall, Y. Gal. What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision? *NeurIPS*, 2017.