МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Инженерная школа информационных технологий и робототехники
Направление 09.04.01 «Информатика и вычислительная техника»
Отделение информационных технологий

Лабораторная работа № 2

«Архитектурные inductive biases в компьютерном зрении
CNN vs Vision Transformer: sample efficiency,
augmentation, transfer и distribution shift»

по дисциплине «Нейронные сети»

Выполнил:
студент гр. 8ВМ53 _____ Ван Чжаофу

Проверил:
_____ Григорьев Д. С.

Томск – 2026

Содержание

1 Профиль и протокол 3

2 Ресурсы моделей 4

3 E1. Эффективность по объёму данных 4

4 E2. Искажения тестовых изображений 6

5 E3 и карта относительного преимущества 7

6 Ответы на контрфактические вопросы и выводы 8

Список использованных источников 10

Приложение. Идентификация запусков 11

1. Профиль и протокол

1.1. Цель и теоретические сведения

Цель работы — сравнить индуктивные смещения CNN и ViT при сопоставимом числе параметров, изменении объёма train и искажении test. Методика соответствует заданию [1]. Локальное ядро и общие веса CNN задают предположение о пространственной структуре изображения; ViT получает глобальные связи через внимание и обучаемые позиционные вложения.

Для свёртки с ядром k, каналами C, C' и выходом $H' \times W'$ число MAC равно $H'W'C'Ck^2$. ViT преобразует патчи $P \times P$ в токены ширины D, добавляет CLS и позиционные вложения. Длина последовательности $N' = HW/P^2 + 1$; в каждом из шести pre-LN блоков применяются внимание и MLP с GELU:

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^\top/\sqrt{d_k})V, \quad C_{block} \approx 12N'D^2 + 2N'^2D. \tag{1}$$

Здесь Q, K, V — проекции токенов, d_k — ширина головы. Квадратичный член объясняет чувствительность стоимости к размеру патча.

Основная метрика — accuracy; относительное преимущество и падение при искажении заданы как

$$\Delta(r) = M_{ViT}(r) - M_{CNN}(r), \quad \delta_c(s) = \frac{M_{clean} - M_c(s)}{M_{clean} + 10^{-12}}, \quad \overline{M}_c = \frac{1}{3}\sum_{s=1}^{3} M_c(s). \tag{2}$$

Искажение c и уровень s не меняют метки. Для смены лидера обе разности, на чистом test и по $\overline{M}_c$, должны иметь противоположные знаки и модуль не менее 0.01.

1.2. Данные и условия обучения

Использован CIFAR-10, разбиение ЛР0: train 43 000, val 5 000, cal 2 000, test 10 000. Нормализация рассчитана только по train; cal не используется. Вложенные стратифицированные подмножества заданы профилем P3adf02: $r = 0.05, 0.15, 0.30, 0.60, 1$. Индексы каждого класса один раз перемешаны генератором базового seed. Изменение r только добавляет объекты.

CNN — ResNet-18 со свёрткой stem 3×3, stride 1 и без начального max-pool. ViT имеет $P = 4$, $D = 384$, шесть блоков и шесть голов, MLP ширины 1536, CLS и обучаемые абсолютные позиции. Предобучение не используется. Общие условия: AdamW, weight decay 0.05, batch 128, ровно $S = 10\,000$ обновлений, 5% прогрева и cosine, FP32 на RTX 3060 Laptop. LR выбрана отдельно по val на полном train из $0.0003, 0.001, 0.003$: CNN 0.003, ViT 0.0003. Сравнивается архитектура вместе с этим заранее фиксированным рецептом обучения.

Политика A1 — случайный crop 32×32 после padding 4 и горизонтальное отражение. Профиль содержит A2 RandAugment+CutMix, но дополнительные обучающие серии A0/A2 здесь не заявляются. Персональные искажения E2: blur, contrast, patch shuffle.

2. Ресурсы моделей

Режим сравнения — param matched. Число параметров ViT составляет 95.72% числа параметров CNN, что укладывается в допуск 20%. Число MAC ViT больше в 1.27965 раза, поэтому равенство вычислений не установлено. Подсчёт включает QKV, выходную проекцию и произведения attention; аналитическая и измеренная суммы совпали.

Таблица 1 – Ресурсы моделей: FP32, CUDA; время обучения при $r = 1$.

Модель	Параметры	MAC, млн	Latency, мс	Объект/с	Train MiB	Train, с
CNN	11173962	555.42	6.399	5987.6	1993.4	1187.95
VIT	10695562	710.75	4.644	3052.0	1912.8	1830.35

Latency при $B = 1$ и throughput при $B = 128$ получены из 30 повторов после 10 прогревов с синхронизацией CUDA. Throughput в этой таблице вычислен по медианному времени собственного batch. Пиковая память относится к обучению. Малый batch CNN показал повышенный разброс времени, поэтому его медиана характеризует данную серию, а не универсальную задержку. При полном train ViT обучался в 1.54076 раза дольше CNN.

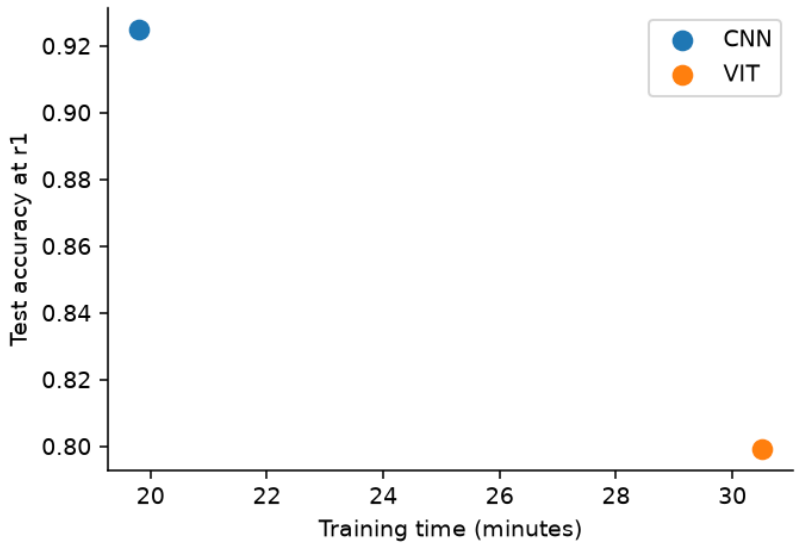


Рис. 1 – Время обучения и test accuracy при полном train; два исходных запуска E1.

3. E1. Эффективность по объёму данных

Теоретическое ожидание — преимущество локальности CNN при малом числе примеров и возможное сокращение разрыва при росте train. Для каждой доли обе модели выполняют ровно 10 000 обновлений, поэтому число проходов по малой выборке больше:

$$E_r \approx S/\lceil n_r/B \rceil. \tag{3}$$

n_r — число обучающих изображений, $B = 128$. В таблице показано фактически обработанное число эквивалентных эпох; различия последнего неполного batch учитываются журналом.

Таблица 2 – E1: validation и test при общем бюджете 10 000 обновлений.

Модель	r	n_r	Val acc.	Test acc.	E_r	Источник
CNN	0.05	2150	0.7130	0.7074	588.24	R01
VIT	0.05	2150	0.4562	0.4502	588.24	R02
CNN	0.15	6450	0.8462	0.8378	196.08	R03
VIT	0.15	6450	0.5952	0.5914	196.08	R04
CNN	0.3	12900	0.8884	0.8799	99.01	R05
VIT	0.3	12900	0.6886	0.6879	99.01	R06
CNN	0.6	25800	0.9150	0.9070	49.51	R07
VIT	0.6	25800	0.7740	0.7601	49.51	R08
CNN	1.0	43000	0.9324	0.9250	29.76	R09
VIT	1.0	43000	0.8030	0.7991	29.76	R10

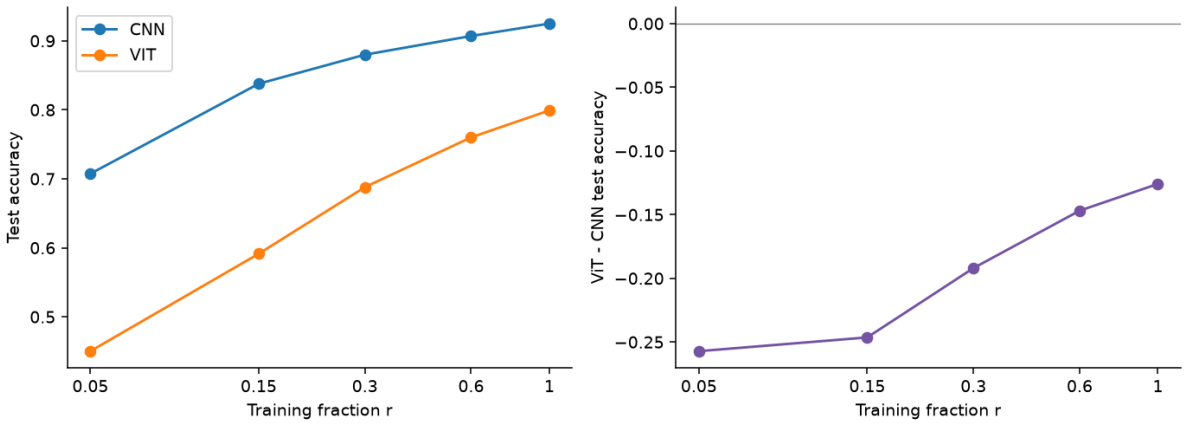


Рис. 2 – Test accuracy и разность ViT минус CNN в зависимости от доли данных; источники приведены в таблице E1.

Разность ViT минус CNN изменилась от -0.2572 при $r = 0.05$ до -0.1259 при $r = 1$. Разрыв сократился на 0.1313, но лидер не сменился ни на одной доле; r^* в измеренном диапазоне отсутствует. Нельзя продолжать кривую за $r = 1$ без новых данных. Увеличение данных здесь одновременно уменьшает число повторных проходов при фиксированном S.

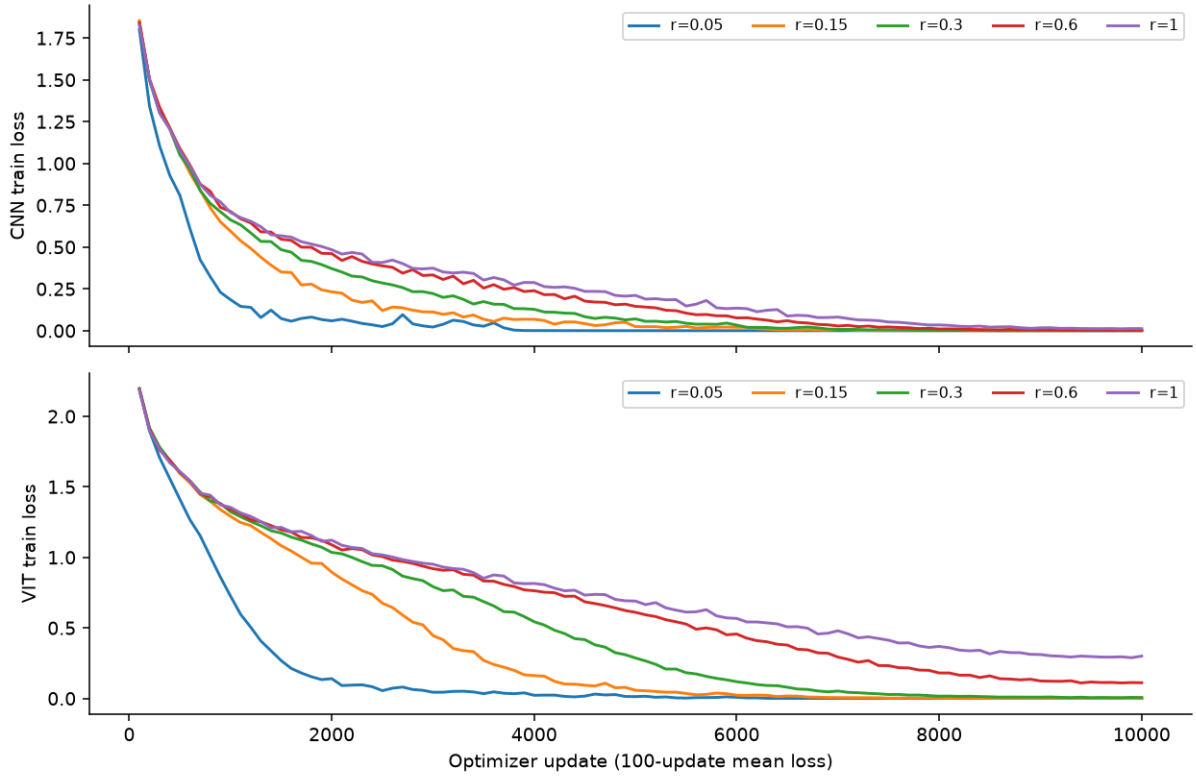


Рис. 3 – Сохранённые train loss всех условий E1 при одинаковом числе обновлений.

4. E2. Искажения тестовых изображений

Использованы фиксированные полные модели E1, CNN R09 и ViT R10. Все преобразования выполнены в RGB $[0, 1]$ до нормализации, затем значения ограничены этим диапазоном. Blur: $\sigma = 0.5, 1, 1.5$ и ядра 5,7,11; contrast: коэффициенты 0.6,0.4,0.2 относительно средней яркости; patch shuffle: стороны блока 16,8,4. При $s = 0$ вход тождествен чистому. Обе архитектуры получают одни и те же случайные преобразования каждого test-изображения.

Таблица 3 – E2: точность и относительное падение качества на test; веса полных моделей фиксированы.

Искажение	s	M_{CNN}	M_{ViT}	δ_{CNN}	δ_{ViT}
blur	0	0.9250	0.7991	0.0000	0.0000
blur	1	0.9163	0.7685	0.0094	0.0383
blur	2	0.3544	0.4972	0.6169	0.3778
blur	3	0.2012	0.3534	0.7825	0.5578
contrast	0	0.9250	0.7991	0.0000	0.0000
contrast	1	0.9101	0.6992	0.0161	0.1250
contrast	2	0.8570	0.4685	0.0735	0.4137
contrast	3	0.5476	0.2028	0.4080	0.7462
patch shuffle	0	0.9250	0.7991	0.0000	0.0000
patch shuffle	1	0.6346	0.5739	0.3139	0.2818
patch shuffle	2	0.3462	0.5700	0.6257	0.2867
patch shuffle	3	0.2055	0.5705	0.7778	0.2861

Таблица 4 – Среднее качество по трём ненулевым уровням и смена лидера.

Искажение	$\overline{M}_{CNN}$	$\overline{M}_{ViT}$	Δ	Смена
blur	0.490633	0.539700	+0.049067	да
contrast	0.771567	0.456833	-0.314733	нет
patch shuffle	0.395433	0.571467	+0.176033	да

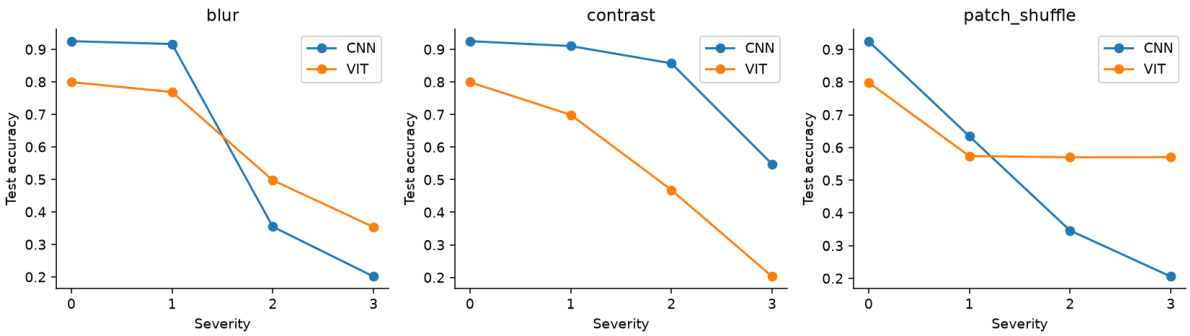


Рис. 4 – Изменение точности при трёх искажениях персонального профиля; веса не переобучаются.

На чистом test преимущество CNN равно 0.1259. Для blur средняя разность ViT минус CNN положительна, 0.049067, для patch shuffle — 0.176033: в обоих случаях выполнено правило смены лидера. Contrast сохраняет преимущество CNN, средняя разность -0.314733. Это показывает зависимость качества от типа сдвига. Перестановка блоков разрушает локальную структуру CNN; для ViT она меняет позиции токенов, но не содержимое патча 4×4. Обучаемые абсолютные позиции не позволяют объявить ViT строго инвариантным к перестановке.

5. E3 и карта относительного преимущества

Режим E3 выбран по максимальному модулю разности на val: $r = 0.05$, исходная разность -0.2568. До дополнительных seed зафиксирована гипотеза о сохранении отрицательного знака и близкой величины на test. Одинаковы подмножество, A1, S, batch, архитектуры и выбранные LR; меняются только общие seed 1,2,3. Seed 1 соответствует E1 и явно повторно используется.

Таблица 5 – E3: все парные результаты на доле $r = 0.05$.

Seed	CNN	ViT	Δ_s	Источники
1	0.7074	0.4502	-0.257200	R01/R02
2	0.6884	0.4587	-0.229700	R11/R12
3	0.7123	0.4508	-0.261500	R13/R14

Для $\Delta_s = M_{ViT,s} - M_{CNN,s}$ среднее равно -0.249467, выборочное SD — 0.017253. Все три разности отрицательны, а $|\overline{\Delta}| > 2s_\Delta = 0.034506$: различие установлено в пользу CNN. Отклонение среднего от численной гипотезы -0.2568 составляет +0.007333. Направление ожидания подтверждено.

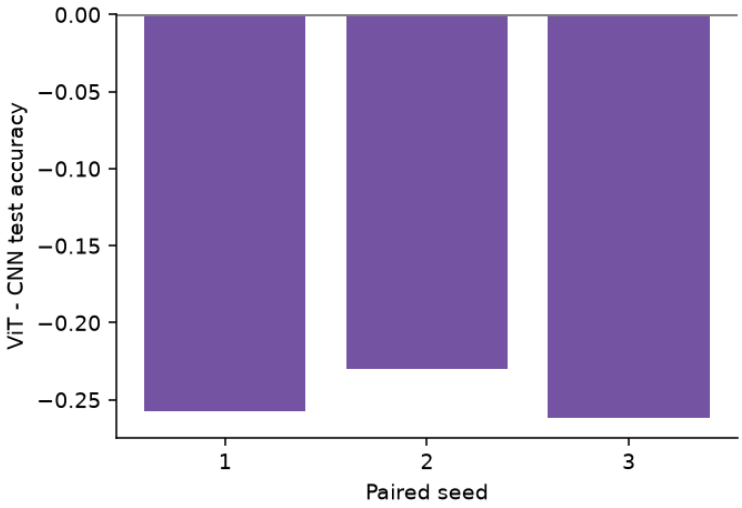


Рис. 5 – Все три парные разности E3. Положительное значение означало бы преимущество ViT.

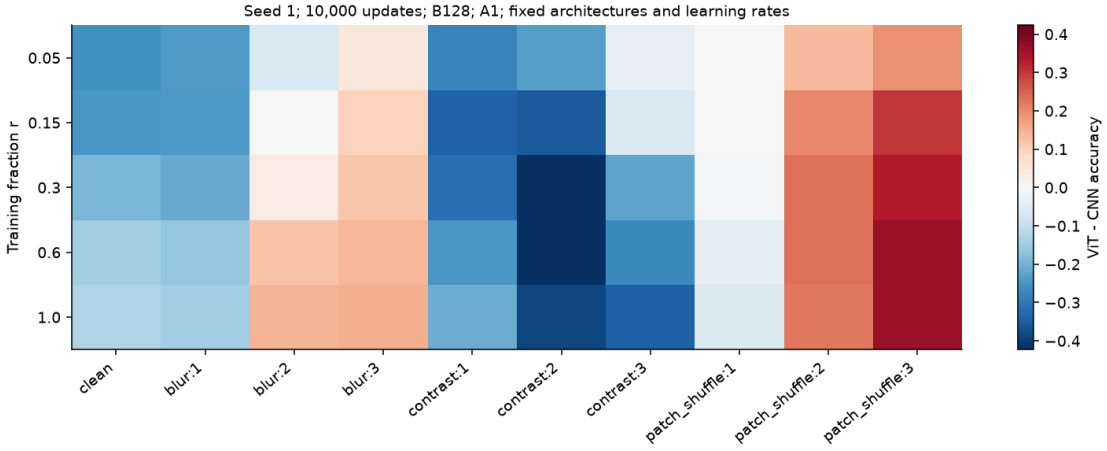


Рис. 6 – Карта относительного преимущества: доля train и условие test; фиксированы модели, A1, бюджет и seed 1.

В карте меняются доля train и условие test; фиксированы A1, бюджет, рецепты оптимизации и seed 1. Это двумерный срез, а не сравнение после подбора по test. Три seed E3 описывают вариативность обучения на одном подмножестве; смену split и рецепта они не охватывают.

6. Ответы на контрфактические вопросы и выводы

Вопрос 1. Рост объёма данных

Разность изменилась с -0.2572 до -0.1259 (R01/R02 и R09/R10), то есть на $+0.1313$. Это сокращение разрыва не предсказывает знак при большем датасете: train CIFAR-10 исчерпан. Локальность, общие веса, A1, конечный бюджет и выбранные LR могут сохранять преимущество CNN; эксперимент не выделяет один из этих механизмов отдельно.

Вопрос 2. Одинаковое число эпох вместо одинаковых шагов

На полном train $E = 10\,000/336 = 29.7619$. Для 2150 изображений это даёт $\lceil 29.7619 \cdot 17 \rceil = 506$ шагов. Сохранённый дополнительный опыт CNN дал test accuracy 0.6169 против 0.7074 при 10 000 шагах: падение 0.0905. Меняется и число предъявлений, и горизонт cosine с прогревом, поэтому это не чистая оценка одного механизма. Источник: R15.

Вопрос 3. Параметры и вычислительный бюджет

По исходным профилям отношение параметров ViT/CNN равно 0.957186, MAC — 1.279649, времени обучения — 1.540765. Режим равных параметров выполнен, равных вычислений — нет. Число параметров не определяет цену внимания и пропускную способность.

Вопрос 4. Уменьшение патча вдвое

Для $P = 4$ имеется $N' = 65$, для $P = 2$ — 257 токенов. Стоимость блока выросла с 118 260 480 до 505 479 936 MAC; квадратичный член — в $(257/65)^2 = 15.632899$ раза. Полная модель с $P = 2$ имеет 10 755 466 параметров, лишь в 1.005601 раза больше исходной. Размеры весов блоков зависят от D, а не числа токенов; меняются patch projection и таблица позиций. Значения подтверждены сохранённым профилированием R16, обучения этой модификации не заявляется.

Вопрос 5. Сдвиги на 2, 4 и 8 пикселей

Таблица 6 – Дополнительная оценка сдвигов без переобучения полных моделей.

Сдвиг, пикс.	CNN accuracy	ViT accuracy	Падение CNN	Падение ViT
2	0.9270	0.7987	-0.0020	+0.0004
4	0.9194	0.7887	+0.0056	+0.0104
8	0.8924	0.7271	+0.0326	+0.0720

Сдвиги 4 и 8 кратны патчу ViT, только 8 кратен общему stride CNN. Однако 8 пикселей дают наибольшее среднее падение, 0.0523, против -0.0008 и 0.0080 при 2 и 4. A1 покрывает сдвиги 2/4, но не 8; границы изображения, padding и pooling также нарушают строгую инвариантность классификации. Поэтому простая кратность stride не объясняет результат, а вклад аугментации нельзя отделить от величины сдвига по этим трём точкам. **Заключение.** CNN точнее ViT на всех долях train, а при 5% данных это подтверждено на трёх seed. Blur и patch shuffle меняют лидера. Преимущество зависит от условий; равенство параметров не означает равенства вычислений.

Список использованных источников

[1] Лабораторная работа 2. Архитектурные inductive biases в компьютерном зрении. CNN vs Vision Transformer: sample efficiency, augmentation, transfer и distribution shift. Курс «Нейронные сети». Методические указания, 2026.

Приложение. Идентификация запусков

Таблица 7 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R01	CNN r0.05 s1	8705d516f9c58ae4458c-2297f86c299c4b998e5a33258a6b8326
R02	VIT r0.05 s1	76a6bee7ce9731bfa4fa-8edbe989a96e427c82f75e87ddd2c0ab
R03	CNN r0.15 s1	b50b6ea8552d63768374-4d1f73742ac24869a8d8cee0b7cfcc77
R04	VIT r0.15 s1	495f34d7f6c639e46a93-9104dc9ff56f47f5aab182fd287ed1a8
R05	CNN r0.3 s1	5b5befc1e4def983b9ee-22c1988662a44a8c9b33328924f411ab
R06	VIT r0.3 s1	29176cb8f39f6f4d8171-6885d00915674ed3ade5cd94f2531767
R07	CNN r0.6 s1	1127217ff6ad88909e85-a8b568720c0c4b4ea2f2098459e6ec33
R08	VIT r0.6 s1	f154afa0aa4ee77b3250-ea30b6ab3cf942eab4e96026e089f583
R09	CNN r1.0 s1	cfd869bd9ae49d9e218c-674bd37aac074d9393378ce924e7c6dc
R10	VIT r1.0 s1	766dbdc705ebc387709a-0ecabc3039f24a5f872dd82e7d55734b
R11	CNN r0.05 s2	f1a84ec3e8723294d4a2-14cad9141a774b6daee3100c969640f6
R12	VIT r0.05 s2	1620cd8ad55b41c9e6c2-7e9c1d9d13e44a5bbee06a6bc7693cac
R13	CNN r0.05 s3	69ac6bd9ed94ae61d1aa-873bbd5089054e138a586cd2a337e139
R14	VIT r0.05 s3	793fe73a531b8002205c-4bc06191663d459e941756cc0e6a26b1
R15	CF2 CNN 506 steps	d1a718622a886ab7d1fd-42792e1b10654612a8812f0182aee6f1
R16	CF4 P2 profiling	3f22804f8649bd648df6-65596ace07164264a7d02cf72f8804d1