МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Инженерная школа информационных технологий и робототехники
Направление 09.04.01 «Информатика и вычислительная техника»
Отделение информационных технологий

Лабораторная работа № 4

«Self-Supervised Representation Learning
Contrastive learning, invariances, collapse diagnostics
и label efficiency»

по дисциплине «Нейронные сети»

Выполнил:
студент гр. 8ВМ53 _____ Ван Чжаофу

Проверил:
_____ Григорьев Д. С.

Томск – 2026

Содержание

1 Профиль и протокол 3

2 E1. SimCLR и базовые модели 4

3 E2. Вклад аугментаций 6

4 E3. Эффективность по меткам 8

5 Ответы на контрфактические вопросы 9

6 Ограничения и заключение 11

Список использованных источников 12

Приложение. Идентификация запусков 13

1. Профиль и протокол

1.1. Цель и основные формулы

Цель — обучить полезное представление без меток, измерить влияние аугментаций и зависимость качества от числа доступных меток [1]. Два независимых преобразования $t_1, t_2 \sim T$ одного изображения образуют положительную пару. ResNet-18 для CIFAR с первой свёрткой 3×3 без max-pool выдаёт $h \in \mathbb{R}^{512}$. Голова без bias $512 \to 512 \to 128$ с ReLU строит z, затем $\hat{z} = z/\|z\|_2$.

$$\ell_i = -\log \frac{\exp(\hat{z}_i^\top \hat{z}_{j(i)}/\tau)}{\sum_{k \neq i} \exp(\hat{z}_i^\top \hat{z}_k/\tau)}, \qquad \mathcal{L} = \frac{1}{2N} \sum_{i=1}^{2N} \ell_i. \tag{1}$$

У каждого вида один положительный и $2N - 2$ отрицательных примера. Самосходство исключается. При равных сходствах $\mathcal{L} = \ln(2N - 1)$. Температура меняет концентрацию весов $p_{ik} \propto \exp(s_{ik}/\tau)$ и масштаб градиента $1/\tau$: сильнее отталкиваются наиболее похожие отрицательные примеры.

Для ковариации C с собственными значениями λ_j эффективный ранг равен

$$q_j = \lambda_j / \operatorname{tr} C, \qquad r_{eff} = \exp\left(-\sum_j q_j \ln q_j \right). \tag{2}$$

При $\operatorname{tr} C \leq 10^{-6} d\, \overline{\|h\|^2}$ ранг не определён и помечается как n/a. Малый $r_{eff}/d < 0.2$ — диагностика размерностного коллапса, а не доказательство отсутствия классовой информации. Полное совпадение нормированных проекций даёт $\|\bar{\hat{z}}\| = 1$.

1.2. Данные и обучение

Профиль: $\tau = 0.1$, третья операция flip, доли меток $r = 0.02, 0.05, 0.25, 1$. CIFAR-10: train 43 000, val 5000, cal 2000, test 10 000; статистики нормализации рассчитаны на train. Предобучение использует только изображения train, cal не читается. Базовый набор T: RandomResizedCrop 32×32, scale $[0.08, 1]$; ColorJitter с вероятностью 0.8, brightness/contrast/saturation 0.4 и hue 0.1; flip с вероятностью 0.5. Генератор видов независим от split и инициализации.

SimCLR: SGD, LR 0.3, momentum 0.9, weight decay 10^{-4}, cosine с прогревом 10 эпох, $N = 256$, полное обучение 100 эпох, короткое 25. Одновременно обрабатываются 512 видов и 510 отрицательных примеров для каждого; AMP используется для сети, NT-Xent считается в float32. Устройство — RTX 3060 Laptop. B0 не обучается; B1 обучен с учителем на всех train-метках за 25 эпох с crop и flip.

Кодировщик и BatchNorm заморожены в eval. Признаки извлечены без аугментаций. Probe — линейный классификатор, 200 эпох, LR 0.1; регуляризация выбирается по val из $0, 0.001, 0.01$. kNN использует только train, $k = 200$, температура 0.07. Во всех условиях одинаковая процедура оценки.

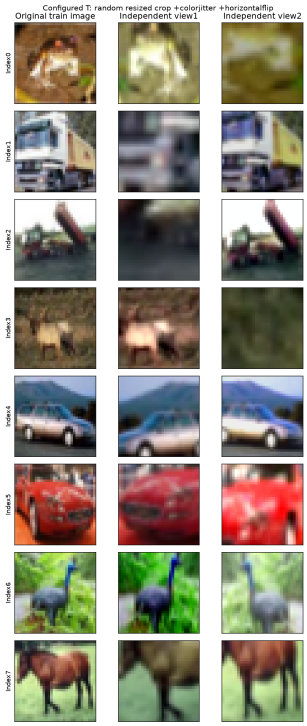


Рис. 1 – Восемь исходных изображений train и независимые виды базового набора.

2. E1. SimCLR и базовые модели

Ожидалось преимущество SimCLR над случайным кодировщиком, но не обязательное равенство модели с учителем. Оценка probe проведена в пяти точках, включая начальную.

Таблица 1 – Три фиксированных кодировщика E1: качество на test и диагностика на train.

Модель	Probe	kNN	$\operatorname{tr} C_h$	$r_{eff,h}$	$r_{eff,h}/512$	$\|\bar{\tilde{z}}\|$	Ист.
B0	0.4357	0.3822	95.464	3.156	0.0062	0.9932	R01
B1	0.8988	0.8959	34.552	16.492	0.0322	0.7673	R02
SimCLR	0.7662	0.7053	8.283	75.610	0.1477	0.0398	R03

Таблица 2 – Масштаб и ранг признаков на 5000 фиксированных train-изображений.

Модель	Признак	d	$\overline{\|h\|}$	$\operatorname{tr} C$	r_{eff}
B0	h	512	35.5166	95.46421	3.156
B0	$\hat{z}$	128	1.0000	0.01348	28.474
B1	h	512	7.6857	34.55226	16.492
B1	$\hat{z}$	128	1.0000	0.41126	19.099
SimCLR	h	512	3.5061	8.28280	75.610
SimCLR	$\hat{z}$	128	1.0000	0.99862	59.873

Таблица 3 – Probe в пяти контрольных точках одного обучения SimCLR.

Эпоха	Test acc.	Val acc.	$r_{eff,h}$	$r_{eff,z}$	Ист.
0	0.4357	0.4302	3.156	28.474	R04
25	0.6769	0.6862	44.777	38.427	R05
50	0.7211	0.7366	56.931	49.145	R06
75	0.7529	0.7532	68.379	56.541	R07
100	0.7662	0.7616	75.610	59.873	R03

Итоговый средний loss по эпохе равен 0.553783, ниже $\ln 511 = 6.236370$. Выигрыш над B0 на полной разметке $G(1) = 0.7662 - 0.4357 = 0.3305$; отставание от B1 равно 0.1326. Это разные бюджеты supervision, а не чистая цена отказа от меток.

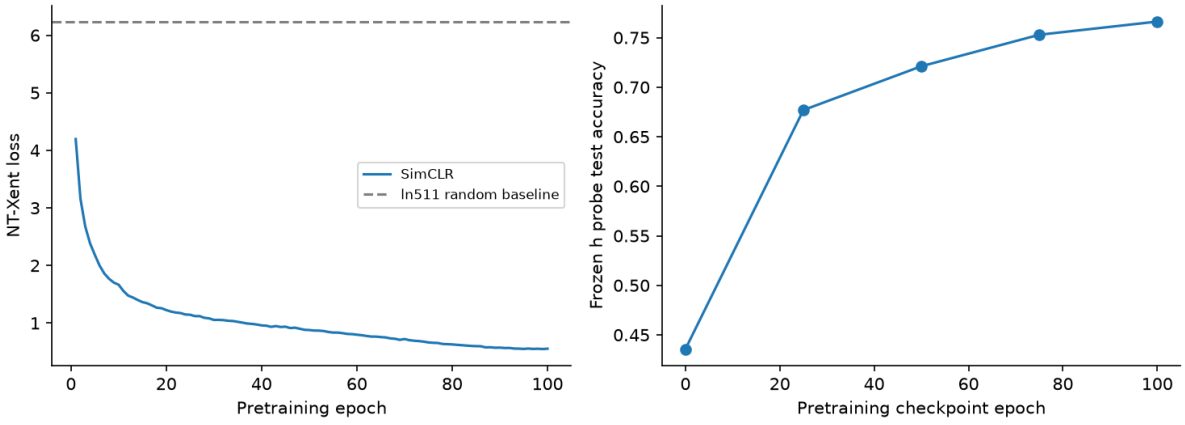


Рис. 2 – E1: NT-Xent, случайный уровень и probe по эпохам.

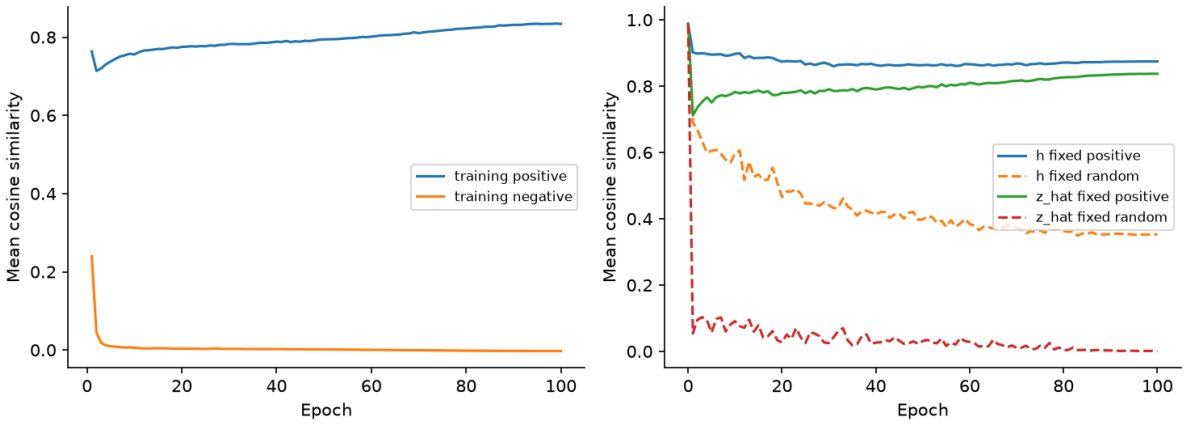


Рис. 3 – Сходства положительных и случайных пар по эпохам.

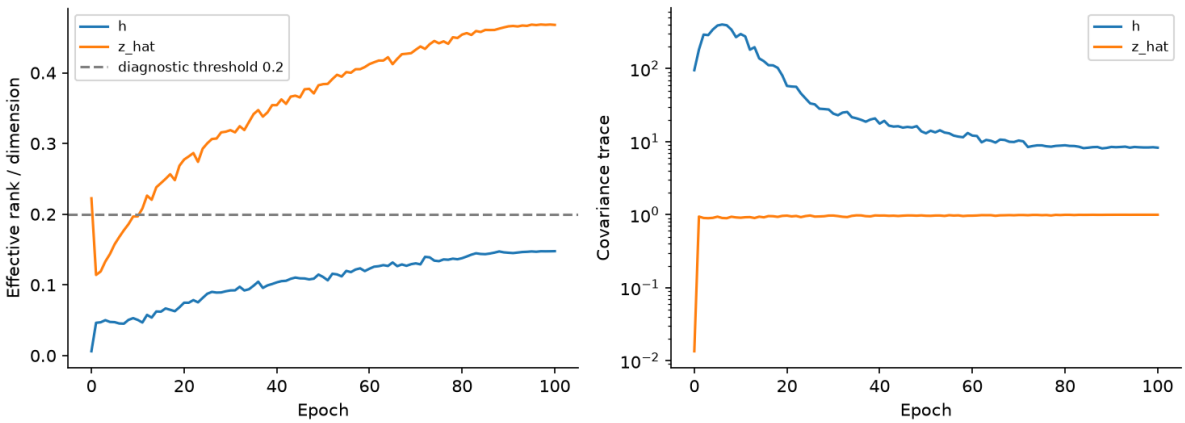


Рис. 4 – Эффективный ранг и след ковариации по эпохам.

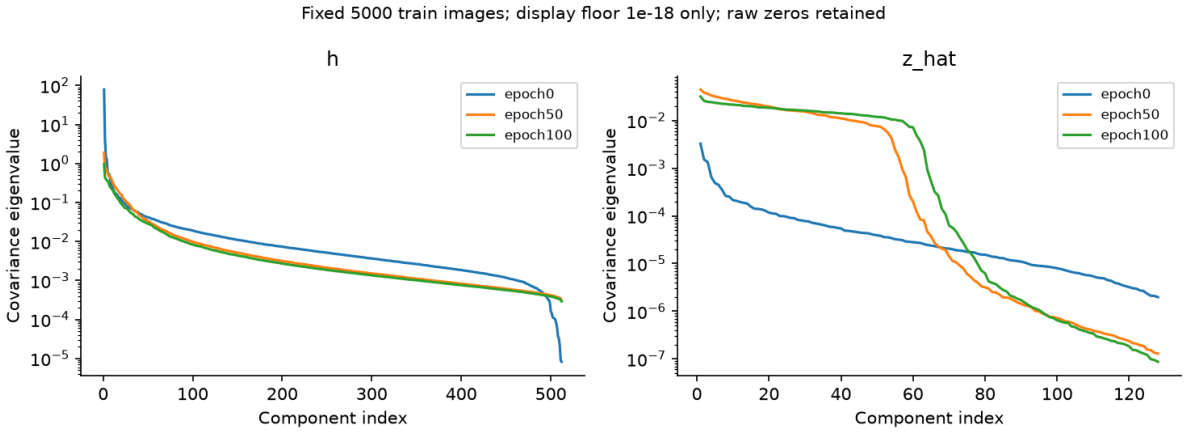


Рис. 5 – Спектры ковариации в начале, середине и конце обучения.

От 25 к 50 эпохам loss снизился на 0.265433, probe вырос на 0.0442; от 50 к 75 — на 0.215363 и 0.0318; от 75 к 100 — на 0.109146 и 0.0133. Рост качества замедляется. На измеренных соседних точках строгого плато с изменением accuracy не более 0.01 при падении loss не менее 0.05 не обнаружено. Нельзя приписывать данным отсутствующее плато.

У всех трёх кодировщиков $r_{eff,h}/512 < 0.2$, однако классификация различается сильно. У SimCLR нормированные проекции хорошо разнесены ($\|\bar{\hat{z}}\| = 0.039754$), их ранг 59.873 из 128 и след 0.998619. Таким образом, диагностический низкий ранг h сосуществует с полезным представлением и не равен полному коллапсу.

3. E2. Вклад аугментаций

Шесть коротких обучений имеют общий seed 1, архитектуру, batch, τ и оптимизацию; меняется только набор операций. $\Delta_j = M(T) - M(T_{-j})$. Для короткого полного набора $G_0 = 0.6691 - 0.4357 = 0.2334$, половина выигрыша 0.1167.

Таблица 4 – E2: 25 эпох, один seed; положительная разность означает пользу удалённой операции.

Вариант	Probe	kNN	Δ_j	$r_{eff,h}/512$	$\|\bar{\tilde{z}}\|$	Ист.
T	0.6691	0.5967	+0.0000	0.0718	0.0339	R08
без crop	0.3889	0.3457	+0.2802	0.0682	0.0171	R09
без color	0.5599	0.4863	+0.1092	0.0811	0.0396	R10
без flip	0.6862	0.6083	-0.0171	0.0718	0.0378	R11
только crop	0.5599	0.4806	+0.1092	0.0805	0.0408	R12
без операций	0.3614	0.3304	+0.3077	0.0931	0.0175	R13

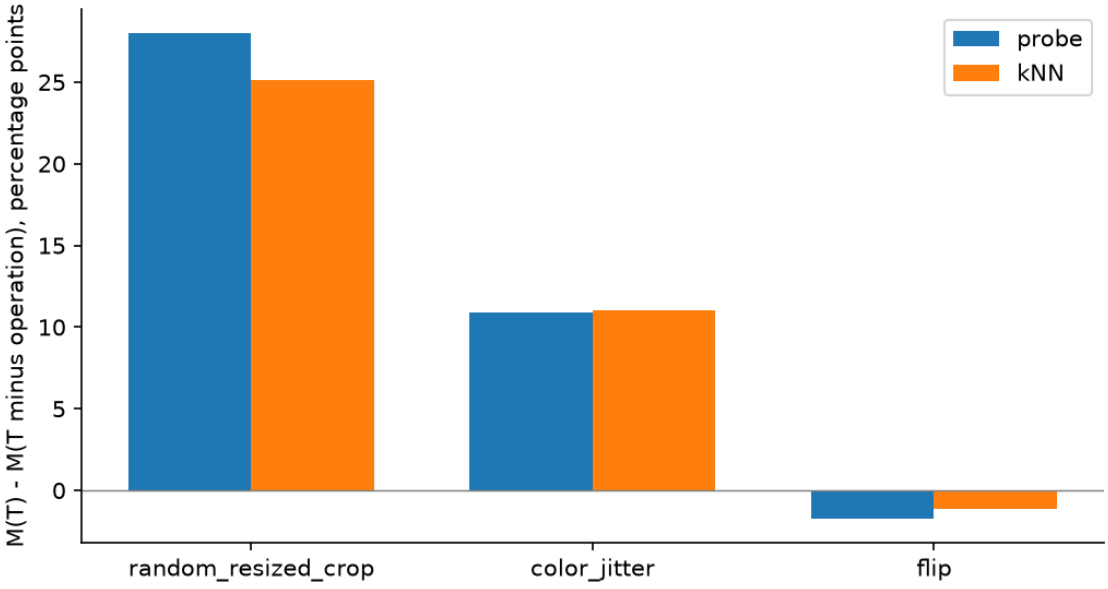


Рис. 6 – Вклад каждой из трёх операций в probe и kNN.

Crop задаёт устойчивость к положению, масштабу и частичной видимости. Его удаление уменьшило probe на 0.2802, что превышает половину выигрыша: операция критична и по качеству. ColorJitter задаёт устойчивость к яркости, контрасту, насыщенности и оттенку; падение 0.1092 ниже половины выигрыша. Flip задаёт устойчивость к горизонтальному отражению; удаление повысило accuracy на 0.0171, но этого недостаточно для вывода о вреде.

Во всех вариантах, включая полный T, присутствует диагностический низкий ранг h. Поэтому формальная коллапсная ветвь правила задания помечает удаления как критичные; она не доказывает нового коллапса из-за удаления. Это ограничение отделено от изменения accuracy. По одному seed малые эффекты не считаются установленными.

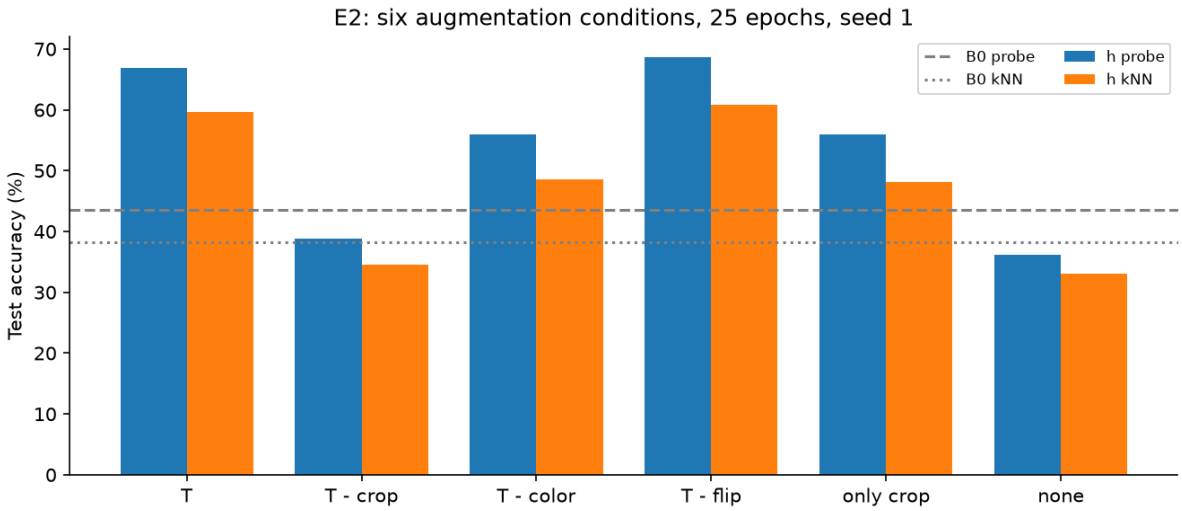


Рис. 7 – Шесть вариантов E2, включая одну операцию и совпадающие виды.

Из одиночных операций оставлен crop, выбранный по максимальному Δ_j; accuracy 0.5599. Совпадающие виды без операций дали 0.3614, ниже B0 0.4357, при $\|\bar{\hat{z}}\| = 0.017496$. Следовательно, плохое качество здесь не связано с совпадением всех проекций. При одинаковых видах притяжение пары почти не требует инвариантности, а отталкивание продолжает различать отдельные изображения; такая геометрия не обязана разделять классы.

4. E3. Эффективность по меткам

Используются одни сохранённые кодировщики E1. Общие seed 1,2,3 меняют стратифицированные вложенные подмножества меток и инициализацию probe. Число меток: 860, 2150, 10 750 и 43 000. Основное сравнение — SimCLR минус B0 при $r_{min} = 0.02$; все остальные условия фиксированы. До запусков предсказан положительный эффект величины 0.165250; отсутствие устойчивого положительного различия опровергло бы направленный прогноз.

Таблица 5 – Полная матрица E3: точность всех трёх кодировщиков при каждой доле и seed.

r	Seed	B0	B1	SimCLR	Источники
0.02	1	0.2903	0.8792	0.6644	R14/R15/R16
0.02	2	0.2882	0.8817	0.6652	R17/R18/R19
0.02	3	0.2922	0.8795	0.6599	R20/R21/R22
0.05	1	0.3404	0.8871	0.7009	R23/R24/R25
0.05	2	0.3489	0.8900	0.7097	R26/R27/R28
0.05	3	0.3400	0.8910	0.7037	R29/R30/R31
0.25	1	0.4142	0.8964	0.7491	R32/R33/R34
0.25	2	0.4108	0.8978	0.7483	R35/R36/R37
0.25	3	0.4093	0.8978	0.7494	R38/R39/R40
1.0	1	0.4357	0.8988	0.7662	R01/R02/R03
1.0	2	0.4380	0.8997	0.7647	R41/R42/R43
1.0	3	0.4385	0.8984	0.7641	R44/R45/R46

Таблица 6 – Парные разности SimCLR минус B0, выборочное SD и критерий задания.

r	Δ_1	Δ_2	Δ_3	$\bar{\Delta}$	s_Δ
0.02	+0.3741	+0.3770	+0.3677	0.372933	0.004759
0.05	+0.3605	+0.3608	+0.3637	0.361667	0.001767
0.25	+0.3349	+0.3375	+0.3401	0.337500	0.002600
1.0	+0.3305	+0.3267	+0.3256	0.327600	0.002571

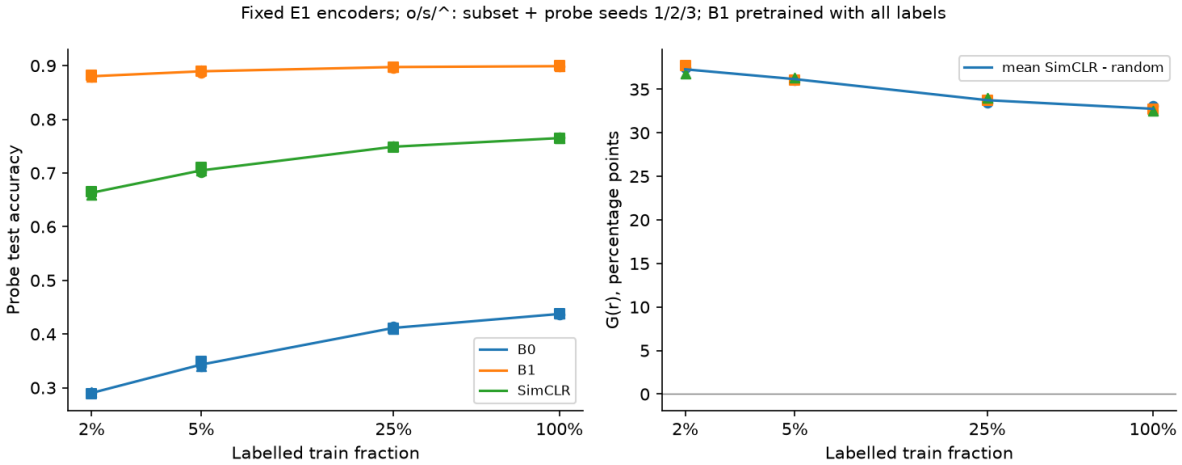


Рис. 8 – E3: все seed по долям разметки и выигрыш SimCLR над B0.

При r_{min} все разности положительны: 0.3741, 0.3770, 0.3677. Среднее 0.372933, выборочное SD 0.004759; $\bar{\Delta} > 2s_\Delta = 0.009517$. Различие установлено в пользу SimCLR. Направление гипотезы поддержано, но точечный прогноз ошибся на +0.207683: количественное ожидание было слишком консервативным. При $r = 1$ средний выигрыш 0.327600 также установлен. Три оценки seed 1 на полном train явно повторно используют E1.

5. Ответы на контрфактические вопросы

Вопрос 1. Сравнимость NT-Xent

В полном E1 первый и последний шаг дали 6.110858 и 0.597880, при случайном уровне 6.236370 (R47). Для $N = 256$, 25 эпох: 6.110858 $\rightarrow$ 1.034946 (R48). Для $N = 64$, 25 эпох: 4.693625 $\rightarrow$ 0.495635 при $\ln 127 = 4.844187$ (R49). Величины loss зависят от числа кандидатов и температуры. При изменении batch также меняются число обновлений и статистики BatchNorm, поэтому это не изолированная проверка одного знаменателя.

Вопрос 2. Класс, определяемый оттенком

Построен HueCIFAR-10: исходные train/val/test 43 000/5 000/10 000 изображений сохраняют роли, cal не читается. Семантические метки отброшены. В каждой роли случайно и точно поровну назначены десять классов оттенка, независимо от содержания, с seed 4601/4602/4603. Для класса k оттенок равен $(k + 0.5)/10 + u$, $u \sim U[-0.015, 0.015]$,

насыщенность 0.8; яркость $V = 0.25 + 0.65(0.299R + 0.587G + 0.114B)$. HSV переведён в RGB с округлением до uint8. Текстура яркости сохраняется, класс задаётся только оттенком.

Использованы два уже обученных 25 эпох кодировщика E2: полный T и вариант без ColorJitter. Предобучение не повторялось, кодировщики и BatchNorm заморожены. На h обучены линейные пробы: 200 эпох, SGD 0.1, momentum 0.9, cosine, seed 1. L2 выбирается из $\{0, 0.001, 0.01\}$ по val; признаки стандартизуются только по train. До обучения ожидалось преимущество варианта без изменения цвета.

Таблица 7 – Цветовой контроль: два замороженных кодировщика E2, один seed и одинаковый probe.

Кодировщик	L2	Val accuracy	Test accuracy	Ист.
T	0.001	0.991800	0.994000	C1
$T_{-ColorJitter}$	0.000	0.999800	0.999700	C2

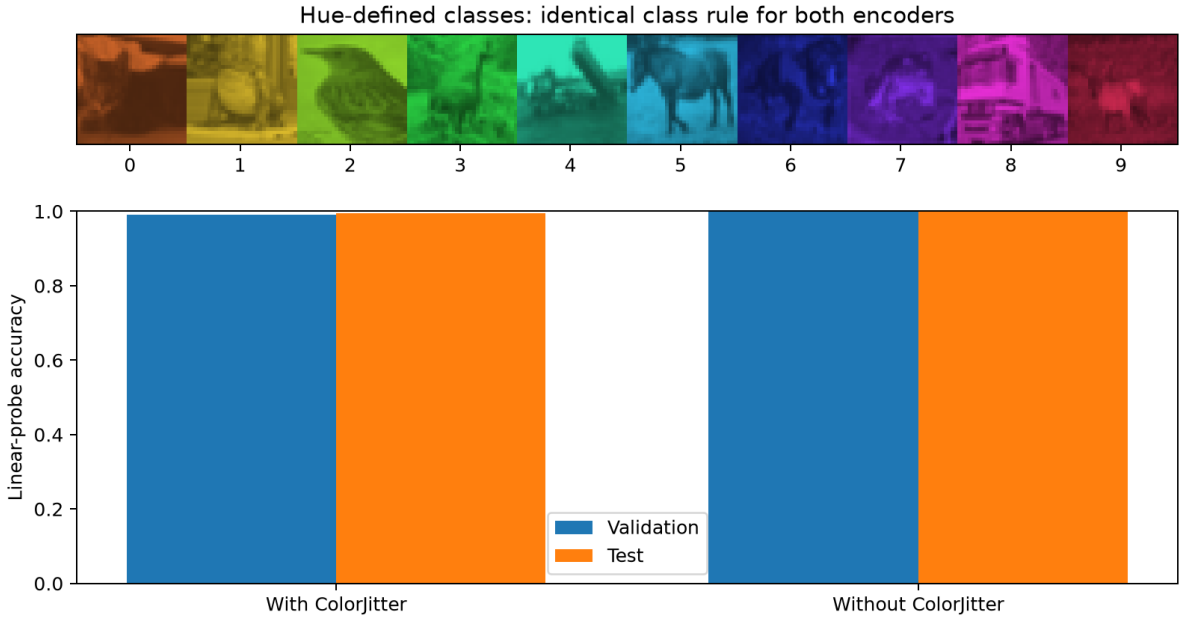


Рис. 9 – Примеры классов по оттенку и точность линейных проб на цветовой задаче.

Точность без ColorJitter выше; разность test accuracy «без минус с» равна +0.005700. Предсказанное направление подтверждено в этом контроле. Это прямой контроль информации об оттенке в h при данных кодировщиках. Один seed не устанавливает устойчивость разности; результат не переносится автоматически на классификацию CIFAR по предметным классам и не означает полного удаления цвета проекционной головой.

Вопрос 3. Ранг и полезность

SimCLR на эпохе 25 имеет $r_{eff,h} = 44.7773$, probe 0.6769 (R05); E2 без ColorJitter — 41.4983 и 0.5599. Ранг отличается примерно на 7.3%, accuracy — на 0.1170. Напротив, полный короткий T имеет ранг 36.7625 и accuracy 0.6691: accuracy близка (разрыв 0.0078),

ранг отличается на 17.9%. Ранг измеряет распределение дисперсии, а не ориентацию относительно классов. При исчезающем следе ковариации вопрос о ранге теряет смысл по принятой конвенции.

Вопрос 4. Голова и признаки

Probe на h даёт 0.7662, на $\hat{z}$ — 0.6820, разность +0.0842; kNN соответственно 0.7053 и 0.7352 (R50). Проекционная голова меняет размерность и геометрию, усиливает заданные аугментациями инвариантности и может отбросить полезные для линейного классификатора сведения. Это не означает вреда головы для самого контрастного обучения или всех downstream-задач.

Вопрос 5. Выигрыш и бюджет supervision

$G(r_{min}) = 0.372933$ больше $G(1) = 0.327600$ на 0.045333. Исходный B1 уже видел 43 000 train-меток, даже если probe видит только 860. Поэтому $M_{B1}(r) - M_{SSL}(r)$ не является ценой отказа от меток. Сохранённый контроль B1 обучен только на тех же 860 индексах: accuracy 0.4155 (R51), против 0.8792 для исходного B1 и 0.6644 для SSL при seed 1. Однако за 25 эпох low-label модель сделала 100 обновлений против 4200 у полного B1; SSL видел все 43 000 изображений без меток за 100 эпох. Бюджеты exposure и вычислений остаются разными.

6. Ограничения и заключение

Seed E3 не меняет предобучение: вывод относится к одному кодировщику SimCLR. Для выбора регуляризации используются 5000 размеченных val-изображений, что делает малую разметку train идеализированной. E2 исследует 25 эпох и один seed; эффекты не равны итогам 100 эпох. Цветовой контроль использует один seed и замороженные кодировщики; его область применимости отделена от предметных классов CIFAR.

SimCLR улучшил качество над случайными признаками и сохранил преимущество при малой разметке. Crop оказался наиболее существенной операцией по accuracy. Loss, эффективный ранг и downstream-качество описывают разные свойства: ни один из первых двух показателей не заменяет оценку probe и kNN.

Список использованных источников

[1] Лабораторная работа 4. Self-Supervised Representation Learning. Contrastive learning, invariances, collapse diagnostics и label efficiency. Курс «Нейронные сети». Методические указания, 2026.

Приложение. Идентификация запусков

Таблица 8 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R01	B0 full probe	20986de0ae364d2e58ce-02995bd34d574f009efb1948d5bbb2de
R02	B1 full probe	6772377c79bbe0439794-1c25b550be9d459ca96f4047f14051de
R03	SimCLR full probe	3ec66db45b2793e9a39a-1178fb68191d4a91813cdcb3596c91f8
R04	SSL epoch0	32b6ee4ef289f8d231a3-6c65a07572794cae8e7d03d90aa20d21
R05	SSL epoch25	161af2ac59fc30cca93c-a9707c14f765463591f3b0b35c51e615
R06	SSL epoch50	814c55f620edc283039f-1d307201830645fbbb91b206ed96f1e6
R07	SSL epoch75	b5657df9be0f7d211876-cb13a08b891d4512b26e0001d0fcf6e7
R08	E2 T	f6930c0a3a68eee5f646-633b0a71ee11487bbda64c3c2b30dfa7
R09	E2 без crop	e0d41b4aae60ede11d38-9215f50ca3ca44209c28a2caef62eb66
R10	E2 без color	03116a6d278a2596e1ac-5c320e06d35f4db9806cc7143980c9c6
R11	E2 без flip	1ba737be8226bf3d27f9-1aec3789ae7943b0a164c7f1b9bb01bc
R12	E2 только crop	76ffb8d4e5612d080fc6-81d66cafbc3f41f68510e06e129e17f9
R13	E2 без операций	11791a48092c8a621248-b32b5566845a44a98a747e62a041c408
R14	E3 B0 r0.02 s1	3c7f8aef44b742e0d740-bd1161b222d74355b48b70233c125f00
R15	E3 B1 r0.02 s1	bb3af5bd7af619070d74-06292b0f3b3c44dc81c24e0ab6d172f5
R16	E3 SimCLR r0.02 s1	d0f2ed8844513313f79a-aecf0e05c9a149a99c35bef5fe93ebf2
R17	E3 B0 r0.02 s2	0a61afbb48f9b3fe8fed-94f3228db806496986f85002bb6ee3af
R18	E3 B1 r0.02 s2	44e30187926a9335ad65-a8df351b229f4891bab31aa621eac135
R19	E3 SimCLR r0.02 s2	f2d962fdb04c1ea9c080-5310603d7990472cbd3f857b3a07b517
R20	E3 B0 r0.02 s3	735bd7988fe54fb5ed5c-6638d16ec9d24dec8fdff3e1e412762a
R21	E3 B1 r0.02 s3	7707b4c1b6abad188a76-fe2824b588b8432097b21ee1b7ff58f1
R22	E3 SimCLR r0.02 s3	e80a6111230ce1625d1d-f62531a87cd0450a89b1cdc99080048f
R23	E3 B0 r0.05 s1	94799e5340c431f44d10-421a68542f484130a956a4d0a2817328
R24	E3 B1 r0.05 s1	e27466bf96573995537d-173f3d881ea24c7f941ccf5d21fba50e
R25	E3 SimCLR r0.05 s1	54eb481fa7f4ad13318f-0ff77e54e49c46859a5d943460833217
R26	E3 B0 r0.05 s2	bd0dbcbac960b45a26f3-e8605a9511454e3195cee8a4c7b9f317
R27	E3 B1 r0.05 s2	3543093bef77b712a843-8817c078559a4bc4920ca010ba26efd5
R28	E3 SimCLR r0.05 s2	ab20bfb7426b53110234-e06e420fdbef4171847aeb70fabc8c1e
R29	E3 B0 r0.05 s3	9ba770d2b17159110ad9-162b1fd219b7475a899e62f211555b88
R30	E3 B1 r0.05 s3	7b196f8df9ea8ff3e18c-1f66f5203af44c6584099c41a72a0562
R31	E3 SimCLR r0.05 s3	035b72c0bf02b565a316-79ff3b006dfb4cf6b8b3146ac93748da
R32	E3 B0 r0.25 s1	9531bceb8a2fc0fe48d9-715cbd9dac20434092978a36fd4a87c8
R33	E3 B1 r0.25 s1	480a91744bca12f73c0e-cb7473269dec4c50819e86ab4bd319ca
R34	E3 SimCLR r0.25 s1	33f6190438bd41880294-5a04e24a81454f3ea6dc208cfa61ad96
R35	E3 B0 r0.25 s2	3751a069a45158ebe2dd-894c21a53c714f7a8aa9623baeab5fd4
R36	E3 B1 r0.25 s2	97c7f59410dcfadba88e-545942d0e323495d9bc099e7a5c70b2a
R37	E3 SimCLR r0.25 s2	71353f2f592eb1389279-e4e337cf357d49948fbff56cbe89d0ea
R38	E3 B0 r0.25 s3	688534d495db805cbde4-8fe5eaffdc464eff91facde1330cf293
R39	E3 B1 r0.25 s3	616404aaa342eb7b876d-6c74dceb1bb04904b0ba182547f99f08
R40	E3 SimCLR r0.25 s3	9fe8c27b6bf7c4483d4e-2c9792a1f4c044469d9f659c420380e9
R41	E3 B0 r1.0 s2	1762c1f110328a969753-7b1f0443d3034873a8a7253b7091fb15
R42	E3 B1 r1.0 s2	2b8d1e2b95c99e891da7-03a4808805dd40249cabb3eec59c1fd2
R43	E3 SimCLR r1.0 s2	782a94d1ba573f6f384a-1afaeebf5b8145e69c7a801d1ce0e7e2
R44	E3 B0 r1.0 s3	4c067fe2b7a607c8510a-9eb34d71f45a466b8cc94e4821c55d5f
R45	E3 B1 r1.0 s3	eab31435e9c36b3cf4d1-a6c2ba2eb0d64cfc80f59bc20acd5349

Таблица 8 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R46	E3 SimCLR r1.0 s3	ab55dcf925cd063924bb-1b8822617b51435997d6d7516dc5e61a
R47	SSL training	c104dc28794c5ceb9246-22c0ee13ed0945a9ad08df8d9a2642ea
R48	T 25 training	cf2097134c33eef5506c-be1a9df9a9714bfe9b95948d626f55c9
R49	CF1 N64	1cc8373c23ca198cfc9c-ea07fbed8d9f4fb4a4ac843ba75fd140
R50	CF4 z probe	e8f5ef72a935dc40e61f-83a8d5792fc843fcbb6adb10d3a3f09e
R51	CF5 low label probe	afdbaaa4186fc95dcffa-6a57d79c78bc4e628112f73574e14af6
C1	Q2 hue with jitter	cc5f31097bceab4ade88-40699df5deee4f98962030c20eca96b7
C1F	Q2 hue features	e8bf9cc6129400af0668-ba66c384b01c485e94c7524fd1244724
C1P1	Q2 probe L2 0.0	b7d8db2afac4978ab77d-3cf77019856b49b4b446dcbbb16bfd46
C1P2	Q2 probe L2 0.001	bf08dd28f7d8ac8e5dc4-757a98f79b4a4761a8a33691a8cb4a6a
C1P3	Q2 probe L2 0.01	c106362b5cc19ae1ba91-fb1f42cfdb4f43f6bf0db42140367ac7
C2	Q2 hue without jitter	51dfa741f7f8d4653b8b-bfec8b15a7674c88bc6e6be4e03d0aed
C2F	Q2 hue features	b52f97284c83be718825-f3a67b7fd70f42a781615efba122f578
C2P1	Q2 probe L2 0.0	7d360d4e26ac56b37c3f-ac6e1b7d96de4fc5bcb879d814b98095
C2P2	Q2 probe L2 0.001	7e9f3cc985bb7965d05a-5febac7b3aae4340bc1ef77de6ef9509
C2P3	Q2 probe L2 0.01	98041b13667aaf90a862-a2da744337e34bfea192dffcd20a30e7