МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»



ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Инженерная школа информационных технологий и робототехники
Направление 09.04.01 «Информатика и вычислительная техника»
Отделение информационных технологий

Лабораторная работа № 5

«Графовые нейронные сети
Насколько результат определяется структурой графа»

по дисциплине «Нейронные сети»

Выполнил:
студент гр. 8ВМ53 _____ Ван Чжаофу

Проверил:
_____ Григорьев Д. С.

Томск – 2026

Содержание

1 Профиль и протокол 3

2 E1. Помогает ли граф 4

3 E2. Конкретная структура рёбер 5

4 E3. Глубина и сглаживание 6

5 Карта зависимости качества от структуры 7

6 Ответы на контрфактические вопросы 8

Список использованных источников 9

Приложение. Идентификация запусков 10

1. Профиль и протокол

1.1. Цель и теория

Цель — установить, даёт ли структура рёбер сведения сверх признаков вершин, и отделить чрезмерное сглаживание от плохой обучаемости [1]. Графовая сеть обновляет вершину агрегированными сообщениями соседей. После L слоёв её рецептивное поле ограничено расстоянием L, но достижимость не гарантирует сохранения информации.

$$\tilde{A} = A + I, \quad \tilde{D}_{ii} = d_i + 1, \quad \hat{A} = \tilde{D}^{-1/2}\tilde{A}\tilde{D}^{-1/2}, \qquad H^{l+1} = \sigma(\hat{A}H^l W^l). \tag{1}$$

Это GCN. В последнем слое ReLU отсутствует. При пустом графе $\hat{A} = I$ и слой совпадает с MLP с теми же весами. GAT заменяет фиксированные веса соседей обучаемыми нормированными коэффициентами $\alpha_{ij} \propto \exp(\text{LeakyReLU}(a^\top[Wh_i; Wh_j]))$, включая петлю.

Гомофилия и два случайных ориентира определены как

$$h_E = \frac{|\{(i,j) \in E : y_i = y_j\}|}{|E|}, \quad h_0 = \sum_c (N_c/N)^2, \quad h_{deg} = \sum_c (\text{vol}_c\,/(2|E|))^2. \tag{2}$$

При независимом удалении рёбер с вероятностью p ожидаемое число изолированных вершин равно $\sum_i p^{d_i}$. Degree-preserving null строится двойными перестановками рёбер без петель и повторов: он сохраняет все степени, но меняет соседей.

Для диагностики используются средний косинус S на 20 000 фиксированных пар, val accuracy линейного probe и нормированная энергия Дирихле

$$\hat{E}(H) = \frac{\text{tr}(H^\top(I - \hat{A})H)}{\|H\|_F^2}. \tag{3}$$

Без весов $\hat{A}^L X$ сходится внутри каждой компоненты к строкам вида $\sqrt{d_i + 1}\, v$. Поэтому степень учитывается в энергии; простое равенство строк на нерегулярном графе не обязано давать ноль.

1.2. Данные и настройки

Персональный профиль: Cora, вторая GNN — GAT, глубины 2,3,6,12,24. Использованы стандартные PyG Planetoid public masks: train 140, val 500, test 1000; cal пуст. Режим трансдуктивный: доступны X и рёбра всех вершин, но loss использует только train-метки, выбор параметров и checkpoint — только val.

Исходный граф: 2708 вершин, 5278 неориентированных рёбер без петель и повторов, 1433 признака, семь классов, 78 компонент, изолированных вершин нет. Средняя степень 3.89808, медиана 3, максимум 168. $h_E = 0.809966$, $h_0 = 0.179568$, $h_{deg} = 0.169847$. Все метки используются только для описательных статистик гомофилии, не для выбора модели.

Основные модели имеют глубину 2, ширину 64, dropout 0.5, Adam, 200 эпох и полный batch единственного графа. У GAT восемь скрытых голов по восемь признаков. Общая сетка LR $\{0.01, 0.005\}$ и weight decay $\{0.0005, 0.005\}$. Выбраны: MLP 0.01/0.005, GCN и GAT 0.01/0.0005. При равной val accuracy выбирается ранняя эпоха. Все формальные модели обучены на CPU, два потока, float32. Ширина 16 используется только для отдельной проверки опубликованного ориентира.

2. E1. Помогает ли граф

Таблица 1 – E1: выбранные по val модели; accuracy в долях.

Модель	Train	Val	Test	Эпоха	G_{top}	Ист.
MLP	1.0000	0.6320	0.6100	168	+0.0000	R01
GCN	0.9786	0.8160	0.8290	48	+0.2190	R02
GAT	0.9786	0.8120	0.8080	48	+0.1980	R03

GCN превосходит MLP на 0.2190, GAT — на 0.1980. Отдельная GCN ширины 16 дала 0.8170: отклонение от ориентира 0.815 составляет 0.2 процентного пункта и укладывается в допуск 3 пункта. Сам по себе положительный G_{top} ещё не выделяет пользу конкретных рёбер.

Таблица 2 – Удаление рёбер: A — фиксированные веса, B — переобучение на повреждённом графе.

p	M_A	M_B	N_{iso}	$\mathbb{E}N_{iso}$	h_E	Ист. A/B
0	0.8290	0.8290	0	0.00	0.8100	R02/R02
0.1	0.8240	0.8140	51	54.92	0.8074	R04/R05
0.3	0.8090	0.8060	206	216.85	0.8073	R06/R07
0.5	0.7710	0.7710	478	493.47	0.8115	R08/R09
0.8	0.7340	0.6890	1343	1366.67	0.8111	R10/R11
1	0.7290	0.6050	2708	2708.00	n/a	R12/R13

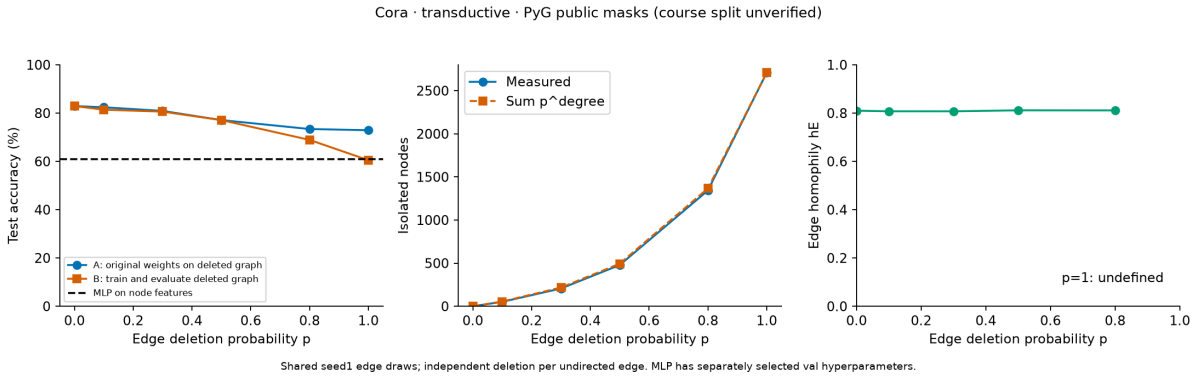


Рис. 1 – E1: два режима удаления рёбер; трансдуктивная оценка.

Для $p = 0.3, 0.5, 0.8$ относительные отклонения числа изолированных вершин от предсказания составили 5.00%, 3.13%, 1.73%, меньше 20%. Гомофилия оставшихся рёбер близка к исходной: случайное удаление уменьшает число соседей, а не систематически меняет долю внутриклассовых связей.

Кривая переобучения B впервые опускается до MLP на $p = 1$: 0.6050 против 0.6100; все 1000 test-вершин изолированы. Разница 0.005 не противоречит тождеству слоёв при пустом графе: MLP и GCN имеют отдельно выбранные по val штрафы и checkpoint. Режим A при $p = 1$ даёт 0.7290, поскольку веса были обучены на исходной структуре.

3. E2. Конкретная структура рёбер

До запусков зафиксировано ожидание положительной разности GCN на исходном графе и degree-preserving null величиной 15–35 процентных пунктов. Меняется только граф; X, masks, глубина 2, LR, weight decay и 200 эпох фиксированы. Общий seed задаёт инициализацию, dropout и нулевой граф; $Q = 10$ попыток на каждое исходное ребро. Случай seed 1 с исходным графом ранее исследовался в E1, поэтому главный вывод не заявляется как полностью независимое подтверждение.

Таблица 3 – E2: GCN на исходном графе и degree-preserving null, три общих seed.

Seed	Исходный	Null	MLP	Δ_s	$h_{E,null}$	Swap	Ист. G/null
1	0.8290	0.3250	0.6100	0.5040	0.1635	0.9805	R14/R15
2	0.8210	0.3280	0.6110	0.4930	0.1646	0.9800	R16/R17
3	0.8200	0.3190	0.6020	0.5010	0.1701	0.9808	R18/R19

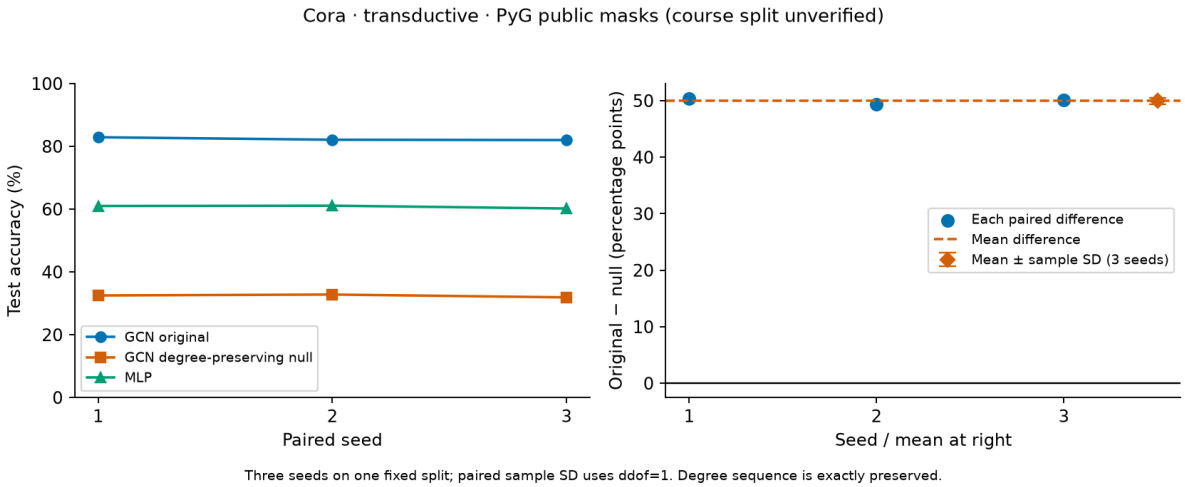


Рис. 2 – E2: точности и парные разности исходного и нулевого графов.

Степени сохранены, успешны около 98% перестановок. Значения h_E null близки к h_{deg} с отклонением менее 20%. Все три разности положительны: 0.5040, 0.4930, 0.5010; среднее 0.499333, выборочное SD 0.005686. $|\bar{\Delta}| \geq 2s_\Delta$, различие установлено: конкретная структура рёбер важна. Направление ожидания поддержано, количественный прогноз 0.15–0.35 не подтвердился. Случайные соседи не просто устраняют пользу рёбер: они способны ухудшить представление относительно MLP.

На графе Эрдёша–Реньи с тем же числом рёбер GCN seed 1 дала 0.3010, ниже degree null 0.3250. ER меняет степени, однако один такой результат не изолирует причинный вклад степени. Три seed E2 описывают неопределённость только на одном фиксированном split.

4. E3. Глубина и сглаживание

До обучения рассмотрено распространение $\hat{A}^l X$, $l = 0, \ldots, 24$: энергия убывает. В обученных plain GCN нет остатка и нормализации. По val лучшая глубина $l^* = 2$. SD val accuracy трёх исходных GCN E2 равно $s_m = 0.005292$; заметное падение — больше $2s_m = 0.010583$.

Таблица 4 – E3: выбранные checkpoint; показатели обучаемости и выходного представления.

L	Train	Val	Test	ρ_T	GI	S	$\hat{E}$	Probe	Исп.
2	0.9786	0.8160	0.8290	0.2585	1.6077	0.1279	0.0638	0.7960	R20
3	1.0000	0.8120	0.8200	0.0200	1.2952	0.1658	0.0356	0.7920	R21
6	0.9571	0.7100	0.7010	0.1209	1.2851	0.2759	0.0206	0.7020	R22
12	0.1857	0.2700	0.2730	0.9965	6.1181	0.5658	0.6793	0.2100	R23
24	0.1571	0.2340	0.2090	0.9801	9.2301	0.7178	0.5704	0.1760	R24

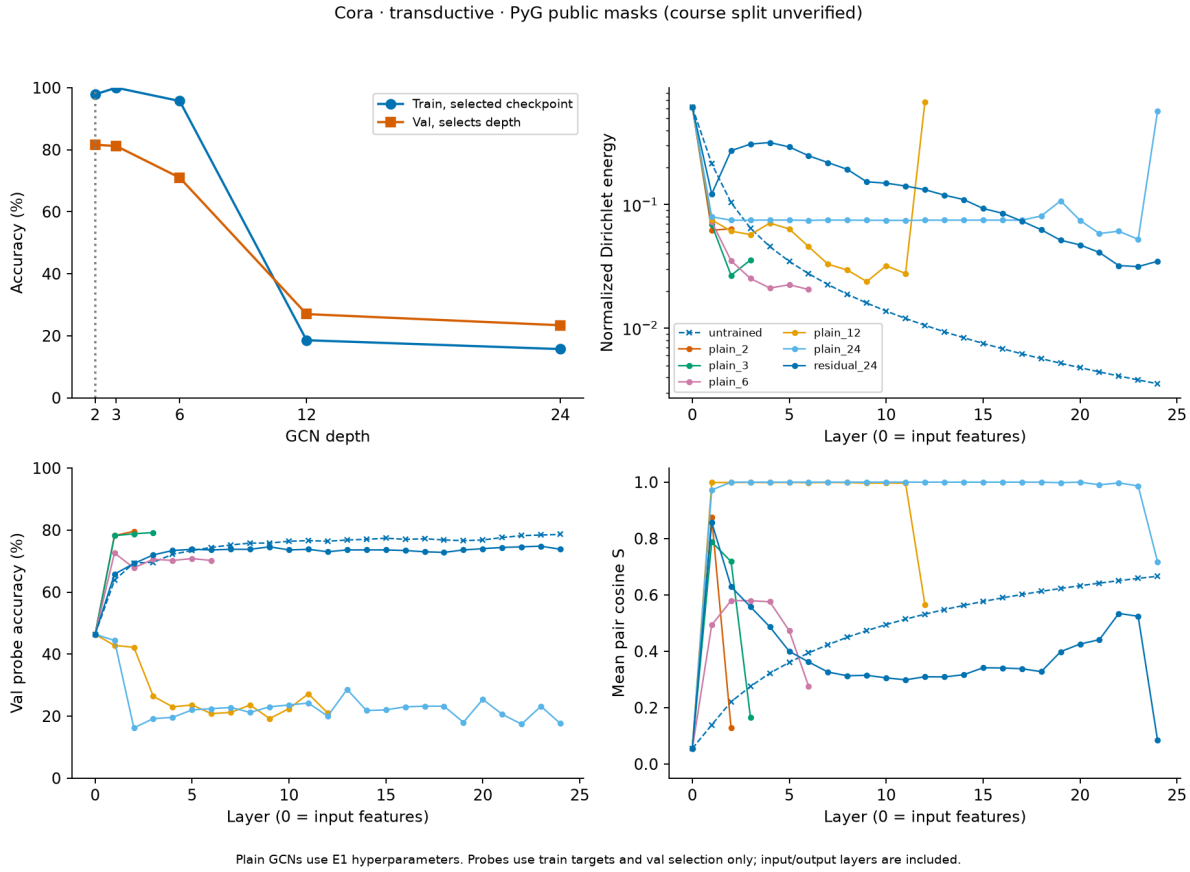


Рис. 3 – E3: точности по глубине, энергия, косинус и val-probe по слоям.

При 6 слоях сеть обучилась ($\rho_T = 0.120879$), энергия 0.020570 и probe 0.7020 ниже двухслойных 0.063777 и 0.7960. Совокупность признаков соответствует вредному сглаживанию. При 12 и 24 слоях $\rho_T \geq 0.9$, train accuracy близка к случайной и GI большой: прежде всего это плохая обучаемость, а не доказанное сглаживание. Конвенция GI≥ 6 использована как аналитический ориентир, численного порога GI преподаватель не задаёт. Таблица показывает диагностику выбранного checkpoint в eval по train; она не смешивается с медианой градиентов по всему обучению.

Обученная сеть имеет меньшую энергию, чем безвесовое распространение, при 2,3,6 слоях: 0.063777/0.103768, 0.035624/0.064405, 0.020570/0.027572. При 12,24 — большую: 0.679321/0.010541, 0.570380/0.003551. Отношения описывают энергию, а не причину неудачного обучения.

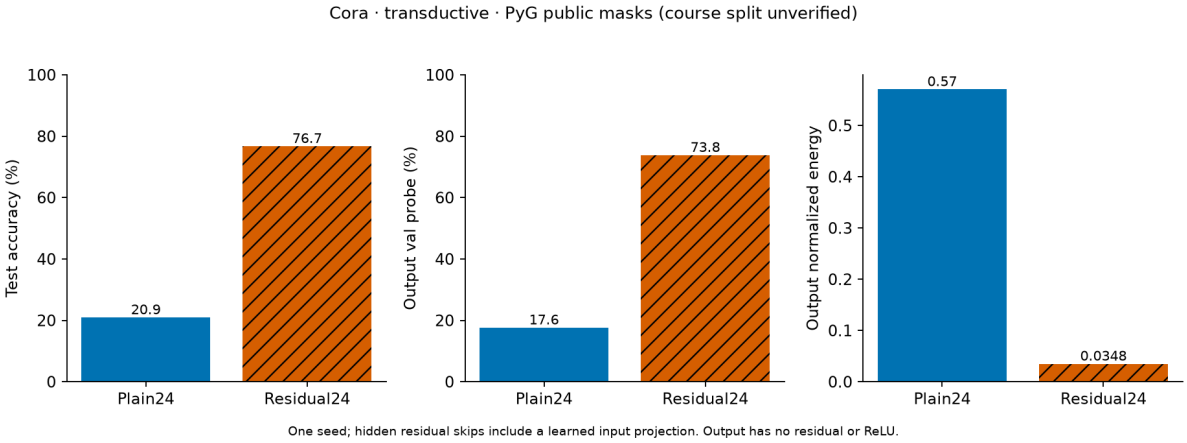


Рис. 4 – Граница применимости: 24 слоя без остатка и с остатком.

24 слоя с остатком дали train/val/test 1.0000/0.7680/0.7670, $\rho_T = 0.00529$, GI 1.5650, $S = 0.08443$, $\hat{E} = 0.034786$, probe 0.7380. При смене размерности используется обучаемая проекция, затем identity skip, выход без skip/ReLU. Предел $\hat{A}^L X$ к этой нелинейной обученной рекурсии прямо не применим.

5. Карта зависимости качества от структуры

Таблица 5 – Карта зависимости от структуры: seed 1, фиксированные X и маски.

Условие	L	Train	Val	Test	Ист.
Исходный граф	2	0.9786	0.8160	0.8290	R02
Удалено 50%	2	1.0000	0.7720	0.7710	R09
Без рёбер	2	1.0000	0.6300	0.6050	R13
Degree null	2	0.9857	0.3540	0.3250	R15
Эрдёш–Реньи	2	1.0000	0.3300	0.3010	R25
Лучшая глубина	2	0.9786	0.8160	0.8290	R20
Максимальная глубина	24	0.1571	0.2340	0.2090	R24
MLP	2	1.0000	0.6320	0.6100	R01
24 слоя с остатком	24	1.0000	0.7680	0.7670	R26

Фиксированы Cora, X, masks, 200 эпох, Adam и правило val checkpoint. Прямое сравнение графов использует одну GCN с фиксированными LR/штрафом; сравнение глубин меняет только глубину plain GCN. MLP и residual — отдельные архитектурные ориентиры, поэтому карта не трактуется как однофакторный эксперимент целиком.

6. Ответы на контрфактические вопросы

Вопрос 1. Null и собственные признаки

Seed 1: MLP 0.6100, null GCN 0.3250, null GAT 0.2690 (R27). Собственный коэффициент GCN равен $1/(d_i+1)$: при степенях 1,3,168 это 0.5,0.25,0.005917. Случайные соседи разбавляют собственные признаки. GAT может ослаблять соседей вниманием, но не обязан полностью их отвергать; наблюдаемое отличие GAT минус null GCN равно -0.0560. Оно не доказывает полезность случайных рёбер.

Вопрос 2. Добавление и удаление

До построения графа предсказано $h'_E \approx (|E|h_E + 2639h_0)/7917 = 0.599833$. Измерено 0.599217, ошибка -0.000616. Добавление 2639 случайных рёбер дало GCN test 0.7490 (R28), удаление примерно половины — 0.7710. Добавление оказалось опаснее на 0.0220 в этом seed: оно снижает гомофилию и вводит чужие сообщения. Удаление преимущественно сохраняет гомофилию. Неопределённость одного сравнения не оценена.

Вопрос 3. Два режима удаления

При $p = 0.5$ оба режима дали 0.7710 против 0.8290 на исходном графе: падение 0.0580; изолированы 177 из 1000 test-вершин. Равные числа не означают равные механизмы: A проверяет сдвиг структуры при фиксированных весах, B позволяет адаптацию. Умеренное падение не доказывает, что граф не используется: остаются гомофильные соседи, признаки и петли.

Вопрос 4. Высокий косинус

В первом слое plain GCN глубины 2 получены $S = 0.875197$, $\hat{E} = 0.061982$, probe 0.7820 при лучшем probe модели 0.7960 (R29). ReLU создаёт общее положительное направление, а косинус не отражает масштаб и небольшие различающие направления. Высокий S сам по себе недостаточен; энергия оценивает соседское выравнивание с поправкой на степень, probe — сохранение классовой информации.

Вопрос 5. Выбор глубины по test

После фиксации выбора по val отдельно рассчитан posthoc argmax test: он тоже равен 2. Совпадение не делает выбор по test допустимым: трансдукция разрешает признаки и рёбра, но не использование test-меток для настройки. Исходный двухслойный test уже присутствовал в E1, поэтому не заявляется полностью невидимый test для этой глубины. **Заключение.** На Cora конкретные рёбра дали устойчивый выигрыш над degree-preserving null. Шесть слоёв привели к вредному сглаживанию, 12 и 24 — к плохой обучаемости; остаток улучшил обучение. Выводы относятся к данному split и рецепту.

Список использованных источников

[1] Лабораторная работа 5. Графовые нейронные сети. Насколько результат определяется структурой графа. Курс «Нейронные сети». Методические указания, 2026.

Приложение. Идентификация запусков

Таблица 6 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R01	E1 mlp	6dc64393605049154c62-e390858402844dfd8439193a33e59414
R02	E1 gcn	19bb59fb13252ba73de3-8e0a3696718f4ddeab1c9f002206edfb
R03	E1 gat	922f39512d2e378e6dbb-c3c1afd5768f4eafa3007b4ab4a1f32a
R04	delete A p0.1	62a3f951f734211c790b-6dca5b96e4e44425b6e5796659c96566
R05	delete B p0.1	7a06b6037c33f8a33db6-6e6f3e43e7f142aba33b93f2d03d250f
R06	delete A p0.3	70e7e801068fbaa14e8f-9467fd3dd4ba44718b292b5c08203fc9
R07	delete B p0.3	6de45895a645a6005574-2da6d1e8af83463083c3385dcf511764
R08	delete A p0.5	03e1619b9899f2883b3d-e8688222db92423ab88987a7a88c7756
R09	delete B p0.5	83bdc4e3aa823dd29101-0d25d7abb9e542859b180983675318bb
R10	delete A p0.8	37127c5b272beb01e37c-e6ee9636a6e3437f91ba82ebb1a250f3
R11	delete B p0.8	34e91694bbcc95320d27-0bfa21f151fc4ecb93ba45132b502497
R12	delete A p1	58d3bc7f71ceff589bf7-671dd326e27249b8b7a9ad18f512935b
R13	delete B p1	4d480d550deb7c01b60b-a2e9c042795a49348f137754b2faaeb7
R14	E2 G s1	170997eb0516db15268e-bc9dd3adb6484c389e2394bef1c25035
R15	E2 null s1	f1612dc13ae579d47fdc-1f33df1ac3aa47ec84dbd76b938a4bbc
R16	E2 G s2	5e3dc7b2b4a8f04c4a58-eff300233e574c70a12504bbae61a014
R17	E2 null s2	12f1a133897b3514871e-78d2f0eafae24f43afdb2e073cf08062
R18	E2 G s3	9f9a170b0c7c29985d28-995dbbd00e024bfe9c0b8241a2a14def
R19	E2 null s3	97644abed27cf38f5473-057f3aed2da14031bce8c388124d7535
R20	E3 depth2	e5ad68ca624d0add75bb-bff2432311f343f38cc3b99ea9cb6706
R21	E3 depth3	dc798ebb889c12508ca1-4181225ecd5749a89b607ef6adcf12a3
R22	E3 depth6	55f726aa5ad6110db52f-4be93b2939ec4cf486e46c79f956fcff
R23	E3 depth12	e419bb0c9f4ea256ac1a-425b7d8b9307440cb45c9e0d132fa69b
R24	E3 depth24	585876aa03341faa5aa8-c2c6fd3a6d7743218e7a3bdc52bbef2b
R25	ER	e1f9226c3807d9516799-e75943f539284dec846455ee78becf0f
R26	maximum residual	d2b7fd35c37f89ad6858-a757e668893346a79a82c1823e72216f
R27	CF1 GAT null	d4019e4d9ffc0f51ebad-da107eb6b1fc474bad480d4ee24e01f3
R28	CF2 added edges	804407ffb262222bf788-5188bcee62fe409d81452e808519f81b
R29	CF4 high cosine	49dc168afb79b6fc9815-380db0ebe0084bc0957d925932b8d12a