МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Инженерная школа информационных технологий и робототехники
Направление 09.04.01 «Информатика и вычислительная техника»
Отделение информационных технологий

Лабораторная работа № 7

«Diffusion и Score-Based Generative Models
Noise schedule, оценка score, численный reverse process
и computational trade-offs»

по дисциплине «Нейронные сети»

Выполнил:
студент гр. 8ВМ53 _____ Ван Чжаофу

Проверил:
_____ Григорьев Д. С.

Томск – 2026

Содержание

1 Профиль и протокол 3

2 E1. Расписания шума 4

3 E2. Качество и стоимость сэмплирования 6

4 Диагностика сети и траекторий 8

5 E3. Покрытие редкой моды 11

6 Ответы на контрфактические вопросы 13

Список использованных источников 15

Приложение. Идентификация запусков 16

1. Профиль и протокол

1.1. Цель и основные соотношения

Цель — разделить влияние расписания шума, ошибки сети и численной схемы генерации [1]. При $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$, $\bar{\alpha}_0 = 1$ прямой процесс вычисляется за один шаг:

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t}\, \epsilon, \quad \epsilon \sim N(0, I), \quad SNR(t) = \frac{\bar{\alpha}_t}{1 - \bar{\alpha}_t}. \tag{1}$$

Линейное расписание интерполирует beta между границами. Косинусное использует $f(t) = \cos^2((t/T + 0.008)\pi/(2 \cdot 1.008))$; после ограничения $\beta_t \le 0.999$ произведение $\bar{\alpha}$ пересчитано. Ядро расписания использует float64.

Сеть предсказывает epsilon; loss — средний квадрат ошибки по объектам и координатам. Поэтому численные L_{simple} приведены на координату; запись нормы без деления на $d = 2$ увеличила бы их вдвое, не меняя обучения. Из предсказания получаются

$$\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t}\, \epsilon_\theta}{\sqrt{\bar{\alpha}_t}}, \qquad s_\theta = -\frac{\epsilon_\theta}{\sqrt{1 - \bar{\alpha}_t}}. \tag{2}$$

Оптимальный предиктор равен $\epsilon_* = E[\epsilon | x_t]$, а не реализованному шуму. Для смеси гауссиан точная плотность после зашумления остаётся смесью с центрами $\sqrt{\bar{\alpha}_t}\mu_m$ и ковариациями $\bar{\alpha}_t \Sigma_m + (1 - \bar{\alpha}_t) I$. Score $s_* = \nabla \log p_t$ вычислен стабильно, через log-sum-exp в стандартизованных координатах.

DDPM проходит все T шагов с $\mu_\theta = \alpha_t^{-1/2}(x_t - \beta_t \epsilon_\theta / \sqrt{1 - \bar{\alpha}_t})$ и posterior variance $\tilde{\beta}_t = \beta_t (1 - \bar{\alpha}_{t-1})/(1 - \bar{\alpha}_t)$. Последний шаг не добавляет шум, clipping выключен. DDIM использует $\tau_i = \text{round}(iT/K)$; при $\eta = 0$

$$x_{\tau_{i-1}} = \sqrt{\bar{\alpha}_{\tau_{i-1}}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{\tau_{i-1}}} \hat{\epsilon}_i. \tag{3}$$

Последний шаг возвращает $\hat{x}_0$. При полной сетке и $\eta = 1$ DDIM совпадает с DDPM. Здесь η — случайность DDIM, не шаг Ланжевена.

1.2. Данные, сеть и метрики

Профиль: $T = 1000$, $\beta \in [0.0001, 0.02]$, $M = 6$, $\rho = 0.1$, $\pi_0 = 0.02$. Центры $\mu_m = (\cos(2\pi m/6), \sin(2\pi m/6))$, ковариация $0.01I$. Мода 0 редкая; прочие веса равны 0.196. Train/val/test 20 000/5000/5000, seeds 701/702/703; cal не используется.

Статистики рассчитаны только по train:

$$\mu = (-0.18077255, 0.00254579), \quad s = (0.62488898, 0.77288930). \tag{4}$$

Преобразование по координатам $z = (x - \mu)/s$, обратное $x = z \odot s + \mu$. Модель и точный score работают в z, качество считается в исходных единицах.

MLP: вход 2, шесть скрытых слоёв ширины 256, SiLU, синусоидальное вложение времени 128 с отдельным MLP. Преобразованное время вводится в каждый скрытый слой.

Adam 0.001, batch 512, 20 000 обновлений; RTX 3060 Laptop, float32, без AMP и TF32. При сравнении расписаний архитектура и все остальные условия одинаковы.

Каждая оценка использует 5000 генерируемых точек и фиксированный test. Частоты цели оценены на 100 000 новых точках, seed 704; внешняя категория включает расстояния не меньше 3ρ. Cov сравнивает частоту каждой моды с половиной её справочной частоты; D_{mode} — полная вариация по шести модам и внешней категории. RBF MMD^2 — V-статистика с фиксированной медианной полосой $h = 1.23793506$ по всем парам train. Пять свежих истинных выборок задают шум метрик. Фиксированные значения: MMD2 noise mean = 0.00012093903, MMD2 noise sd = 4.1371986e-05, Dmode noise mean = 0.009434, Dmode noise sd = 0.0019972431.

2. E1. Расписания шума

Теоретическое ожидание: оба расписания стирают конечный сигнал, но различно распределяют сложность по времени. Доля шагов SNR< 0.01 равна 0.326 у linear и 0.064 у cosine. Конечный условный KL усреднён по train:

$$\overline{KL}_T = \frac{1}{2}\overline{\bar{\alpha}_T\|x_0\|^2 - d\bar{\alpha}_T - d\ln(1-\bar{\alpha}_T)}. \tag{5}$$

Таблица 1 – E1: единственное различие обучения — расписание шума; DDPM, 5000 точек.

Расписание	$\bar{\alpha}_T$	KL	Train loss	Val loss	MMD^2	D_{mode}	Ист.
linear	4.036e-05	4.036e-05	0.40611	0.40820	0.0021705	0.05625	R01
cosine	2.429e-09	2.429e-09	0.69308	0.68686	0.0021917	0.05185	R02

Оба $\bar{\alpha}_T$ ниже 10^{-3}. Cov обеих моделей равен 1. Более низкий linear loss не даёт однозначного превосходства двух метрик качества: разница $\mathrm{MMD}^2 = -0.000021205$, Dmode=+0.00440.

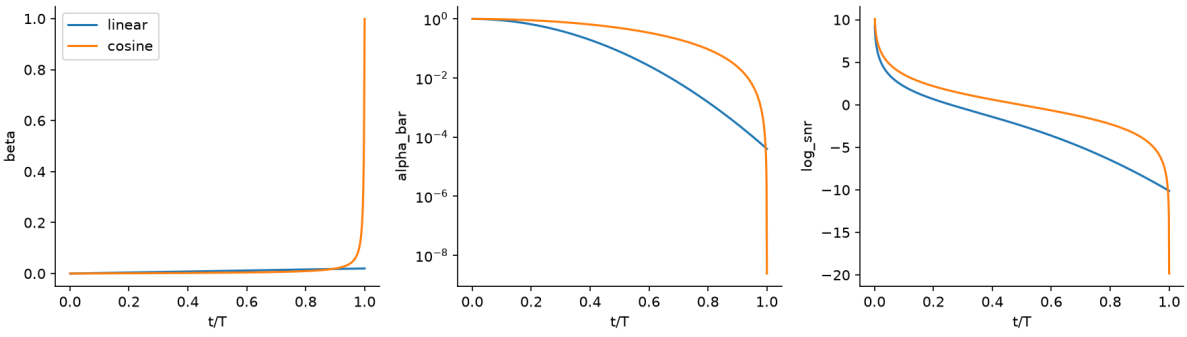


Рис. 1 – E1: beta, накопленный сигнал и log SNR двух расписаний.

Для фиксированного x_0 получено 10 000 независимых шумовых реализаций на каждом из пяти t. Все координаты прошли исходную проверку четырёх стандартных ошибок; seed не подбирался (R29).

Таблица 2 – Проверка q sample: максимальная по координатам ошибка среднего и относительная ошибка дисперсии.

Schedule	t	$\max \lvert\hat{m} - m\rvert$	Порог	$\max \lvert\hat{v}/v - 1\rvert$	Порог
linear	100	0.004218	0.012836	0.010893	0.056569
linear	250	0.007435	0.027595	0.009194	0.056569
linear	500	0.010862	0.038396	0.008333	0.056569
linear	750	0.007942	0.039933	0.017253	0.056569
linear	1000	0.008787	0.039999	0.030062	0.056569
cosine	100	0.002196	0.006682	0.010893	0.056569
cosine	250	0.004215	0.015645	0.009194	0.056569
cosine	500	0.008051	0.028458	0.008333	0.056569
cosine	750	0.007359	0.037002	0.017253	0.056569
cosine	1000	0.008788	0.040000	0.030062	0.056569

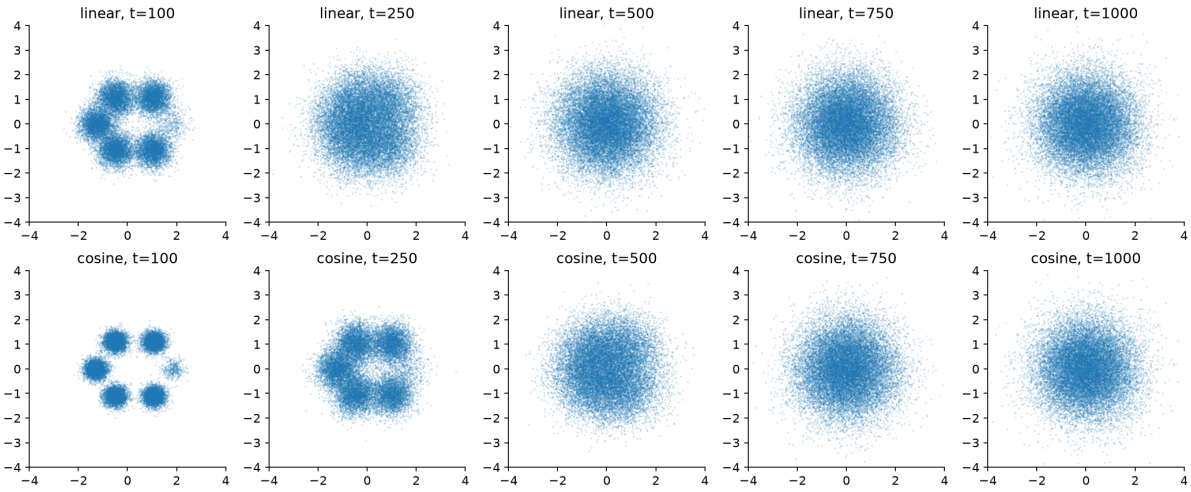


Рис. 2 – Прямой процесс при пяти уровнях шума.

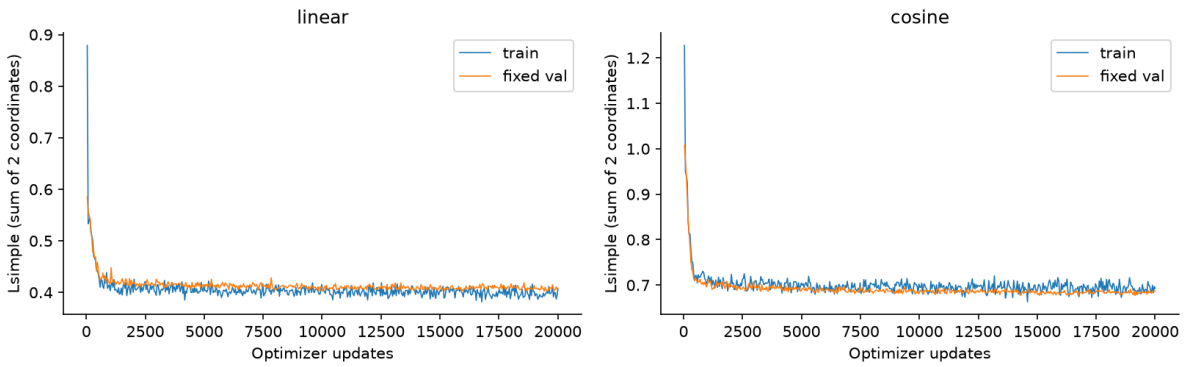


Рис. 3 – E1: train и фиксированный val loss при 20 000 обновлений.

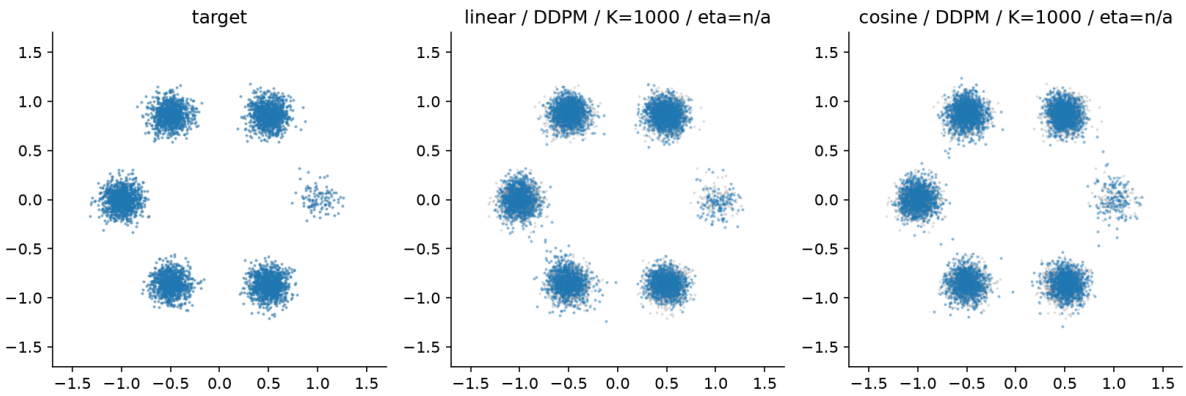


Рис. 4 – E1: linear и cosine, DDPM K=1000, posterior variance, без clipping.

Граница применимости: $T = 100$ при прежних beta даёт $\bar{\alpha}_T = 0.363563$, KL=0.451870, нарушая конечный порог. Это отдельная диагностика точного предиктора, не формальное обучение. Exact DDPM дал MMD$^2 = 0.000072387$, Dmode=0.01229 (R30), против 0.000139853 и 0.01627 при полном T. В одном измерении ухудшения нет. Условный KL из формулы не равен KL смеси к нормальному шуму, поэтому наблюдение не отменяет протокольный порог и не доказывает пользу его нарушения.

3. E2. Качество и стоимость сэмплирования

Linear-модель E1 заморожена. Меняется только обратная схема; начальные шумы общие, для стохастических шагов зафиксирован отдельный seed. Сеть не переобучается при смене K. Exact — отдельный предиктор, не обученная сеть.

Таблица 3 – E2: общий начальный шум; время — медиана пяти повторов после прогрева.

Предиктор	Сэмплер	NFE	MMD^2	D_{mode}	Cov	Время, с	Ист.
network	ddpm	1000	0.0021705	0.05625	1.000	1.61582	R03
network	ddim	5	0.0516226	0.66303	0.167	0.00899	R04
network	ddim	10	0.0147229	0.21945	1.000	0.01749	R05
network	ddim	20	0.0085653	0.12585	1.000	0.04071	R06
network	ddim	50	0.0066821	0.09245	1.000	0.08617	R07
network	ddim	100	0.0060813	0.08865	1.000	0.17946	R08
network	ddim	1000	0.0056764	0.08525	1.000	1.82389	R09
exact	ddpm	1000	0.0001399	0.01627	1.000	2.05166	R10
exact	ddim	5	0.0140085	0.48883	0.500	0.01182	R11
exact	ddim	10	0.0010714	0.12103	1.000	0.02350	R12
exact	ddim	20	0.0002459	0.01882	1.000	0.04725	R13
exact	ddim	50	0.0000802	0.01152	1.000	0.11504	R14
exact	ddim	100	0.0000507	0.01292	1.000	0.24209	R15
exact	ddim	1000	0.0000395	0.01169	1.000	2.37442	R16

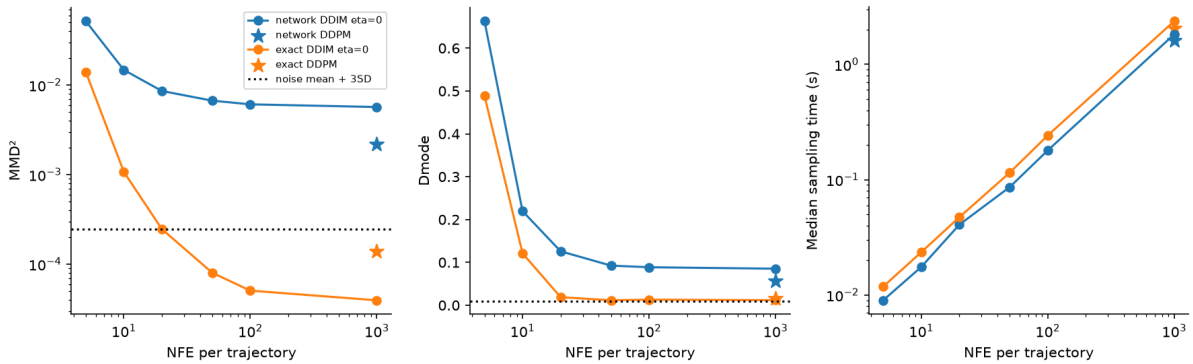


Рис. 5 – E2: качество и время от NFE, linear; DDIM eta=0, DDPM posterior variance.

NFE на траекторию равен T у DDPM и K у DDIM. Для $K \geq 10$ времена на вызов укладываются в 20% от соответствующей медианы: максимум отклонения сети 16.37%, точного предиктора 12.68%. При полном T точный DDPM и DDIM ниже порога $\mathrm{MMD}^2 = 0.000245055$ (шум плюс три SD). Рост ошибки exact при малых K показывает вклад численной схемы, разрыв network–exact при том же K — вклад сети.

Для DDIM T использованы три начальных шума. Значения MMD^2: 0.005676381, 0.006164185 и 0.004929829; $s_{MMD} = 0.000621681$. Критерий

$$|MMD^2(K) - MMD^2(T)| \leq 2s_{MMD} = 0.001243363 \tag{6}$$

впервые выполняется на измеренной сетке при $K = 50$. Это минимум сетки, а не точный оптимум среди всех целых K.

Таблица 4 – Крайне малое число шагов DDIM; отдельная оценка, без заявления о пяти повторах времени.

Предиктор	K	MMD^2	D_{mode}	Cov	Ист.
network	1	0.573304	0.98063	0.000	R17
network	2	0.128446	0.98563	0.000	R18
exact	1	0.130350	0.98903	0.000	R19
exact	2	0.107975	0.98863	0.000	R20

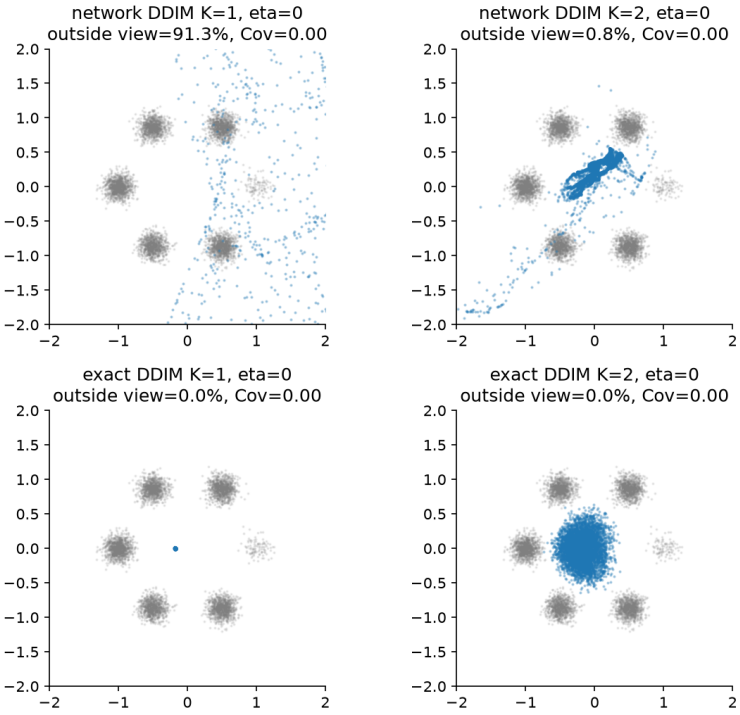


Рис. 6 – Linear DDIM eta=0, K=1 и 2: сеть и точный предиктор.

При K=1 точный DDIM возвращает Tweedie posterior mean, лежащий между модами при почти чистом шуме; Cov=0. При K=2 покрытие также нулевое, а при K=5 появляются покрытые моды: exact Cov=0.5, сеть 0.1667. С K=10 оба предиктора достигают Cov=1, хотя частоты и MMD ещё различаются.

4. Диагностика сети и траекторий

Ошибки рассчитаны на общих фиксированных val и шуме в 25 t, включая 1 и T:

$$E_\epsilon = \tfrac{1}{d} E\|\epsilon - \epsilon_\theta\|^2, \quad E_{x_0} = E_\epsilon / SNR, \quad E_{net} = \tfrac{1}{d} E\|\epsilon_* - \epsilon_\theta\|^2. \tag{7}$$

В ожидании $E_\epsilon = E^*_\epsilon + E_{net}$. На конечной выборке сохраняется измеренный перекрёстный член с SEM; его не обнуляют принудительно. Для exact собственная ошибка равна нулю.

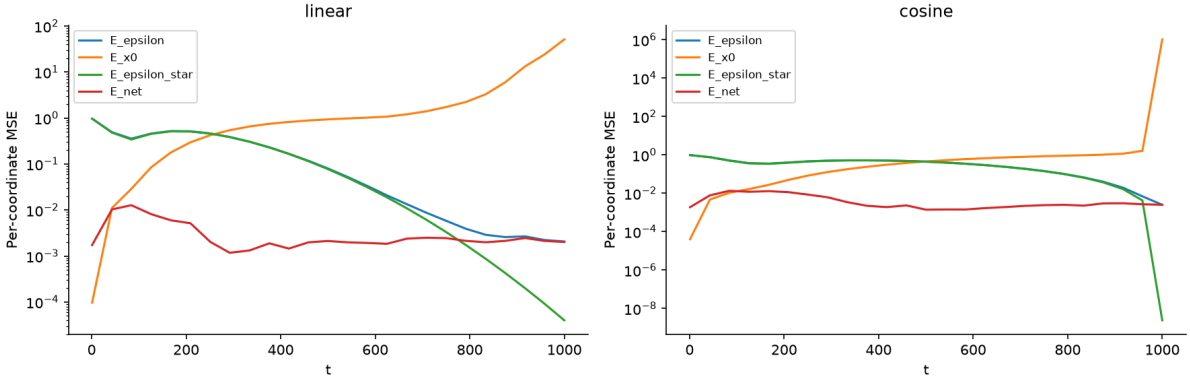


Рис. 7 – Ошибки на 25 шагах для двух расписаний, фиксированные val и шум.

На T linear имеет $E_\epsilon = 0.002069320$, $E_\epsilon^* = 0.000040065$, $E_{net} = 0.002022949$, $E_{x_0} = 51.271643$. Cosine: 0.002514774, $2.4111 \cdot 10^{-9}$, 0.002514743 и $1.035412 \cdot 10^{6}$. Разные единицы ошибок принципиальны: маленькая ошибка epsilon при низком SNR может дать большую ошибку восстановления.

Таблица 5 – Score на сетке 41×41: средние с весами $p_t(x)$.

Schedule	t	Косинус	Отношение длин	Ист.
linear	10	0.979138	1.099804	R21
linear	100	0.967361	0.978513	R21
linear	400	0.996687	1.028544	R21
linear	800	0.995145	1.602079	R21
cosine	10	0.974234	1.214775	R22
cosine	100	0.986461	0.964783	R22
cosine	400	0.985098	1.027589	R22
cosine	800	0.987465	1.067802	R22

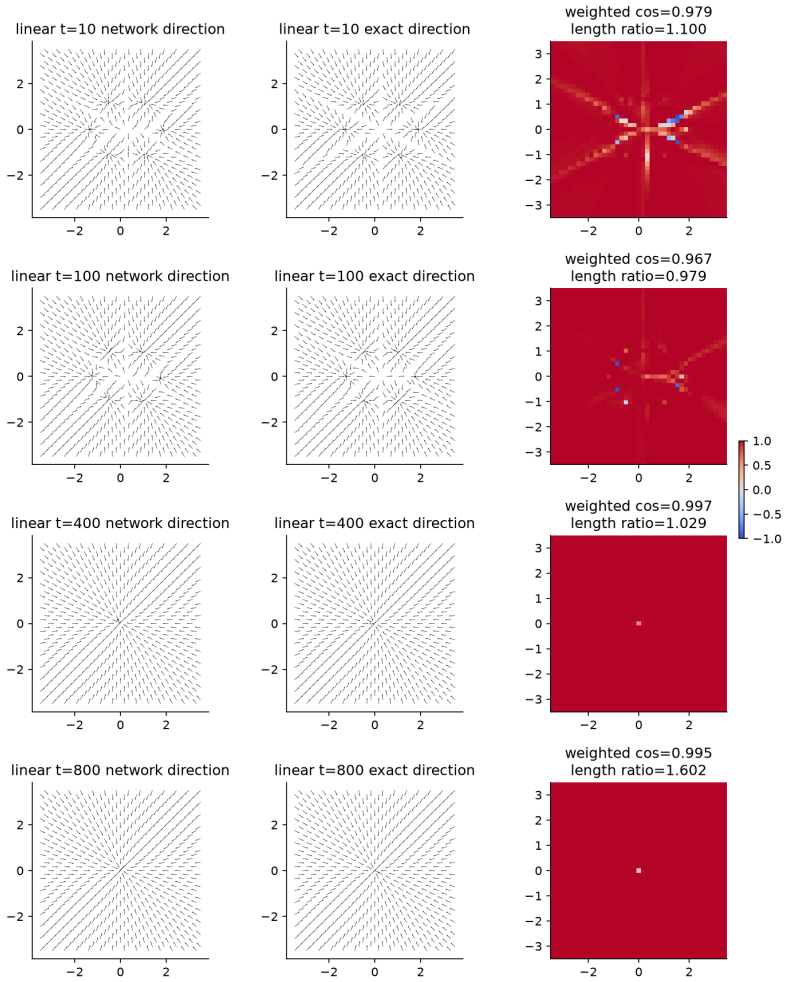


Рис. 8 – Linear: поля score, косинусы и длины на четырёх уровнях шума.

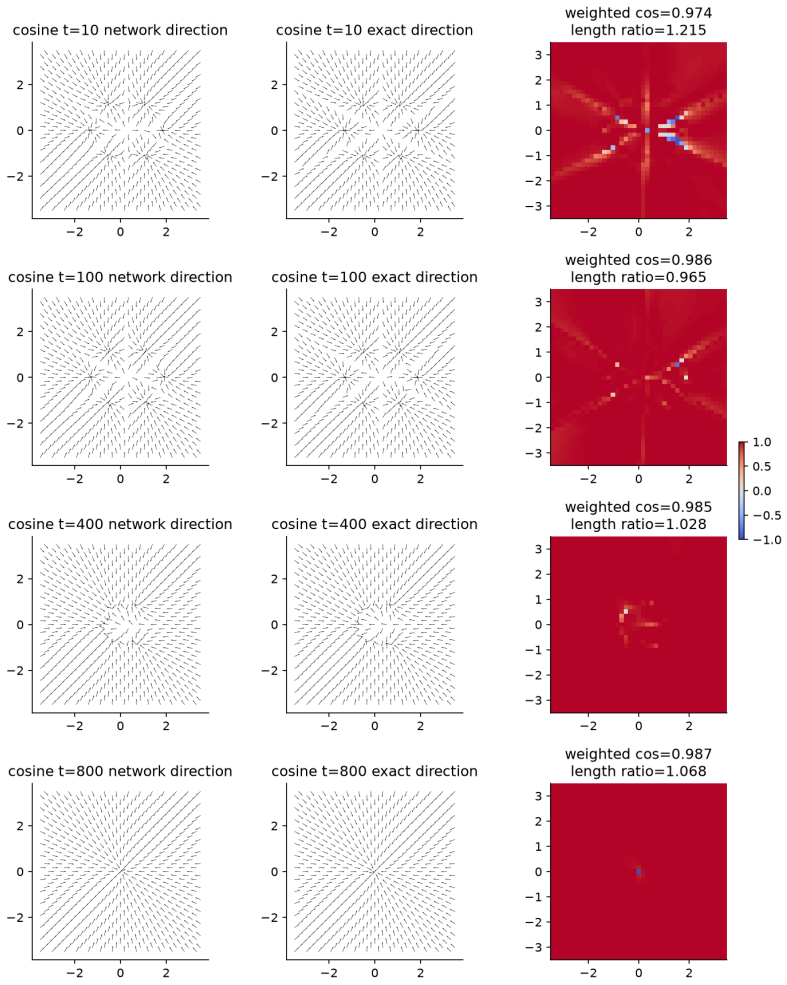


Рис. 9 – Cosine: аналогичная диагностика с весами вероятностной массы.

Косинусы высоки, но отношение длин не всегда близко к 1: например linear t=800 даёт 1.602079. Вероятностные веса p_t предотвращают преобладание пустых областей над выводом о поле.

Таблица 6 – Доля 1000 траекторий DDPM, направленных к итоговой моде.

t/T	Linear	Cosine
0.8	0.155	0.285
0.6	0.197	0.416
0.4	0.336	0.667
0.2	0.67	0.943
0.05	0.989	0.991

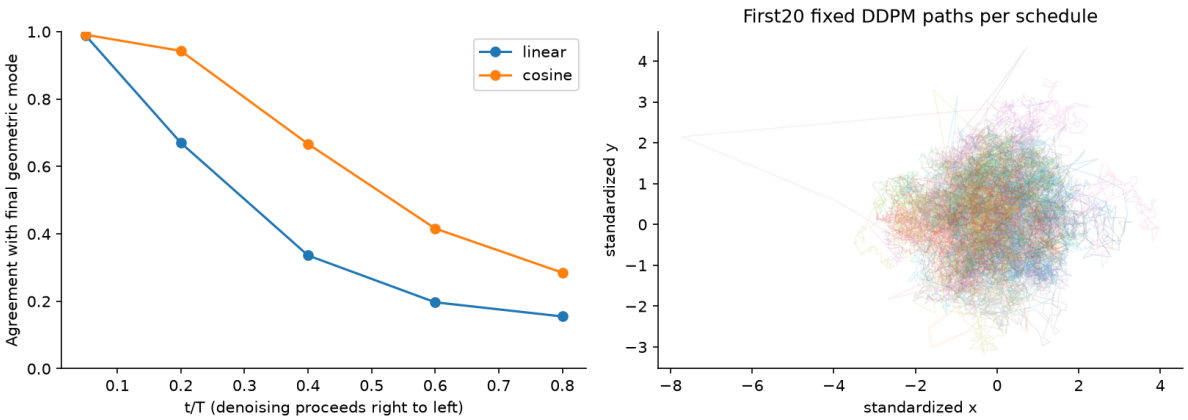


Рис. 10 – 1000 DDPM-траекторий и постепенное формирование моды.

Начальные шумы фиксированы, для каждой модели сохранено 1000 полных DDPM-траекторий (R31 / R32). Ближайший масштабированный центр сравнивается с финальной модой. У linear выбор формируется позднее по индексу t, чем у cosine; индексы соответствуют разным SNR. Рост согласия постепенный, единственный универсальный момент выбора не установлен.

5. E3. Покрытие редкой моды

A — linear DDPM, T=1000, posterior variance; B — DDIM K=50, eta=0 на тех же весах. Единственный фактор — конфигурация обратного сэмплера. Фиксированы данные, стандартизация, архитектура, полоса, обучение и общий x_T. До дополнительных seed предсказан отрицательный знак $Dmode(A) - Dmode(B)$ из-за дискретизационной ошибки малого K; отсутствие устойчивого отрицательного различия опровергло бы прогноз. Seed 1 явно повторно использует E1/E2, seed 2 и 3 проведены после фиксации гипотезы.

Таблица 7 – E3: A — DDPM T, B — DDIM 50; общая linear-сеть внутри seed.

Seed	Arm	Cov	$\hat{p}_0$	D_{mode}	MMD^2	Ист.
1	A	1.0	0.0238	0.05625	0.00217049	R03
1	B	1.0	0.0320	0.09245	0.00668209	R07
2	A	1.0	0.0176	0.02143	0.00049002	R23
2	B	1.0	0.0146	0.06917	0.00150298	R24
3	A	1.0	0.0300	0.02502	0.00040347	R25
3	B	1.0	0.0308	0.07214	0.00142802	R26

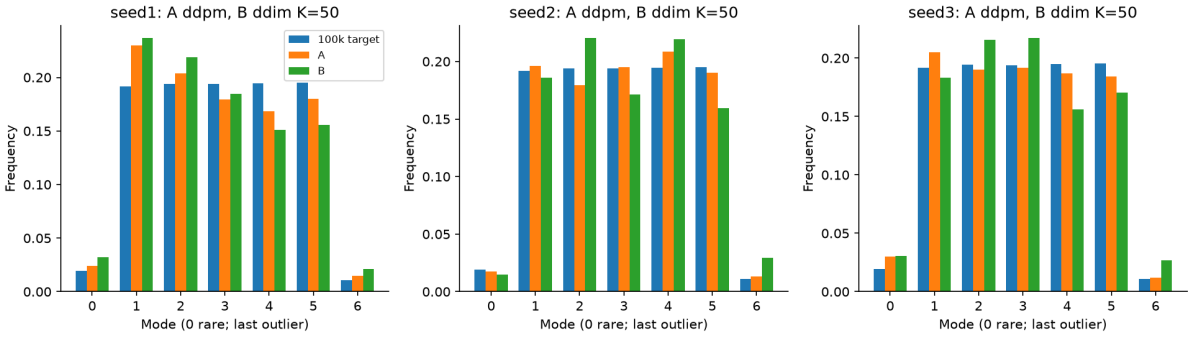


Рис. 11 – E3: полные частоты шести мод и внешней категории; linear, DDPM T / DDIM 50 eta=0.

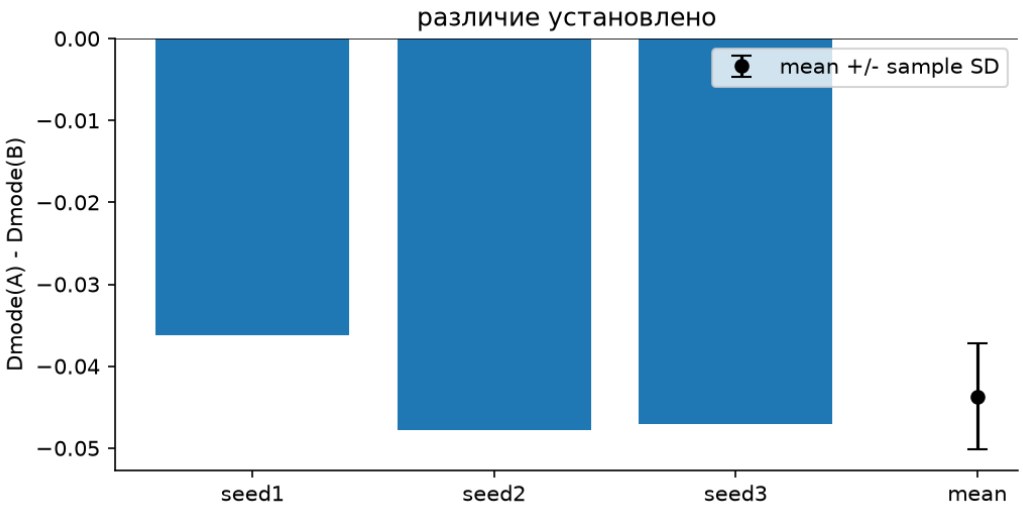


Рис. 12 – Три парные разности Dmode: DDPM минус DDIM 50.

Три разности $-0.03620, -0.04774, -0.04712$, среднее -0.043686667, выборочное SD 0.006491050. Знаки одинаковы, модуль среднего выше $2s_\Delta = 0.012982101$ и шума Dmode=0.009434: различие установлено в пользу A, гипотеза поддержана. Все редкие частоты превышают $\pi_0/2 = 0.01$. Смена seed не переносит вывод на другие цели.

Таблица 8 – Новый target и полное обучение A при уменьшенном весе редкой моды.

π_0	Train: компонент 0	$\hat{p}_0$	Cov	D_{mode}	Ист.
0.01	199	0.0102	1.0	0.05335	R27
0.005	113	0.0050	1.0	0.05564	R28

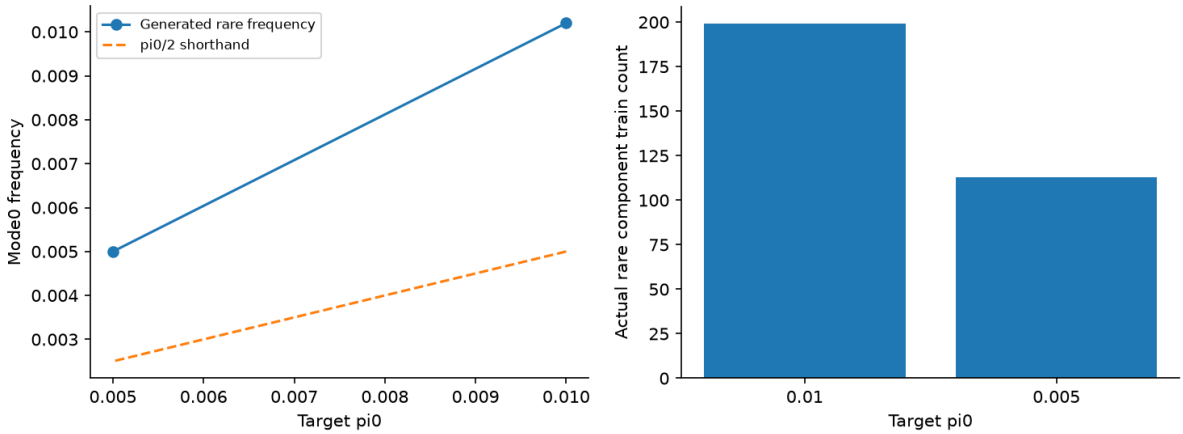


Рис. 13 – Дополнительные A-модели с pi0/2 и pi0/4; linear DDPM T.

Для каждого меньшего веса созданы новые train/val/test, заново рассчитаны train-статистики и обучена отдельная A-модель полные 20 000 шагов. При $\pi_0 = 0.01$ и 0.005 редкая мода остаётся покрытой: $\hat{p}_0 = 0.0102$ и 0.0050. Точка потери покрытия в проверенном диапазоне не найдена; неизвестный порог не экстраполируется.

6. Ответы на контрфактические вопросы

Вопрос 1. Десятикратное T

Сохранённое дополнительное обучение при T=10 000 и прежних beta содержит 20 000 обновлений (R33). $\bar{\alpha}_T = 1.146727 \cdot 10^{-44}$, средний условный KL такой же по порядку, против $4.035911 \cdot 10^{-5}$ при T=1000. NFE вырос в 10 раз, медианное время DDPM — в 11.702753 раза. MMD^2 снизилась с 0.002170494 до 0.000369903, Dmode с 0.05625 до 0.02903, Cov=1. Улучшение наблюдалось в одном seed; оно не является необходимым следствием меньшего конечного KL, поскольку меняется и распределение обучающих задач по времени.

Вопрос 2. Нулевой предиктор

Для $\epsilon_\theta = 0$ имеем $v_T = 1$, $v_{t-1} = v_t/\alpha_t + \tilde{\beta}_t$ при $t > 1$, $v_0 = v_1/\alpha_1$ без последнего шума. Расчёт даёт 49 085.039063, реальные 5000 точек — дисперсии 49 473.790459 и 49 843.273129, ошибки 0.792% и 1.545% (R34). Без оценки шума обратная цепь расширяет облако и не направляет его к данным.

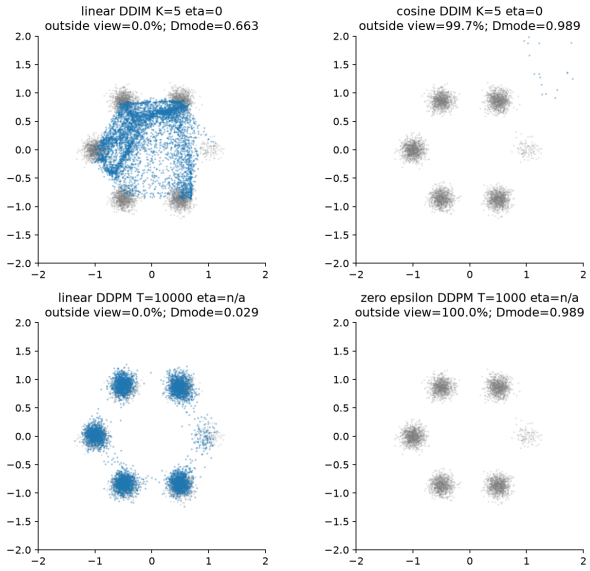


Рис. 14 – Контрфактические оценки: короткое T, десятикратное T и нулевой предиктор.

Вопрос 3. Loss и качество

Linear/cosine val loss 0.408203/0.686859, MMD^2 0.002170494/0.002191699, Dmode 0.05625/0.05185. Linear лучше по численной MMD, cosine по Dmode; различия малы относительно шума. Равномерные t в разных расписаниях дают разные смеси задач: linear имеет 32.6% низкого SNR, cosine 6.4%. Высокий шум облегчает epsilon prediction, но не восстановление x0. Поэтому L_{simple} не заменяет качество и не является точным NLL.

Вопрос 4. Усиление терминальной ошибки

$E_{net}(T)/SNR(T)$ равно 50.122722 для linear и 1 035 399.171539 для cosine. Это MSE относительно точного posterior mean на первом шаге, а не финальная MMD. При DDIM K=5 linear даёт Cov=0.1667, $\text{MMD}^2 = 0.051623$, cosine Cov=0, $\text{MMD}^2 = 0.600008$ (R35). Данные согласуются с сильным усилением ошибки малого SNR; последующие шаги способны частично её исправить, поэтому прямого равенства с финальным качеством нет.

Вопрос 5. Cov недостаточно

Среди формальных E3 с Cov=1 максимальный Dmode=0.09245 у seed 1, B. Частоты мод 0–5 и внешней категории: 0.0320,0.2366,0.2188,0.1844,0.1512,0.1558,0.0212. Мода 4 недооценена на 0.04349, мода 1 переоценена на 0.04490; редкая мода имеет 0.0320 против справочных 0.01931. Дополнительные траектории этой DDIM-конфигурации дают согласия с финальной модой 0.696,0.712,0.783,0.880,0.981 при t=800,600,400,200,60 (для запроса 50 использован ближайший сохранённый tau=60). Cov допускает дисбаланс и внешние точки; нужны полные частоты и Dmode.

Заключение. DDPM точнее по частотам, DDIM 50 быстрее.

Список использованных источников

[1] Лабораторная работа 7. Diffusion и Score-Based Generative Models. Noise schedule, оценка score, численный reverse process и computational trade-offs. Курс «Нейронные сети». Методические указания, 2026.

Приложение. Идентификация запусков

Таблица 9 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R01	E1 linear	6166b1c66f39bc269e25-5caf87cfcdea4065acccb5837a8371c4
R02	E1 cosine	2db3dda8cd907b076db0-f602c1d1c4e643fdb23d079baf92c928
R03	E2 network ddpm K1000	deed2ad27ea6dc9b82a2-9bde9515fc6f4be4b836698669d64ef6
R04	E2 network ddim K5	8bb864eb20b7936a8893-0029cd3498bd4a598bf5fe81e3e428f5
R05	E2 network ddim K10	9db76aabb6e8383c4b82-084d6fec26054359b64c0b8ddc79a3a4
R06	E2 network ddim K20	4f2b4ed83734347bcc82-3bde0c5c0f674beead091bc398cc0951
R07	E2 network ddim K50	a1bee33a693a2f0588bb-59d9b1c17aab43d9b3a85c3b6e9aa76d
R08	E2 network ddim K100	29aec0ea2f756acc6639-1de816295c7a472d9cdbd69b2d37f74a
R09	E2 network ddim K1000	0fbd4ffcb74fc35a520b-b72ba38fc00d4ee1991e8673c276ae66
R10	E2 exact ddpm K1000	2fe25d54fee39b604917-ef345080701c4b2895cdc6b24f7c10c7
R11	E2 exact ddim K5	622bdc881ca8055f1b01-d6ac5cef7b8d4357b9aa03ce48cb4f7e
R12	E2 exact ddim K10	5fa6c52f7d8adf496252-e8beab3114bc446b922737116479b82b
R13	E2 exact ddim K20	a875b6acfd5af99091f2-8bcb24336fa6418c8bbfd1ff3757cf1e
R14	E2 exact ddim K50	0f83221e00b224e1a376-0bba1a3a83584af2b79bd4ecf27b6ef1
R15	E2 exact ddim K100	df097c5a7198a8b3c28a-30d04405ad0e44aeaba848cd03631704
R16	E2 exact ddim K1000	44630ed4fab7291adb68-9bbb419ea8b040778ef10fa9e5c40405
R17	lowK network K1	66c8b48041c5283a85d1-efd774427a9944d7891b459215d5091b
R18	lowK network K2	251b7fcad9e3cd7d22ed-61674e24f2594f1f804bea5acc1f02df
R19	lowK exact K1	fcb808b60bd0ce223fc2-702c82c1f041441782ffdc4f89af2ca8
R20	lowK exact K2	e32a84e7e0024abc2a2e-0283fb99577d4db49c7f51f90a73d0ee
R21	diagnostics linear	2eab682c97301a2c54f9-fea523703ac945e2b8e2eead483c933b
R22	diagnostics cosine	15091763c37a105f0965-345f5eb681694ccb9ceb9949489df73d
R23	E3 A s2	250c19ef7ca7b9338b63-4f723f99f0904780a4b7afeb083bb9b8
R24	E3 B s2	7312b330f611f76c8e21-a0ad8fecfe1a44d68d0c19e4c31292db
R25	E3 A s3	e9dc77c09db6e8a2e9e9-d3abdfee6d00443d82c09e1339d720ea
R26	E3 B s3	c96d001bc559c4c4d5e3-3577f31765e5485e8f0eb3eae5e874c3
R27	rare pi0.01	f5f2a7bcf9309844bda6-b981d028081d4e7fa64113cd5f11d596
R28	rare pi0.005	decd3af863ab72e6f11f-c6044dd606c64bfe84e128a774e2ebf4
R29	E1 forward moments	000d770a472366d3977b-7a3ea9b86ef64583b908895f787ec050
R30	T100 exact DDPM	3500712e1f9546c4fd3a-5b44110051804e37ac2ed9be2c34f09d
R31	DDPM trajectory linear	3c55407c6814cc043462-6ad641b2543442c9a3c1228945d91438
R32	DDPM trajectory cosine	45945a99cc56d483caa0-48f7849726024e5e8efcf613420e64ad
R33	CF1 T10000	5ae7726298f578610804-3d602c10e8c34e5a9963b3c1d409b136
R34	CF2 zero predictor	476f26ebdc21b7ee2c74-2d138b6540c54eee9497364bc4c6e39e
R35	CF4 cosine K5	62c7f506ef8820f3492a-948a92e6a72f4c02bd54d3d5458ab738