МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Инженерная школа информационных технологий и робототехники
Направление 09.04.01 «Информатика и вычислительная техника»
Отделение информационных технологий

Лабораторная работа № 8

«Когда предсказанию сети можно доверять
Надёжность, калибровка и неопределённость»

по дисциплине «Нейронные сети»

Выполнил:
студент гр. 8ВМ53 _____ Ван Чжаофу

Проверил:
_____ Григорьев Д. С.

Томск – 2026

Содержание

1 Профиль и протокол 3

2 E1. Калибровка и температура 4

3 E2. Перенос температуры на искажённые данные 5

4 E3. Состязательные возмущения 10

5 Профиль надёжности: отказ и OOD 12

6 Ответы на контрфактические вопросы 14

Список использованных источников 15

Приложение. Идентификация запусков 16

1. Профиль и протокол

1.1. Цель и определения

Цель — оценить, когда уверенность замороженной модели соответствует ошибкам и где она перестаёт быть надёжной [1]. Accuracy и калибровка — разные свойства. Для вероятностей $p = \mathrm{softmax}(z)$ уверенность $conf = \max_c p_c$, а калибровка требует $P(\hat{Y} = Y \mid conf = p) = p$. Использованы

$$ECE = \sum_m \frac{|B_m|}{N} |acc(B_m) - conf(B_m)|, \quad NLL = -\frac{1}{N} \sum_i \log p_{y_i},$$
$$BS = \frac{1}{N} \sum_{i,c} (p_{ic} - 1[y_i = c])^2. \tag{1}$$

ECE зависит от интервалов и учитывает верхнюю вероятность; NLL и Brier используют весь вектор. Пустые интервалы не дают определённой accuracy и исключаются из суммы.

Температура $p^{(T)} = \mathrm{softmax}(z/T)$ при $T > 0$ сохраняет argmax, но меняет вероятности. $\ln T$ минимизирует NLL только на val, с кандидатом T=1. Основные меры неопределённости, больше означает менее уверенно:

$$U_{MSP} = 1 - \max_c p_c, \qquad H = -\sum_c p_c \ln p_c, \qquad U_{margin} = 1 - p_{(1)} + p_{(2)}. \tag{2}$$

1.2. Данные, модели и искажения

Профиль: CNN, основное искажение occlusion, PGD $\epsilon = 2/255$. ECE: 15 интервалов равной ширины. Использованы сохранённые модели ЛР2, обученные на 2150 train-изображениях (доля 0.05) за 10 000 обновлений. Для CNN имеются три подлинных seed, поэтому test не делится на псевдонезависимые seed. ViT seed 1 служит вторым архитектурным ориентиром. Новые классификаторы не обучаются.

Таблица 1 – Использованные источники моделей ЛР2: доля train 0.05, 10 000 обновлений.

Модель	Seed	Архитектура	Источник
CNN	1	ResNet-18	R01
CNN	2	ResNet-18	R02
CNN	3	ResNet-18	R03
VIT	1	ViT P4 D384	R04

CIFAR-10: train 43 000, val 5000, cal 2000, test 10 000. Нормализация взята из train ЛР2 и применяется ровно один раз. T подбирается на val; cal не используется, поскольку дополнительное conformal prediction не выполняется. Все атаки и оценки используют общий полный test. Устройство — RTX 3060 Laptop. Для semantic OOD использован полный test SVHN, 26 032 изображения, без смысловых меток цифр.

Реализованы пять локальных параметризованных искажений уровней 0–5. Gaussian noise: std 0,0.04,0.06,0.08,0.09,0.10; Gaussian blur: sigma 0,0.4,0.7,1.0,1.3,1.6; brightness: множители 1,1.15,1.30,1.45,1.60,1.75; contrast: 1,0.8,0.6,0.4,0.2,0.1; occlusion:

доля площади 0,0.1,0.2,0.3,0.4,0.5. Это явные локальные приближения, а не сертифицированная реализация CIFAR-10-C. Они работают до нормализации в RGB [0,1], сохраняют форму и метку; уровень 0 тождественный.

2. E1. Калибровка и температура

Таблица 2 – E1: чистый test; ECE — 15 интервалов равной ширины.

Модель	T	Accuracy	Conf.	ECE	NLL	Brier	Пусто	Ист.
CNN	1.00000	0.70740	0.92225	0.21485	1.64031	0.49371	3	R05
CNN	2.95638	0.70740	0.72477	0.02842	0.90976	0.40894	2	R05
VIT	1.00000	0.45020	0.91751	0.46731	4.06538	0.98785	4	R06
VIT	4.27331	0.45020	0.49568	0.06678	1.67486	0.70922	5	R06

Все 10 000 предсказанных классов каждой модели сохранены: разность accuracy равна нулю. CNN val NLL уменьшилась с 1.602649 до 0.890119. На test обе модели улучшили ECE, NLL и Brier. До масштабирования CNN одновременно точнее и лучше откалибрована; после него порядок сохраняется. Это наблюдаемая связь двух моделей, а не тождество точности и калибровки.

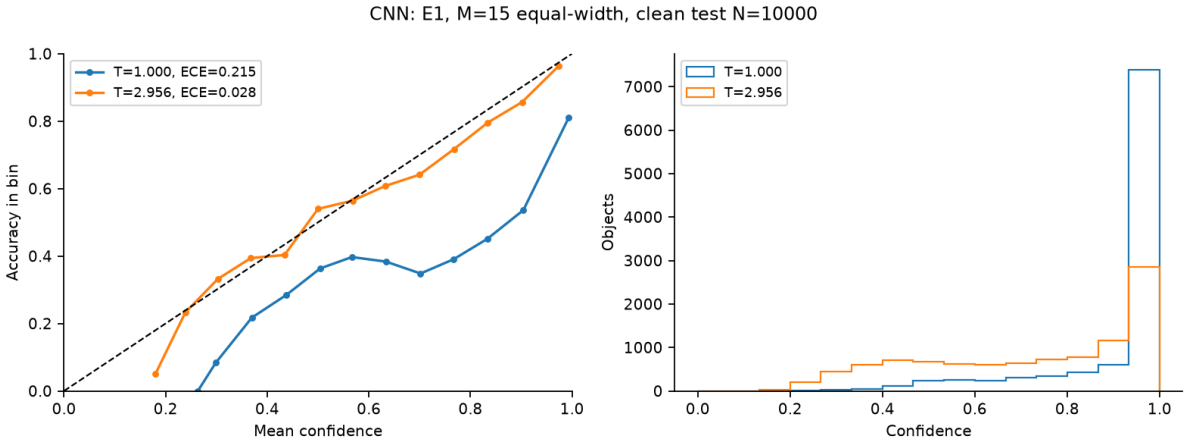


Рис. 1 – CNN: reliability diagram и confidence до/после T*=2.956378; ECE 15 equal-width.

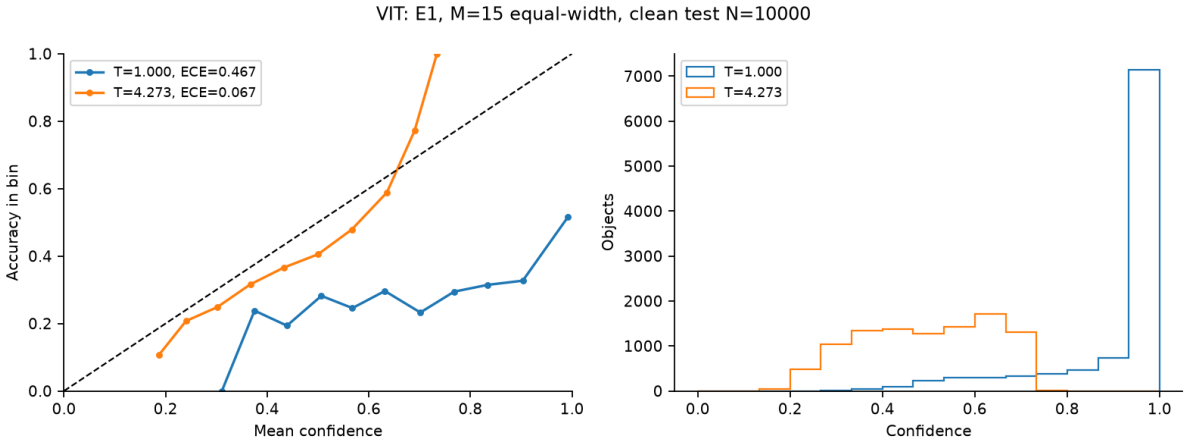


Рис. 2 – ViT: аналогичная оценка, T*=4.273313, ECE 15 equal-width.

Таблица 3 – Граница E1: другие схемы ECE, те же предсказания.

Модель	M	Интервалы	T	ECE	Пусто
CNN	5	равной ширины	1.0000	0.214846	1
CNN	50	равной ширины	1.0000	0.214846	13
CNN	15	равное число	1.0000	0.214846	0
CNN	5	равной ширины	2.9564	0.023358	0
CNN	50	равной ширины	2.9564	0.029443	8
CNN	15	равное число	2.9564	0.026857	0
VIT	5	равной ширины	1.0000	0.467313	1
VIT	50	равной ширины	1.0000	0.467313	13
VIT	15	равное число	1.0000	0.467313	0
VIT	5	равной ширины	4.2733	0.050628	1
VIT	50	равной ширины	4.2733	0.070663	20
VIT	15	равное число	4.2733	0.067447	0

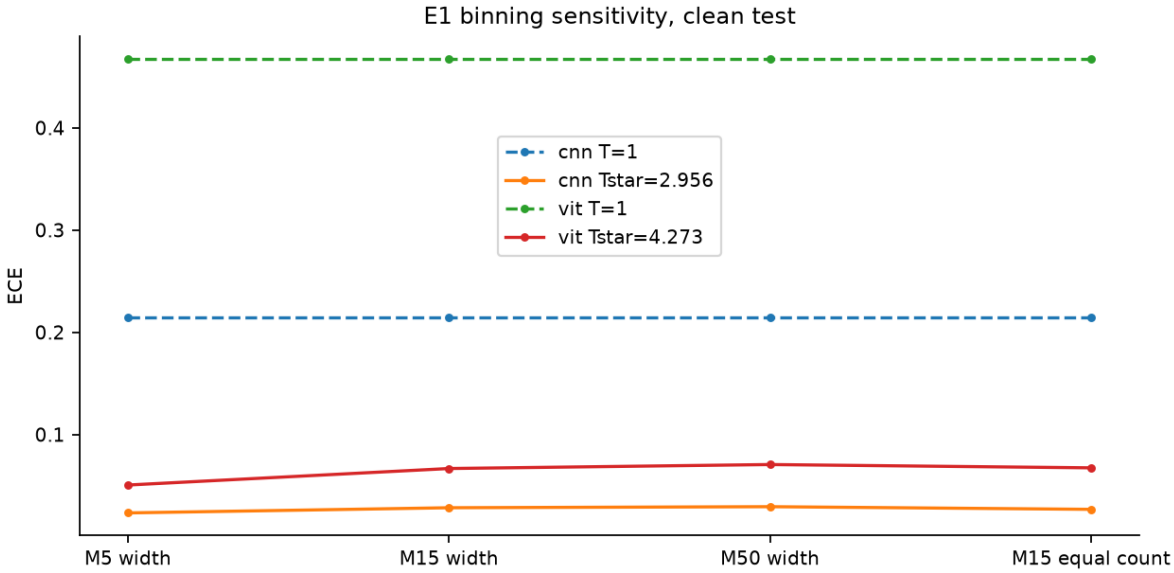


Рис. 3 – ECE при изменении схемы интервалов для обеих моделей.

Вывод о снижении ECE сохраняется при 5 и 50 интервалах равной ширины и при 15 интервалах с равным числом объектов. Значения при разных схемах сравниваются только внутри одной схемы. Они не доказывают идеальную калибровку каждого отдельного класса или объекта.

3. E2. Перенос температуры на искажённые данные

CNN seed 1 исследована при всех пяти типах и шести уровнях; веса и T* с чистой val фиксированы. В таблице значения после масштабирования помечены индексом T. Accuracy одинакова при обеих температурах.

Таблица 4 – E2: CNN seed 1, общий test; индексы 1 и T обозначают температуры 1 и T^*.

Искажение	ℓ	Acc.	$Conf_1$	$Conf_T$	ECE_1	ECE_T	NLL_1	NLL_T
Шум	0	0.7074	0.9222	0.7248	0.2148	0.0284	1.6403	0.9098
Шум	1	0.6834	0.9140	0.7082	0.2306	0.0299	1.7810	0.9800
Шум	2	0.6452	0.9074	0.6890	0.2622	0.0444	2.0642	1.1025
Шум	3	0.5926	0.8974	0.6661	0.3048	0.0746	2.4767	1.2743
Шум	4	0.5597	0.8938	0.6561	0.3341	0.0964	2.7234	1.3726
Шум	5	0.5284	0.8899	0.6470	0.3615	0.1188	2.9892	1.4759
Размытие	0	0.7074	0.9222	0.7248	0.2148	0.0284	1.6403	0.9098
Размытие	1	0.7004	0.9192	0.7197	0.2188	0.0265	1.6694	0.9256
Размытие	2	0.5841	0.8984	0.6679	0.3151	0.0840	2.4963	1.2734
Размытие	3	0.4369	0.8781	0.6172	0.4412	0.1816	3.8016	1.7857
Размытие	4	0.3211	0.8703	0.5938	0.5492	0.2728	4.9671	2.2141
Размытие	5	0.2668	0.8637	0.5781	0.5969	0.3113	5.5802	2.4465
Яркость	0	0.7074	0.9222	0.7248	0.2148	0.0284	1.6403	0.9098
Яркость	1	0.6942	0.9193	0.7183	0.2251	0.0290	1.7271	0.9480
Яркость	2	0.6738	0.9136	0.7030	0.2398	0.0385	1.9023	1.0289
Яркость	3	0.6322	0.9059	0.6840	0.2741	0.0519	2.1684	1.1456
Яркость	4	0.5913	0.8973	0.6650	0.3061	0.0739	2.4919	1.2815
Яркость	5	0.5507	0.8909	0.6481	0.3402	0.0974	2.8553	1.4281
Контраст	0	0.7074	0.9222	0.7248	0.2148	0.0284	1.6403	0.9098
Контраст	1	0.6946	0.9162	0.7123	0.2218	0.0286	1.6995	0.9460
Контраст	2	0.6348	0.8984	0.6691	0.2639	0.0364	2.0089	1.1116
Контраст	3	0.4779	0.8648	0.5909	0.3871	0.1130	3.0512	1.5797
Контраст	4	0.2040	0.8468	0.5483	0.6428	0.3443	6.4212	2.7752
Контраст	5	0.1524	0.8479	0.5297	0.6955	0.3773	7.7569	3.2450
Закрытие	0	0.7074	0.9222	0.7248	0.2148	0.0284	1.6403	0.9098
Закрытие	1	0.6301	0.8940	0.6567	0.2639	0.0332	2.0049	1.1311
Закрытие	2	0.5343	0.8647	0.5873	0.3304	0.0530	2.5039	1.4081
Закрытие	3	0.3911	0.8200	0.5066	0.4289	0.1155	3.3605	1.8285
Закрытие	4	0.3230	0.7954	0.4676	0.4724	0.1446	3.7742	2.0323
Закрытие	5	0.2447	0.7528	0.4133	0.5081	0.1686	4.3104	2.3025

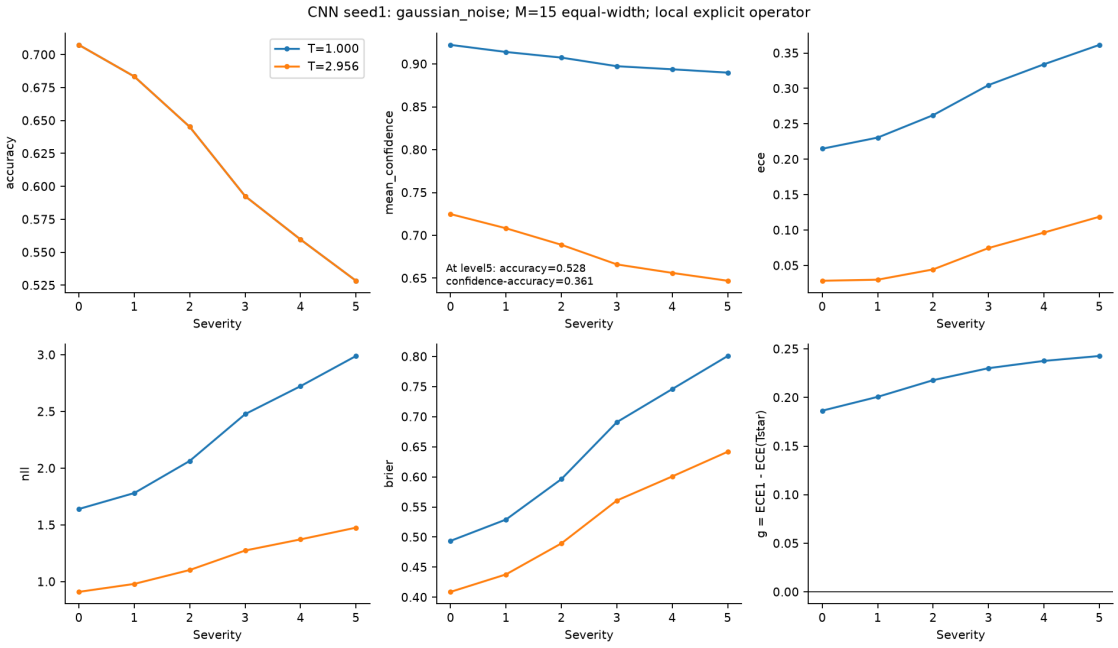


Рис. 4 – E2: Шум, CNN seed 1; ECE 15 equal-width, T=1 и T*=2.956378.

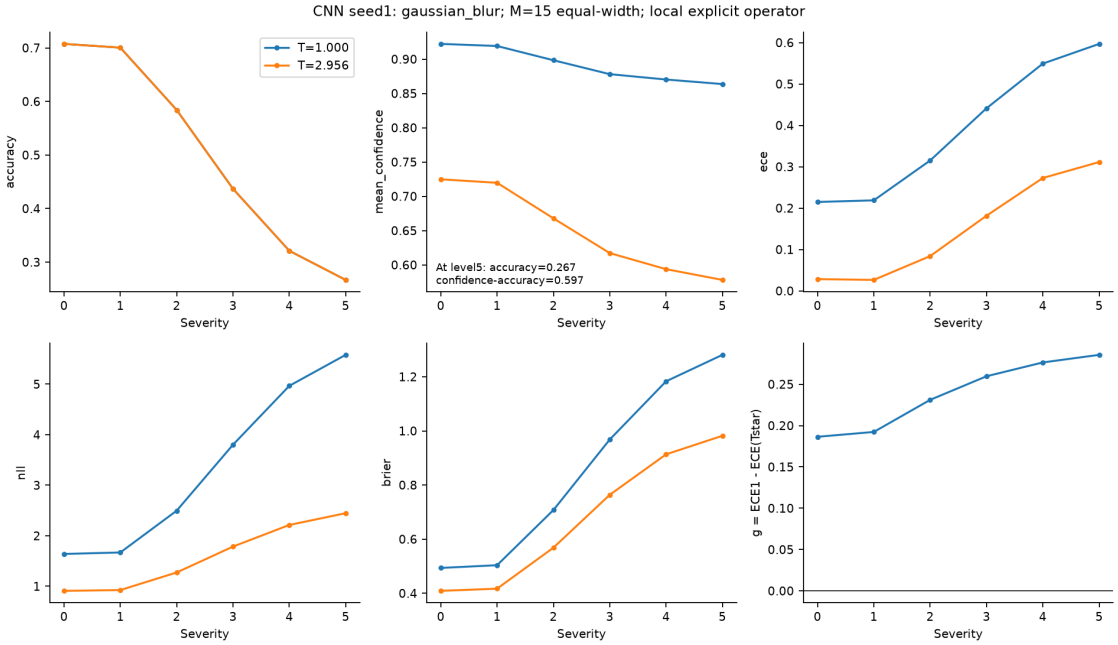


Рис. 5 – E2: Размытие, CNN seed 1; ECE 15 equal-width, T=1 и T*=2.956378.

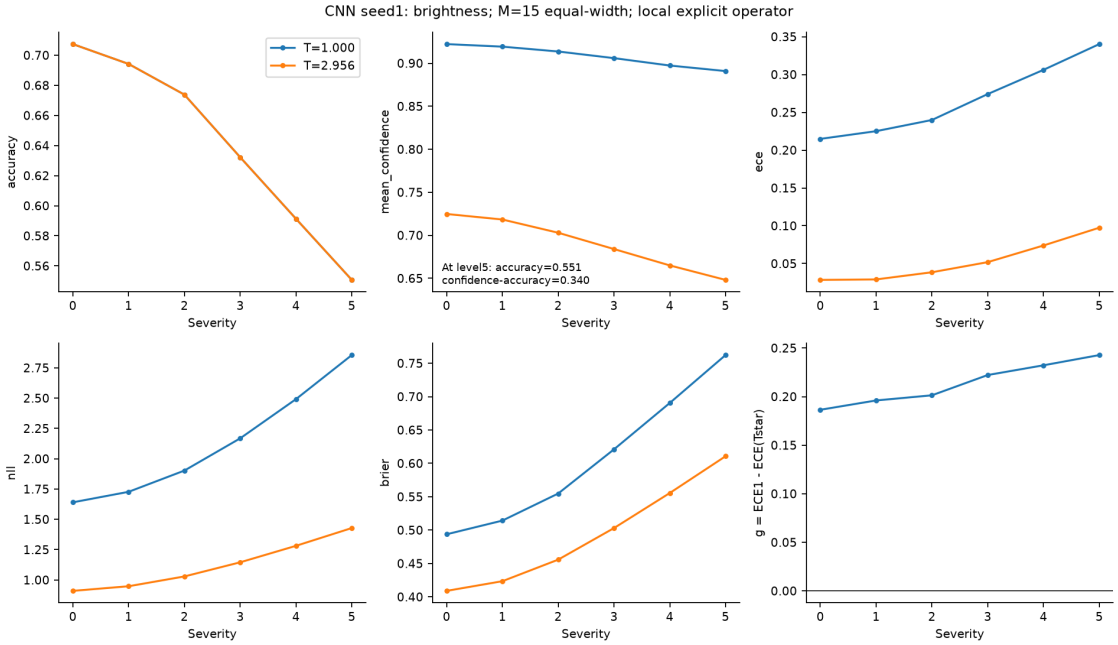


Рис. 6 – E2: Яркость, CNN seed 1; ECE 15 equal-width, T=1 и T*=2.956378.

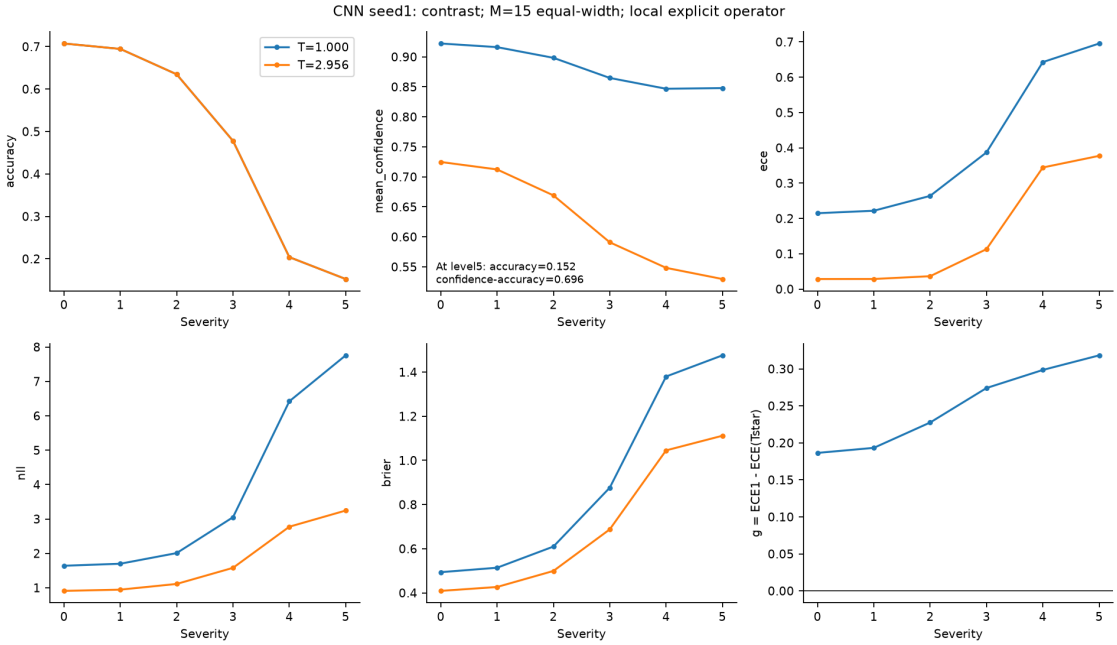


Рис. 7 – E2: Контраст, CNN seed 1; ECE 15 equal-width, T=1 и T*=2.956378.

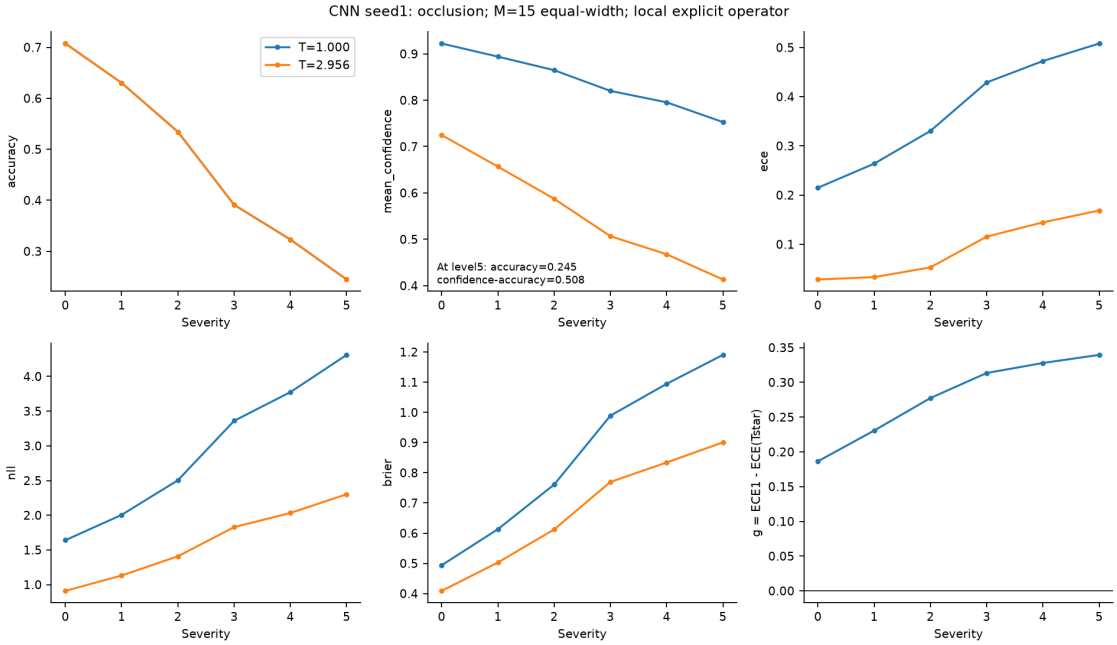


Рис. 8 – E2: Закрытие, CNN seed 1; ECE 15 equal-width, T=1 и T*=2.956378.

При occlusion5 accuracy падает с 0.7074 до 0.2447, тогда как исходная confidence — с 0.922246 до 0.752771. Модель становится гораздо менее правильной, оставаясь уверенной. Температура смягчает overconfidence, но не восстанавливает классы.

До основного сравнения ожидалось $\Delta_s = g_A(s) - g_B(s) > 0$, где $g = ECE_1 - ECE_{T^*}$, A — clean, B — occlusion5. Единственный фактор пары — входное условие; для каждого seed одна модель и T*, подобранная на его чистой val. Три исходных checkpoint задают вариативность обучения, а не случайное разбиение test.

Таблица 5 – Основное сравнение E2: выигрыш температуры на clean минус occlusion5.

Seed	T^*	g_A	g_B	Δ_s	Ист. clean/shift
1	2.956378	0.186429	0.339474	-0.153045	R05/R07
2	3.103821	0.203712	0.362654	-0.158942	R08/R09
3	3.114989	0.189247	0.363411	-0.174164	R10/R11

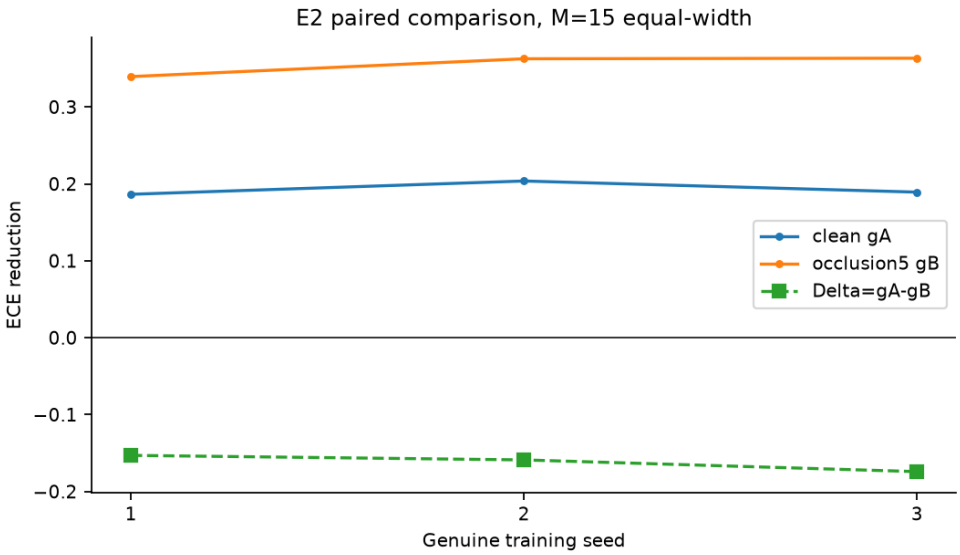


Рис. 9 – Три парные разности E2; положительный знак ожидался до измерения.

Все разности отрицательны, среднее -0.162050322, выборочное SD 0.010897215; модуль среднего превышает $2s_\Delta = 0.021794431$. Установлен обратный вывод: в этих условиях абсолютный выигрыш температуры больше на сильном искажении. Предположение о порядке выигрышей опровергнуто. Причина согласуется с намного большей исходной избыточной уверенностью на искажении. При этом итоговая ECE после T* на occlusion5 0.168598 хуже clean 0.028418, так что больший выигрыш не означает лучшую конечную калибровку.

На исследованной сетке ни одного $g \leq 0$ не найдено. Граница отсутствия пользы температуры лежит вне измеренных условий, если она существует. Для известного сдвига отдельно подобрана $T_5 = 6.108734$ на occlusion5 val.

Таблица 6 – Температура, подобранная на corrupted val, и её перенос на два test-условия.

Test	T	Accuracy	Conf.	ECE	NLL	Brier	Пусто
clean	1.00000	0.70740	0.92225	0.21485	1.64031	0.49371	3
clean	2.95638	0.70740	0.72477	0.02842	0.90976	0.40894	2
clean	6.10873	0.70740	0.44196	0.26552	1.16225	0.49697	1
shift5	1.00000	0.24470	0.75277	0.50807	4.31040	1.19033	2
shift5	2.95638	0.24470	0.41329	0.16860	2.30249	0.90077	2
shift5	6.10873	0.24470	0.23413	0.02918	2.14317	0.85721	5

4. E3. Состязательные возмущения

Атаки максимизируют CE исходной модели T=1 в eval. FGSM делает $x_{adv} = \Pi_{[0,1]}[x + \epsilon \operatorname{sign} \nabla_x L]$. PGD начинает в случайной точке допустимого шара, делает K шагов $\alpha = 2.5\epsilon/K$ и после каждого проецирует на пересечение $[x - \epsilon, x + \epsilon]$ и [0,1]. При R стартах выбирается худший вариант для каждого изображения. Все ограничения заданы в исходных пикселях, параметры модели фиксированы.

Таблица 7 – E3: T=1, один и тот же полный test, 10 000 изображений.

Модель	Атака	255ϵ	K/R	Acc.	Conf.	ECE	Ист.
cnn 1	FGSM	0	1/1	0.70740	0.92225	0.21485	R12
cnn 1	FGSM	1	1/1	0.47210	0.91979	0.44769	R13
cnn 1	FGSM	2	1/1	0.29880	0.92462	0.62592	R14
cnn 1	FGSM	4	1/1	0.12870	0.93452	0.80597	R15
cnn 1	FGSM	8	1/1	0.03440	0.93806	0.90375	R16
cnn 1	PGD	2.0	10/1	0.24580	0.95869	0.71303	R17
cnn 1	PGD	2.0	20/2	0.24310	0.96018	0.71736	R18
cnn 1	random	2.0	/	0.70570	0.92182	0.21612	R19
vit 1	FGSM	0	1/1	0.45020	0.91751	0.46731	R20
vit 1	FGSM	1	1/1	0.21000	0.94867	0.73867	R21
vit 1	FGSM	2	1/1	0.10310	0.96118	0.85808	R22
vit 1	FGSM	4	1/1	0.04030	0.96663	0.92633	R23
vit 1	FGSM	8	1/1	0.01740	0.95602	0.93862	R24
vit 1	PGD	2.0	10/1	0.07600	0.98578	0.90978	R25
vit 1	PGD	2.0	20/2	0.07540	0.98618	0.91109	R26
vit 1	random	2.0	/	0.44890	0.91775	0.46885	R27

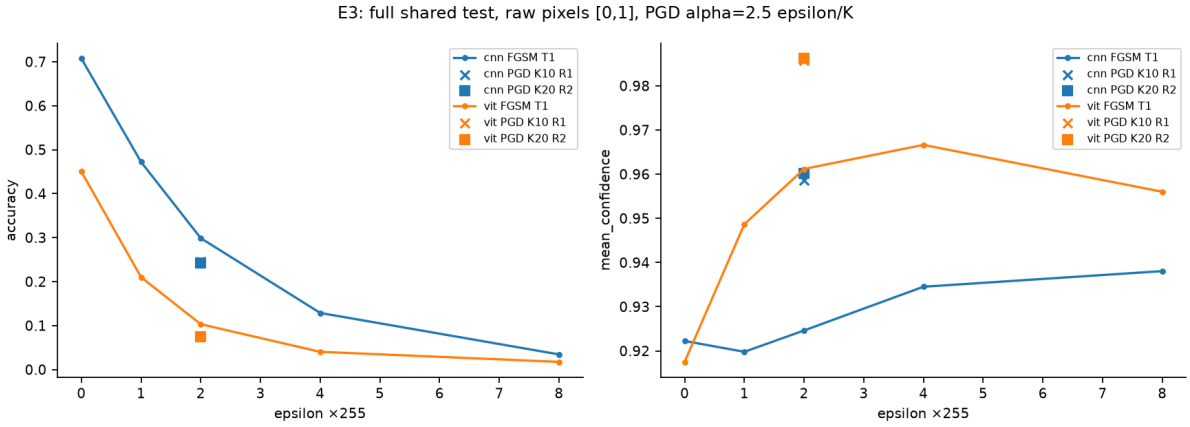


Рис. 10 – FGSM eps=0,1,2,4,8 /255 и PGD eps=2/255, K10 R1 и K20 R2, alpha=2.5 eps/K.

PGD10 даёт accuracy 0.2458/0.0760 для CNN/ViT против FGSM 0.2988/0.1031 при том же $\epsilon = 2/255$. Усиление до K20,R2 снижает их до 0.2431/0.0754: десять шагов ещё не дали окончательной оценки. Во всех реальных примерах и шагах PGD выполнены Linf и диапазон; при нулевом epsilon результат совпадает с чистым test.

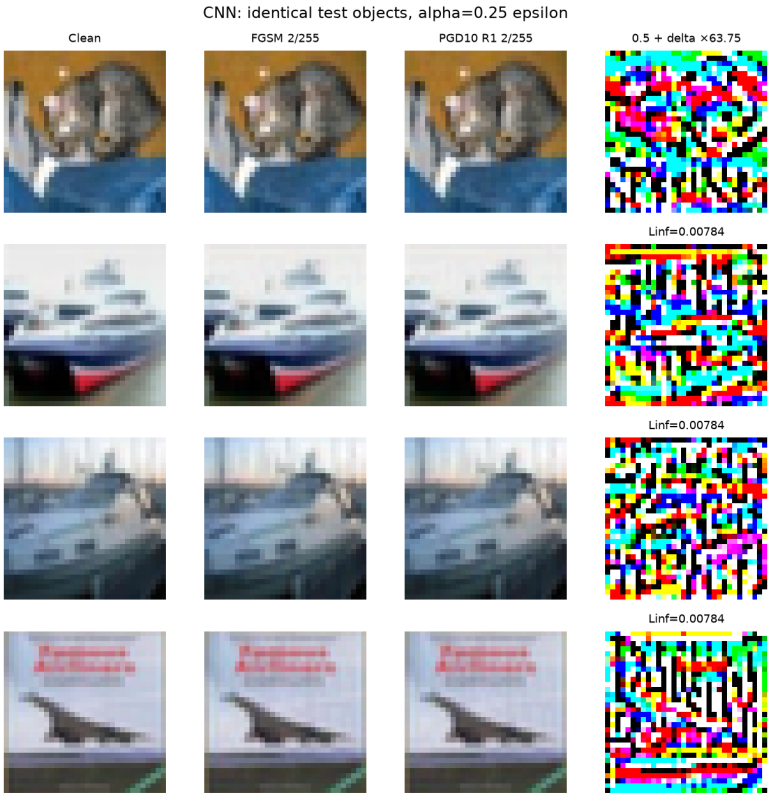


Рис. 11 – CNN: исходные и атакованные изображения, усиленное возмущение и его Linf-норма.

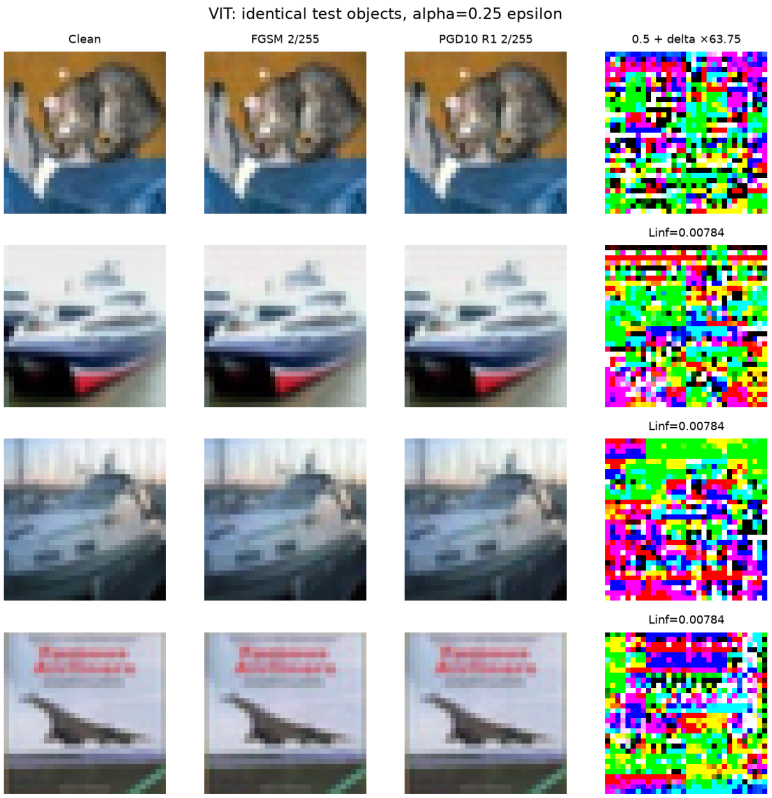


Рис. 12 – ViT: соответствующие примеры на тех же test ID.

Точность под конкретной атакой — верхняя оценка устойчивости к наихудшему допустимому возмущению. Она не является сертификатом против любых атак. Высокая confidence после атаки может сопровождать почти всегда неверный класс.

5. Профиль надёжности: отказ и OOD

Модель отвечает при $U \leq \tau$. Coverage — доля принятых, risk — доля ошибок среди них. При нулевом coverage риск не определён. AURC — средний накопленный риск при сортировке U по возрастанию. Вместе с AURC показан избыток над oracle, ставящим ошибки в конец; это учитывает различную исходную accuracy моделей.

В OOD-задаче положительный класс — SVHN. AUROC оценивает вероятность большего U у OOD с половинным весом ties; FPR95 — доля ID, отклонённых при обнаружении не менее 95% OOD. AUPR зависит от доли OOD: здесь $26032/(26032 + 10000) = 0.72247$. Смысловые метки SVHN не используются.

Таблица 8 – Selective и semantic OOD: меньше AURC и FPR95, больше AUROC/AUPR лучше.

Модель	T	Мера	AURC	Избыток	AUROC	AUPR	FPR95
cnn 1	1.000	msp	0.1159	0.0682	0.6741	0.8042	0.7037
cnn 1	1.000	entropy	0.1154	0.0677	0.6730	0.7999	0.7034
cnn 1	1.000	margin	0.1164	0.0687	0.6744	0.8067	0.7042
cnn 1	2.956	msp	0.1150	0.0672	0.6673	0.7935	0.7057
cnn 1	2.956	entropy	0.1164	0.0687	0.6557	0.7777	0.7092
cnn 1	2.956	margin	0.1155	0.0678	0.6724	0.8047	0.7047
vit 1	1.000	msp	0.3931	0.2025	0.5789	0.7600	0.8640
vit 1	1.000	entropy	0.3919	0.2014	0.5803	0.7619	0.8632
vit 1	1.000	margin	0.3947	0.2042	0.5779	0.7591	0.8658
vit 1	4.273	msp	0.3850	0.1945	0.5920	0.7680	0.8530
vit 1	4.273	entropy	0.3825	0.1920	0.6025	0.7729	0.8480
vit 1	4.273	margin	0.3901	0.1995	0.5834	0.7616	0.8572
cnn 2	1.000	msp	0.1251	0.0705	0.6601	0.7981	0.7306
cnn 2	1.000	entropy	0.1245	0.0700	0.6600	0.7957	0.7299
cnn 2	1.000	margin	0.1257	0.0711	0.6597	0.7993	0.7325
cnn 2	3.104	msp	0.1227	0.0681	0.6595	0.7938	0.7286
cnn 2	3.104	entropy	0.1236	0.0690	0.6548	0.7872	0.7308
cnn 2	3.104	margin	0.1240	0.0695	0.6601	0.7991	0.7279
cnn 3	1.000	msp	0.1111	0.0650	0.6396	0.7889	0.7623
cnn 3	1.000	entropy	0.1107	0.0647	0.6396	0.7892	0.7622
cnn 3	1.000	margin	0.1115	0.0655	0.6391	0.7873	0.7619
cnn 3	3.115	msp	0.1100	0.0640	0.6378	0.7864	0.7570
cnn 3	3.115	entropy	0.1117	0.0656	0.6320	0.7820	0.7577
cnn 3	3.115	margin	0.1105	0.0645	0.6392	0.7867	0.7580

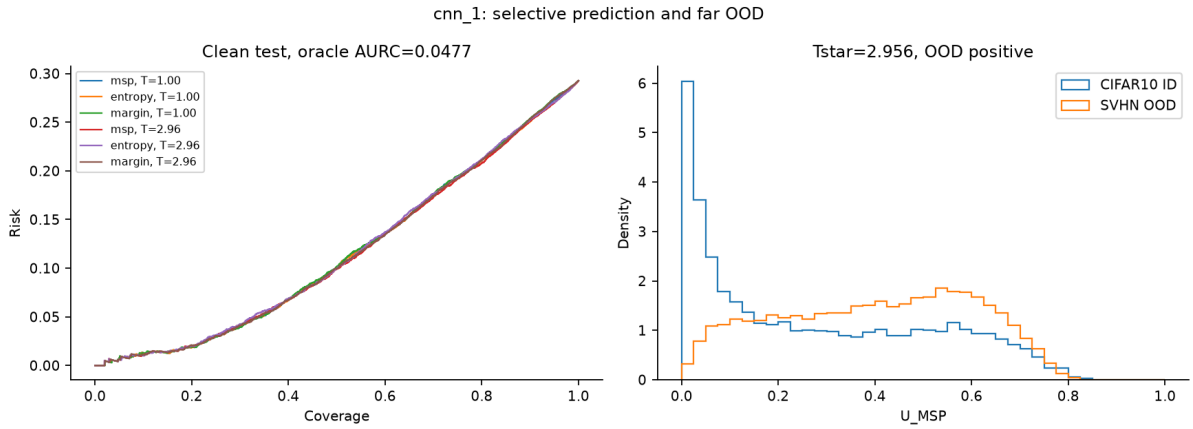


Рис. 13 – CNN seed 1: risk–coverage и OOD при T=1 / T*=2.956378.

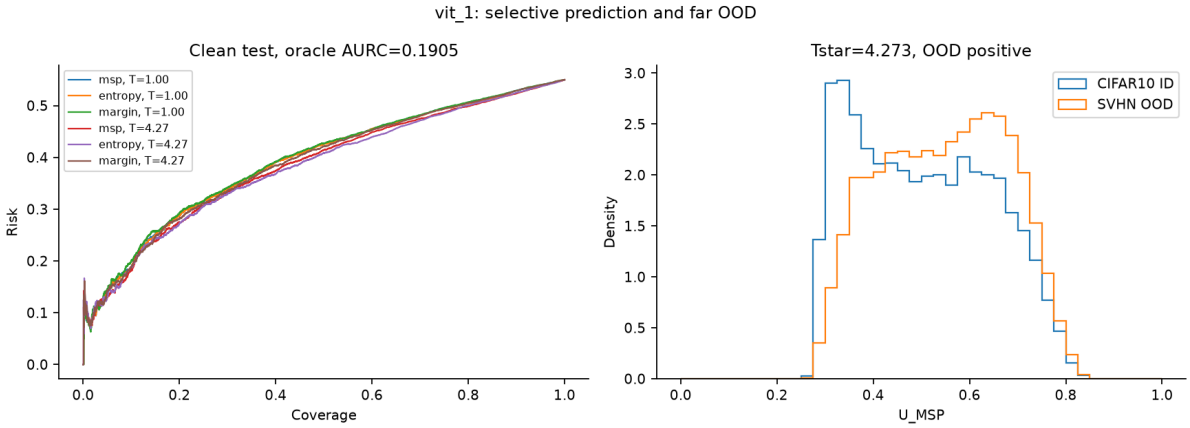


Рис. 14 – ViT seed 1: risk–coverage и OOD при T=1 / T*=4.273313.

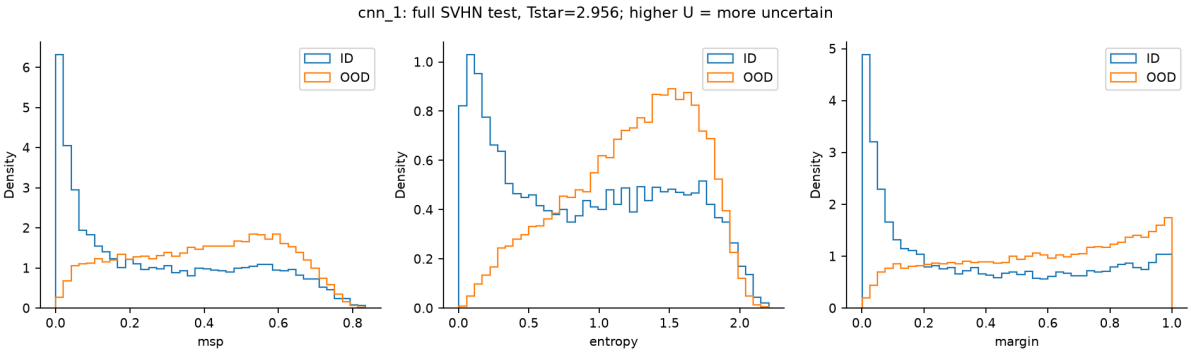


Рис. 15 – Распределения трёх мер неопределённости CNN на CIFAR-10 и SVHN.

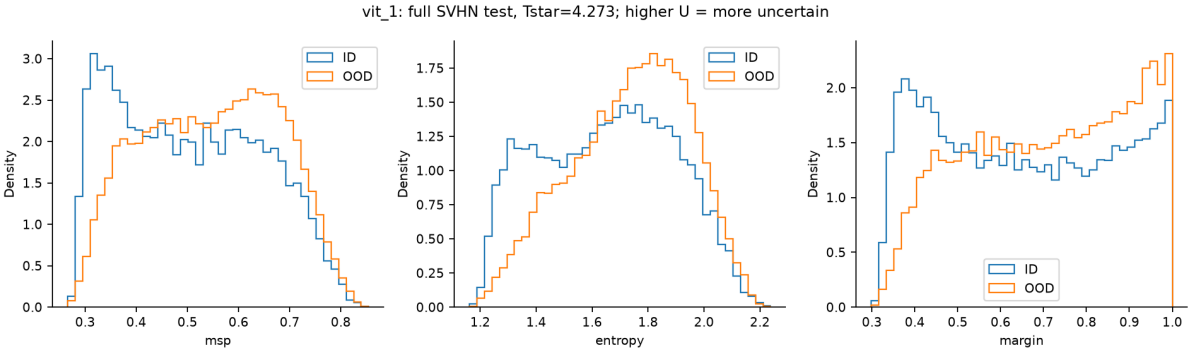


Рис. 16 – Распределения трёх мер неопределённости ViT на CIFAR-10 и SVHN.

Для CNN seed 1 MSP-AURC 0.115934 при oracle 0.047742, после T* 0.114975; AUROC 0.674099 уменьшается до 0.667306. Для ViT AURC 0.393064 уменьшается до 0.385041, AUROC 0.578933 растёт до 0.592006. Хорошая калибровка на clean не обеспечила сильного разделения semantic OOD.

На SVHN accuracy, ECE, NLL и Brier не определены: в десяти классах CIFAR-10 нет правильного класса цифры. В профиле также не заявлены conformal coverage, near-OOD и ансамбль. Оценки относятся к измеренным искажениям, epsilon и далёкому OOD; будущий неизвестный сдвиг не покрыт.

6. Ответы на контрфактические вопросы

Вопрос 1. ECE против NLL и Brier

У CNN изменения после T*: ECE -0.186429, NLL -0.730550, Brier -0.084769; у ViT $-0.400536, -2.390522, -0.278635$. Все улучшились, измеренного контрпримера нет. Теоретически снижение ECE не гарантирует снижения NLL/Brier, поскольку они учитывают разные аспекты вероятностей. Val NLL не растёт из-за целевой минимизации с включённым T=1; на test такой гарантии нет.

Вопрос 2. T5 на clean и shift

Относительно T* температура T5 уменьшает occlusion5 ECE с 0.168598 до 0.029181, NLL с 2.302492 до 2.143172, Brier с 0.900775 до 0.857212. На clean ECE растёт с 0.028418 до 0.265515, NLL с 0.909765 до 1.162255, Brier с 0.408943 до 0.496966. T5 соответствует известному сдвигу, но не является универсальным калибратором. Для будущего неизвестного сдвига такой val заранее нет.

Вопрос 3. Случайный знак при той же норме

При $\epsilon = 2/255$ случайный знак даёт accuracy CNN 0.7057 и ViT 0.4489, FGSM 0.2988/0.1031, PGD10 0.2458/0.0760. Предсказанный порядок random $>$ FGSM $\geq$ PGD подтвердился на общих ID. Случайное направление не согласовано с градиентом CE, тогда как FGSM максимизирует линейное приближение; одна норма не определяет вред возмущения.

Вопрос 4. Температура и уверенные ошибки

На FGSM $2/255$ CNN confidence меняется 0.924621 $\rightarrow$ 0.717081, ECE 0.625821 $\rightarrow$ 0.418460; ViT 0.961179 $\rightarrow$ 0.572030, ECE 0.858079 $\rightarrow$ 0.468930. Изменённых предсказаний и исправленных ошибочных классов нет. Температура корректирует вероятности, а не классификационное решение.

Вопрос 5. Ранжирование объектов

MSP-AURC и AUROC до/после приведены в профиле. Позиции в сортировке ID изменились у 9973 объектов CNN и 9981 ViT, классы — у нуля. Температура сохраняет порядок логитов внутри изображения, но не обязана сохранять порядок максимальных вероятностей между изображениями. Инвариантность AUROC относится к строго возрастающему преобразованию уже готового скалярного U, а softmax(z/T) не является одним таким преобразованием MSP для всех векторов z.

Заключение. Температура улучшила калибровку, но не исправила классы и не гарантировала надёжность при сдвиге.

Список использованных источников

[1] Лабораторная работа 8. Когда предсказанию сети можно доверять. Надёжность, калибровка и неопределённость. Курс «Нейронные сети». Методические указания, 2026.

Приложение. Идентификация запусков

Таблица 9 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R01	Lab2 cnn 1	8705d516f9c58ae4458c-2297f86c299c4b998e5a33258a6b8326
R02	Lab2 cnn 2	f1a84ec3e8723294d4a2-14cad9141a774b6daee3100c969640f6
R03	Lab2 cnn 3	69ac6bd9ed94ae61d1aa-873bbd5089054e138a586cd2a337e139
R04	Lab2 vit 1	76a6bee7ce9731bfa4fa-8edbe989a96e427c82f75e87ddd2c0ab
R05	E1 cnn	73968c7a84a5394c6aa0-5b8b87df36624d71a8c08781804ed7fd
R06	E1 vit	0799d8eab079cab5e620-ec0903e00a2f4df899b1f979e3032c7c
R07	E2 occ5 s1	d916efcb86dbc37ed0fd-5ea6c8d7ae3a4713abdc9196f866be8f
R08	E2 clean s2	adf7875f58dc5a33abcb-9beff1f907e6459d9241c8da09dcbf6d
R09	E2 occ5 s2	1b9e2c8adc87da51f43e-21c97ce47ce14c5094c6d8f322577b71
R10	E2 clean s3	fb2bf5669b606f7353b3-fb200b8facea453892a7cb99672a9126
R11	E2 occ5 s3	9fbe4b23ef2186c639a8-621b2bf393314d84992ba240404c4b4e
R12	cnn 1 FGSM eps0 K1	f669bc74fac0f59ecb07-92578798ac0a4ac881373db791f892a9
R13	cnn 1 FGSM eps1 K1	269235b4e42469f1f427-31afe187d8874ccd90810cd729cb9751
R14	cnn 1 FGSM eps2 K1	1a44bb9104623fa07cb4-60472984ecd94626b9d910b76e11e7c3
R15	cnn 1 FGSM eps4 K1	9e73f0a9a788cd0a7e15-633c44687fba46c7b47e051459944848
R16	cnn 1 FGSM eps8 K1	e2b28e527a75a35a8c24-4ddb2e6f24c54581951d73310baa4fbd
R17	cnn 1 PGD eps2.0 K10	00aed6b3019eda8bd2b0-e1833f1367e4430f8aeccd94a49d11b6
R18	cnn 1 PGD eps2.0 K20	669f74441c1d0bdf9cf6-ef275b8799014ee79fb03a5693b2d6ee
R19	cnn 1 random eps2.0 K	07fec26d48c701023bbd-28ec2dc11eff416185d2bb75ca985d2f
R20	vit 1 FGSM eps0 K1	a05b46698998adbde31d-f3ad6d2937eb4c93b6b015c90911a9e0
R21	vit 1 FGSM eps1 K1	22db9ba6ab867bcc1d57-e727981c4ca647488299d2fa01151396
R22	vit 1 FGSM eps2 K1	be749c9af8d7ccb534e2-69374eeafcc54854810477dd4e5d9500
R23	vit 1 FGSM eps4 K1	82a6087687cc2c8c5c9b-19454af7b1184b9299a761b6bea4cf27
R24	vit 1 FGSM eps8 K1	8d1e5819f7bc0d28b6dd-c705a88f9353488ab16a0427fcb193ef
R25	vit 1 PGD eps2.0 K10	79a1b4800fce5956a2d9-2d085f1bce3b439aa37201e020dabd75
R26	vit 1 PGD eps2.0 K20	f43e239aca6b8f9a3c27-6d81a2d31c5a46c59dd4c858023ddcfd
R27	vit 1 random eps2.0 K	4ed189b2245186f3b436-7011dd2f77284357931c0e901a28d9d2
R28	selective OOD cnn 1	c4bd07267e884795ad42-9f79f9e6c4534bf9ae92ce4d5fbd849f
R29	selective OOD vit 1	28c6a867fdd60b50e742-b8ff8463a4ac44f38517e4b96fe64ebe
R30	selective OOD cnn 2	ee51a112fbd8ca02ceac-0fbadfbec7b946c6b6e26b3bedc5b2a1
R31	selective OOD cnn 3	62769d38becb70261a95-0f87c25adf8344b599bf1396638e8f47