МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Инженерная школа информационных технологий и робототехники
Направление 09.04.01 «Информатика и вычислительная техника»
Отделение информационных технологий

Лабораторная работа № 9

«Multimodal Representation Learning
Audio-visual emotion recognition: fusion,
missing modalities и modality reliability»

по дисциплине «Нейронные сети»

Выполнил:
студент гр. 8ВМ53 _____ Ван Чжаофу

Проверил:
_____ Григорьев Д. С.

Томск – 2026

Содержание

1 Профиль и протокол 3

2 E1. Одномодальные модели и слияние 5

3 E2. Пропуск и шум модальности 8

4 E3. Конфликтующие пары 10

5 Ответы на контрфактические вопросы 12

6 Ограничения и выводы 13

Список использованных источников 14

Приложение. Идентификация запусков 15

1. Профиль и протокол

1.1. Цель и данные

Цель — проверить, даёт ли объединение аудио и видео сведения сверх ёмкости головы и как модель реагирует на пропуск и конфликт модальностей [1]. Использованы 1440 официальных речевых клипов RAVDESS, 24 актёра, восемь эмоций. В каждом актёре 60 клипов: четыре neutral и по восемь остальных эмоций. Единица анализа — клип.

Актёры не пересекаются между ролями: train 14/840 клипов, val 3/180, cal 2/120, test 5/300. Применено фиксированное разбиение с seed 1729. Cal не декодируется и не участвует в признаках. На val выбираются checkpoint, стратегия и вес late fusion, test служит для итоговых оценок. В test 20 neutral и по 40 прочих классов. Основная метрика

$$M = \frac{1}{8}\sum_{c=1}^{8} F1_c, \qquad F1_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}; \tag{1}$$

при отсутствующих верных ответах класса его F1 равен нулю. Accuracy — дополнительная характеристика.

1.2. Кодировщики и временная обработка

Визуальный источник — CNN из ЛР2, CIFAR ResNet-18 с выходом $d_v = 512$ (R37). Кадры лица 224×224 извлечены с частотой 10 fps и кодируются на сетке 5 fps; ненайденные лица пропускаются, padding не входит в среднее. Полностью отсутствующих video-клипов нет. Замороженный CIFAR-кодировщик допускает размер 224 через spatial pooling, однако перенос с изображений 32×32 на лица является ограничением домена и масштаба.

Аудио — mono 16 кГц. Log-mel использует 64 полосы, окно 400 отсчётов (25 мс), hop 160 (10 мс), center=True. Логарифм энергии сжимает динамический диапазон. AudioCNN имеет четыре Conv2D 3×3 с каналами 16,32,64,128, ReLU и pooling $(2, 1)$: частота уменьшается, временной шаг остаётся 10 мс ($r = 1$). AudioCNN обучена на train с остановкой по val macro-F1: максимум 100 эпох, patience 15, затем заморожена (R38). Статистики mel и pooled features рассчитаны только по train.

Время видео $\tau_t^v = t/5$, аудио $\tau_k^a = 160k/16000$. Окно ширины 200 мс полуоткрыто: $-0.1 \le \tau_k^a - \tau_t^v < 0.1$. Границы сравниваются в целых отсчётах, av offset фиксирован метаданными. Для основной классификации используются средние валидных признаков клипа; проверка выравнивания не означает, что модель использует синхронную динамику.

1.3. Слияние и обучение голов

Раннее слияние конкатенирует $[z_v; z_a]$. Позднее усредняет вероятности $p_f = \lambda p_V + (1-\lambda)p_A$: обязательное $\lambda = 0.5$ и выбранное по val $\lambda = 0.4$ из сетки 0–1 с шагом 0.1. Нелинейная голова имеет один скрытый слой 128. Для gated общая ширина 128 и скалярный шлюз профиля:

$$u_v = \tanh(W_v z_v), \quad u_a = \tanh(W_a z_a), \quad g = \sigma(W_g[z_v; z_a] + b_g), \quad z_f = g u_v + (1-g)u_a. \quad (2)$$

Соглашение: $g = 1$ — видео, $g = 0$ — аудио. Кодировщики фиксированы. Головы обучаются 200 эпох, AdamW 0.001, weight decay 10^{-4}, batch 64, CPU с двумя потоками; выбирается лучший val checkpoint без досрочной остановки головы. Признаки извлечены один раз, GPU используется для кодировщиков. Число параметров ниже относится только к обучаемой части.

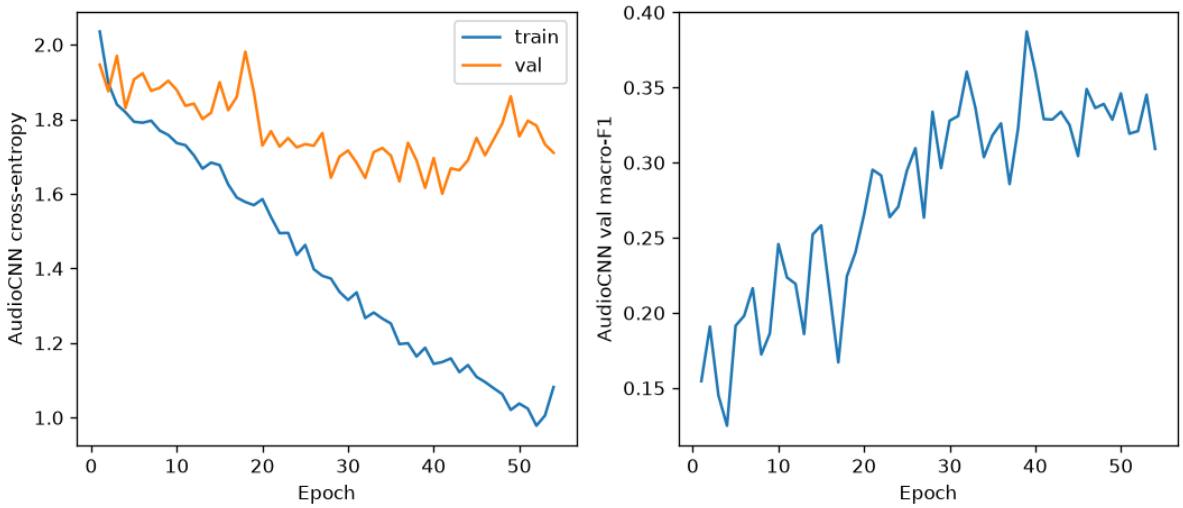


Рис. 1 – Обучение AudioCNN только на train, выбор по val macro-F1.

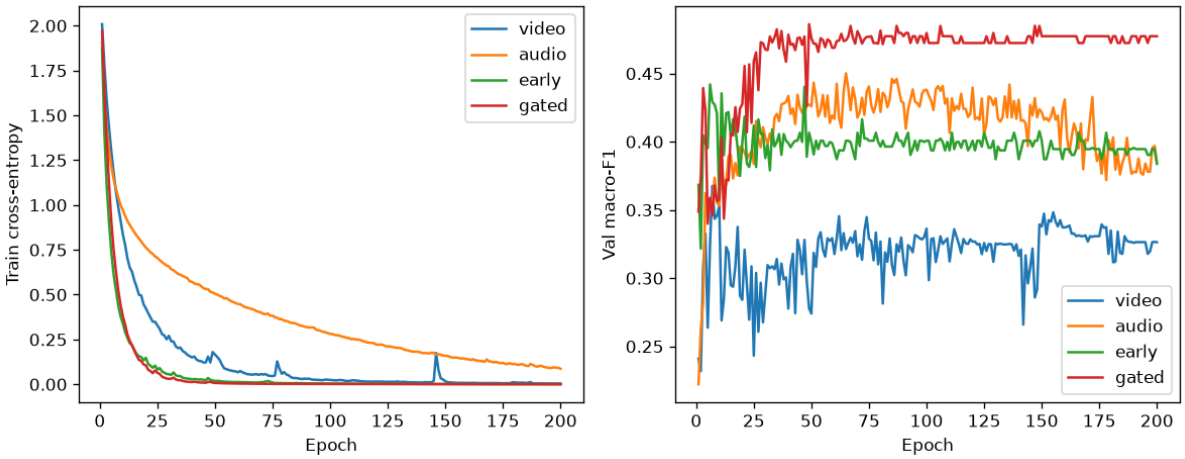


Рис. 2 – Кривые обучения голов на сохранённых признаках.

2. E1. Одномодальные модели и слияние

Сначала исследованы обе одномодальные модели и три стратегии fusion. Для каждого размера fusion построены ближайшие по ширине контроли каждой модальности. Параметрический шаг равен $d_v + C + 1 = 521$ или $d_a + C + 1 = 137$; все фактические расхождения меньше 1%.

Таблица 1 – E1: фиксированные признаки и обучаемые головы; параметры кодировщиков не включены.

Модель	Val F1	Test F1	Accuracy	$\lvert\theta_m\rvert$	Ист.
Video	0.367578	0.288684	0.306667	66696	R01
Audio	0.450167	0.438427	0.456667	17544	R02
Early	0.441990	0.488125	0.486667	83080	R03
Gated	0.486164	0.509938	0.523333	100105	R04
Late 0.5	0.453507	0.456888	0.493333	84240	R05
Late val	0.473582	0.450878	0.476667	84240	R06
Video+ early	0.374748	0.292051	0.306667	82847	R07
Audio+ early	0.455090	0.424482	0.440000	83030	R08
Video+ gated	0.375731	0.321880	0.303333	100040	R09
Audio+ gated	0.451224	0.416379	0.436667	100155	R10
Video+ late	0.379016	0.308484	0.310000	84410	R11
Audio+ late	0.459745	0.423007	0.440000	84263	R12

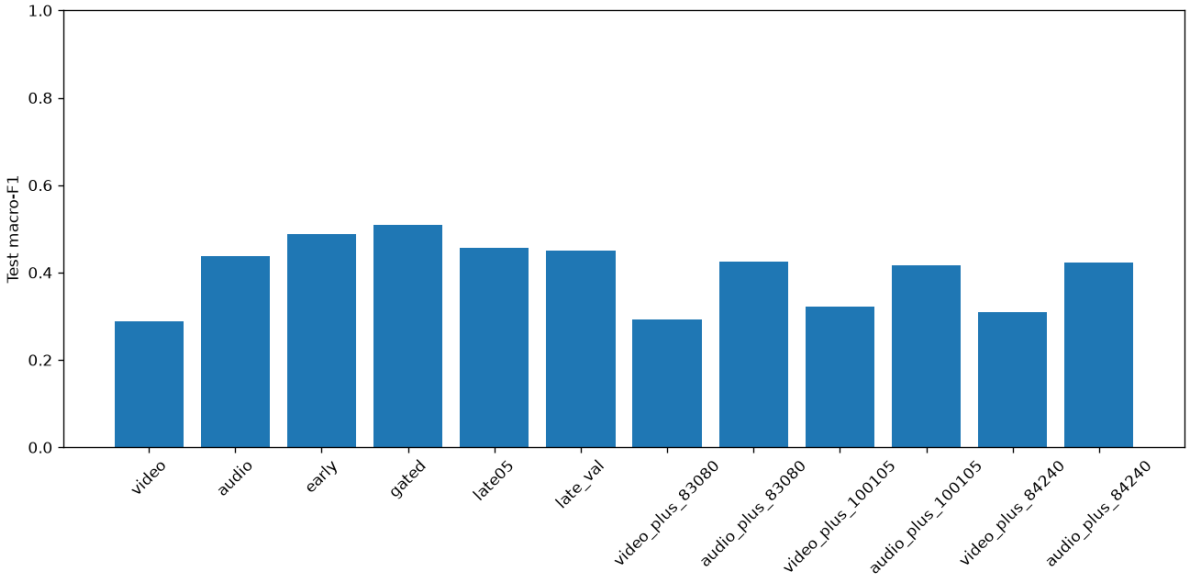


Рис. 3 – E1: macro-F1 моделей и число обучаемых параметров.

Определены $G = M_{AV} - \max(M_V, M_A)$, $G_{ctrl} = M_{AV} - \max(M_{V^+}, M_{A^+})$, $G_{int} = M_{AV} - M_{late,val}$. Late val служит ориентиром без обучаемого взаимодействия, а не доказанно оптимальным правилом fusion.

Таблица 2 – Исследовательские выигрыши: сравнение по одному seed, не статистическое доказательство.

Fusion	G	G_{int}	G_{ctrl}
Early	+0.049698	+0.037246	+0.063642
Gated	+0.071512	+0.059060	+0.093560
Late 0.5	+0.018461	+0.006009	+0.033881
Late val	+0.012452	+0.000000	+0.027872

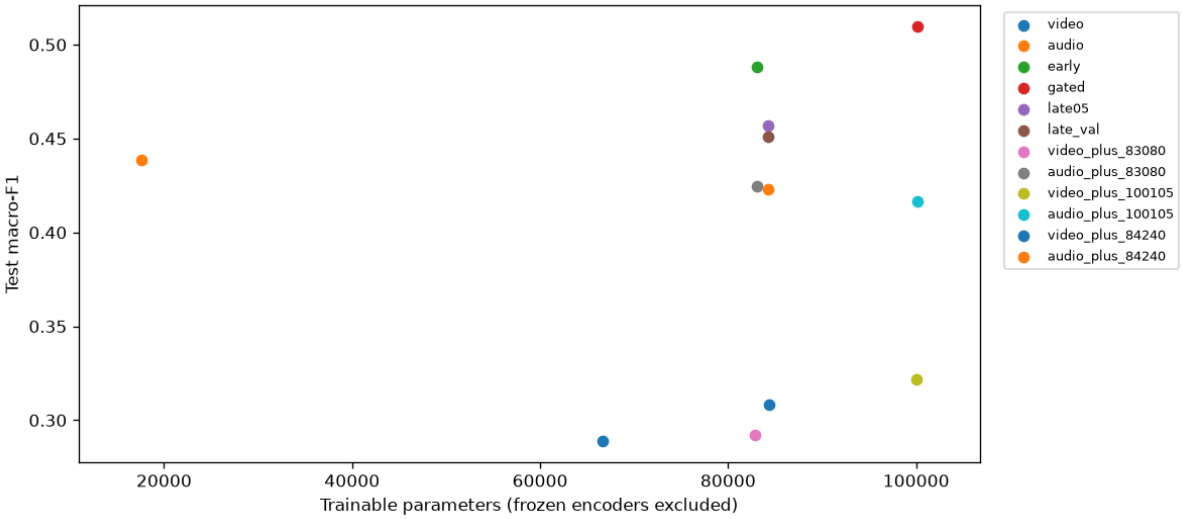


Рис. 4 – Одномодальные контроли с ближайшей параметрической ёмкостью.

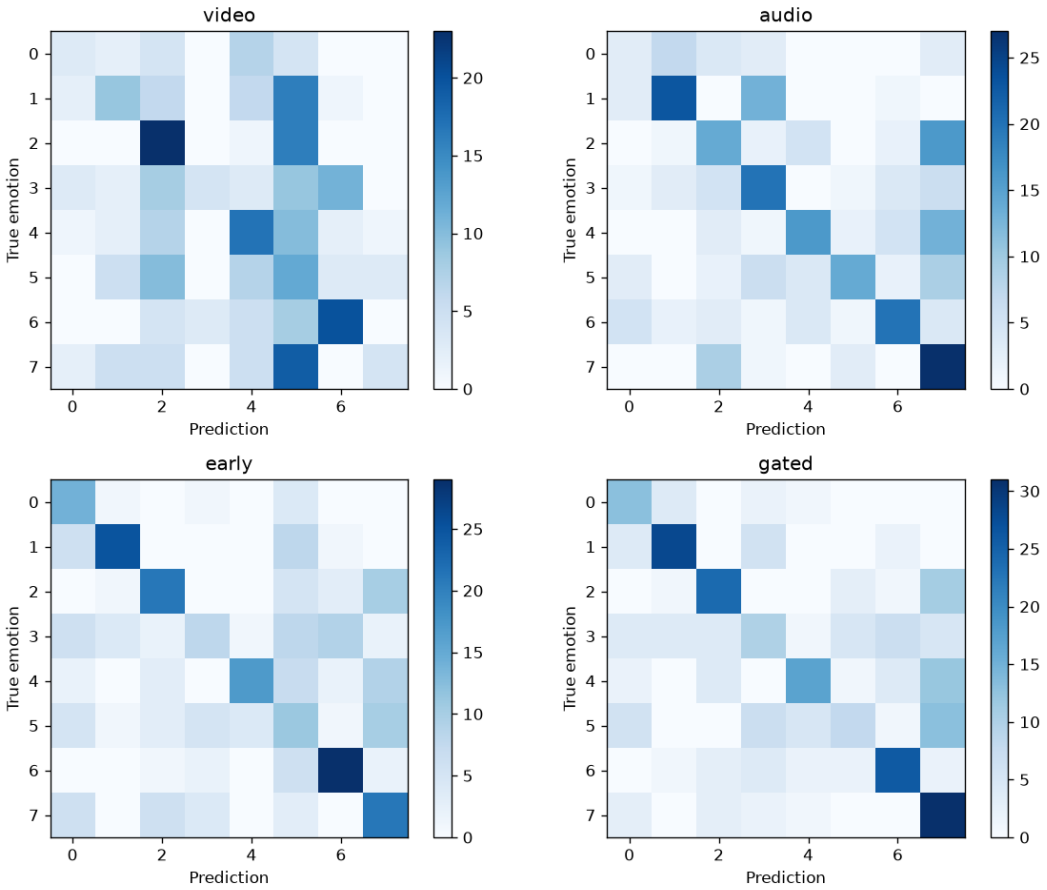


Рис. 5 – Матрицы ошибок E1; единица анализа — клип.

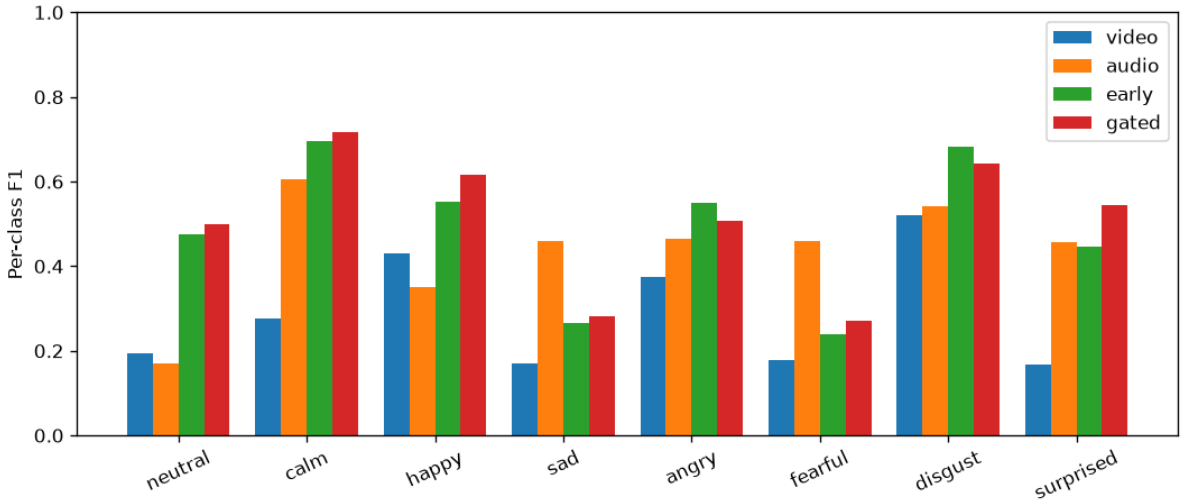


Рис. 6 – Поклассовые F1 для восьми эмоций.

Gated выбран по val F1=0.486164, сильнейший соответствующий контроль — audio+ ширины 731. Gated имеет 100 105 параметров, контроль 100 155, расхождение около 0.050%. Видео-контроль имеет ширину 192 и 100 040 параметров. Простые audio/video различаются по ёмкости более чем вдвое, поэтому их разность не отделяет качество модальности от размера головы.

До основного сравнения F=Gated и U=audio+ предсказан положительный знак $\Delta_s = M_F(s) - M_U(s)$: дополнительное видео может давать комплементарные сведения. Фиксированы split, признаки, оптимизация, бюджет, правило val и близкая ёмкость. Отсутствие устойчивого положительного эффекта по правилу задания опровергло бы утверждение об установленном выигрыше. Три seed меняют инициализацию и batch голов, но не кодировщики. Все три пары заново обучены после фиксации гипотезы; исследовательский seed 1 ранее наблюдался, поэтому не объявляется новой независимой информацией.

Таблица 3 – Основное сравнение E1: F=Gated, U=Audio+ gated.

Seed	F macro-F1	U macro-F1	Δ_s	Ист. F/U
1	0.509938445	0.416378607	+0.093559838	R13/R14
2	0.528176173	0.442624674	+0.085551499	R15/R16
3	0.453179355	0.425341767	+0.027837589	R17/R18

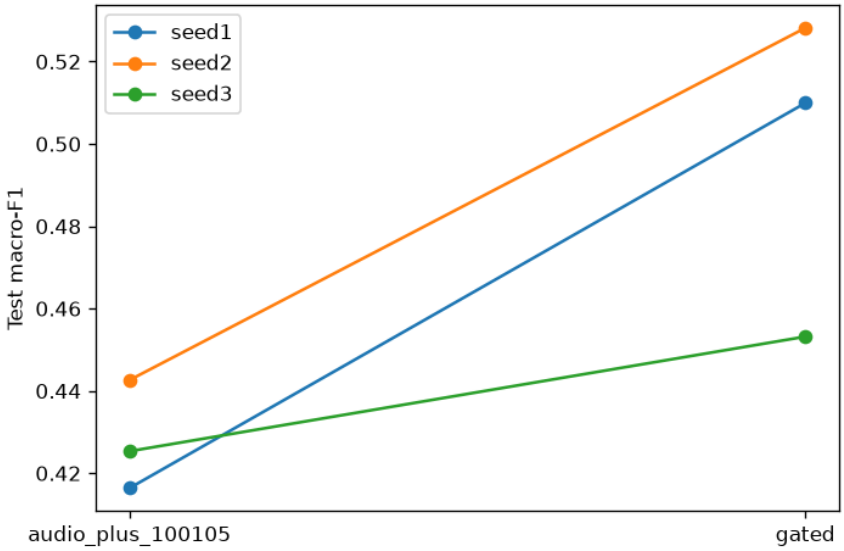


Рис. 7 – Три положительные разности F минус U и выборочное SD; различие не установлено.

Среднее 0.068982975, выборочное SD 0.035857224. Все знаки положительны, однако $\bar{\Delta} < 2s_\Delta = 0.071714448$. Различие не установлено. Наблюдаемое направление согласуется с ожиданием, но преимущество сверх контроля по критерию преподавателя не подтверждено. Один положительный G или G_{ctrl} не заменяет этот вывод.

3. E2. Пропуск и шум модальности

Вмешательство задаётся маской $\tilde{z}_a = m_a z_a + (1 - m_a)e_a$ и аналогично для видео; $e_a = e_v = 0$ в стандартизованном пространстве, одновременно обе модальности не удаляются. Для каждой фиксированной модели

$$R_a = M_{AV} - M_{-a}, \quad \tilde{R}_a = \frac{R_a}{M_{AV} - M_0}, \quad \delta_a(x) = \|p(x) - p^{(-a)}(x)\|_1, \tag{3}$$

где $M_0 = 0.0294118$ — наиболее частый класс; симметрично определены видео-показатели. Это вмешательство в одну модель, а не разность разных классификаторов.

Таблица 4 – E2: вмешательства в одну модель, нулевой заменитель, test 300 клипов.

Fusion	M_{AV}	M_{-a}	M_{-v}	R_a	R_v	$\tilde{R}_a$	$\tilde{R}_v$	Ист.
Early	0.48812	0.24326	0.33993	0.24486	0.14819	0.53380	0.32306	R19
Gated	0.50994	0.23820	0.35209	0.27174	0.15785	0.56551	0.32849	R20
Late 0.5	0.45689	0.28868	0.43843	0.16820	0.01846	0.39348	0.04319	R21
Late val	0.45088	0.28868	0.43843	0.16219	0.01245	0.38483	0.02954	R22
Gated drop	0.43944	0.30555	0.38191	0.13389	0.05753	0.32654	0.14031	R23

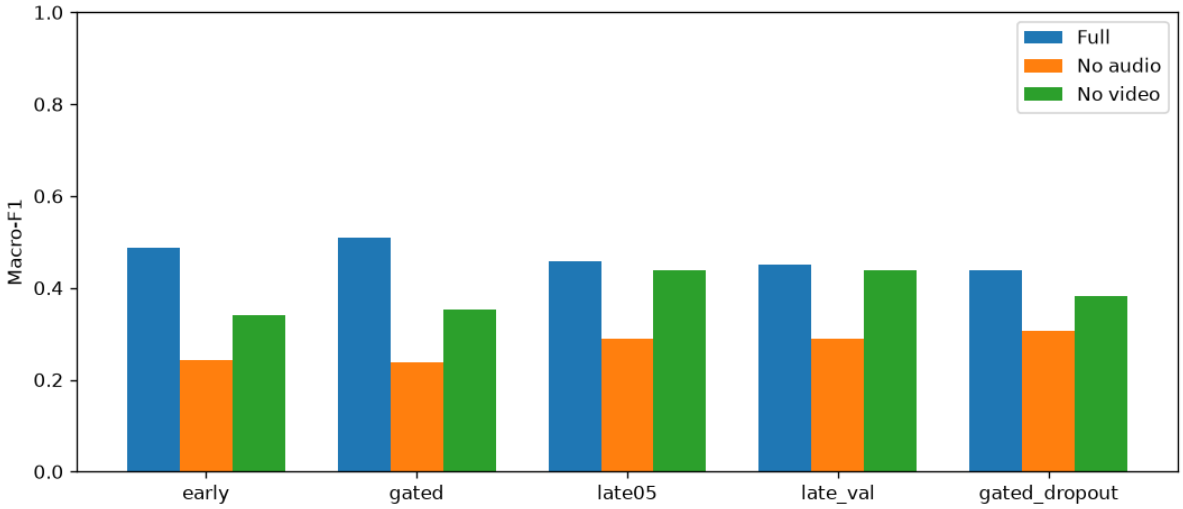


Рис. 8 – E2: полные пары, без аудио, без видео; отдельная модель с dropout.

Для Gated $R_v - R_a = -0.113896$, тогда как отдельно обученные $M_V - M_A = -0.149743$. Эти разности не обязаны совпадать: разнятся архитектуры, обучение и эффект нулевого входа. Dropout с $p_{drop} = 0.5$ сохраняет полную пару с вероятностью 0.5 и удаляет каждую модальность с вероятностью 0.25. В этом seed он повышает F1 без аудио с 0.238197 до 0.305552 и без видео с 0.352093 до 0.381911, но снижает полный F1 с 0.509938 до 0.439444. Это компромисс одного seed, не установленное общее преимущество.

Перестановка аудио без неподвижных точек (seed запуска 1, перестановка сохранена) даёт Gated F1=0.187489 (R39). Средний L1-эффект shuffle=1.354553 против zero mask=1.157492, доли смены класса 0.683333 и 0.620000. Значит, модель зависит от аудио; два разных заменителя не обязаны давать одну оценку вклада.

К исходной волне добавлен шум с точной мощностью:

$$\gamma = \sqrt{\sum x_a^2 / (10^{SNR/10} \sum \xi^2)}. \tag{4}$$

Затем mel и признаки заново рассчитаны тем же AudioCNN. Это искажение сигнала, не добавление шума к готовому вектору.

Таблица 5 – SNR по мощности исходной волны; g=1 означает видео.

SNR, dB	Gated F1	$\bar{g}$	Drop F1	$\bar{g}_{drop}$	Ист. / drop
30	0.242099	0.512415	0.302544	0.590143	R24/R25
20	0.202144	0.394448	0.309845	0.654320	R26/R27
10	0.139632	0.175207	0.279502	0.679308	R28/R29
0	0.050072	0.042026	0.257294	0.674308	R30/R31
-5	0.035479	0.017611	0.248194	0.683334	R32/R33

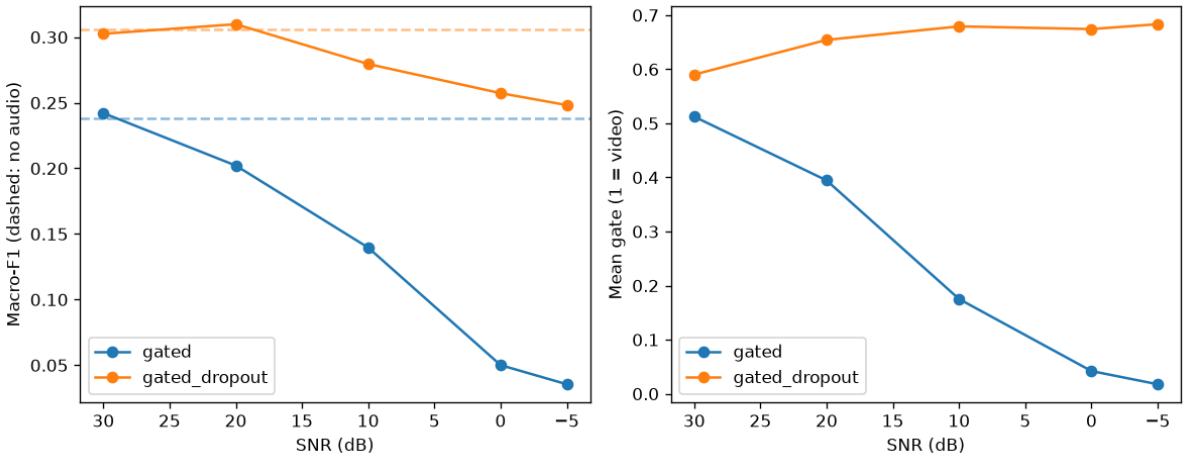


Рис. 9 – Macro-F1 и средний gate при пяти измеренных SNR.

Наибольший измеренный SNR, при котором шум хуже полного удаления аудио, — 20 дБ для Gated и 30 дБ для dropout-модели. Кривая dropout немонотонна, отличие при 30 дБ мало; это сравнение дискретных точек, не непрерывный порог. У обычной модели g уменьшается вместе с SNR, то есть смещается к шумному аудио. Dropout-модель чаще смещается к видео, но также не строго монотонно.

Таблица 6 – Скалярный gate на исходных test-клипах, соглашение 1=video.

Эмоция	0	1	2	3	4	5	6	7
$\bar{g}$	0.4675	0.5117	0.4888	0.5271	0.3345	0.4455	0.5311	0.4920

На исходном test средний g=0.475251, SD=0.138423; для верных/ошибочных ответов 0.474931/0.475604. Такое близкое среднее само по себе не является показателем надёжности.

4. E3. Конфликтующие пары

Сформированы по 300 уникальных упорядоченных пар разных актёров: A с одинаковыми эмоциями, B с разными. Seed 1 фиксирован. В A правильная метка определена; в B единого правильного класса нет. Вместо accuracy считаются доли следования видео r_v, аудио r_a и третьему классу $r_0 = 1 - r_v - r_a$. Для обнаружения рассогласования B — положительный класс, A — отрицательный; показатели $1 - conf$ и эффект удаления аудио δ_a оцениваются AUROC.

Таблица 7 – E3: разные актёры; A — одинаковая эмоция, B — разные эмоции.

Fusion	A F1	A acc.	r_v	r_a	r_0	AUROC U	AUROC delta	Ист.
Early	0.434759	0.456667	0.173333	0.296667	0.530000	0.501611	0.504500	R34
Gated	0.440716	0.476667	0.133333	0.340000	0.526667	0.564300	0.556700	R35
Late 0.5	0.417586	0.470000	0.136667	0.436667	0.426667	0.539272	0.590767	R36

Таблица 8 – Средняя уверенность и изменение вероятностей при подмене аудио.

Fusion	Conf. A	Conf. B	$\delta_{ij,A}$	$\delta_{ij,B}$	$\bar{g}_A$	$\bar{g}_B$
Early	0.612918	0.611936	0.718412	1.037994	n/a	n/a
Gated	0.891621	0.858043	1.019965	1.429506	0.478021	0.470309
Late 0.5	0.501510	0.474590	0.654309	0.853524	n/a	n/a

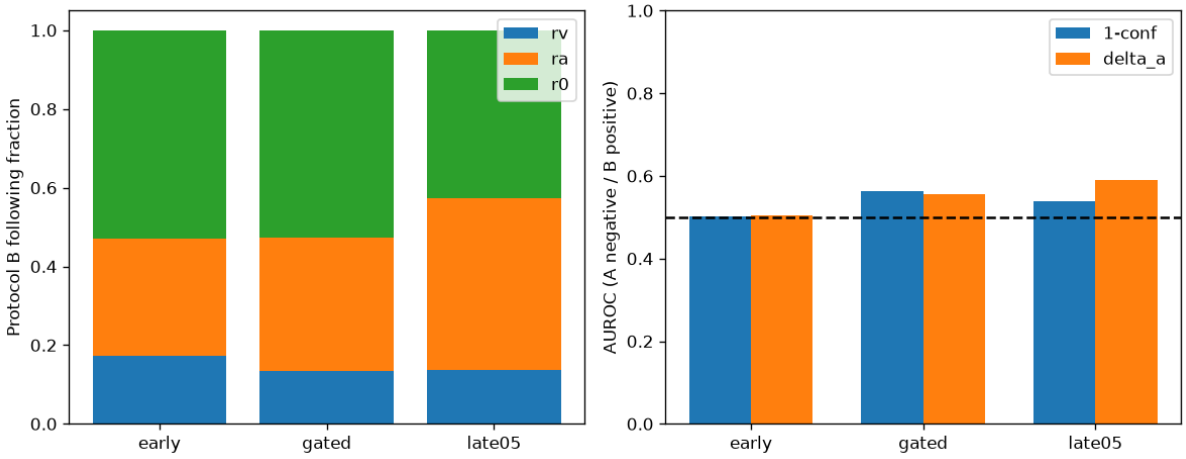


Рис. 10 – E3: следование видео, аудио, третьему классу и обнаружение конфликта.

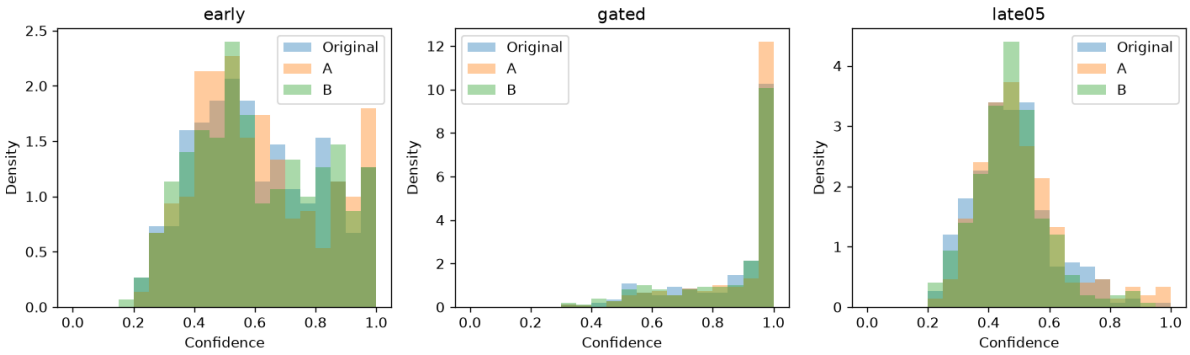


Рис. 11 – Уверенность на исходных клипах, парах A и B.

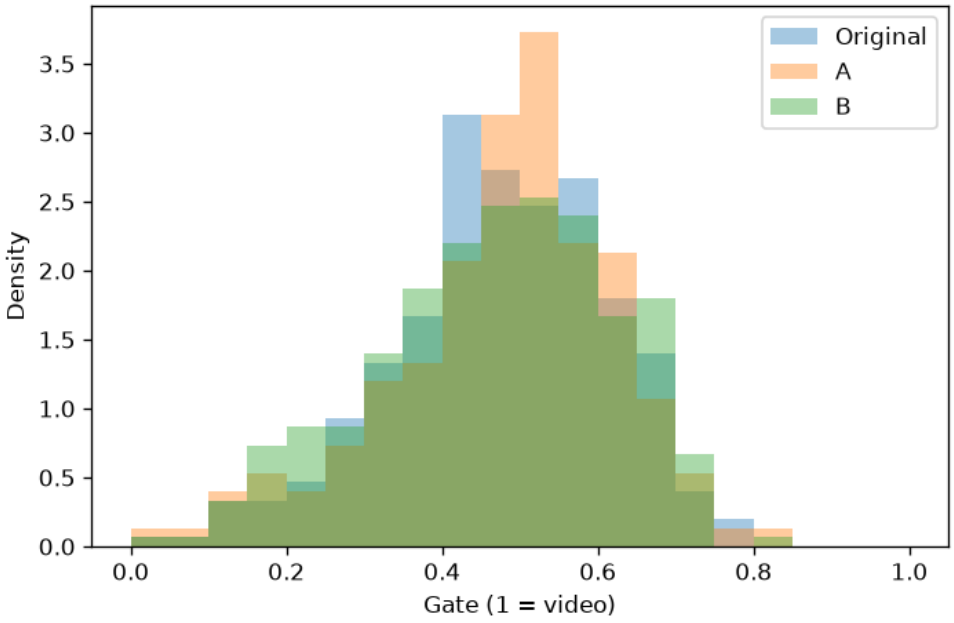


Рис. 12 – Gate на исходных и переставленных парах; высокое значение соответствует видео.

Все три модели чаще следуют аудио, чем видео, но Early и Gated примерно в 53% случаев выбирают третий класс. Поэтому «в конфликте модель всегда следует аудио» данными не подтверждается. AUROC невысок: для Gated 0.564300 по $1 - conf$ и 0.556700 по δ_a, близко к случайному ориентиру 0.5. Средний gate исходных пар 0.475251, A 0.478021, B 0.470309; резкого переключения не наблюдается.

На B accuracy, macro-F1, ECE и selective risk не определены, поскольку нет события «предсказание верно». Высокая confidence там не доказывает плохую калибровку. A контролирует смену актёра при совпадающей эмоции, однако повторное использование исходных клипов делает пары зависимыми. Их 300 не равнозначны 300 независимым актёрам.

5. Ответы на контрфактические вопросы

Вопрос 1. Использование слабой модальности

Отдельная audio-модель сильнее video: 0.438427 против 0.288684. Это не обязывает fusion использовать слабое видео. В собственной Gated $\tilde{R}_a = 0.565508$, $\tilde{R}_v = 0.328485$, средние $\delta_a = 1.157492$, $\delta_v = 0.876780$. Удаление видео снижает F1 на 0.157846: зависимость вероятностей и потеря качества наблюдаются. Вывод ограничен zero-вмешательством; зависимость не равна доказанной причинной полезности во всех условиях.

Вопрос 2. Двойная ширина контроля

Сохранённый контроль audio действительно переобучен 200 эпох с шириной $731 \rightarrow 1462$ (R40). Его F1 изменился 0.416379 $\rightarrow$ 0.406640. Новый $G_{ctrl} = 0.103299$

против прежних 0.093560, изменение +0.009739. Положительное направление сохранилось в одном дополнительном seed; оно не отменяет неустановленный трёхseedовый основной результат. Дополнительная ёмкость сама по себе не гарантирует улучшения на 840 train-клипах.

Вопрос 3. Перемешивание и маскирование

Почти нулевой shuffle-эффект означал бы слабую зависимость от аудио, но в наших данных он велик: L1=1.354553, смена класса 68.33%. Маска даёт 1.157492 и 62.00%, $R_a = 0.271742$. Подмена чужим реальным аудио и нулевой вектор — разные интервенции; чужое аудио несёт конкретный, иногда противоречащий класс, тогда как zero может быть необычным входом.

Вопрос 4. Размытие видео

К исходным face-кадрам применено размытие уровня 1 сохранённого протокола, sigma 0.5, kernel 5; кадры повторно закодированы (R41). F1 упал с 0.509938 до 0.354929, g изменился лишь с 0.475251 до 0.476391. После размытия $R_v = 0.002837$, средний $\delta_v = 0.801904$. Даже неизменный F1 не доказывал бы устойчивости: нужно отличить сохранение полезной визуальной информации от её игнорирования. Здесь падение реально, а почти неизменный g его не отразил.

Вопрос 5. Должен ли gate отвергать шум

Таблица SNR показывает противоположные реакции моделей: у обычной g падает от 0.512415 при 30 дБ до 0.017611 при -5 дБ, то есть вес аудио растёт. У dropout-модели g в этих точках растёт от 0.590143 до 0.683334 с немонотонными промежуточными изменениями. Обучение на чистых парах минимизирует ошибку эмоции, а не обучает детектор качества аудио. Нулевой пропуск и шумная волна тоже не одно и то же. Монотонная реакция из формулы sigmoid не следует.

6. Ограничения и выводы

Использован один split с пятью test-актёрами; три seed меняют только головы. Перенос CIFAR CNN на лица ограничивает обобщение. В E3 согласованность смешана с идентичностью и составом эмоций, поэтому AUROC описателен. Zero-вмешательства зависят от заменителя; изменения вероятностей не равны причинной важности.

Fusion повысил F1 относительно простых одномодальных моделей, но выигрыш над контролем той же ёмкости не установлен. Dropout улучшил обработку пропусков ценой полного качества. Gate не стал надёжным индикатором качества; конфликт требует отдельных метрик.

Список использованных источников

[1] Лабораторная работа 9. Multimodal Representation Learning. Audio-visual emotion recognition: fusion, missing modalities и modality reliability. Курс «Нейронные сети». Методические указания, 2026.

Приложение. Идентификация запусков

Таблица 9 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R01	E1 Video	73b7c031da6acfd09b36-3d018c3486d345a5bfbf442430be428e
R02	E1 Audio	872fb29a87d782c21051-cf1b54e8d2144cdda6e02712bcaef9bf
R03	E1 Early	05e36ac62488f7796fd6-370796fdf66a43a0adedf95d30e3e7ec
R04	E1 Gated	347c6157a20f623bbee4-d363e4726c5f48af848904756452a54e
R05	E1 Late 0.5	6bce04d107b27fb66fc8-ba4bd30fd0654388bf9658deb27fd3af
R06	E1 Late val	e4f5de4987b4b2abe336-1f93deb10d944a25a354bce75dbbc85c
R07	E1 Video+ early	22f9948b3abb4e7644b2-4373bbba4ee44e4e8a9d1d8257447580
R08	E1 Audio+ early	747355daa60d2cc08a42-7018b6909b604f41b5dd48f0f459c1ae
R09	E1 Video+ gated	72d3e5c3ceda440965c2-8330b1637b8e41988ef1ee3046ecd911
R10	E1 Audio+ gated	e4b3f5a0c4e93bcc9098-08ab915d587344f9b4b4d15e30657a3e
R11	E1 Video+ late	8eb4311ca1c7650f5e21-3a6cc9195aa04290b33eeaa1488774f4
R12	E1 Audio+ late	af77dcffac5fbb7f9ab1-e7e966beb7934d78b0835c8f4079cf83
R13	main F s1	5eaab7ee33e888c71fa7-fceda1ca709347878fe9090a1126afd6
R14	main U s1	6d0bc1656002341df4e9-4eda2af5d1be4aeab430cced95c91b87
R15	main F s2	071c6c3a878330b2e586-ef72728ed1404818bfb6d9dda97e29db
R16	main U s2	e680333297ee1350883d-f8690e49d712401fb142404bab7178fa
R17	main F s3	a29d0207d0691539b9fb-052d3bc061f04cbca48da4fb1d243237
R18	main U s3	78d4d7224dc94ed76d19-fe318f92354b4fa9aab2d71e9007a865
R19	E2 Early	da815801667760cba3f0-f653366b50c04783bc48d69e65dc5308
R20	E2 Gated	5c2e15819ab203e984c5-dae3fc0aaf3b4cb69f28de679c8d7226
R21	E2 Late 0.5	1b42bfe68b7ff9394755-75d0ae54282d486d96b30b596c0bd289
R22	E2 Late val	f72622bc263024125579-3642aca850794e0aae3c4a14fb0a585d
R23	E2 Gated drop	57166cbd0c7ff3e2e33f-64da840110db4d13a3e90f81c190fba6
R24	noise 30	62cb2d053fcae434ac45-591717f25cfd44e9bdd2c69fd030d21c
R25	drop noise 30	2094a246f6f3d4d1edc4-71d86323611f402a8148d498254c1e80
R26	noise 20	83846d29c387fa1a0063-63cf5cfa0fca4acfacd3f08846be165a
R27	drop noise 20	875463cbaa18bc930376-86f19dad7ac546e98298a5dfcf34c0cb
R28	noise 10	e3556bc1cc4fa5706bd0-c427c6b42ea846378b4d650ef85fb8d9
R29	drop noise 10	15134648de73dc39a432-33b697df06dd412d9c69e9f88970e9d6
R30	noise 0	7cc5656e3d5ec6af2e70-d0bda4345e4e4d268d99ebef9c4adb43
R31	drop noise 0	596dfe58808803fba854-3ed93fee76314ff48f654a8bcb3a83b6
R32	noise -5	a219b55b3e82174a9b09-e8d748b383514f7f8e9f043155332f19
R33	drop noise -5	a87dd8f47a24de9d1dbd-84988a0f9d2c4590a8dc369c3765f4e3
R34	E3 early	75cdef3b3621ec713c4d-8f3b5388e56e4af5b0e635d25d018b33
R35	E3 gated	bfaf1a95582bbc738bad-8f91e3804e2741cfb08e2df37488ac16
R36	E3 late05	281261d23ef5b6ce2337-311678e304db457f8417e218a87b070e
R37	visual CNN Lab2	cfd869bd9ae49d9e218c-674bd37aac074d9393378ce924e7c6dc
R38	AudioCNN training	1475403250d4ae591ddd-186c0d2ef7314984861ec3bcb01e4c54
R39	E2 shuffle	60613c91030bc0779023-78b0b950695a4d7cb5c3948cd630b08a
R40	CF2 double width	5d7b42d2fbe578cc1409-e0ce7e930e514b6a999d49c6b612446a
R41	CF4 blur video	975c246e6d8598e85966-8bca42f74e7d440388ce89eef547a0e0