МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Инженерная школа информационных технологий и робототехники
Направление 09.04.01 «Информатика и вычислительная техника»
Отделение информационных технологий

Лабораторная работа № 1

«Почему глубокая сеть обучается или не обучается Инициализация, нормализация и остаточные связи»

по дисциплине «Нейронные сети»

Выполнил:
студент гр. 8ВМ53 _____ Ван Чжаофу

Проверил:
_____ Григорьев Д. С.

Томск – 2026

Содержание

1 Профиль и протокол 3

2 E1: сигнал и градиент при инициализации 5

3 E2: глубина и остаточные связи 8

4 Карта обучаемости 10

5 E3: основное парное сравнение 11

6 Ответы на контрфактические вопросы 11

Список использованных источников 14

Приложение. Идентификация запусков 15

1. Профиль и протокол

1.1. Цель и теоретические сведения

Цель работы — выяснить, как инициализация и остаточные связи влияют на сохранение сигнала, градиенты и обучение глубоких сетей, а затем проверить основной вывод на трёх seed. Протокол и критерии взяты из методических указаний [1].

Номера вида (1.x) в анализе относятся к формулам исходного задания; основные используемые зависимости приведены ниже.

Для слоя $h_l = \phi(N_l(W_l h_{l-1} + b_l))$ измеряется средний квадрат $q_l = \mathbb{E}[h_l^2]$. При независимых центрированных весах, нулевых смещениях и ReLU приближение имеет вид

$$q_l = \chi_l q_{l-1}, \qquad \chi_l = n_{l-1}\sigma_l^2/2. \tag{1}$$

Поэтому He даёт $\chi = 1$, Xavier при равной ширине — $1/2$, а фиксированное $\sigma = 0.02$ при $n = 256$ — 0.0512. Небольшое отклонение от единицы накапливается с глубиной. Для BatchNorm статистики вычисляются по batch, для LayerNorm — по признакам отдельного объекта; обязательные серии ниже выполняются без этих нормализаций.

Остаточный блок $h_{l+1} = h_l + \alpha F_l(h_l)$ имеет якобиан $I + \alpha \partial F_l/\partial h_l$. При общем коэффициенте ветви c ожидается

$$q_L/q_0 \approx (1 + \alpha^2 c)^L. \tag{2}$$

Масштаб $\alpha = L^{-1/2}$ ограничивает это приближение величиной e^c; прямой путь при $\alpha = 1$ сам по себе не ограничивает рост сигнала.

Измеряемые показатели обучаемости определены как

$$\rho_T = \frac{\mathcal{L}_T}{\ln 10}, \quad g_l = \frac{\|\nabla_{\theta_l}\mathcal{L}\|_2}{\sqrt{|\theta_l|}}, \quad GI = \log_{10}\frac{\max_l \widetilde{g}_l + \varepsilon}{\min_l \widetilde{g}_l + \varepsilon}, \tag{3}$$

$$AVD = \max_l |\log_{10}(v_l + \varepsilon) - \log_{10}(v_1 + \varepsilon)|. \tag{4}$$

Здесь $\mathcal{L}_T$ — cross-entropy на фиксированной обучающей подвыборке, $\widetilde{g}_l$ — медиана по измеряемым шагам, v_l — дисперсия активаций, $\varepsilon = 10^{-12}$. Значения $\rho_T \le 0.5$ и $\rho_T \ge 0.9$ задают обучаемый и необучаемый режимы; остальные значения пограничны.

1.2. Фактический протокол

Глубины 8, 24, 48, 96; ширина 256; $\sigma = 0.02$; SGD с импульсом 0.9. Использован CIFAR-10, допустимый по §6 задания. Данные и единый цикл обучения унаследованы из ЛР0.

Полная обучающая роль: 43000 изображений; val 5000; cal 2000; test 10000. Выбор условий не использует test. Нормализация вычислена только по train. В ЛР1 используется вся обучающая роль, а не 25%, использованные в ЛР0.

Использовано стратифицированное разбиение ЛР0 с seed 1729: по 500 объектов каждого класса для val и по 200 для cal. Роль cal не используется.

Три полные эпохи; batch 128; weight decay 0; постоянная скорость обучения; без AMP и ограничения градиента. Для завершённых трёхэпоховых обучений сохранены 1008 шагов; для одноэпоховой проверки Gaussian – 336. Численные сбои остановлены раньше и зарегистрированы отдельно. Архитектура, seed, хеши кода/данных и точный RUN_ID находятся в паспорте. Обозначения Rxx ниже разрешаются в полные RUN_ID в реестре в конце отчёта.

Обычная сеть имеет L скрытых линейных слоёв. Остаточная сеть содержит входную проекцию 3072→256 и L блоков, по два линейных слоя в каждом; после сложения нет активации. Поэтому число параметров и линейных преобразований различается; сравнение архитектур не является сравнением равных бюджетов параметров.

Проба: первые 64 фиксированных объекта train, режим eval, $\|u\| = 1$, генератор u из seed профиля 987693601. Для измерений используется float64-копия исходных float32-весов. Это исключает потерю очень малых сигналов при диагностике; обучение остаётся float32. Копирование не меняет веса, режим, BN-буферы, RNG и градиенты обучаемой модели.

Окончательная $\rho_T = L_T / \ln 10$ измеряется по первым 1024 фиксированным объектам train после обучения. GI вычисляется по всем непосредственно параметризованным слоям, включая проекцию и классификатор: сначала медиана $g_l = \|\nabla_{\theta_l} L\| / \sqrt{|\theta_l|}$ по первому, среднему и последнему batch каждой эпохи, затем $\log_{10}[(\max g_l + 10^{-12})/(\min g_l + 10^{-12})]$. Вес и bias входят в один слой. AVD вычисляется по дисперсиям скрытых выходов фиксированной eval-пробы, включая h_0 остаточной сети. Максимальная доля нулей берётся на настоящих ReLU-выходах, а не на сумме ветви и skip.

Монитор также сохраняет среднее, std, min/max, второй момент, насыщение tanh при $|1 - h^2| < 0.1$, нормы и относительные нормы градиента. Квадраты вычисляются после приведения к float64. Отсутствующий градиент классификатора в линейной пробе отмечен как unused, а не как нулевой измеренный градиент.

Скорость обучения выбрана один раз по максимальной итоговой val accuracy; при равенстве используется меньшая val loss, затем меньшая LR. Все кандидаты обучались три эпохи. Выбрана LR=0.003.

Таблица 1 – Выбор единой скорости обучения по validation, три эпохи.

LR	val accuracy	val loss	Источник
0.001	0.4298	1.589	R17
0.003	0.4558	1.51	R18
0.01	0.4558	1.52	R19
0.03	0.4498	1.561	R20
0.1	0.37	1.717	R21

2. E1: сигнал и градиент при инициализации

Заранее записанная гипотеза: по (1.4)–(1.8) ожидаются $\chi = 1$ (He), 0.5 (Xavier), $n\sigma^2/2 = 0.0512$ (Gaussian). Выполнены все 12 комбинаций без оптимизатора. Множители оцениваются геометрически между равными по ширине скрытыми слоями; при $q < 10^{-30}$ применяется правило исключения из PDF. Для Gaussian L=96 эффективная конечная точка может быть раньше последнего слоя; это не замена полного обратного прохода.

Таблица 2 – Предсказанный и измеренные множители при инициализации.

Init	L	χ	$\hat{\chi}_f$	$\hat{\chi}_b$	L_{eff}	Источник
he	8	1	1.004	0.9898	8	R05
he	24	1	1.015	1.012	24	R06
he	48	1	0.9772	1.009	48	R07
he	96	1	0.9804	0.9947	96	R08
xavier	8	0.5	0.5018	0.4949	8	R09
xavier	24	0.5	0.5076	0.5062	24	R10
xavier	48	0.5	0.4886	0.5045	48	R11
xavier	96	0.5	0.4902	0.4973	96	R12
gaussian	8	0.0512	0.05138	0.05068	8	R13
gaussian	24	0.0512	0.05198	0.05183	24	R14
gaussian	48	0.0512	0.05221	0.05065	24	R15
gaussian	96	0.0512	0.0499	0.05042	23	R16

На максимальной глубине относительные ошибки (forward; backward): he: 1.964%; 0.533%; xavier: 1.964%; 0.533%; gaussian: 2.536%; 1.521%. Все шесть сравнений проверяются с допуском 20%.

Граница применимости: Gaussian после одной полной эпохи с выбранной общей LR. Результаты повторной пробы:

Таблица 3 – Повторная проба Gaussian после одной эпохи обучения.

L	$\hat{\chi}_f$	$\hat{\chi}_b$	Учтено / посл. слой	ρ_T	Источник
8	0.09712	0.04066	8 / 8	1	R34
24	0.4029	0.02549	24 / 24	1	R35
48	0.5668	–	39 / 47	1	R36
96	0.0499	0.05042	23 / 23	1	R37

Прочерк в backward для R36 означает неопределённую оценку: q последнего скрытого выхода=0, средний квадрат delta первого слоя=0. Последний ReLU равен нулю на всей фиксированной пробе, и все предыдущие delta равны нулю. Отношение 0/0 не заменяется нулём или теоретическим множителем. Все эти значения конечны; флаг NaN/Inf поэтому не ставится.

Для R37 максимальная медиана g скрытых слоёв при реальном float32-обучении равна 0. Ненулевой градиент float64-пробы не означает ненулевого градиента при float32-обучении: численное обнуление путей и статистика в повышенной точности должны различаться.

Уже первое обновление SGD связывает веса с обучающими входами через градиент и в общем случае меняет нулевые bias. Поэтому исходные независимые случайные веса и нулевые смещения (1.4) больше не предполагаются. Эти нарушения возникают в одном шаге оптимизатора; измерение после эпохи не позволяет приписать одному из них более ранний момент. Совпадение части множителей с теорией не восстанавливает предположения; изменение bias способно создать сигнал даже при затухающих весовых путях.

Проверка фактических checkpoint: максимальное абсолютное bias после эпохи R34: 0.005028; R35: 0.005018; R36: 0.005015; R37: 0.005017. Начальное bias во всех случаях равно нулю; агрегат включает классификатор и скрытые слои.

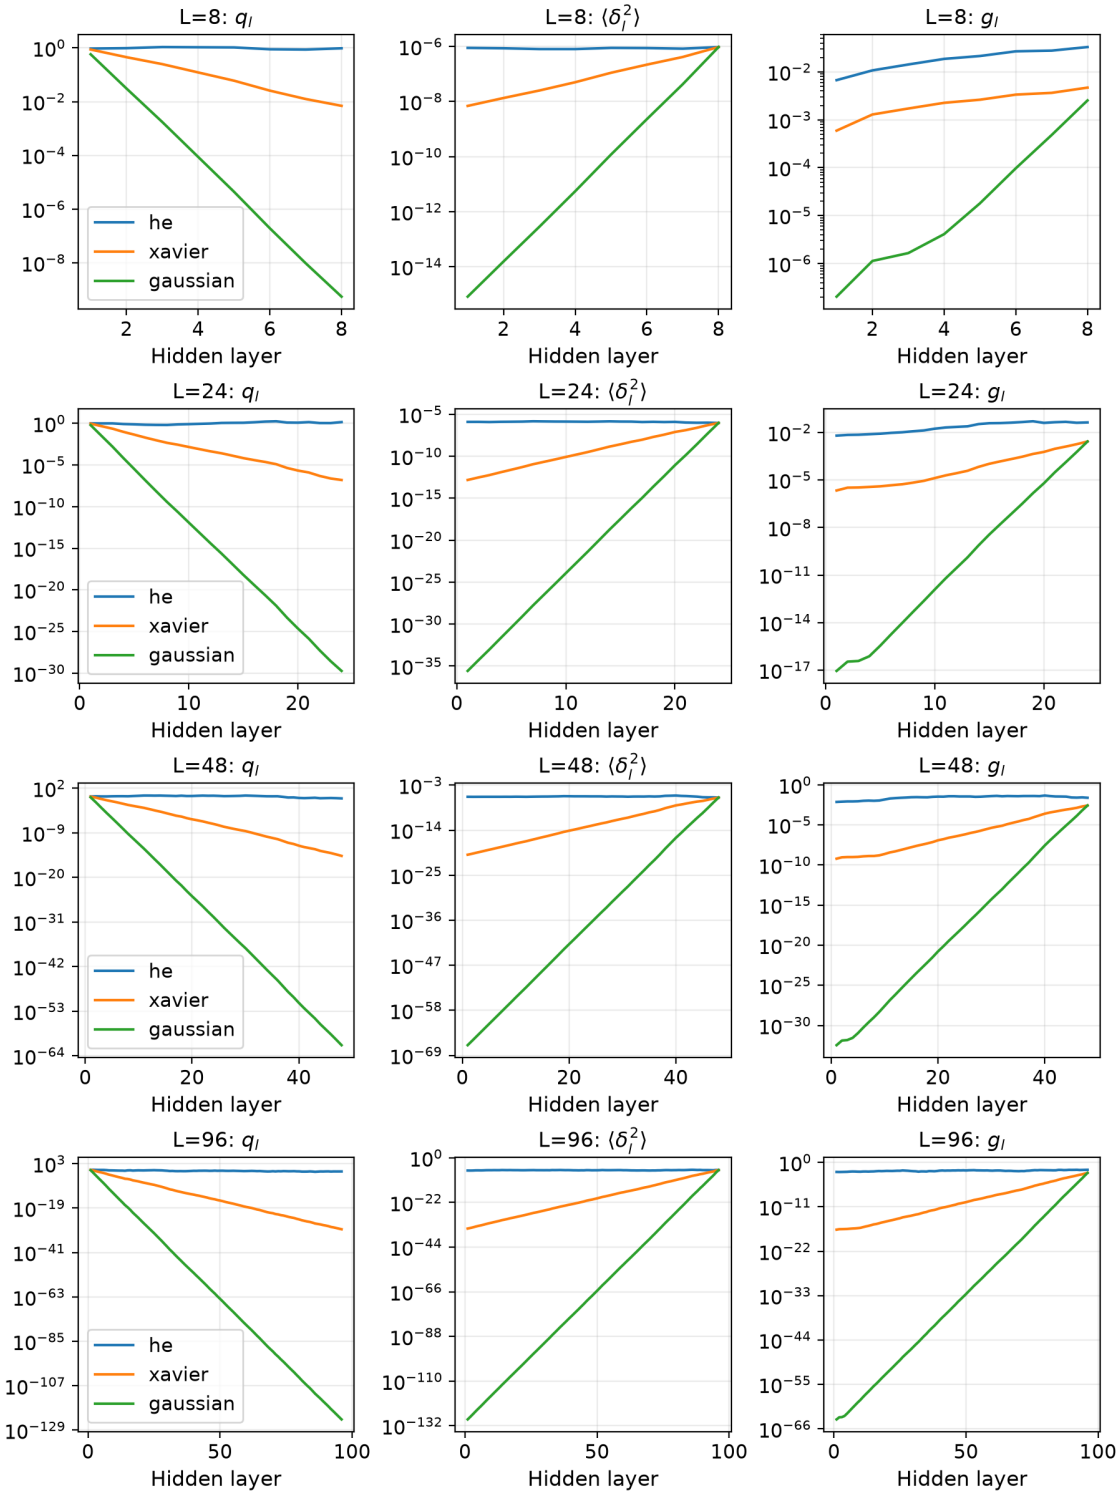


Рис. 1 – Сигнал, градиент по выходу и нормированный градиент параметров: все глубины и три схемы. Источники: R05, R09, R13, R06, R10, R14, R07, R11, R15, R08, R12, R16.

3. E2: глубина и остаточные связи

Заранее записанная гипотеза: Не сохраняет масштаб обычной сети лишь в среднем; для остаточной сети (1.13) предсказывает $(1 + \alpha^2 c)^L$, $c \approx 2$. При $\alpha = 1$ сигнал растёт экспоненциально, а при $\alpha = L^{-1/2}$ ограничивается e^c. Оптимизация и конечная ширина могут нарушать независимость слагаемых.

Таблица 4 – Обучение сетей разной глубины: все условия E2.

Архитектура	L	ρ_T	GI	AVD	val acc.	Статус	Источник
MLP	8	0.5801	0.739	0.469	0.4558	OK	R22
MLP	24	0.6557	0.7856	0.758	0.4056	OK	R23
MLP	48	0.7112	0.8132	1.045	0.3294	OK	R24
MLP	96	0.8061	1.116	0.8217	0.2204	OK	R25
Res $\alpha = 1$	8	–	1.253	–	–	сбой	R26
Res $\alpha = 1$	24	–	1.279	–	–	сбой	R27
Res $\alpha = 1$	48	–	1.434	–	–	сбой	R28
Res $\alpha = 1$	96	–	1.286	–	–	сбой	R29
Res $\alpha = L^{-1/2}$	8	0.5184	1.253	0.4786	0.4688	OK	R30
Res $\alpha = L^{-1/2}$	24	0.5085	1.495	0.5452	0.469	OK	R31
Res $\alpha = L^{-1/2}$	48	0.5202	1.632	0.5518	0.477	OK	R32
Res $\alpha = L^{-1/2}$	96	0.5136	1.773	0.5427	0.4704	OK	R33

Численный сбой является наблюдаемым отрицательным результатом, а не завершёнными тремя эпохами. Для него отсутствующие итоговые метрики обозначены прочерком; не используются случайная точность или нулевая ошибка вместо отсутствующего измерения.

GI при сбое вычислен только по доступным измерениям до остановки, поэтому не сопоставляется как полноценная девятиточечная медиана с завершёнными запусками. Доли нулей в сводке сбоя относятся к исходной пробе. Точная остановка:

Таблица 5 – Число обновлений до численного сбоя при единичной ветви.

L	Завершено эпох	Шагов SGD	Источник
8	0	3	R26
24	0	1	R27
48	0	1	R28
96	0	1	R29

Первая необучаемая глубина (rho≥0.9 либо численный сбой): MLP: не найдена в профиле; Res $\alpha = 1$: 8; Res $\alpha = L^{-1/2}$: не найдена в профиле.

Таблица 6 – Глубина и число параметров обычных и остаточных сетей.

Архитектура	L	Параметры	Линейных слоёв	Источник
MLP	8	1249802	9	R22
MLP	96	7039498	97	R25
Res $\alpha = 1$	8	1841930	18	R26
Res $\alpha = 1$	96	13421322	194	R29
Res $\alpha = L^{-1/2}$	8	1841930	18	R30
Res $\alpha = L^{-1/2}$	96	13421322	194	R33

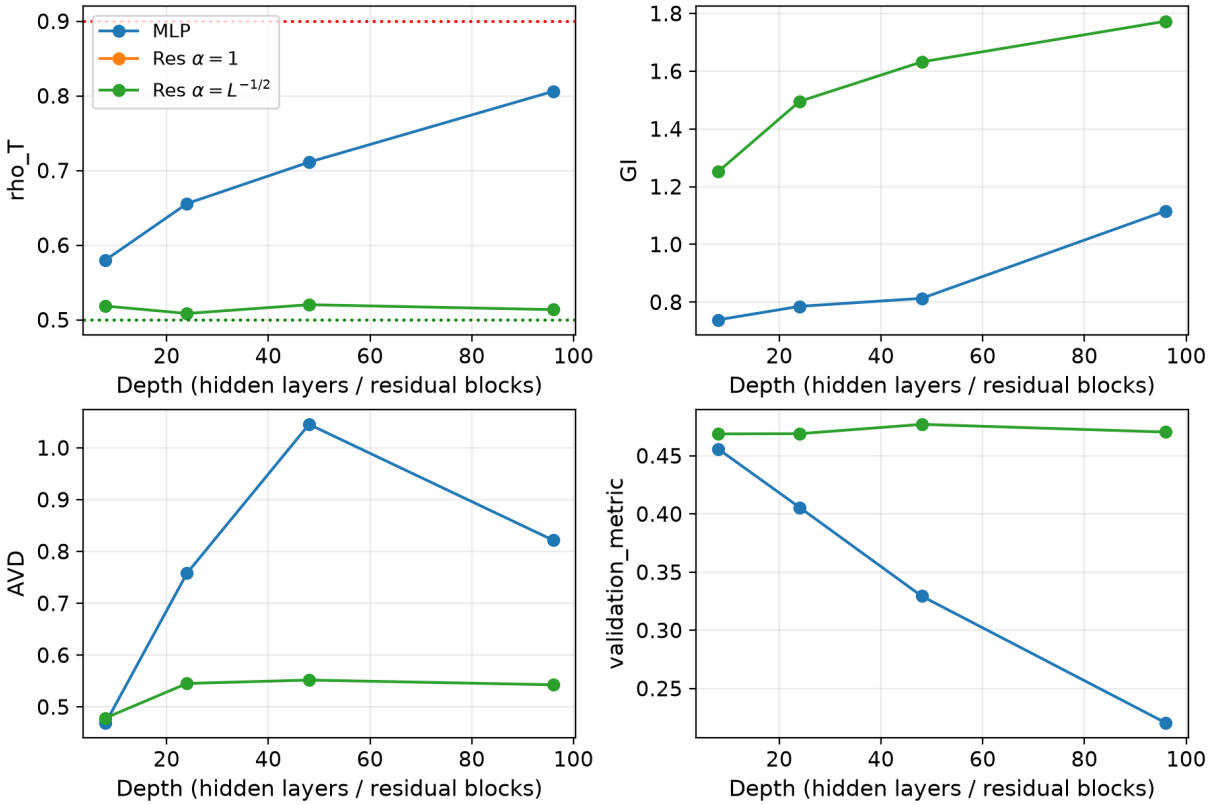


Рис. 2 – Результаты трёх эпох: численно неуспешные условия не выводятся как итоговые кривые. Частичные GI до сбоя сохранены в таблице. Источники соответствуют таблице E2.

Проверка роста сигнала до обучения. Для единичной ветви сравнивается корень степени L, поскольку прямое отношение накапливает малые ошибки каждого блока. Для масштабированной ветви применяется именно верхняя граница 1.2 exp(c).

Таблица 7 – Рост сигнала остаточных сетей до обучения.

Ветвь	L	c	q_L/q_0	$(q_L/q_0)^{1/L}$	Порог	Источник
1	8	2.134	6006	2.967	PASS	R26
1	24	1.718	1.855e+11	2.948	PASS	R27
1	48	1.833	3.773e+22	2.954	PASS	R28
1	96	1.742	2.861e+45	2.975	PASS	R29
$L^{-1/2}$	8	2.134	5.477	1.237	PASS	R30
$L^{-1/2}$	24	1.718	5.693	1.075	PASS	R31
$L^{-1/2}$	48	1.833	7.179	1.042	PASS	R32
$L^{-1/2}$	96	1.742	6.996	1.02	FAIL	R33

Зарегистрированное исключение: на L=96 масштабированная ветвь превышает границу на 2.148%. Этот численный порог не пройден; его нельзя объявить PASS по результатам обучения или подменить другим seed.

Отдельная проба с теми же весами и batch (R40) локализует причину: с первого блока 1.742, среднее с по 96 блокам 2.029, диапазон [1.461, 2.67]. Одно измерение первого блока не является общей константой всех ветвей конечной сети.

Точное равенство для измеренных моментов: $q_{l+1}/q_l = 1 + \alpha^2 c_l + 2\alpha\kappa_l$, где $\kappa_l = \langle h_l, F_l \rangle / q_l$. Произведение этих множителей равно 6.996, непосредственно измеренное отношение 6.996. Если сохранить все разные c_l, но отбросить перекрёстные члены, получится 7.442. Значит, в данном запуске перекрёстные члены суммарно уменьшают рост; превышение границы связано прежде всего с использованием заниженного с первого блока вместо разных c_l. Предположения общего с и нулевого эмпирического перекрёстного момента не выполняются точно. Равенство с полными моментами проверено отдельным автоматическим тестом. Исходное невыполнение порога сохраняется в выводе.

4. Карта обучаемости

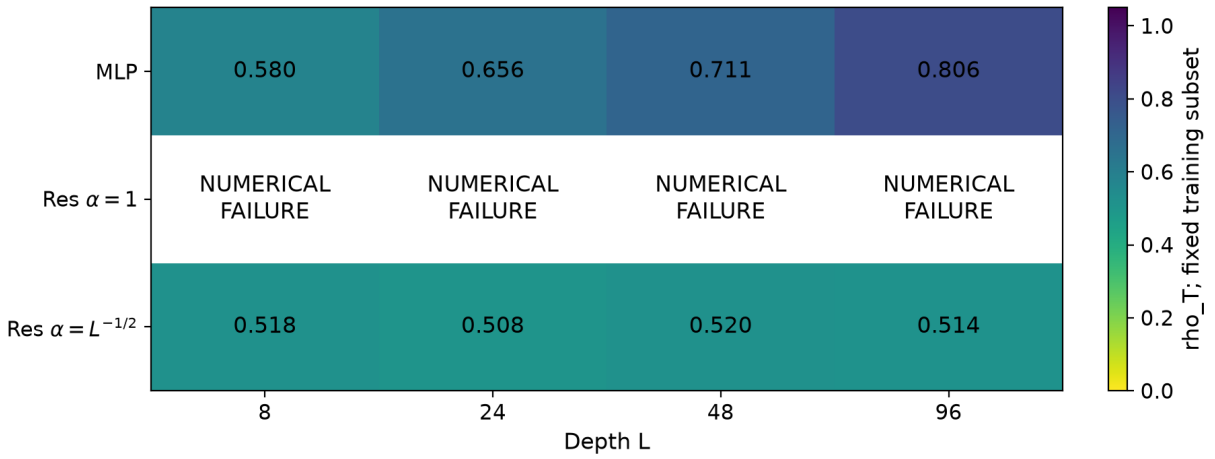


Рис. 3 – Двумерный срез: глубина × архитектура → ρ_T. Численный сбой показан текстом, а не искусственным значением.

Изменяются только глубина и архитектура; фиксированы: CIFAR-10 и его разбиение, полный train, нормализация данных, seed профиля, ширина 256, He, ReLU, отсутствие нормализации слоёв, SGD momentum 0.9, LR=0.003, batch 128, три эпохи, float32, отсутствие AMP и клиппинга, подмножество вычисления rho и расписание измерений. Источники ячеек: таблица E2 и реестр RUN_ID.

Порог $\rho_T \leq 0.5$ обозначает обучаемость; $\rho_T \geq 0.9$ – необучаемость; промежуточные значения – пограничный режим. Более высокая val accuracy сама по себе не означает выполнения порога обучаемости. Карта относится к одному seed и одному разбиению и не доказывает универсальную границу глубины.

5. E3: основное парное сравнение

До обучения E3 сформулирована гипотеза о меньшей относительной ошибке остаточной сети. A: обычная MLP, 96 скрытых слоёв. B: остаточная MLP, 96 блоков, alpha=1/sqrt(96). Единственный изменяемый фактор: архитектура (model.name); остальные поля модели одинаковы.

Основная метрика: ρ_T, меньше лучше. Ожидается положительная разность A−B. Условие опровержения: отсутствие трёх положительных разностей либо средняя разность меньше двух выборочных стандартных отклонений. Все остальные условия совпадают, включая буквальные seeds 1, 2, 3.

Таблица 8 – Основное сравнение E3: все три парных seed.

seed	$\rho_T(A)$	$\rho_T(B)$	Δ_s	A / B
1	0.8074	0.5239	0.2835	R41 / R44
2	0.8038	0.5162	0.2877	R42 / R45
3	0.8003	0.4977	0.3026	R43 / R46

Средняя разность 0.2913, выборочное sΔ=0.01003, 2sΔ=0.02007. По установленному правилу: различие установлено. Это проверка главного эффекта на данном разбиении; три seeds отражают только случайность обучения, а не перенос на другие данные.

Таблица 9 – Средние значения и выборочные SD в E3.

Вариант	Среднее rho	SD rho	Среднее val acc.	SD val acc.
A	0.8039	0.003548	0.2341	0.009979
B	0.5126	0.01345	0.4675	0.008649

6. Ответы на контрфактические вопросы

1. Экстраполяция He до глубины 256

Из R08: $\hat{\chi}_f = 0.9804$. Формальная экстраполяция даёт $q_{256}/q_1 = \hat{\chi}_f^{255} = 0.006359$. Это прогноз по (1.4), а не измерение L=256. Даже небольшое отклонение множителя от единицы накапливается экспоненциально. Стабильность на L=16 не гарантирует ни сохранения масштаба, ни оптимизации на L=256: конечная ширина создаёт корреляции активаций и производных; при обратном проходе предположение независимости градиента от тех же весов уже приближённо. После первого обновления нарушается и предположение исходных независимых весов. Скалярный второй момент не контролирует весь спектр Якобиана.

2. Увеличение ширины в четыре раза

При n=1024 и прежнем $\sigma = 0.02$ прогноз $\chi = 1024\sigma^2/2 = 0.2048$. Отдельная проба R38 дала forward 0.208, backward 0.2056, эффективных слоёв 44. Рост ширины изменяет множитель, но не делает его единичным; sigma не перенастраивалась.

3. Градиент по выходу и градиент по весу

Источник R14: средние квадраты delta на первом и последнем скрытых слоях 2.604e-36 и 9.537e-07; g первого и последнего скрытых слоёв 9.064e-18 и 0.002694.

Для весов $\nabla_{W_l} L$ содержит произведение входа h_{l-1} и обратного сигнала с маской ReLU. По (1.4), (1.8) уменьшение прямого сигнала при продвижении к выходу компенсируется ростом delta в том же направлении; поэтому весовые градиенты внутренних слоёв имеют близкий порядок. Первый слой имеет другую ширину входа и статистику. Однако в обязательном g_l здесь учтены также bias: $\nabla_b L$ не умножается на малый вход. Поэтому полное g может существенно расти к выходу, и буквально одинаковые значения на исходном графике не заявляются. Этот предел подсказки PDF и отличие bias от весов проверены отдельным разложением R39. Константа epsilon в GI дополнительно маскирует различия величин намного меньше 10^{-12}; такой GI не означает сохранения абсолютных градиентов.

В пробе R39 внутренние весовые g (слои 2–24) лежат от $3.479 \cdot 10^{-17}$ до $2.521 \cdot 10^{-16}$, отношение максимума к минимуму равно 7.244. Для bias диапазон составляет от $4.91 \cdot 10^{-17}$ до 0.04318. Это измеренное разложение, а не изменение определения обязательного GI.

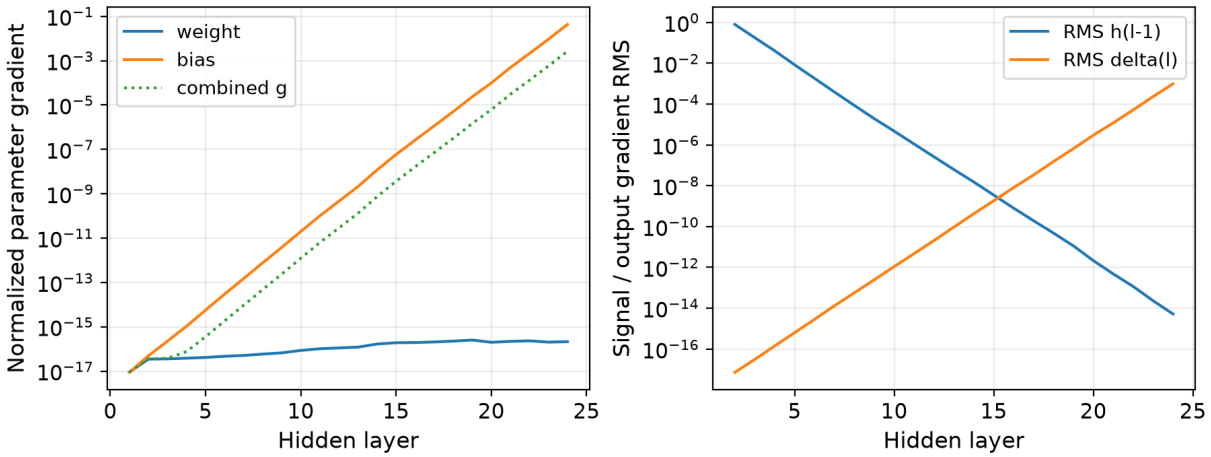


Рис. 4 – Разложение весов и bias; компенсация масштабов прямого и обратного сигналов. Источник R39.

4. Почему единичный skip не предотвращает взрыв

Таблица 10 – Измеренный и предсказанный рост при единичной ветви.

L	Измерено q ratio	Прогноз $(1+c)^L$	Ошибка корня	Источник
8	6006	9299	0.05319	R26
24	1.855e+11	2.641e+10	0.08461	R27
48	3.773e+22	5.07e+21	0.0427	R28
96	2.861e+45	1.127e+42	0.08509	R29

Единичный член Якобиана обеспечивает прямой путь, но не убирает вклад ветви. При $\alpha = 1$ накопление энергии ветвей экспоненциально; огромные логиты и производные делают обучение неустойчивым. Формула предсказывает средний рост при инициализации, а не устойчивость конечного шага SGD. Расхождения полных отношений при глубине 96 могут быть большими даже при допустимой ошибке среднего множителя за блок.

5. Близкая точность не означает одинаковую устойчивость

Пара выбрана исследовательски из E2: разность val accuracy не более0.02, разность GI не менее0.5; следующая глубина для каждой конфигурации уже содержится в сетке E2, поэтому это проверка на имеющихся данных, а не независимый прогноз. Текущие конфигурации: R22 и R30; проверка следующей глубины: R23, R31. Обе исходные сети имеют глубину 8; следующий уровень профиля равен 24.

Таблица 11 – Проверка следующей глубины для конфигураций с близкой точностью.

Архитектура	L	val acc.	GI	ρ_T	Источник
MLP	8	0.4558	0.739	0.5801	R22
Res $\alpha = L^{-1/2}$	8	0.4688	1.253	0.5184	R30
MLP	24	0.4056	0.7856	0.6557	R23
Res $\alpha = L^{-1/2}$	24	0.469	1.495	0.5085	R31

При переходе от глубины 8 к 24 accuracy обычной сети снизилась на 0.0502, а ρ_T выросла на 0.07559 (R22/R23). Для масштабированной остаточной сети accuracy изменилась на +0.0002, а ρ_T — на -0.009899 (R30/R31). Одинаково устойчивыми эти конфигурации считать нельзя. В выбранной паре масштабированная остаточная сеть сохраняет точность лучше, хотя её GI выше: GI не является достаточным сертификатом устойчивости при сравнении разных архитектур, масштаба ветви и нормировки числа параметров. Проверка соседней глубины не даёт права объявить общий причинный закон по четырём точкам.

Заключение

Не сохраняет средний масштаб сигнала значительно лучше Xavier и Gaussian с фиксированным малым σ. Масштабирование остаточной ветви предотвращает наблюдавшиеся численные сбои единичной ветви и снижает ρ_T на глубине 96: средняя парная разность равна 0.291256 при SD 0.010034. По правилу задания различие установлено. Однако граница роста $1.2e^c$ в одном условии не выполнена, а значения ρ_T большей части обученных сетей остаются пограничными. Вывод относится к одному split, трём эпохам и выбранным архитектурам; разные числа параметров plain/residual следует учитывать при переносе сравнения.

Список использованных источников

[1] Лабораторная работа 1. Почему глубокая сеть обучается или не обучается. Инициализация, нормализация и остаточные связи. Курс «Нейронные сети». Методические указания, 2026.

Приложение. Идентификация запусков

Таблица 12 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R03	budget deep mlp8	f35bc17d724ab6701081-82b8437770094d618463160db216475b
R04	budget residual mlp96	7985b20739cc3e05fbf7-3ee53f04473f463e91f20cf0a9489de8
R05	E1 he 8	835b5aa0a6f48bd5d01a-f54918af472940a8bda1544bbb329a16
R06	E1 he 24	daa1a446d8bceaabc44b-0020695fecef4a11b1175d6777f6a866
R07	E1 he 48	534625583d5990da50fd-6b7164b3c8a84bf484d39fb270e6e418
R08	E1 he 96	42b49b40517988afe273-40a880f74e9442d594137504c5cea87a
R09	E1 xavier 8	49b8b7c74a10aa5a1a64-72e0590df7f948ef842011c216d05444
R10	E1 xavier 24	6144c2152d8b81e8e800-e50fafcc7ae24bbc85d0ee8a28e452df
R11	E1 xavier 48	67cc401b4bb5ac8738d7-601c39a72896441bb8dc2572ef47ddb1
R12	E1 xavier 96	e6a6b92aec9f1b597e47-59437c84059143c0a7a006c5e2cc9afa
R13	E1 gaussian 8	d268af8bc42f48f6aedb-28e24e9853d241b4964e0fcc831a33d0
R14	E1 gaussian 24	4e0cd7079a80871a0fd2-0bd00f5a2a5c4d44b609ad1887b3c9ae
R15	E1 gaussian 48	1b3500a435561a91443f-289aa271826f4edeab053939b401b384
R16	E1 gaussian 96	25e23c0eead538f90a0d-589b8c19d95b4d7d99ce737c9178879a
R17	LR 0.001	a33e03472d5d93fa15fc-c04ce6a1e9de4cbc9a55963b7c6efe8f
R18	LR 0.003	2a04c5f5545b92efa370-90029285e78c4036b5045079e0040cb3
R19	LR 0.01	400ffa75051d3a2de91e-33949168d69e4583b9df2dcaec27996f
R20	LR 0.03	1d8d7a73e2b3bb3c5592-5d490d650a6b489f9f3cd00163c0e9e8
R21	LR 0.1	8f701c927e6893a8a94d-d190e54bf6b140c1b06756b2fe7e9f69
R22	E2 plain 8	072042389309a9d0e7ed-1f2cf56abb4346aaaf4c984d8453e7cb
R23	E2 plain 24	58dafff69939ce9dbcb6-e66dade201944d788880ac3ce569c948
R24	E2 plain 48	6ed9fd9deccbf25d4dbe-cc78467e46a3445c94defd782f4fc343
R25	E2 plain 96	f02840c34662292f2550-7cdcbabd38c5472aa0d47e49f5bb04a5
R26	E2 residual unit 8	f6f40777a94fe870b3f5-7aca80a890724e3f9bda60579352ab21
R27	E2 residual unit 24	760974ee261830470993-0f7a8c6bd49543a3841314e919684f77
R28	E2 residual unit 48	3dbe3c0827c108c86e2a-e047f8229707429c93184bc75d3c244e
R29	E2 residual unit 96	bc1cfc0f52214e75038c-38c277eeab774b1194dd1844f372dc67
R30	E2 residual scaled 8	43ffb961514ceb1ea9d8-f27c2da7032640ada2cfd54df8a038c8
R31	E2 residual scaled 24	b48bb6d07e183f729073-5be4e5eaf78049d6964cdcc1cb02e95c
R32	E2 residual scaled 48	1ef26c51c6f46c53cce1-8d3592e5eea64c9eaf0fe094da598ca9
R33	E2 residual scaled 96	0f7c5a6ad6fc18622306-27adbadc93c941d1af43fd88e9bac108
R34	E1 after epoch gaussian 8	f65cc36c6722183555aa-55a880a1f0d6428a854d9626cdcb4442
R35	E1 after epoch gaussian 24	6a2dbdc4016e278bf3ac-57c9588a9af74ea1b49fabff4156f78a
R36	E1 after epoch gaussian 48	46cc2d0333f98ec911be-63cd8333272b4ec09520e3337f7b87cf
R37	E1 after epoch gaussian 96	670167bc6a9b50380a01-fe8eb710b34741b4a0978cfb2c3294a7
R38	CF2 gaussian width1024 depth96	e5d33ffe2c320c0cf4ed-90f1f3c566024a2684f150ddc75997b6
R39	CF3 weight bias decomposition	7cef8aaa61602a4f04d9-91b54d0671914614a3854f8c4544cee4
R40	E2 scaled96 growth diagnosis	3d2329355cfed30d7490-9c4f04a2bdf744f3a1b3c4df418355b6

Таблица 12 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R41	E3 A seed1	`e8c645d9482cd256deae-3f76ac4a3a8949d1af2fd196756c229b`
R42	E3 A seed2	`3306f27ee19bbcebd235-ffc3d19080444f2e86a38406c6784fb8`
R43	E3 A seed3	`3a67488efc107b654691-80b220070f3146d985a3ab8ca3068b80`
R44	E3 B seed1	`779d5c921f74c67065a7-644d33a4885e46dc89cb2d71aa80648d`
R45	E3 B seed2	`0433af61b3f2e9d2763d-399fdc59a4944ec58dcf970657b2a013`
R46	E3 B seed3	`dc6ad98cb134159efb9f-a47999757e4141b29594336febc1a142`