МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»



ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Инженерная школа информационных технологий и робототехники
Направление 09.04.01 «Информатика и вычислительная техника»
Отделение информационных технологий

Лабораторная работа № 3

«Attention и моделирование длинных последовательностей Positional representations, extrapolation, complexity и local attention»

по дисциплине «Нейронные сети»

Выполнил:
студент гр. 8ВМ53 _____ Ван Чжаофу

Проверил:
_____ Григорьев Д. С.

Томск – 2026

Содержание

1 Профиль и протокол 3

2 E1. Позиция и экстраполяция 4

3 E2. Измеренная стоимость внимания 5

4 Диагностика внимания 7

5 E3. Основное сравнение на трёх seed 8

6 Ответы на контрфактические вопросы 9

Список использованных источников 11

Приложение. Идентификация запусков 12

1. Профиль и протокол

1.1. Цель и теория

Цель — отделить ограничения позиционного представления от стоимости внимания и переноса зависимости в задаче копирования [1]. Для одной головы

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V, \qquad A = \text{softmax}(QK^\top/\sqrt{d_k}), \quad Y = AV. \quad (1)$$

Делитель удерживает дисперсию скалярного произведения: при независимых единичных компонентах $\text{Var}(q^\top k) = d_k$. Pre-norm блок имеет две остаточные ветви: $X' = X + \text{MHSA}(\text{LN}(X))$ и $X^+ = X' + \text{MLP}(\text{LN}(X'))$. Без позиции и маски перестановка входа переставляет выход. В задаче copy все пустые позиции одинаковы, поэтому такой режим не может восстановить разные символы по порядку.

Сравниваются четыре режима. Обучаемая таблица прибавляет p_m к токену и содержит ровно L_0 обученных строк. Синусоида определена как

$$PE(m, 2i) = \sin(m/10000^{2i/d}), \quad PE(m, 2i+1) = \cos(m/10000^{2i/d}). \qquad (2)$$

RoPE вращает пары координат Q, K на угол $m\theta_i$, где $\theta_i = 10000^{-2(i-1)/d_k}$, поэтому $(R_m q)^\top (R_n k) = q^\top R_{n-m} k$. Формальная определённость синусоиды и относительный вид RoPE не гарантируют сохранения навыка на новых длинах.

Для таблицы основное правило P2 линейно интерполирует строки по координате $t = m(L_0 - 1)/(L - 1)$. P1 сохраняет старые строки и добавляет случайные необученные; P3 отказывает за границей таблицы. Никакого дообучения на новых длинах нет.

1.2. Данные, модель и метрики

Профиль P3adf02: copy, $L_0 = 128$, два блока. Алфавит содержит 64 символа. Первая половина входа — независимый случайный фрагмент, вторая — пустые позиции; перекрёстная энтропия считается только на второй половине. Нечётная длина уменьшается на один. В обучении длина равномерно выбирается в диапазоне 64–128, внутри batch она общая. Нет padding и каузальной маски. Train, val, cal, test имеют независимые генераторы; cal не участвует в работе. На каждой test-длине 256 последовательностей.

Ширина 128, четыре головы, FFN 256, два pre-norm блока; dropout отсутствует. Общие условия: AdamW, weight decay 0.01, batch 32, 2000 обновлений, FP32, CUDA. LR 0.003 выбрана один раз по val синусоидальной модели из $0.0003, 0.001, 0.003$. Во всех четырёх режимах E1 используется seed 1 и явное внимание. Бюджет не увеличивался: требуемый разрыв val достигнут уже на 2000 шагах.

$$M(L) = \frac{\text{верные целевые токены}}{\text{все целевые токены}}, \qquad ER(L) = \frac{M(L)}{M(L_0) + 10^{-8}}, \quad \Delta_{pos} = M_{method} - M_{P2}. \qquad (3)$$

2. E1. Позиция и экстраполяция

Исходное ожидание: без позиции копирование не будет освоено, а коды позиции дадут преимущество на L_0; сохранение этого преимущества за L_0 требует отдельной проверки. На val получены 0.057861 без позиции, 0.126770 для P2, 0.461243 для синусоиды и 0.109558 для RoPE. Порог $1/64 + 0.05 = 0.065625$ для режима без позиции выполнен. Отрыв лучшего кода равен 0.403381, выше требуемых 0.20.

Таблица 1 – E1: точность целевых токенов и отношение к обучающей длине; таблица позиций использует P2.

Код	L	$M(L)$	$ER(L)$	Δ_{pos}	Источник
none	128	0.058594	—	-0.067078	R01
none	256	0.041473	—	-0.061798	R02
none	512	0.030777	—	-0.047409	R03
none	1024	0.024765	—	-0.031013	R04
absolute	128	0.125671	1.000000	+0.000000	R05
absolute	256	0.103271	0.821758	+0.000000	R06
absolute	512	0.078186	0.622147	+0.000000	R07
absolute	1024	0.055779	0.443844	+0.000000	R08
sinusoidal	128	0.469177	1.000000	+0.343506	R09
sinusoidal	256	0.024963	0.053207	-0.078308	R10
sinusoidal	512	0.021469	0.045759	-0.056717	R11
sinusoidal	1024	0.016548	0.035271	-0.039230	R12
rope	128	0.110718	1.000000	-0.014954	R13
rope	256	0.015015	0.135612	-0.088257	R14
rope	512	0.015152	0.136852	-0.063034	R15
rope	1024	0.015938	0.143950	-0.039841	R16

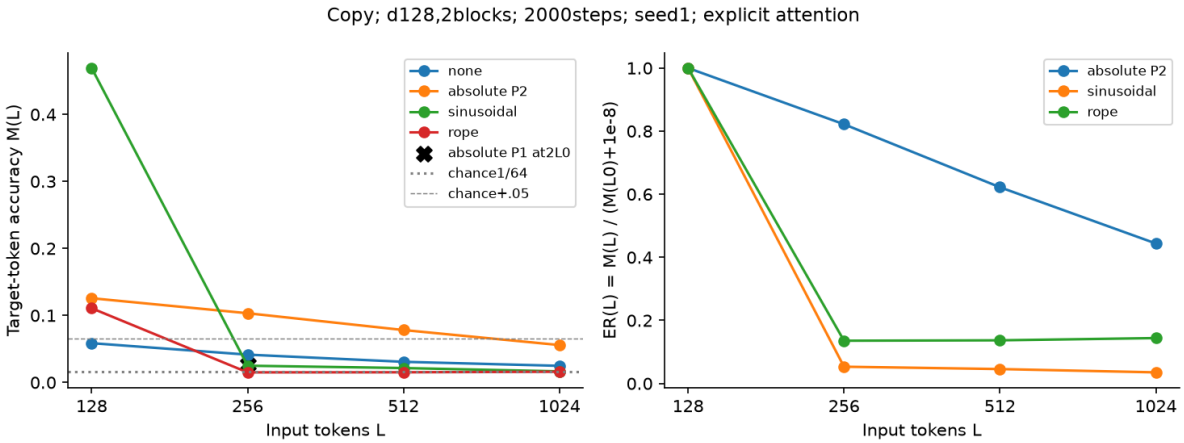


Рис. 1 – E1: точность и ER на новых длинах без дообучения; absolute использует P2.

Синусоида лучше при обучающей длине, но уже на 256 её точность снижается до 0.024963. P2 даёт меньшую точность на L_0, зато сохраняет преимущество на длинных входах. Для none ER не интерпретируется как перенос навыка: уже исходный результат близок к частотному уровню и ниже практического порога. Все длины поместились в память.

Первая измеренная длина больше L_0 с $M \leq 0.065625$: P2 — 1024, синусоида и RoPE — 256. У none условие выполнено уже на 128, а первая более длинная точка — 256. Максимальные проверенные длины выше порога: P2 — 512, синусоида и RoPE — 128. Это границы сетки для данного генератора, а не универсальная длина контекста.

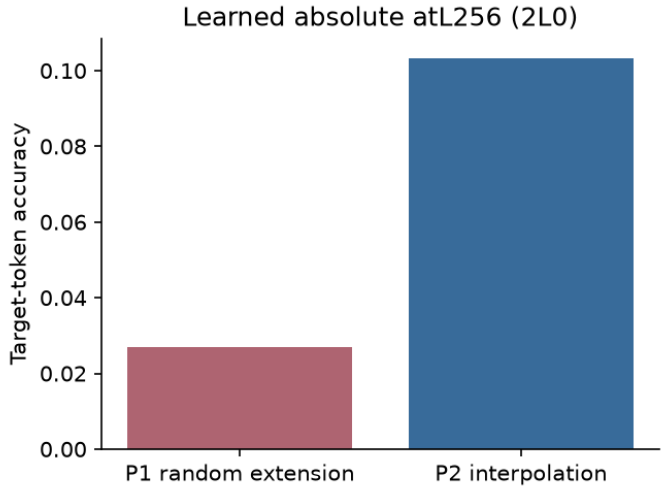


Рис. 2 – Сравнение P1 и P2 при удвоении длины для одних обученных весов.

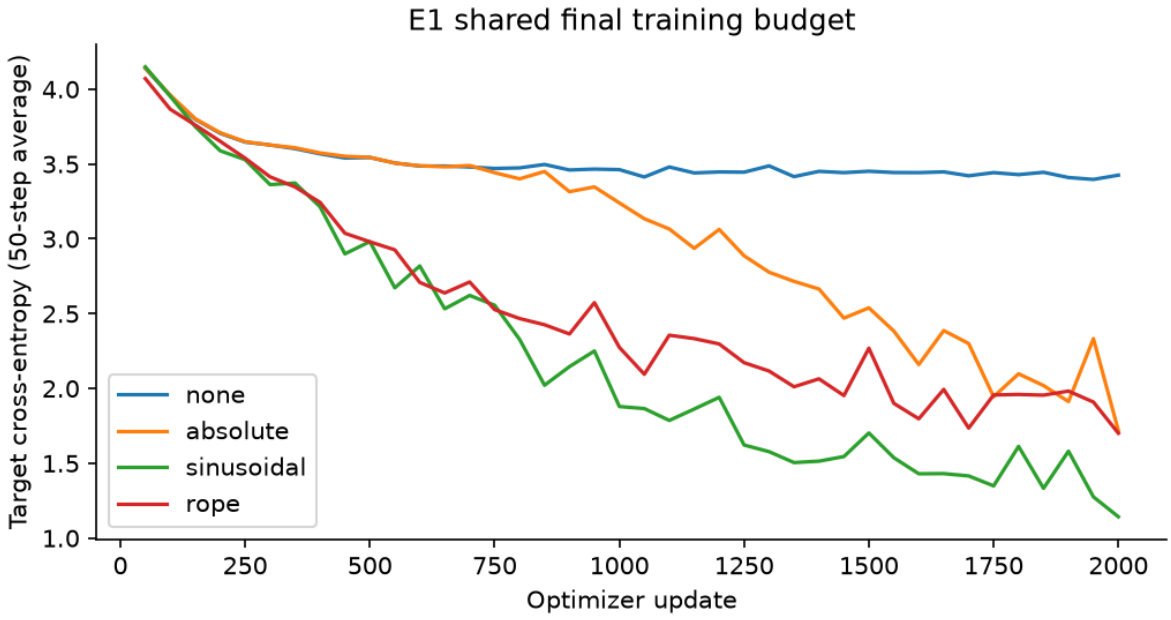


Рис. 3 – Train loss четырёх режимов позиции при общем бюджете 2000 обновлений.

3. E2. Измеренная стоимость внимания

Профилирование не является обучающим сравнением: случайные веса фиксированы, batch 4, FP16. Каждая точка измерена в отдельном процессе после 10 прогревов по 30 повторам с синхронизацией CUDA; пик — фактический максимум распределителя. Сравниваются explicit и принудительно выбранный efficient SDPA. FlashAttention в этой сборке Windows недоступен, поэтому efficient не обозначается как Flash.

Таблица 2 – E2: средние времена после прогрева и измеренный пик CUDA, batch 4, FP16.

Backend	L	Forward, мс	Шаг, мс	Пик, MiB	Токен/с	Ист.
explicit	64	2.252	8.739	68.549	113659	R17
explicit	128	2.461	9.264	71.023	208019	R18
explicit	256	2.283	9.670	80.345	448472	R19
explicit	512	3.198	9.318	114.884	640374	R20
explicit	1024	2.975	9.176	243.962	1376727	R21
efficient	64	1.840	8.365	68.307	139102	R22
efficient	128	1.757	7.599	69.984	291369	R23
efficient	256	1.798	7.929	73.852	569427	R24
efficient	512	1.686	7.405	81.930	1214745	R25
efficient	1024	2.835	9.243	98.086	1445015	R26

Таблица 3 – Наклоны log–log регрессии по пяти длинам и по двум наибольшим.

Backend	Величина	α_{all}	$\alpha_{512,1024}$
explicit	Время forward	0.118089	-0.104255
explicit	Время шага	0.014908	-0.022257
explicit	Пик памяти	0.435671	1.086481
efficient	Время forward	0.118652	0.749570
efficient	Время шага	0.025052	0.319792
efficient	Пик памяти	0.127139	0.259660

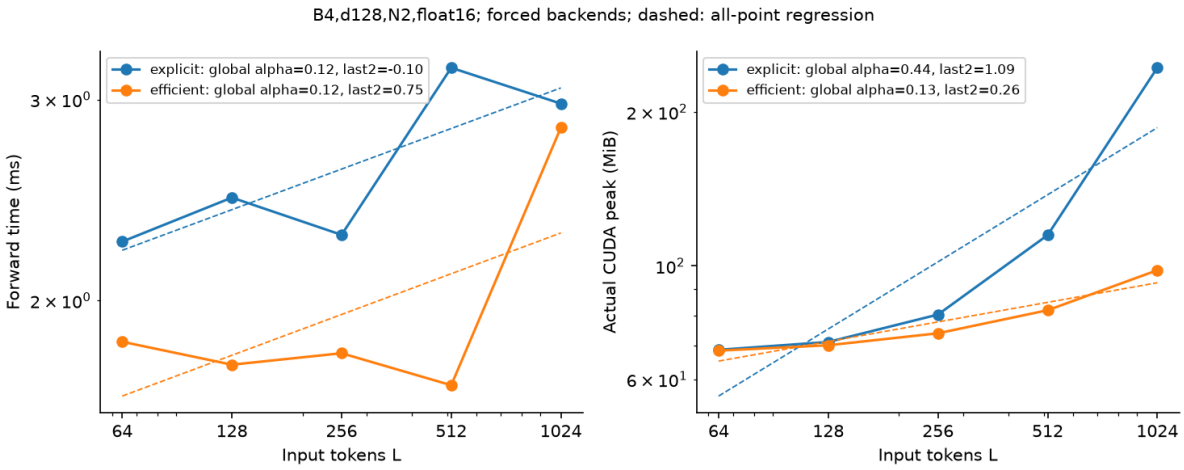


Рис. 4 – E2: измеренная стоимость explicit и efficient SDPA; log–log регрессии.

Теоретическая стоимость блока имеет слагаемые L^2d и Ld^2. В данной архитектуре MAC произведений внимания равен $2BL^2d$, проекций и FFN — $8BLd^2$; отношение равно $L/(4d)$ и меняется от 0.125 до 2. Полный пик памяти включает веса, состояния оптимизатора, линейные активации и временные буферы.

Глобальные наклоны памяти 0.435671 и 0.127139 не попали в интервалы 1.6–2.4 для явного и 0.8–1.2 для эффективного внимания. Этот отрицательный результат сохраняется. Время немонотонно и не подтверждает квадратичный асимптотический режим. По допускаемому в разделе 9.2 задания способу выполнено неотрицательное описательное разложение $aL^2 + bL + c$. На $L = 1024$ доли этих компонент в пике: explicit 66.72%, 5.90%, 27.38%; efficient 1.43%, 31.03%, 67.55%. Фиксированная составляющая уменьшает

наблюдаемый наклон. Пять длин не позволяют причинно отождествить каждый коэффициент с отдельным механизмом. Подстановка теоретического размера A вместо измеренного пика здесь не используется.

4. Диагностика внимания

Для лучшей по val синусоидальной модели сохранены 256 последовательностей на каждой длине. По каждой голове отдельно рассчитаны

$$H_i = -\sum_j A_{ij} \ln(A_{ij} + \varepsilon), \quad D_i = \sum_j A_{ij}|i-j|, \quad \mu_i(16) = \sum_{|i-j|\le 16} A_{ij}. \tag{4}$$

Также показаны максимальный вес строки, масса на соответствующем исходном символе μ_{tgt} и энтропия на позициях ответа H_{ans}. Остальные средние берутся по всем query и объектам, масса цели — по целевым позициям.

Таблица 4 – Диагностика синусоидальной модели по головам: R27 при $L = 128$ и R28 при $L = 256$.

L	Блок	Гол.	H	D	$\mu(16)$	max A	μ_{tgt}	H_{ans}
128	1	1	4.0864	50.6866	0.1602	0.0611	0.0115	4.6631
128	1	2	3.8492	55.4976	0.0885	0.0728	0.0146	4.1606
128	1	3	4.2182	53.4020	0.1149	0.0421	0.0209	4.4416
128	1	4	4.3923	40.9418	0.2781	0.0406	0.0081	4.4746
128	2	1	2.0715	45.1388	0.2309	0.2988	0.2231	1.7876
128	2	2	2.0912	45.5602	0.2321	0.2908	0.2202	1.8238
128	2	3	2.1303	45.4354	0.2299	0.2817	0.2201	1.8415
128	2	4	2.1185	44.9189	0.2416	0.2802	0.2262	1.8339
256	1	1	5.0163	96.1305	0.0674	0.0194	0.0049	5.3194
256	1	2	4.3674	112.0862	0.0218	0.0481	0.0089	4.0874
256	1	3	4.9851	107.1343	0.0434	0.0223	0.0081	4.8035
256	1	4	4.9017	106.9133	0.0583	0.0245	0.0087	4.8682
256	2	1	2.9694	100.2339	0.1205	0.2039	0.0085	2.4816
256	2	2	2.8748	101.9694	0.1154	0.2128	0.0078	2.3935
256	2	3	2.9838	103.6340	0.1215	0.1925	0.0083	2.5291
256	2	4	3.0121	102.5506	0.1242	0.1798	0.0082	2.5281

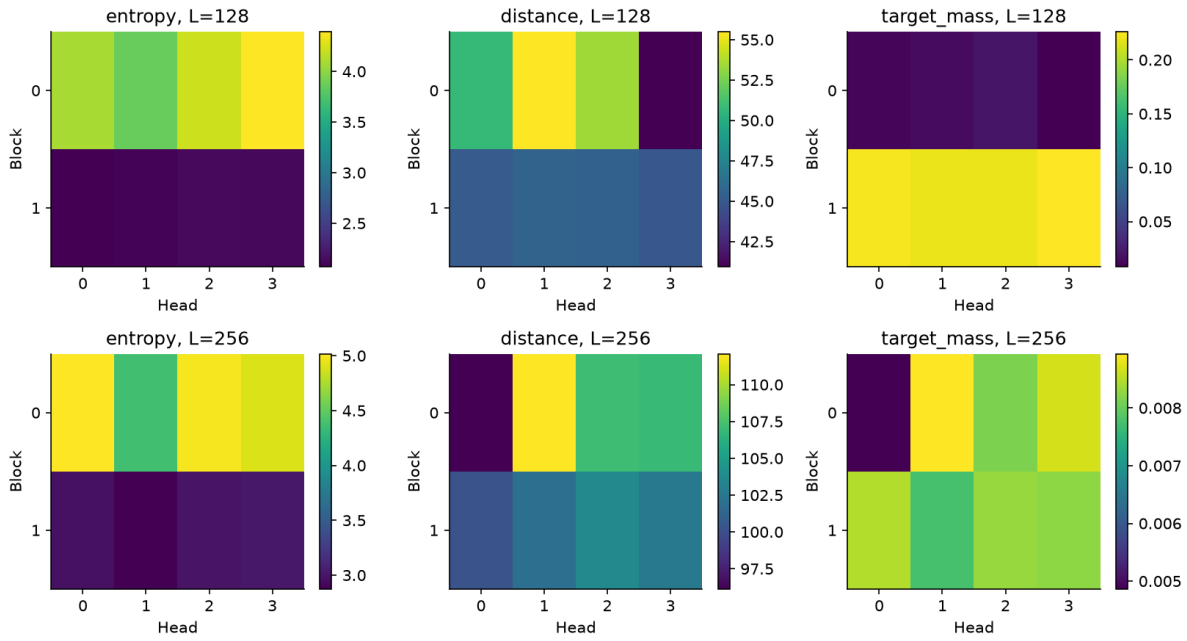


Рис. 5 – Энтропия, расстояние и масса внимания по головам синусоидальной модели.

Во втором блоке средняя масса на нужном исходном символе падает с 0.222375 до 0.008194, одновременно с падением точности. Среднее расстояние растёт примерно с 45 до 102 токенов, масса в окне 16 уменьшается. Энтропия тоже зависит от длины, поэтому её сравнение учитывает изменение числа ключей: равномерная строка имеет $\ln L$. Эти наблюдения согласуются с нарушением маршрутизации, но карта внимания не доказывает необходимость конкретной головы без вмешательства.

5. E3. Основное сравнение на трёх seed

До дополнительных запусков зафиксирована гипотеза $M_{RoPE}(256) - M_{P2}(256) < 0$: интерполяция P2 может лучше сохранить используемую сетку, тогда как относительная форма RoPE сама по себе не обеспечивает переноса. Единственный изменяемый фактор — позиционное представление. Архитектура, LR, бюджет, генератор, explicit backend и длина оценки фиксированы. Нулевая либо положительная разность или отсутствие устойчивости по критерию задания опровергли бы ожидаемый установленный отрицательный эффект. Seed 1 повторно использует веса E1; seed 2 и 3 независимы и общие для пары.

Таблица 5 – E3: RoPE минус абсолютная таблица P2, $L^* = 256$.

Seed	RoPE	P2	Δ_s	Источники
1	0.015015	0.103271	-0.088257	R29/R30
2	0.022491	0.093964	-0.071472	R31/R32
3	0.017029	0.073639	-0.056610	R33/R34

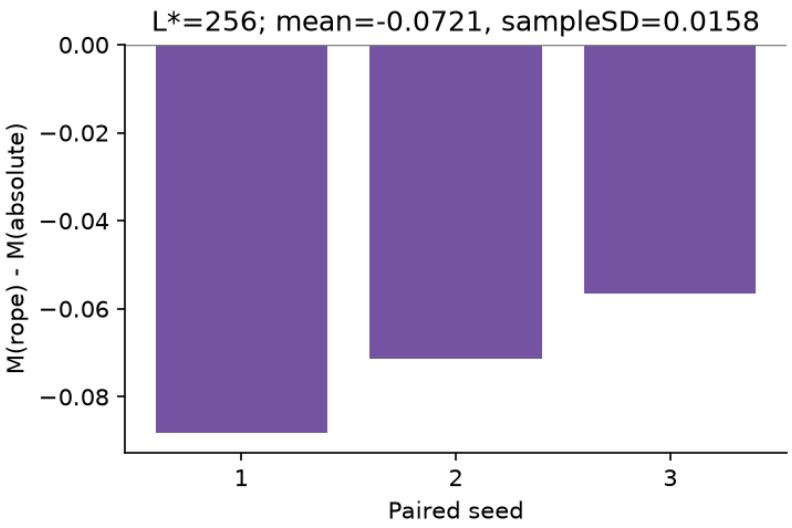


Рис. 6 – Три парные разности RoPE минус P2.

Средняя разность равна -0.072113, выборочное SD — 0.015833. Все три значения отрицательны и $|\overline{\Delta}| \geq 2s_{\Delta} = 0.031666$: различие установлено в пользу P2, гипотеза поддержана. Вывод относится к сору, длине 256 и данному рецепту; он не переносится автоматически на естественные тексты.

6. Ответы на контрфактические вопросы

Вопрос 1. Определённость синусоиды и перенос

На максимальной длине 1024 синусоида даёт $M = 0.016548$, $ER = 0.035271$ (R12). Модель обучалась только до 128. Новые фазы и расстояния формально допустимы, однако закономерность копирования на них не была освоена. Определённость вектора позиции не является гарантией качества.

Вопрос 2. Четырёхкратное увеличение длины

При 256 $\rightarrow$ 1024 число элементов A растёт в $4^2 = 16$ раз. Фактический пик explicit растёт в 3.036440 раза, efficient — в 1.328150 (R19/R21 и R24/R26). Парные наклоны равны $\log(3.036440)/\log 4 = 0.801190$ и 0.204709. Фиксированные и линейные компоненты пика объясняют отличие от чистого размера матрицы; efficient не хранит полную матрицу A.

Вопрос 3. P1 против P2

При 256 получены $M_{P1} = 0.027008$ (R35) и $M_{P2} = 0.103271$ (R06). Разность P2 минус P1 равна 0.076263. P1 добавляет случайные необученные строки, P2 интерполирует всю сетку внутри обученного диапазона и меняет расстояния между кодами. Числа характеризуют два правила для одних весов без дообучения.

Вопрос 4. Одна длина и вся кривая

Даже преимущество RoPE на одной длине не означало бы независимость навыка от длины. В собственных данных RoPE уступил P2 на всех четырёх длинах, а три разности E3 отрицательны. Его M изменяется с 0.110718 до 0.015938, то есть навык явно не сохраняется. Установленный знак E3 относится только к выбранной длине и генератору.

Вопрос 5. Удвоение ширины

При $L = 512$, $d : 128 \to 256$ сохранённые времена forward равны 2.299830 и 3.128763 мс (R36 / R37), отношение 1.360432. Члены $L^2 d$ и $L d^2$ увеличиваются в 2 и 4 раза. При исходных размерах их MAC-вклады равны, поэтому суммарный теоретический рост — в 3 раза. Замер ближе к 2, но ниже обоих чистых множителей: фиксированные расходы и загрузка GPU существенны, а близость к 2 не доказывает доминирования одного члена. **Заключение.** Максимальная длина, помещающаяся в память, не совпала с длиной сохранения навыка. P2 оказался устойчивее RoPE на выбранном режиме, хотя синусоида лучше на обучающей длине. Полный пик и время на данной сетке не достигли простых асимптотических режимов; разложение стоимости позволяет описать это ограничение без подмены измерений.

Список использованных источников

[1] Лабораторная работа 3. Attention и моделирование длинных последовательностей. Positional representations, extrapolation, complexity и local attention. Курс «Нейронные сети». Методические указания, 2026.

Приложение. Идентификация запусков

Таблица 6 – Полные RUN_ID источников результатов.

Код	Условие	RUN_ID
R01	E1 none L128	39a1e67c568afe0e37ae-fbdaf429f02949d3aa954ef0a7413191
R02	E1 none L256	f114fe509648da7b49f7-1b8c6edd068e418bac214fba181fdd09
R03	E1 none L512	e1ac564e288280b848d4-502bea42f55047859fa3a1731b1f1bda
R04	E1 none L1024	6de547c4c16e6eb48409-a3de018b67e940b582cf6a3f528614ae
R05	E1 absolute L128	d736946de91b20c626c4-a6f215ba70b84066af2d941dbbe12ee7
R06	E1 absolute L256	845d705bc5bb903516c8-748407084dd1465c887abe46f362f47d
R07	E1 absolute L512	f8074c189505727e0ccf-3981eb86dc464a3f9f68f8031b5af2f2
R08	E1 absolute L1024	cb812fc715c93835c683-84b994ebe1e346af8b5ed4bd654ca86a
R09	E1 sinusoidal L128	ba603459beba7c94148e-5e3c9760ad2e49f9872957427a668afd
R10	E1 sinusoidal L256	8c10d0590ae01638d9dd-7337e208cccc48fda1929186f0f36f01
R11	E1 sinusoidal L512	4d707f93887c3d8b4457-251ba15323f044d7a744e6bc931b3b9b
R12	E1 sinusoidal L1024	a52079b305a573b0a345-873c9a3089794dd7adb24c832d642ab5
R13	E1 rope L128	61fdba3d7d201fa4d57f-a4b611115fa4462a806c8e87183cadcf
R14	E1 rope L256	3b50ed6e7f33d6181d3f-f56b595426f14655b5f51ccd12feda63
R15	E1 rope L512	2d84c8b5e95f6e3f3142-7b9aff603250409484ac8d6dfaa1ce25
R16	E1 rope L1024	92370f1efe2928f08dd0-7aab1815493d4fb482d0e0beb0ec0f06
R17	E2 explicit L64	24f7a8ba7960c3f9e999-f228a00ba2c347bcbb206618a346bcf5
R18	E2 explicit L128	a7b35549eff6ece9eb69-a9b4449f96a24e4292114bc491bdc52d
R19	E2 explicit L256	e5d04a9497324471d3a0-e6e5c7472e18460ea27e19556d23e10b
R20	E2 explicit L512	4931af932992351dfa50-cec56a3b47ad417a8c33b962b88da271
R21	E2 explicit L1024	a086c993bc6d504fa01c-c14c5e9c287546348a7e18640a62bf27
R22	E2 efficient L64	1550b6a9b24f1e551915-4edd8677db9c4fe19e100650ebfae848
R23	E2 efficient L128	6b665e12a6c53dfe2711-6bacc96b732a4dec945d276cfc54cb22
R24	E2 efficient L256	54002e33bd89266b4aa0-5d661f49f1044fb7ac129f098f820b8b
R25	E2 efficient L512	d07391af265a5628039e-173659cdb29b4766b24ffe9bd80cf1b3
R26	E2 efficient L1024	e648147c7ab327beb2f0-876b5110f59748429fd2dd3d6c803968
R27	Attention L128	57972cf22da5f30ef01e-53864dfbbfa643008504498d71bbd92b
R28	Attention L256	982d0e8b62adcf1060bb-8e10b294ace440fc9b6ed4ad48b6481c
R29	E3 rope s1	73af15a95254a9e7505e-2e6fac200dc94a5cb29771d88a799892
R30	E3 absolute s1	81e535c7a7b9c0de7464-43393f737a44426d8e19b60afe00a413
R31	E3 rope s2	193c197aef769453e75d-e9a9467ad1ae40259380dc6fa5f2de8a
R32	E3 absolute s2	f8268a85bca09e3e6428-fb23fd829ffb493996177de32bea4628
R33	E3 rope s3	eb89d1360a5bbf004cd5-db43c23a876243ef9b928d34e4eeb852
R34	E3 absolute s3	91d130aa0b251a01039b-c16e40fd77ae43b48536503b6812c710
R35	P1 L256	6b6c3022238da3f20ce2-57fd7d84b9754079827c89cfc1f1bcef
R36	CF5 width 128	2441610fedefbc0a2067-a9deed5346cb43c9b4fb0663612cd0ac
R37	CF5 width 256	f4afe447f7b29d71c175-487015fc65f842b19e08b2a8a161bd32